

THÈSE DE DOCTORAT DE

L'ÉCOLE NATIONALE
D'INGÉNIEURS DE BREST

ÉCOLE DOCTORALE N° 601
*Mathématiques et Sciences et Technologies
de l'Information et de la Communication*
Spécialité : Informatique

Par

François LASSON

Intérêts des Auto-Encodeurs profonds pour les systèmes d'aide à l'individualisation de thérapies

Application à la prise en charge personnalisée du patient hémophile

Thèse présentée et soutenue à Plouzané, le 5 octobre 2020

Unité de recherche : Lab-STICC, UMR CNRS 6285

Thèse n° : 5

Rapporteuses :

Su RUAN Professeure, Université de Rouen
Monique THONNAT Directrice de recherche, INRIA, Sophia Antipolis

Composition du Jury :

Présidente :	Su RUAN	Professeure, Université de Rouen
Examineurs :	Pierre CHELLE	Docteur, Université de Waterloo, Kitchener (Canada)
	Sébastien KERDÉLO	Docteur, Paris
	Pascal REDOU	Maître de conférences HDR, ENIB, Plouzané
	Monique THONNAT	Directrice de recherche, INRIA, Sophia Antipolis
Dir. de thèse :	Cédric BUCHE	Professeur, ENIB, Plouzané

Invitée :

Agathe DE MIJOLLA Docteure, Stago, Paris

Remerciements

Je tiens à exprimer toute ma gratitude à l'ensemble des personnes qui ont contribué, de près ou de loin, à la réussite de cette thèse.

Mes premiers remerciements vont naturellement à Mmes Su Ruan et Monique Thonnat pour avoir chaleureusement accepté de rapporter mon manuscrit et pour la qualité de leurs critiques. Je remercie également les examinateurs, MM. Pierre Chelle et Pascal Redou, qui par la justesse de leurs questions et remarques ont su souligner la pertinence de mes travaux et embellir ma soutenance.

Il va sans dire que je remercie très sincèrement mon directeur de thèse, M. Cédric Buche, entre autres pour m'avoir promulgué de nombreux conseils tout au long de ces travaux. De même, j'exprime une profonde reconnaissance à mon encadrant interne, M. Sébastien Kerdélo, qui par son expertise et ses grandes qualités humaines a très largement contribué à ce projet de recherche.

Un projet qui ne se serait pas concrétisé sans le financement de la société Diagnostica Stago et de l'Association Nationale de la Recherche et de la Technologie. Je tiens principalement à remercier M. Dominique Vital pour la confiance qu'il m'a accordée et pour les excellentes conditions de travail dont j'ai bénéficié. À cet égard, je tiens également à remercier l'institut de recherche Synapse pour la pertinence du protocole expérimental proposé et pour la qualité des données qui en ont résulté.

J'aurais besoin de bien plus qu'un mémoire pour remercier ma merveilleuse Claire, mes fabuleux amis, ma magnifique famille et mes chers collègues. Il m'aurait été impossible de marcher dans ce borbier scientifique sans votre soutien quotidien ou, a minima, hebdomadaire. Dire le contraire serait mentir, la vie a bien plus de saveur en votre compagnie.

Enfin, j'adresse un remerciement particulier à M. Hervé Mauxion qui m'a offert, il y a déjà quelques années, une très belle image de l'enseignement et qui s'avère être à la genèse de mon parcours académique.

Merci à vous et belle lecture.

Table des matières

Table des matières	v
Table des figures	x
Liste des tableaux	xiii
Acronymes	xv
Introduction	xvii
Contexte	xvii
Problématique	xix
Proposition biologique	xx
Verrous scientifiques	xxi
Organisation du mémoire	xxii
I Étude bibliographique	1
1 Une brique de base de l'apprentissage automatique : l'auto-encodeur . . .	2
1.1 Un réseau de neurones à propagation avant	2
1.2 Un modèle non supervisé	5
1.3 Procédure d'optimisation	8
1.3.1 Algorithme d'apprentissage	8
1.3.2 Fonction de coût	10
1.3.3 Optimisation hyper-paramétrique	12
1.4 De la reconstruction à la détection de nouveautés	13
1.5 Discussion	15
2 Vers un plus haut degré d'abstraction : l'auto-encodeur profond	16
2.1 Intérêts théoriques de l'apprentissage profond	16
2.2 Complexité liée à l'optimisation paramétrique	17
2.2.1 Initialisation aléatoire	18
2.2.2 Pré-entraînement non supervisé	18
2.2.3 Apprentissage par transfert	20
2.2.4 Discussion	20
2.3 Complexité liée à l'optimisation hyper-paramétrique	21

2.3.1	Approche basée sur la validation croisée	21
2.3.2	Approche basée sur l'apprentissage incrémental	22
2.3.3	Des taux d'apprentissage aléatoires : ALRAO	27
2.3.4	Discussion	29
3	Optimisation en boucle fermée	29
3.1	Intérêts des métaheuristiques bio-inspirées	30
3.2	Optimisation multi-objectif par essais particuliers	31
3.3	Discussion	32
4	Discussion générale	33
II	Propositions	35
5	Spécification de l'AE conditionnel	36
5.1	Une architecture simple : le CAE	36
5.2	Une architecture profonde : le DCAE	38
6	Proposition d'un algorithme de pré-entraînement conditionnel	39
6.1	Principe de fonctionnement	40
6.1.1	Pré-entraînements parallèles	41
6.1.2	Lien conditionnel supervisé	42
6.1.3	Ajustement conjoint des paramètres	43
6.2	Évaluation sur une base de données de référence	43
6.2.1	Modélisation du problème	44
6.2.2	Configurations	44
6.2.3	Expérimentation	45
6.2.4	Discussion	47
7	Proposition d'une stratégie d'optimisation basée sur l'apprentissage in- crémental	49
7.1	Une brique de base : l'AE incrémental	49
7.1.1	Principe de fonctionnement	49
7.1.2	Initialisation de la topologie	50
7.1.3	Évaluation du critère d'arrêt	51
7.1.4	Sélection automatique du sous-ensemble	52
7.1.5	Stratégie de réduction du sous-apprentissage	52
7.1.6	Stratégie de réduction du sur-apprentissage	53
7.1.7	Extension conditionnelle	53
7.1.8	Évaluation sur une base de données de référence	53
7.1.9	Discussion	56
7.2	Vers un plus haut degré d'abstraction : l'AE incrémental profond . . .	58
7.2.1	Principe de fonctionnement	58
7.2.2	Application au DCAE	59
7.2.3	Intérêt pour l'apprentissage par transfert	61
7.2.4	Évaluation sur une base de données de référence	62
7.2.5	Discussion	64

8	Discussion générale	65
III	Application à la prise en charge personnalisée du patient hémophile	67
9	Contexte biologique	68
10	Proposition biologique	70
	10.1 Présentation du CDSS	71
	10.2 Présentation du modèle PK/PD	72
11	Base de données	74
	11.1 Modèle <i>in silico</i>	75
	11.1.1 Base de données dédiée au modèle conditionnel	75
	11.1.2 Base de données dédiée au modèle de détection de nouveautés	76
	11.2 Modèle <i>in vitro</i>	77
	11.2.1 Base de données dédiée au modèle conditionnel	78
	11.2.2 Base de données dédiée au modèle de détection de nouveautés	78
	11.3 Discussion	79
12	Modèle conditionnel	80
	12.1 GAN et génération conditionnelle	80
	12.2 Objectifs	81
	12.3 Processus d'estimation	81
	12.4 Protocole expérimental	82
	12.5 Cas des données <i>in silico</i>	83
	12.5.1 Architectures simples	83
	12.5.2 Architectures profondes	84
	12.5.3 Discussion	85
	12.6 Cas des données <i>in vitro</i>	86
	12.6.1 Architectures simples	86
	12.6.2 Architectures profondes	87
	12.6.3 Discussion	88
	12.7 De <i>in silico</i> vers <i>in vitro</i>	89
	12.7.1 Discussion	89
	12.8 Discussion générale	90
13	Modèle de détection de nouveautés	91
	13.1 GAN et détection de nouveautés	92
	13.2 Objectifs	92
	13.3 Processus d'estimation	93
	13.4 Protocole expérimental	94
	13.5 Cas des données <i>in silico</i>	95
	13.5.1 Architectures simples	95
	13.5.2 Architectures profondes	96
	13.5.3 Discussion	97
	13.6 Cas des données <i>in vitro</i>	99
	13.6.1 Architectures simples	99

13.6.2 Architectures profondes	100
13.6.3 Discussion	101
13.7 Discussion générale	103
14 Algorithme d'optimisation stochastique	103
14.1 Protocole expérimental	103
14.2 Cas des données <i>in silico</i>	104
14.3 Cas des données <i>in vitro</i>	105
14.4 Discussion	106
15 Conclusion	106
Conclusion	109
A Base de données <i>in silico</i>	115
A.1 Contexte	115
A.2 Modèle numérique de GT	116
A.3 Évaluation	116
A.3.1 Une recherche biomédicale : HémoTIV	116
A.3.2 Cohorte étudiée	117
A.3.3 Protocole de validation	118
A.3.3.1 Validation absolue	118
A.3.3.2 Validation relative	119
A.4 Proposition de corrections	121
A.4.1 Régression linéaire	121
A.4.2 Coefficient multiplicateur	124
A.4.3 Évaluation et discussion	126
B Base de données <i>in vitro</i>	127
B.5 Contexte	127
B.6 Hypothèse et preuve expérimentale	127
B.7 Élaboration de la base de données	128
B.8 Modélisation mathématique	131
B.8.1 Mise en équation	131
B.8.2 Conversion des unités	134
B.8.2.1 Protocole expérimental de dosage	134
B.8.2.2 Conversion des taux de FVIII	134
B.8.2.3 Conversion des concentrations d'anticorps	134
B.8.3 Application du modèle	135
B.8.3.1 Détermination d'un K_D spécifique	136
B.8.3.2 Détermination d'un K_D global	136
B.8.3.3 Discussion	138

Bibliographie	139
----------------------	------------

Table des figures

1	Modélisation de la problématique	xix
2	Illustration du principe de fonctionnement de notre proposition de CDSS	xx
I.1	Architecture d'un FFNN	3
I.2	Fonctions d'activation	4
I.3	Architecture d'un AE	5
I.4	Représentation sous-complète et sur-complète	7
I.5	Architecture d'un AE supervisé	7
I.6	Illustration du principe de validation croisée	13
I.7	Application des AE à la détection de nouveautés	14
I.8	Architecture d'un AE profond	16
I.9	Illustration d'une zone critique pour l'optimisation	17
I.10	Principe de l'algorithme de pré-entraînement non supervisé	19
I.11	Illustration de la <i>cascade-correlation</i>	23
I.12	Principe de fonctionnement de la proposition de G. ZHOU et al., 2012a	25
I.13	Principe de fonctionnement de la proposition de PRATAMA et al., 2018	27
II.1	Architecture du CAE	37
II.2	Architecture du DCAE	38
II.3	Décomposition de l'architecture du DCAE	40
II.4	Représentation de la stratégie de pré-entraînement conditionnel	41
II.5	Représentation de l'étape de pré-entraînements parallèles	42
II.6	Division de la base de données MNIST en quadrants	44
II.7	Représentation des taux d'erreur associés à la figure (II.8)	46
II.8	Diagramme en boîte résultant de l'expérimentation du pré-entraînement conditionnel	47
II.9	Représentation graphique des taux d'erreur résultant de l'expérimentation du pré-entraînement conditionnel	48
II.10	Principe de fonctionnement de notre proposition d'AE incrémental simple	50
II.11	Exemples de prédictions obtenues par les AE incrémentaux	55
II.12	Représentation graphique des taux d'erreur obtenus par les AE incrémentaux	55
II.13	Principe de fonctionnement détaillé de notre proposition d'AE incrémental simple	57
II.14	Principe de fonctionnement de notre proposition d'optimisation incrémentale non supervisée	59

II.15	Principe de fonctionnement de notre proposition d'optimisation incrémentale conditionnelle	60
II.16	Optimisation incrémentale conditionnelle et apprentissage par transfert	62
II.17	Exemples de prédictions de données tests cibles	64
III.1	Présentation des thrombinogrammes et des caractéristiques biologiques associées	70
III.2	Présentation de notre proposition de CDSS appliquée au contexte de l'hémophilie A	71
III.3	Présentation du modèle PK/PD de l'ADVATE®	74
III.4	Illustration du triplet provenant de la base de données <i>in silico</i> conditionnelle	76
III.5	Distribution des taux de facteur VIII associée à la base de test numérique	77
III.6	Illustration du triplet provenant de la base de données <i>in vitro</i> conditionnelle	78
III.7	Distribution des taux de facteur VIII associée à la base de test <i>in vitro</i>	79
III.8	Application des GAN à une tâche conditionnelle	80
III.9	Représentation des taux d'erreur associés à la table (III.1)	83
III.10	Représentation des taux d'erreur associés à la table (III.2)	84
III.11	Diagramme en boîte résumant les taux d'erreur obtenus par les modèles conditionnels sur la base de données <i>in silico</i>	85
III.12	Représentation des taux d'erreur associés à la table (III.4)	86
III.13	Représentation des taux d'erreur associés à la table (III.5)	87
III.14	Diagramme en boîte résumant les taux d'erreur obtenus par les modèles conditionnels sur la base de données <i>in vitro</i>	88
III.15	Diagramme en boîte résumant les taux d'erreur obtenus par les stratégies d'apprentissage par transfert	90
III.16	Application des GAN à une tâche de détection de nouveautés	92
III.17	Matrice de confusion et indicateurs de performance	93
III.18	Illustration des performances de la table (III.8)	95
III.19	Représentation des performances associées à la table (III.9)	96
III.20	Diagrammes en boîte résumant les performances obtenues par les modèles de détection de nouveautés sur la base de données <i>in silico</i>	98
III.21	Performances obtenues par le GAN sur la base de données <i>in silico</i>	98
III.22	Matrices de confusion normalisées associées au contexte <i>in silico</i>	99
III.23	Illustration des performances de la table (III.11)	99
III.24	Représentation des performances associées à la table (III.12)	100
III.25	Diagrammes en boîte résumant les performances obtenues par les modèles de détection de nouveautés sur la base de données <i>in vitro</i>	101
III.26	Performances obtenues par le GAN sur les données <i>in vitro</i>	102
III.27	Matrices de confusion normalisées associées au contexte <i>in vitro</i>	102
III.28	Exemple de thrombinogrammes <i>in silico</i> obtenus <i>a posteriori</i> de l'optimisation	105
III.29	Exemple de thrombinogrammes <i>in vitro</i> obtenus <i>a posteriori</i> de l'optimisation	105
A.1	Illustration des valeurs moyennes présentées dans le tableau (A.2)	119

A.2	Illustration des valeurs moyennes présentées dans le tableau (A.3)	120
A.3	Influence du facteur II	121
A.4	Relation existante entre le temps latence et le facteur VIIa	122
A.5	Régression linéaire entre le facteur VIIa dosé et sa valeur estimée	122
A.6	Illustration des valeurs moyennes présentées dans le tableau (A.4)	123
A.7	Illustration de la correction (A.4.1) pour le patient ABD-BO	123
A.8	Représentation graphique des écarts moyens en LT et TTP	124
A.9	Illustration des valeurs moyennes présentées dans le tableau (A.5)	125
A.10	Illustration de la correction (A.4.2) pour le patient ABD-BO	125
B.1	Influence des concentrations en anticorps anti-VIII sur les courbes de GT associées au plasma n° 001.	129
B.2	Influence des concentrations en anticorps anti-VIII sur les caractéristiques extraites des courbes de GT associées au plasma n° 001.	130
B.3	Détermination du K_D spécifique au plasma n° 026	136
B.4	Distribution des valeurs de K_D	137
B.5	K_D spécifique au plasma n° 026 versus K_D global	137
B.6	K_D spécifique au plasma n° 024 versus K_D global	138

Liste des tableaux

II.1	Description des 4 architectures utilisées	45
II.2	Erreurs de reconstruction et AE incrémentaux régularisés	54
II.3	AE incrémentaux et influence des topologies initiales	56
II.4	Optimisation incrémentale et transfert d'apprentissage	63
III.1	Performances obtenues par les CAE sur la base de données <i>in silico</i>	84
III.2	Performances obtenues par les DCAE sur la base de données <i>in silico</i> . . .	84
III.3	Architectures des DCAE obtenues par l'approche n° 3 sur la base de données <i>in silico</i>	85
III.4	Performances obtenues par les CAE sur la base de données <i>in vitro</i>	87
III.5	Performances obtenues par les DCAE sur la base de données <i>in vitro</i> . . .	87
III.6	Architectures des DCAE obtenues par l'approche n° 3 sur la base de données <i>in vitro</i>	88
III.7	Taux d'erreur et temps d'optimisation associés aux stratégies d'apprentissage par transfert	89
III.8	Performances obtenues par les AE simples sur la base de données <i>in silico</i>	96
III.9	Performances obtenues par les AE profonds sur la base de données <i>in silico</i>	96
III.10	Architectures des AE profonds obtenues par l'approche n° 3 sur la base de données <i>in silico</i>	97
III.11	Performances obtenues par les AE simples sur la base de données <i>in vitro</i>	100
III.12	Performances obtenues par les AE profonds sur la base de données <i>in vitro</i>	100
III.13	Architecture des AE profonds obtenue par l'approche n° 3 sur la base de données <i>in vitro</i>	101
III.14	Application de notre proposition de CDSS aux données <i>in silico</i>	104
III.15	Application de notre proposition de CDSS aux données <i>in vitro</i>	106
A.1	Liste des réactions biochimiques	117
A.2	Application de l'équation (A.1)	119
A.3	Application de l'équation (A.2)	120
A.4	Application de l'équation (A.2) à l'ensemble des cinétiques corrigées par la proposition (A.4.1)	124
A.5	Application de l'équation (A.2) à l'ensemble des cinétiques corrigées par la proposition (A.4.2)	126
B.1	Dosages en facteur VIII du plasma vrai n° 001	130

Acronymes

ACP	Analyse en Composantes Principales 6
AE	Auto-Encodeur vi, x, xiii, xxi–xxiii, 1, 2, 5–16, 18, 19, 21, 22, 27, 33–40, 42, 49–51, 53–60, 64, 65, 67, 68, 71, 72, 81, 83, 91–100, 102–104, 107, 109–114
ALRAO	All Learning Rates at Once xxii, 28, 29, 33, 35, 36, 49, 51, 53, 54, 56, 58, 65, 90, 106, 110, 111
CAE	Auto-Encodeur conditionnel (<i>Conditional AutoEncoder</i>) vi, xiii, 36–40, 42, 53, 59–61, 64, 65, 81–87, 89, 90, 106, 111, 113
CDSS	Système d’Aide à la prise de Décision Clinique vii, x, xi, xiii, xix–xxi, xxiii, 1, 2, 15, 21, 29, 33, 35, 38, 49, 58, 64, 65, 67, 68, 71, 72, 74, 81, 86, 91, 92, 103, 104, 106–111, 113, 116, 127
CHRU	Centre Hospitalier Régional Universitaire 116
CVAE	Auto-Encodeur variationnel conditionnel (<i>Conditional Variational AutoEncoder</i>) 8, 36
DAE	Auto-Encodeur débruiteur (<i>Denoising AutoEncoder</i>) 11, 24, 25, 29, 51, 54, 55, 57
DCAE	Auto-Encodeur conditionnel profond (<i>Deep Conditional AutoEncoder</i>) vi, xiii, 38–40, 42–45, 47–49, 51, 59–65, 71, 80–84, 86, 87, 89–91, 104, 106, 107, 110, 111
EDO	Équation Différentielle Ordinaire 116, 131
ETP	Potentiel de thrombine endogène (<i>Endogenous Thrombin Potential</i>) 118–120, 124, 129
FFNN	Réseau de neurone à propagation avant (<i>FeedForward Neural Network</i>) 2–5, 8, 9, 22, 23, 37
GAN	Réseaux antagonistes génératifs (<i>Generative Adversarial Networks</i>) vii, xi, 80, 81, 83, 86, 91–93, 95, 97–99, 102, 103, 107, 111, 112
GT	Génération de Thrombine viii, xii, xviii, 67–72, 74, 75, 77–80, 86, 89, 91, 106, 107, 111, 114, 116–121, 126, 129–131
lr	Taux d’apprentissage (<i>Learning Rate</i>) 10, 27, 28

LT	Temps de latence (<i>Lag Time</i>) xii, 118–122, 124, 129
MNIST	Institut national des normes et de la technologie - base de données modifiée (<i>Modified - National Institute of Standards and Technology</i>) x, 43, 44, 46, 49, 53, 54, 56, 57, 62, 64, 65, 91, 110
MOPSO	Optimisation multi-objectif par essaims particuliers (<i>Multiple Objective Particle Swarm Optimization</i>) 31–34, 67, 68, 72, 75, 103, 104, 107, 110, 111
MSE	Erreur quadratique moyenne (<i>Mean Square Error</i>) 10, 11, 14, 25, 56, 63, 81, 112, 136, 138
NMSE	Erreur quadratique moyenne normalisée (<i>Normalized Mean Square Error</i>) 11, 14
NRMSE	Racine carrée de l'erreur quadratique moyenne normalisée (<i>Normalized Root Mean Square Error</i>) 81, 87, 89–91, 94, 97, 101, 107
PK/PD	Pharmacocynétique/Pharmacodynamique 30
PPP	Plasma Pauvre en Plaquettes 134, 135
PSO	Optimisation par essaims particuliers (<i>Particle Swarm Optimization</i>) 31, 32, 34
ReLU	Unité de rectification linéaire (<i>Rectified Linear Unit</i>) 4, 5, 37
SAE	Auto-Encodeurs empilés (<i>Stacked AutoEncoder</i>) 19, 20, 22, 24, 58
TF	Facteur tissulaire (<i>Tissue Factor</i>) 117–124, 126, 130, 131
TTP	Temps au pic (<i>Time To Peak</i>) xii, 118, 120, 124, 129
VAE	Auto-Encodeur variationnel (<i>Variational AutoEncoder</i>) 8, 15

Introduction

Dans une récente étude menée par l'Université Johns-Hopkins (MAKARY et DANIEL, 2016), les erreurs médicales ont été identifiées comme la troisième cause de mortalité aux États-Unis. En Angleterre, 237 millions de patients sont victimes de ce type d'erreurs chaque année. D'un point de vue économique, le coût international annuel de ces accidents est estimé à 42 milliards de dollars (HARKANEN et al., 2019). Au vu de ces constatations, l'Organisation mondiale de la Santé (OMS) a lancé un défi pour la sécurité des patients intitulé « *une médication sans erreurs* » (SHEIKH et al., 2017). Il vise au développement de diverses mesures relatives à la prise de décisions cliniques, en particulier pour les médicaments jugés à haut risque tels que les anticoagulants (COMMISSION, 2019). Par la conception de dispositifs de soins favorisant la transmission des connaissances émergentes aux professionnels de santé, il serait possible de réduire la fréquence de ces événements indésirables. À cet effet, les systèmes d'aide à l'individualisation de thérapies se présentent comme des outils pertinents (KAWAMOTO et al., 2005).

Contexte

L'hémostase

La coagulation du sang, ou hémostase est le phénomène biologique qui a pour but de limiter et de stopper une hémorragie causée par une brèche vasculaire. Ce système complexe repose sur un judicieux équilibre entre les voies pro-coagulantes, responsables de la formation d'un caillot sanguin, et les voies anti-coagulantes qui permettent de réguler et d'inhiber cette formation. Un déséquilibre de cette balance peut causer deux types de pathologies : les maladies thrombotiques d'une part, qui sont dues à une suractivité du processus de coagulation et qui sont, par exemple, à l'origine d'embolies pulmonaires, de cardiopathies ischémiques ou encore d'accidents vasculaires cérébraux; les maladies hémorragiques d'autre part, qui sont induites par une sous-activité du processus de coagulation. L'hémophilie, par exemple, est source de saignements spontanés (CHELLE, 2017).

Bien que la prévalence de ces pathologies soit relativement faible (inférieure à 1% de la population européenne pour les thrombophilies héréditaires induites par des déficits en inhibiteurs de la coagulation (PRESS et al., 2002) et environ 0.01% des hommes pour l'hémophilie (CHELLE, 2017)), elles sont facteur de morbidité et de mortalité. Il est donc indispensable que les cliniciens soient en mesure de les diagnostiquer et de les traiter efficacement.

Les tests de routine : de mauvais prédicteurs du phénotype clinique

Il est courant d'évaluer le potentiel hémostatique d'un échantillon biologique en utilisant des tests de laboratoires de routine tels que le temps de Quick ou le temps de céphaline activée, ou encore par le biais de tests spécifiques permettant de quantifier les concentrations unitaires des facteurs de la coagulation dans le plasma. Toutefois, bien que ces tests occupent une place importante dans le diagnostic et le traitement des déficits en facteurs, ils ne sont pas en mesure de refléter rigoureusement l'état de la balance hémostatique. Étant spécifiques à certaines étapes de la coagulation, ils possèdent un champ d'action restreint qui représente un frein à l'analyse des relations inter-facteurs. Par conséquent, les résultats de ces tests traditionnels ne fournissent qu'une étude partielle de la formation du caillot (LANCÉ, 2015).

Les tests globaux : des candidats prometteurs

Les tests globaux d'hémostase s'avèrent être de meilleurs prédicteurs des phénotypes cliniques patients. Basés sur une mesure continue de la viscosité du caillot (thromboélastométrie/thromboélastographie initialement proposée par HARTERT, 1948), ou sur le suivi temporel de la concentration d'une enzyme clé de la coagulation (test de génération de thrombine abrégé GT qui a été proposé par MACFARLANE et BIGGS, 1953 puis amélioré par HEMKER et al., 2003) ou encore sur l'analyse de la cinétique de formation du caillot (*clot waveform analysis* initiée par BRAUN et al., 1997), ces tests fournissent aux cliniciens une évaluation macroscopique du fonctionnement du système de coagulation. De ce fait, de nombreuses études scientifiques les présentent comme des outils pertinents pour estimer les risques d'évènements thrombotiques et hémorragiques (CATE et al., 2017). Ils sont notamment décrits comme des candidats prometteurs pour améliorer la gestion des hémorragies aiguës, des thromboses veineuses ou encore pour l'inversion de médicaments anticoagulants dans des contextes d'urgences médicales (BRINKMAN, 2015). Leur utilisation permettrait notamment d'éviter des surdosages ou des transfusions inutiles et ainsi de diminuer les coûts des traitements tout en améliorant la qualité des soins.

Les tests globaux : une absence de standardisation

Cependant, bien qu'ils présentent un intérêt non négligeable pour la prise en charge personnalisée de patients victimes de troubles hémostatiques, les tests globaux manquent de standardisation. Au vu de leur forte sensibilité aux étapes pré-analytiques et compte tenu des variabilités intra- et inter-laboratoires, la problématique de la reproductibilité des résultats est primordiale (LOEFFEN et al., 2012). Par conséquent, les tests globaux nécessitent d'être standardisés avant de pouvoir être employés à grande échelle en études cliniques (LANCÉ, 2015). De cette absence d'utilisation résulte une méconnaissance des tests globaux (BRINKMAN, 2015), ils demeurent ainsi difficilement interprétables par des cliniciens non experts du domaine.

Une perspective : les systèmes d'aide à la prise de décisions cliniques

Pour faire face à cette complexité, il convient de favoriser la transmission de connaissances émergentes aux professionnels de santé. Dans cette optique, les systèmes d'aide à la prise de décisions cliniques (*Clinical Decision Support System* ou CDSS en anglais; (KAPLAN, 2001; KAWAMOTO et al., 2005)) s'avèrent pertinents. Axés sur la gestion de règles expertes ou d'informations statistiques, ils ont pour objectif d'assister les cliniciens dans l'analyse de données biologiques complexes et dans l'élaboration de diagnostics ou de décisions thérapeutiques. Facilitant alors la définition de traitements patient-spécifiques, ils mènent à une réduction du risque d'erreurs médicales. L'utilisation de ces systèmes informatiques permet, par conséquent, d'améliorer la qualité des soins tout en diminuant les coûts des traitements.

Problématique

Dans le cadre de cette thèse, nous concentrons nos travaux sur l'utilisation des CDSS pour la mise en place et le suivi de traitements médicamenteux de troubles de la coagulation du sang. En associant un test global d'hémostase à un CDSS, le but est ainsi de fournir aux cliniciens un outil pouvant les assister dans leurs démarches d'individualisation de thérapies. En d'autres termes, nous souhaitons prédire de manière automatique la dose minimale de médicament suffisante pour diminuer le risque hémorragique ou thrombotique chez un patient victime d'un trouble de l'hémostase. Les enjeux d'une telle optimisation sont doubles, à savoir : l'amélioration de la qualité des soins et des résultats thérapeutiques tout en diminuant les coûts de traitements.

Comme l'illustre la figure (1), notre problématique se modélise donc naturellement sous la forme d'une régression du type $p(y|x)$ où x est le résultat du test global du patient et y est la dose optimale de médicament à lui administrer. D'ordinaire, la réponse à un tel problème consiste en une fonction $y = f(x)$ où la règle f est issue de connaissances expertes. Elle pourrait sinon être établie à partir de données issues de patients malades, sous traitement ou non, pour lesquels les couples $\{x, y\}$ auraient été déterminés par évaluations cliniques. Néanmoins, au vu des forts coûts temporels et économiques nécessaires à la construction d'une cohorte spécifique et à la génération de ces données, cette approche ne peut être envisagée dans le contexte de cette thèse.



FIGURE 1 – Modélisation de la problématique sous la forme d'une régression.

Proposition biologique

Afin de contourner ce besoin d'évaluations cliniques, nous avons songé à tirer profit du caractère prédictif de ces nouveaux tests biologiques que sont les tests globaux. Comme illustré en figure (2), nous proposons de répondre à ce problème de régression en utilisant un système d'optimisation en boucle fermée contenant un modèle conditionnel, un modèle de détection de nouveautés et un algorithme d'optimisation stochastique.




FIGURE 2 – Principe de fonctionnement de notre proposition de CDSS. Au sein de ce schéma, les boîtes pleines illustrent les trois modèles envisagés, celle en ligne continue représente la valeur réelle du test biologique et celles en lignes pointillées sont associées aux valeurs estimées.

Dans l'intention de prédire la dose minimale suffisante pour limiter le risque hémorragique ou thrombotique chez un patient victime d'un trouble de l'hémostase, nous proposons d'optimiser sa posologie de manière itérative. À cet effet, il convient tout d'abord de caractériser l'impact que l'administration d'une dose de médicament pourrait avoir sur ce risque d'accident. Compte tenu de notre contexte d'application, nous avons envisagé de répondre à ce sous-problème de régression par la mise en série de deux systèmes.

Le rôle du premier est de qualifier l'impact qu'une administration médicamenteuse pourrait avoir sur le résultat du test global du patient. Il s'agit d'un modèle conditionnel ayant pour but de répondre à une tâche du type $p(y|x, c)$ où c est une dose de médicament, x est le résultat biologique initial du patient et y est celui du test réalisé *a posteriori* de cette administration. Pour développer un tel modèle, nous devons disposer d'une base de données composée de tests globaux patients, de surcharges en termes de concentration de médicaments et des tests biologiques résultants.

Le second système a quant à lui pour but de quantifier le risque d'accident associé à un résultat de test global et, en l'occurrence, à celui résultant de cette administration. Afin de faire abstraction du besoin d'évaluations physiologiques, nous proposons de le développer par l'intermédiaire d'un modèle de détection de nouveautés. En d'autres termes, cette seconde tâche sera perçue comme un problème de classification au sein duquel le comportement du résultat biologique sera comparé à celui d'un ensemble de référence. Du fait que les patients sains sont par définition associés à des risques d'accidents nuls, ils se présentent comme des éléments

de référence dans notre cas d'étude. Il conviendra donc de définir cet ensemble de comparaison à partir de résultats des tests globaux de patients sains. Compte tenu du caractère prédictif de ces tests biologiques, le risque d'accident associé au résultat d'un test pourra être déduit du degré de nouveautés ainsi obtenu. En outre, l'intérêt de cette approche est double, à savoir : contourner le besoin d'évaluation clinique et pallier la faible prévalence des pathologies étudiées (PIMENTEL et al., 2014).

Par la juxtaposition de ces deux modèles, nous sommes en capacité de prédire le risque d'accident résultant de l'administration d'une dose de médicament à un patient malade. Nous chercherons alors à minimiser ce risque par ajustement itératif de la posologie. Pour ce faire, nous proposons d'employer un algorithme d'optimisation stochastique (MÜLLER-MERBACH, 1981) tel qu'une métaheuristique bio-inspirée (BINITHA et SIVA SATHYA, 2012).

Du fait de l'absence de règles expertes au sujet de l'analyse multivariée des tests globaux, le développement de cette proposition de CDSS nécessite l'utilisation de méthodes statistiques. Pour ce faire, il convient d'extraire des prédicats caractéristiques de ces résultats biologiques en adoptant une démarche de réduction dimensionnelle. Dans cette même intention, les biologistes du domaine ont cherché à y identifier des caractéristiques discriminantes en se basant sur des grandeurs physiques connues telles que le temps, l'amplitude ou encore la vitesse. Néanmoins, bien que cette approche soit pertinente, elle s'avère limitée au vu du manque de standardisation des tests globaux et des problèmes de reproductibilité qui en résultent (Francois LASSON et al., 2019). Afin d'exploiter pleinement ces sources d'information décrites comme révélatrices des phénotypes cliniques des patients, il est pertinent d'en extraire des caractéristiques fortement abstraites en utilisant des techniques d'apprentissage automatique. D'après la littérature, les modèles profonds sont capables de représenter de manière compacte des fonctions hautement non-linéaires (BENGIO, 2009; GOODFELLOW et al., 2016). Ils se présentent donc comme des candidats prometteurs pour pallier la complexité d'interprétation des tests globaux. Par ailleurs, les stratégies d'apprentissage non supervisées telles que celle des auto-encodeurs (abrégiés AE et parfois appelés réseaux auto-associatifs) sont à privilégier dans des contextes où les données sont coûteuses (Yann LECUN et al., 2015). Par conséquent, nous utiliserons la forme profonde de ces derniers pour développer les modèles conditionnels et de détection de nouveautés qui composent notre proposition CDSS.

Verrous scientifiques

Dans le cadre de ces travaux de thèse, nous allons évaluer les intérêts que présentent les AE profonds pour les systèmes d'aide à l'individualisation de thérapies. Après avoir mis en évidence l'applicabilité de ces modèles non supervisés à notre proposition biologique, nous allons nous intéresser à la procédure d'optimisation de leur architecture profonde. De cette étude va toutefois résulter une double difficulté.

Premièrement, les fonctions objectives de ces modèles sont des fonctions fortement non convexes qui possèdent de nombreuses régions critiques. Afin d'y faire face, c'est-à-dire éviter qu'elles n'impactent drastiquement la convergence des méthodes d'optimisation, il convient d'initialiser les réseaux de manière pertinente. À cet effet, nous avons souligné les apports des stratégies d'initialisation basées sur l'apprentissage automatique. Au vu de la spécificité de notre problématique biologique, l'algorithme de pré-entraînement non supervisé s'est avéré être la solution la plus pertinente. Néanmoins, bien qu'il soit applicable dans le cas de l'AE profond purement non supervisé que nous utiliserons à des fins de détection de nouveautés, son principe de fonctionnement n'est pas adapté aux AE conditionnels. Dans la mesure où aucune méthode d'initialisation de ces modèles n'est présentée dans la littérature, nous faisons face à un premier verrou scientifique.

Est-il possible de pré-entraîner un AE conditionnel ?

Deuxièmement, une grande combinatoire est associée à l'optimisation hyper-paramétrique des réseaux composés de plusieurs couches cachées. Par conséquent, les stratégies de recherche opérationnelle basées sur des méthodes essai-erreur s'avèrent peu pertinentes dans le cas d'AE profonds. Pour remédier à cette difficulté, les chercheurs du domaine suggèrent d'ajuster dynamiquement les paramètres et les hyper-paramètres des réseaux. Dans cette intention, nous avons introduit l'apprentissage incrémental et la procédure de génération aléatoire des taux d'apprentissage nommée ALRAO. Cependant, outre le fait que la combinaison de ces techniques n'ait pas encore été étudiée par les chercheurs du domaine, les propositions d'AE incrémentaux que nous avons détaillées s'avèrent limitées dans notre cas d'étude. Du fait qu'aucune solution optimale ne soit recensée dans la littérature, nous faisons face à un second verrou scientifique.

Pouvons-nous optimiser les AE profonds par le biais d'une stratégie quasi autonome basée sur l'apprentissage incrémental et la procédure de génération aléatoire des taux d'apprentissage ?

Organisation du mémoire

Ce manuscrit de thèse s'articule autour de trois grands chapitres : une étude bibliographique permettant d'introduire les concepts théoriques nécessaires à la compréhension de ce mémoire (chapitre I), la présentation des propositions que nous avons envisagées pour répondre aux verrous scientifiques rencontrés (chapitre II), et enfin une application de ces dernières à la prise en charge personnalisée du patient hémophile par le test de génération de thrombine (chapitre III).

Chapitre I - Étude bibliographique

La section 1 présente le principe de fonctionnement des AE simples et leur applicabilité à notre proposition biologique.

La section 2 met en évidence l'intérêt des architectures profondes avant de faire l'état de l'art des solutions envisageables pour remédier aux complexités d'opti-

sation paramétrique et hyper-paramétrique.

La section 3 est une revue des méthodes d'optimisation stochastique et plus précisément, des métaheuristiques bio-inspirées.

Une discussion générale est présentée en section 4. Elle synthétise le contenu de ce premier chapitre et soulève les deux verrous scientifiques rencontrés.

Chapitre II - Propositions

Dans la section 5, nous détaillons la procédure de notre proposition de pré-entraînement conditionnel.

Quant à la section 6, nous y présentons notre proposition de stratégie d'optimisation basée sur l'apprentissage incrémental. Pour ce faire, nous traitons tout d'abord le cas des AE simples avant de considérer celui des architectures profondes.

Chapitre III - Application

Enfin, la section 7 développe l'application de nos propositions à la prise en charge personnalisée du patient hémophile A sévère sans inhibiteur. Les performances des trois modèles qui composent notre CDSS sont évaluées sur des données générées *in silico* et *in vitro*.

La conclusion dresse un bilan des résultats obtenus et ouvre des perspectives pour des travaux futurs.

L'annexe A détaille la construction de la base de données *in silico*

L'annexe B présente les travaux associés à l'élaboration de la base de données *in vitro*.



Étude bibliographique

Résumé Au sein de cet état de l’art, nous avons concentré nos efforts de recherche sur les deux méthodes qui ont été envisagées pour développer notre proposition de CDSS. Dans ce dessein, nous avons présenté le principe de fonctionnement des AE simples avant de mettre en évidence leur applicabilité à notre contexte biologique. Au vu de la faible prévalence de certaines pathologies de l’hémostase et de la complexité d’interprétation des tests globaux, il nous a ensuite semblé pertinent d’introduire les AE profonds. Nous avons alors exposé l’intérêt théorique de ces modèles avant de souligner les difficultés associées à leur optimisation paramétrique et hyper-paramétrique. Dans l’intention d’obvier à ces dernières, diverses stratégies ont été envisagées par les chercheurs du domaine. De leur étude ont émergé deux verrous scientifiques : 1) l’algorithme de pré-entraînement non supervisé n’est pas applicable au cas du modèle conditionnel ; 2) les AE incrémentaux issus de la littérature présentent des limites dans notre cas d’étude. Suite à cette analyse, nous nous sommes intéressés aux méthodes d’optimisation stochastique, et plus particulièrement aux métaheuristiques bio-inspirées. Il en a résulté l’optimisation multi-objectif par essaims particulaires, un algorithme basé sur l’intelligence distribuée et l’équilibre de Pareto que nous utiliserons au sein de notre proposition CDSS.

La proposition que nous avons envisagée pour répondre au problème d’individualisation de thérapies consiste en un CDSS utilisant les tests globaux. Comme nous l’évoquions en introduction, elle se présente sous la forme d’un système d’optimisation en boucle fermée dont la structure peut être divisée en deux parties. La première d’entre elles, qui correspond à la mise en série d’un modèle conditionnel et d’un modèle de détection de nouveautés, a pour but de qualifier l’impact de l’administration d’une dose de médicament sur le risque hémorragique ou thrombotique d’un patient. Compte tenu des difficultés induites par ce contexte d’application, nous avons proposé d’implémenter ces derniers par le biais d’AE profonds. En ce qui concerne la seconde partie, elle consiste en un algorithme d’optimisation

multi-objectif. Son rôle est de déterminer la dose de médicament minimale suffisante pour assurer la disparition des symptômes, c'est-à-dire minimiser le risque. Du fait de la place centrale que l'AE occupe dans notre proposition de CDSS, il semble primordial d'en expliciter le fonctionnement. En premier lieu, nous introduirons l'AE simple, c'est-à-dire composé d'une unique couche cachée. Pour ce faire, nous en présenterons la structure générale ainsi que la procédure d'optimisation. Au sein de la seconde section, nous nous intéresserons ensuite aux AE composés de plusieurs couches cachées. Nous exposerons les multiples avantages que présentent ces architectures profondes avant d'évoquer les complexités associées à leur optimisation paramétrique et hyper-paramétrique. Il conviendra alors de détailler diverses solutions que les chercheurs du domaine ont envisagées pour remédier à cette double difficulté. Enfin, une dernière section sera consacrée aux algorithmes d'optimisation stochastique. Nous y présenterons le fondement des méta-heuristiques bio-inspirées en concentrant nos efforts sur les algorithmes d'optimisation multi-objectif par essais particuliers.

1 Une brique de base de l'apprentissage automatique : l'auto-encodeur

Au travers de cette section, nous souhaitons expliciter le principe de fonctionnement de l'AE simple. À cet effet, nous en présenterons tout d'abord l'origine : le réseau de neurones à propagation avant (*FeedForward Neural Network* ou FFNN en anglais). Grâce à l'introduction des divers concepts théoriques qui sont associés à ce modèle de référence, nous pourrions aisément mettre en évidence la spécificité de l'AE. Il conviendra alors d'exposer le principe de reconstruction non supervisé sur lequel repose la structure générale de leur réseau. Par la définition des contraintes dimensionnelle et opérationnelle qui résultent de leur architecture, nous verrons ensuite que ces modèles sont capables d'extraire des prédicats caractéristiques de données d'apprentissage non étiquetées. Nous devrions pour ce faire, détailler les diverses étapes de leur procédure d'optimisation. Enfin, nous montrerons que ces modèles sont également adaptés aux tâches de détection de nouveautés telle que celle rencontrée dans notre cas d'étude.

1.1 Un réseau de neurones à propagation avant

Les FFNN sont des modèles d'apprentissage automatique supervisés. Ils ont pour objectif d'approximer une fonction $y = f^*(x)$ par le biais d'une fonction paramétrique $y = f(x, \theta)$ où θ est optimisé par un principe d'entraînement. Ils reposent sur la théorie qu'une fonction complexe f^* puisse être décomposée en plusieurs fonctions simples. Cela signifie qu'il est possible de concevoir f comme une imbriation de fonctions paramétriques. Dans ce sens, l'architecture d'un FFNN est une structure en chaîne au sein de laquelle l'information se propage depuis l'entrée jusqu'à la sortie.




FIGURE I.1 – Graphe d'un FFNN dans lequel les nœuds représentent les unités indépendantes tandis que les flèches illustrent les relations inter-unités. Ces relations sont unidirectionnelles et dirigées de l'entrée vers la sortie. Le réseau présenté dans cet exemple possède une unique couche cachée composée de deux unités. Le nombre de couches définit la profondeur de l'architecture. Lorsqu'il n'y en a qu'une, elle est qualifiée de « simple » sinon elle est dite « profonde ». Le nombre d'unités définit quant à lui la largeur de l'architecture. Par ailleurs, les individus de la base de données sont ici des couples $\{x, y\}$ dans lesquels x est un vecteur composé de deux paramètres et y est une variable.

Comme illustrée en figure (I.1), cette architecture est composée de deux couches visibles et d'une ou plusieurs couches cachées.

Les couches visibles correspondent à l'entrée et à la sortie du modèle. Lors de la phase d'apprentissage, elles sont associées aux couples $\{x, y\}$ présents dans la base où x est une donnée d'entrée et y une étiquette. Lors de l'inférence, seule x est fournie au modèle qui se charge de prédire y par application de la fonction f .

Les couches cachées consistent, quant à elles, en des vecteurs d'unités indépendantes dont le rôle est de synthétiser les prédicats intermédiaires (Y. LECUN et FOGELMAN-SOULIE, 1987). Chacune de ces unités cachées est en relation unidirectionnelle avec celles de la couche inférieure. Ces relations se traduisent par l'intermédiaire de connexions pondérées dont les valeurs sont optimisées au cours de l'entraînement. Compte tenu de ce principe, il est possible de comparer le comportement des unités à celui des neurones biologiques. Elles sont donc appelées neurones artificiels (GOODFELLOW et al., 2016).

Afin de déterminer la valeur d'une unité, c'est-à-dire le degré d'activation, il est tout d'abord nécessaire de calculer la somme pondérée de ses entrées. La valeur ainsi obtenue, nommée degré de pré-activation, est ensuite injectée dans une fonction non-linéaire dite d'activation. De ce fait, la valeur vectorielle d'une couche cachée résulte de la composition d'une transformation affine, dont les paramètres ont été déterminés par apprentissage, et d'une fonction d'activation non-linéaire. Cette composition est exprimée en équation (I.1) dans laquelle f^n est la fonction d'activation utilisée, h^n est le degré d'activation de la *nième* couche cachée et h^{n-1} est celui de la couche inférieure. W^n est la matrice de poids, elle regroupe l'ensemble des connexions associées aux neurones de cette *nième* couche. Enfin, c^n est un vecteur de biais. Il a pour rôle d'assurer la propagation du gradient lors de la phase d'apprentissage.

$$h^n = f^n(W^n h^{n-1} + c^n) \quad (\text{I.1})$$

Le dernier point à considérer pour compléter le réseau concerne les unités de sortie du modèle. De manière analogue aux couches cachées, la valeur de pré-activation de ces neurones est obtenue par une transformation affine. Cependant, afin d'être en mesure de prédire l'étiquette y , cette couche visible possède une transformation supplémentaire. Lorsque y est une variable catégorielle, c'est-à-dire que le FFNN est utilisé dans une optique de classification, ces valeurs de pré-activation sont nommées *logits*. Dans ce cas, la fonction exponentielle normalisée est appliquée à la suite de la transformation affine de façon à attribuer des probabilités décimales à chaque catégorie. Ce type d'unités de sortie est appelé softmax. Lorsque y est une variable continue ou binaire, il convient d'utiliser respectivement des unités de sortie linéaires ou sigmoïdes.

D'après la littérature, il existe une pluralité de fonctions d'activation. D'un point de vue historique, les premières à avoir été proposées sont les fonctions d'activation tangente hyperbolique et sigmoïde. Compte tenu de leurs similitudes sur le plan mathématique, le comportement de ces dernières est sensiblement identique (NG, 2017). Comme illustrées en figure (I.2), elles sont globalement linéaires lorsque la valeur absolue du degré de pré-activation est faible, mais saturent dans le cas de valeurs élevées. Dans la suite de cette étude bibliographique, nous montrerons que ces saturations engendrent une annulation des dérivées, ce qui s'avère être un frein à l'application d'algorithmes d'apprentissage basés sur le calcul du gradient. De ce fait, elles sont généralement déconseillées dans le cas des FFNN.




FIGURE I.2 – Représentation des fonctions d'activation tangente hyperbolique, sigmoïde et ReLU (courbes bleues) ainsi de leur dérivée (courbes orange).

Celle qui est classiquement recommandée est l'Unité de Rectification Linéaire (abrégée ReLU et illustrée en figure (I.2)). Proposée par NAIR et Geoffrey E. HINTON, 2010, il s'agit d'une fonction linéaire par partie qui est définie par l'équation (I.2) où x est un degré de pré-activation. Elle possède donc le pouvoir contractif des fonctions non-linéaires tout en ayant l'avantage des fonctions d'activation li-

néaires, à savoir faciliter l'application d'algorithmes basés sur le gradient. Toutefois, il convient de mentionner que la dérivée de cette fonction est nulle pour l'ensemble des degrés de pré-activation négatifs. Des vecteurs de biais non nuls doivent alors être utilisés pour éviter une annulation du gradient et donc assurer la modification des paramètres au cours de la phase d'apprentissage. De ce fait, diverses améliorations de ReLU ont été proposées dans la littérature. Les bien connues Parametric ReLU (HE et al., 2015b) et le ELU (CLEVERT et al., 2015) permettent par exemple de contourner cette limite.

$$y = \max\{0, x\} \quad (\text{I.2})$$

1.2 Un modèle non supervisé

L'auto-encodeur est un cas particulier des FFNN. Initialement proposé dans les travaux de thèse de Yann Lecun (Y. LECUN et FOGELMAN-SOULIE, 1987), ce modèle paramétrique de référence est capable d'extraire des prédicats caractéristiques d'une base de données d'apprentissage non étiquetée (GÉRON, 2017). Il s'agit donc d'un modèle non supervisé.




FIGURE I.3 – Graphe d'un AE simple. Les nœuds correspondent aux couches du modèle tandis que les flèches orientées illustrent les matrices de poids. En comparaison avec la figure (I.1), l'intérêt de ce type de représentation est qu'elle permet de représenter efficacement des réseaux larges et/ou profonds.

Comme illustrée en figure (I.3), sa structure générale est composée de deux sous-modèles. Le premier a pour rôle d'encoder la donnée d'entrée x par le biais d'une fonction paramétrique f telle que décrite en équation (I.3) où les paramètres θ_{encodeur} sont optimisés par apprentissage. Dans cette dernière, h représente l'unique couche cachée de l'AE nommée « code ». Le second modèle consiste quant à lui en une fonction de décodage notée g . Telle que l'exprime l'équation (I.4), il vise à reconstruire la donnée d'entrée par l'intermédiaire de sa représentation interne h . La donnée résultante de la mise en série de ces deux modèles (équation (I.5)) correspond à la sortie de l'AE.

Les architectures associées aux fonctions paramétriques f et g peuvent également être profondes. Nous en expliciterons les avantages et les inconvénients dans la suite de l'étude bibliographique. Dans cette section, seule la forme simple de ce modèle est considérée, c'est-à-dire un AE composé d'une unique couche cachée.

$$h = f(x, \theta_{\text{encodeur}}) \quad (\text{I.3})$$

$$r = g(h, \theta_{\text{décodeur}}) \quad (\text{I.4})$$

$$r = g(f(x, \theta_{\text{encodeur}}), \theta_{\text{décodeur}}) \quad (\text{I.5})$$

Bien que la tâche de reconstruction d'un AE puisse sembler inutile à première vue, elle est pourtant à la base de sa stratégie d'apprentissage non supervisée. En réalité, l'intérêt de ce modèle ne se situe pas dans son aptitude à reconstruire des données d'entraînement non étiquetées, mais dans sa capacité à les représenter efficacement. Cependant, du fait que le décodeur g soit fonction du code h , l'erreur de reconstruction permet d'estimer indirectement la pertinence des caractéristiques extraites. Ce principe d'évaluation est viable à l'unique condition que les fonctions d'encodage et de décodage ne se résument pas à de triviales fonctions identités. Dans une telle situation, le modèle ne serait aucunement généralisable. Afin d'éviter ce cas, il est nécessaire de contraindre la dimension de h .

Dans ce sens, il existe deux représentations possibles de l'architecture d'un AE (cf. figure (I.4)). Elle est dite sous-complète (*undercomplete* en anglais) lorsque la dimension de la couche cachée h est inférieure à celle de la donnée d'entrée x et sur-complète (*overcomplete*) dans les autres cas.

Historiquement, c'est la représentation sous-complète de l'AE qui a été proposée dans les travaux de Y. LECUN et FOGELMAN-SOULIE, 1987. Dans le cas d'unités cachées linéaires, cette contrainte dimensionnelle vise à pénaliser la fonction de décodage afin d'accroître la pertinence de l'information extraite par l'encodeur. En d'autres termes, ce goulot d'étranglement permet de forcer le réseau à extraire des caractéristiques discriminantes de la distribution des données d'apprentissage, ce qui permet de réaliser de la réduction dimensionnelle. Comme indiqué dans GOODFELLOW et al., 2016, un tel AE couvre le même espace de projection qu'une analyse en composante principale (abrégée ACP). Lorsque ses unités cachées sont non-linéaires, l'AE peut alors être considéré comme une généralisation non-linéaire de l'ACP (Geoffrey E HINTON et SALAKHUTDINOV, 2006). Dans ce cas, compte tenu du caractère contractif de ces fonctions d'activation, la contrainte dimensionnelle induite par une architecture sous-complète n'est pas une condition nécessairement suffisante à l'extraction de caractéristiques discriminantes. Il devient alors indispensable d'évaluer l'erreur de généralisation du modèle sur un jeu de données distinct de son ensemble d'entraînement.




FIGURE I.4 – Illustration des deux représentations possibles d'un AE. L'architecture de gauche est dite sous complète dans la sens où sa couche cachée h est contrainte dimensionnellement. On parle de goulot d'étranglement. L'AE de droite est quant à lui sur-complet. La largeur de sa couche cachée peut être identique ou supérieure à la taille de la donnée d'entrée.

La représentation sur-complète a quant à elle fait une apparition plus tardive. Initiée par les travaux de P. VINCENT et al., 2008, elle fait suite à l'algorithme de pré-entraînement non supervisé qui a été proposé par Hinton en 2006 (G. E. HINTON et al., 2006). Nous détaillerons le principe de cet algorithme glouton en section (2) de l'étude bibliographique. À l'inverse des architectures sous-complètes qui forcent l'extraction de caractéristiques par le biais d'une contrainte dimensionnelle, les AE sur-complets s'appuient sur un principe de régularisation pour parvenir à ces mêmes fins. Cette régularisation consiste en une modification de la fonction de coût qui est utilisée par l'algorithme d'apprentissage. Cela a pour effet de doter les AE de propriétés supplémentaires. Certains auront par exemple une fonction de décodage robuste aux variations de h (P. VINCENT et al., 2008) et d'autres, une fonction d'encodage capable de résister à de faibles perturbations de x (RIFAI et al., 2011). Par ce principe, il est également possible d'utiliser des AE pour répondre des critères annexes supervisés (NG, 2017). Une telle architecture est présentée en figure (I.5).




FIGURE I.5 – Graphe d'un AE régularisé entraîné de manière à répondre à un critère supervisé tel que $y = a(h, \theta_a)$ où a est une fonction paramétrique. La distribution des données de sortie $p(y)$ peut être de Bernoulli (variable binaire), multinoulli (variable catégorielle) ou gaussienne (variable(s) continue(s)).

Il convient également de mentionner un AE régularisé de par la nature de sa couche cachée : l'auto-encodeur variationnel (*variational autoencoder* abrégé VAE ; DOERSCH, 2016). Il s'agit d'une variante générative et probabiliste de ce modèle non supervisé. Le code h de son réseau est obtenu par le biais d'un générateur de nombres pseudo-aléatoires de loi normale $\mathcal{N}(\mu, \sigma)$ où μ et σ sont déterminés par apprentissage. De ce fait, la distribution de sortie du VAE est $p_{\text{décodeur}}(x|h)$ où h est échantillonné aléatoirement. Une extension conditionnelle de ce modèle (nommée *conditional VAE* ou CVAE) a été proposée dans la littérature (D. KINGMA et al., 2014 ; SOHN et al., 2015). Elle permet de contrôler la génération telle que $p_{\text{décodeur}}(x|h, c)$ où c est une variable catégorielle ou continue représentant une condition. Néanmoins, bien que ces modèles génératifs aient suscité un engouement récent auprès de la communauté scientifique du domaine, ils n'ont pas été développés pour répondre à des problèmes du type $p(y|x, c)$. Ils ne seront donc pas traités dans la suite de ce mémoire.

1.3 Procédure d'optimisation

En vue d'appliquer des AE à notre proposition biologique, il est nécessaire de comprendre plus précisément comment des réseaux sur-complets et non-linéaires parviennent à extraire des représentations utiles de distributions de données. Au sein de cette sous-section, nous allons donc exposer le principe de leur procédure d'optimisation. Comme énoncé dans les travaux de Y. Lecun (Y. LECUN et FOGELMAN-SOULIE, 1987), la phase d'apprentissage vise à coder l'information utile dans un réseau de neurones de manière compacte et distribuée. À cet effet, il convient de définir les hyper-paramètres du modèle *a priori*. Dans le cas d'un AE, ces règles de conception concernent le choix de l'algorithme d'apprentissage, de la fonction de coût, de l'architecture du réseau et ses diverses fonctions d'activations.

1.3.1 Algorithme d'apprentissage

Principe Les algorithmes d'apprentissage automatique sont des méthodes d'optimisation utilisées pour ajuster les paramètres d'un réseau de neurones. Dans l'optique d'en maximiser les performances, ces algorithmes cherchent à minimiser une fonction d'évaluation intermédiaire appelée fonction de coût et notée $J(\theta)$. Cette métrique, qui se doit d'être corrélée aux performances du modèle, est détaillée dans la suite de cette sous-section.

La méthode classiquement utilisée dans le cas des FFNN et des AE est l'algorithme de descente de gradient (RUMELHART et al., 1986). Cette dernière, qui consiste en une évaluation du gradient sur un ensemble de données d'apprentissage, a pour objectif de minimiser $J(\theta)$ de manière itérative. Elle peut être réalisée en ligne, par lot ou par mini-lot. La première approche, qualifiée de stochastique, consiste à calculer le gradient pour chaque donnée. Elle s'avère efficace d'un point de vue computationnel mais ne fournit pas une estimation très précise du gradient. Dans la seconde, le gradient est calculé sur l'ensemble des données d'apprentissage. Cette approche, qui est jugée intéressante pour son caractère déterministe, peut néanmoins s'avérer particulièrement coûteuse en temps de calcul dans le cas de bases d'ap-

prentissage volumineuses. La dernière approche, dite par mini-lot (*mini-batch*), se présente comme une alternative aux deux premières. Elle s'appuie sur une subdivision de la base d'apprentissage en divers sous-ensembles distincts. Le gradient est alors calculé de manière itérative sur chacun de ces groupes d'exemples.

La taille des mini-lots est choisie en fonction du volume de données, du nombre de paramètres à optimiser et de la configuration matérielle. Lorsqu'un processeur graphique est utilisé, il est conseillé dans la littérature de choisir une taille égale à 2^n avec $5 \leq n \leq 8$ (GOODFELLOW et al., 2016). À savoir qu'il est également possible de se tourner vers des tailles de mini-lot adaptatives (YAO et al., 2018).

Sous réserve que la base de données ne soit pas trop volumineuse, il est possible de réutiliser plusieurs fois les mêmes données pour tenter de poursuivre la minimisation de $J(\theta)$. Chaque passage sur l'ensemble des échantillons d'apprentissage est appelé une *epoch*. Lorsque ce principe est employé, l'ordonnancement des données doit être modifié aléatoirement à chaque *epoch* pour éviter d'introduire un biais dans l'apprentissage. Par ailleurs, seule la première *epoch* permet d'obtenir un gradient non biaisé de l'erreur de généralisation. Afin d'éviter un potentiel surajustement des paramètres du réseau, il est alors nécessaire de définir un critère d'arrêt de l'algorithme d'apprentissage. En règle générale, il convient d'évaluer la généralisation du modèle au cours de l'entraînement par le biais d'un jeu de données annexe. Un critère d'arrêt basé sur cette approche est qualifié de précoce (*early stopping* en anglais) (PRECHELT, 1996).

Dans la pratique, les fonctions de coût considérées sont généralement non-linéaires. De ce fait, la convergence de l'algorithme d'apprentissage n'est pas toujours garantie. Deux facteurs d'influence doivent alors être considérés : l'initialisation des paramètres et la valeur du taux d'apprentissage.

Initialisation des paramètres De manière analogue aux méthodes d'optimisation traditionnelles, l'application d'algorithmes d'apprentissage automatique implique d'initialiser préalablement les paramètres concernés. Dans le cas des FFNN, il s'agit d'affecter une valeur aux matrices de poids et aux vecteurs de biais. Lorsque l'architecture d'un réseau est faiblement profonde, il convient d'en initialiser les poids de manière aléatoire à partir d'une distribution gaussienne ou uniforme. La disparité des paramètres qu'engendre une telle initialisation permet d'éviter une redondance dans les fonctions apprises par les unités cachées (GOODFELLOW et al., 2016). Cependant, compte tenu du caractère généralement non convexe des fonctions de coût des AE, la valeur initiale de ces paramètres a une influence non négligeable sur les temps d'apprentissage et les performances des modèles. Il est donc nécessaire d'initialiser le réseau proche d'une solution pertinente en procédant de manière déterministe. Pour ce faire, l'approche classique se résume à faire varier la valeur de la graine du générateur de nombres pseudo-aléatoires. Ce principe d'initialisation s'apparente aux tâches d'optimisation hyper-paramétriques que nous détaillons dans la suite de cette section.

L'initialisation du biais est quant à elle une tâche moins complexe. D'après la littérature, il convient de lui affecter de faibles valeurs non nulles, telle que $1e^{-1}$ (GOODFELLOW et al., 2016). Cela permet d'obtenir des degrés de pré-activation positifs et donc d'assurer la propagation du gradient.

Taux d'apprentissage Outre cette initialisation, il est également nécessaire d'optimiser la valeur du taux d'apprentissage (appelé *learning rate* en anglais et abrégé *lr*). Ce scalaire positif détermine la taille du pas utilisé par l'algorithme de descente de gradient pour minimiser la fonction de coût. Dans le cas d'une valeur trop faible, l'apprentissage sera lent et particulièrement sensible aux minima locaux. *A contrario*, un taux trop élevé générera une forte oscillation des valeurs des paramètres et mènera donc à une non-convergence, voire même à une divergence de l'algorithme d'apprentissage (GOODFELLOW et al., 2016). Les auteurs de JASTRZKEBSKI et al., 2017 ont également montré que dans le cas d'un entraînement par mini-lots, le quotient du taux d'apprentissage par la taille des sous-ensembles était un facteur clé de la dynamique de l'algorithme de descente de gradient. Les résultats expérimentaux ont révélé que ce ratio affectait fortement la généralisation des modèles.

Afin de faire face à cette difficulté, il est possible d'employer des extensions de l'algorithme de descente de gradient nommées algorithmes à taux d'apprentissage adaptatif. Ces derniers tels que delta-bar-delta (JACOBS, 1988), AdaGrad (DUCHI et al., 2011), son extension nommée RMSProp (TIELEMAN et G. HINTON, 2012) ou encore le très populaire Adam (D. P. KINGMA et BA, 2014), ont pour but d'adapter individuellement les taux d'apprentissage des paramètres du modèle en s'appuyant sur l'évolution du gradient. Bien que le comportement dynamique du *lr* permette d'atténuer l'influence de sa valeur initiale, son optimisation reste indispensable. Pour ce faire, il est nécessaire d'adopter les mêmes approches que celles utilisées pour l'optimisation hyper-paramétrique. Par ailleurs, un grand nombre d'études comparatives ont ciblé ces divers algorithmes à taux adaptatif. Aucun consensus n'a émergé au sujet de celui à favoriser ; l'algorithme de descente de gradient s'étant montré tout aussi robuste que ses successeurs.

1.3.2 Fonction de coût

Afin d'optimiser la distribution de sortie $p(y|x, \theta)$ d'un modèle paramétrique supervisé, il convient d'optimiser l'entropie croisée entre les étiquettes provenant de la base d'apprentissage et celles prédites par le modèle. Cela correspond au principe de maximum de vraisemblance. Compte tenu de l'objectif des algorithmes d'apprentissage, la fonction de coût que nous cherchons à minimiser est donc la log-vraisemblance négative (*negative log-likelihood* en anglais) qui est exprimée en équation (I.6). L'intérêt du *log* présent dans cette dernière, est qu'il permet d'annuler la fonction exponentielle présente dans les unités sigmoïdes et tangentes hyperboliques, fonction qui est source des saturations évoquées précédemment.

Étant dépendante des prédictions, la forme de la log-vraisemblance varie selon les modèles utilisés. Dans le cas de l'AE où l'apprentissage est non supervisé, la donnée x est associée à l'entrée et à la sortie du modèle. La fonction de coût à minimiser est alors exprimée sous la forme de l'équation (I.7). Tel qu'indiqué dans BERKSON, 1956, lorsque x est à valeur réelle et que les unités de sorties sont linéaires, la log-vraisemblance négative s'apparente à une erreur quadratique moyenne (*Mean Square Error* abrégée MSE et représentée en équation (I.8)).

Au travers de l'équation (I.9), on peut également constater que la MSE est une mesure globale puisqu'elle permet d'évaluer la variance et le biais du modèle. De ce fait, elle est souvent utilisée comme fonction objective de substitution dans les cas

où les unités de sorties sont non-linéaires. En d'autres termes, elle se présente dans le cas des AE comme une alternative possible à la log-vraisemblance négative.

Par ailleurs, cet indicateur fait partie des erreurs prévisionnelles absolues. Les éléments de cette famille sont présentés dans le rapport bibliographique SHCHERBAKOV et al., 2013. Parmi eux, il nous semble important de mentionner la MSE normalisée (NMSE). Elle permet de réduire l'influence négative que des valeurs aberrantes pourraient avoir sur le processus de normalisation des données d'apprentissage et donc sur la convergence des procédures d'optimisation (POLI et CIRILLO, 1993). Cependant, du fait que différentes méthodes de normalisation soient proposées dans la littérature, il existe plusieurs formules de NMSE. En ce qui nous concerne, nous avons statué en faveur de l'équation (I.10).

$$J(\theta) = -\log p(y|x) \quad (\text{I.6})$$

$$J(\theta) = -\log p_{\text{décodeur}}(x|h) \quad (\text{I.7})$$

$$MSE = \frac{1}{n} \sum_{i=1}^n (x_i - r_i)^2 \quad (\text{I.8})$$

$$MSE = \sigma^2 + \text{bi}ais^2 \quad (\text{I.9})$$

$$NMSE = \frac{1}{n} \frac{\sum_{i=1}^n (x_i - r_i)^2}{\max(x) - \min(x)} \quad (\text{I.10})$$

Un terme de régularisation est souvent sommé à la fonction de coût afin d'assurer la pertinence des prédicats intermédiaires. Cela a pour effet de pénaliser la phase d'apprentissage afin que de nouvelles propriétés soient acquises par le modèle. Certains AE régularisés sont optimisés de cette manière. C'est par exemple le cas de l'AE parcimonieux et de l'AE contractif. Leur critère d'apprentissage implique respectivement une pénalité de parcimonie et un terme visant à minimiser les dérivées de la fonction d'encodage. Le code du premier possède ainsi des caractéristiques de parcimonie ce qui permet au modèle de répondre à des tâches annexes pouvant être supervisées. Le code du second s'avère quant à lui robuste aux légères variations présentes dans les données d'apprentissage.

Il est également possible de régulariser un modèle en modifiant directement les termes de sa fonction de coût. L'AE débruiteur (DAE), mieux connu sous le nom de *denoising autoencoder*, en est un exemple. Il est entraîné de sorte que son décodeur soit robuste aux légères perturbations de sa donnée d'entrée. Pour ce faire, sa fonction de coût est définie par l'équation (I.11) où $\tilde{x}$ est une corruption de x . Cette corruption peut être réalisée par addition d'un bruit gaussien ou d'un bruit impulsionnel. Au travers de cette pénalisation, le DAE a donc pour rôle de débruiteur son ensemble d'entraînement ce qui le force à en apprendre la distribution $p(x)$.

Par ailleurs, une fonction de coût hybride est utilisée dans le cas de l'AE parcimonieux répondant à une tâche annexe supervisée (modèle présenté en figure (I.5)). Comme indiquée en équation (I.12), elle correspond à la somme de deux fonctions de coût. Dans cette dernière, $J_{reconstruction}(\theta)$ est associée à la tâche non supervisée, $J_{supervisé}(\theta)$ à la tâche supervisée et $\Omega(h)$ à la pénalité de parcimonie (G. ZHOU et al., 2012a). Compte tenu de cette fonction objective, l'apprentissage est dit semi-supervisé.

$$J(\theta) = -\log p_{\text{décodeur}}(x|h = f(\tilde{x})) \quad (\text{I.11})$$

$$J(\theta) = J_{reconstruction}(\theta) + J_{supervisé}(\theta) + \Omega(h) \quad (\text{I.12})$$

1.3.3 Optimisation hyper-paramétrique

Afin d'être en mesure de réaliser les phases d'apprentissage et d'évaluation d'un modèle, il est tout d'abord nécessaire d'en définir l'architecture. Dans le cas de l'AE, qu'il soit régularisé ou non, la dimension de la couche cachée et le type de fonctions d'activation utilisées ont tous deux un impact non négligeable sur le sur-ajustement et le sous-ajustement des paramètres.

Dans l'optique d'optimiser ces derniers, il convient de diviser la base d'apprentissage en deux sous-ensembles disjoints¹. Le premier, appelé ensemble d'entraînement, est utilisé pour réaliser l'optimisation paramétrique du modèle. Le second, qui est quant à lui nommé ensemble de validation, sert à estimer l'erreur de généralisation au cours de la procédure d'optimisation. De ce fait, il permet d'évaluer l'influence qu'exercent les hyper-paramètres sur les performances du modèle et est donc utilisé pour l'optimisation hyper-paramétrique.

Compte tenu de la faible combinatoire associée à la recherche de ces valeurs optimales dans le cas des AE simples, il est usuel d'employer des stratégies de recherche peu complexes telles que la recherche par grille ou la recherche aléatoire (BERGSTRA et BENGIO, 2012).

Bien que cette approche soit viable dans le cas de base de données volumineuses (Francois LASSON et al., 2019), la tâche qui vise à définir un ensemble de validation représentatif de celui d'entraînement s'avère complexe lorsque la quantité de données est réduite. En effet, cela génère une incertitude statistique dans l'estimation de l'erreur de généralisation, ce qui a pour conséquence de rendre flou l'optimisation hyper-paramétrique (GOODFELLOW et al., 2016). Afin de faire face à cette difficulté, on divise communément la base d'apprentissage en plusieurs sous-ensembles par l'intermédiaire de la validation croisée (ANDREW, 1997). Tels qu'illustrés en figure (I.6), ces divers sous-ensembles sont appelés des échantillons. À chaque itération, un échantillon est considéré comme jeu de validation tandis que les

1. La base d'apprentissage ne doit pas être confondue avec celle de test. Bien que leurs données soient issues de la même distribution, l'une sert à l'optimisation paramétrique et hyper-paramétrique du modèle tandis que l'autre permet d'en estimer l'erreur de généralisation. Il est important de noter que la base de données de test ne doit en aucun cas être considérée lors de la procédure d'optimisation du modèle (GOODFELLOW et al., 2016)

autres sont concaténés pour former un ensemble d'entraînement. Ce processus est réitéré jusqu'à ce que l'intégralité des sous-ensembles aient été considérée. L'estimation de l'erreur de généralisation du modèle, alors appelée erreur de validation croisée, est obtenue par le biais d'une valeur moyenne.

Réaliser de la validation croisée avec un nombre important d'échantillons permet donc de pallier l'incertitude statistique que nous venons d'évoquer. Cependant, compte tenu du principe de fonctionnement de cette méthode, cela a un coût computationnel non négligeable. À noter que dans le cas particulier où la taille des échantillons est égale à 1, la procédure est appelée *leave-one-out* (traduit littéralement « tous sauf un »).




FIGURE I.6 – Cette figure provient des notes de lecture de NG, 2003. Elle illustre le principe de fonctionnement de la méthode de validation croisée dans le cas où la base d'entraînement a été divisée en k sous-ensembles de même dimension (k échantillons).

1.4 De la reconstruction à la détection de nouveautés

De par son principe de fonctionnement, l'AE peut également être appliqué en réponse à une tâche de détection de nouveautés. Tel qu'indiqué dans le rapport bibliographique PIMENTEL et al., 2014, ce terme fait référence à un problème de classification dans lequel le comportement d'une donnée de test est comparé à celui du jeu d'apprentissage. Selon le contexte d'application, cette tâche peut également être nommée détection d'anomalies ou de valeurs aberrantes.

Bien qu'il n'existe pas de définition universelle, les anomalies ou valeurs aberrantes font généralement référence à des données incohérentes devant être écartées lors de la procédure d'optimisation des modèles. À l'inverse, une nouveauté présente un comportement sensiblement similaire à celui des données dites normales. Il peut donc être intéressant de l'intégrer à la base d'apprentissage (CHANDOLA et al., 2009). Dans le cadre de nos travaux, nous souhaitons aider le clinicien à déterminer une dose de médicament suffisante pour assurer la disparition des symptômes chez le patient. Après validation de cette posologie, il est envisageable d'enrichir notre base d'apprentissage avec le résultat du test global associé. De ce fait, nous faisons face à un problème de détection de nouveautés.


Toutefois, ces synonymes impliquent en réalité les mêmes méthodes de résolution. Compte tenu de la nature variable et non déterministe des données anormales, l'approche qui consisterait à répondre à un tel problème par l'intermédiaire

d'un classifieur binaire n'est pas pertinente. Il convient d'adopter une approche uni-classe pouvant être réalisée par le biais d'un modèle paramétrique non supervisé tel que l'AE (SAKURADA et YAIRI, 2014).


D'un point de vue théorique, un AE régularisé et optimisé est en mesure de bien reconstruire des données similaires à celles de son jeu d'apprentissage. *A contrario*, le taux d'erreur associé à la reconstruction de données anormales est censé être élevé. En d'autres termes, la MSE (ou NMSE) entre les données réelles et prédites est révélatrice de leur degré de similitude. Il est donc concevable de seuiller cette métrique dans l'optique de réaliser de la classification (HAWKINS et al., 2002).

Bien que dans un cas optimal, les distributions des erreurs de reconstruction des données normales et anormales s'avèrent très différentes, un recouvrement est bien souvent constaté en pratique. Nous illustrons ces propos en figure (I.7). Afin d'y faire face, les auteurs de JAPKOWICZ et al., 1995 proposent de déterminer la valeur seuil optimale en intégrant des données anormales dans le jeu de validation. Cependant, une telle approche est à écarter dans un contexte de classification uni-classe où seules les données normales peuvent être utilisées pour réaliser les phases d'optimisation paramétrique et hyper-paramétrique (C. ZHOU et PAFFENROTH, 2017). Dans ce sens, la valeur seuil est généralement définie par application de la règle des trois sigmas à la distribution des erreurs des données normales (CHANDOLA et al., 2009). En fonction des contraintes associées au contexte, d'autres valeurs de percentiles peuvent également être utilisées.

Validation



Test



Classe réelle	Classe prédite	
	Vrai normaux	Faux anormaux
Faux normaux		
Vrai anormaux		

FIGURE I.7 – Ce schéma représente les phases de validation et de test associées au principe de classification par seuil. Les densités de probabilité des données normales sont illustrées en bleu, celle des données anormales est représentée en orange. Le seuil, qui est défini au cours de la phase de validation, correspond quant à lui à l'axe vertical pointillé. Dans le graphique associé au test, on constate un recouvrement entre les deux distributions. Ses effets sont retranscrits dans la matrice de confusion (tableau de droite).

Après définition de ce seuil, il est alors possible d'évaluer l'erreur de généralisation du modèle sur un jeu de test composé de données normales et anormales. Pour ce faire, il convient de calculer la matrice de confusion ainsi que les différents indicateurs de performances qui lui sont associés (la précision, le rappel ou encore la F-mesure) (FAWCETT, 2006).

1.5 Discussion

Tel que nous l'évoquions en introduction, le but de notre proposition de CDSS est d'aider le clinicien à déterminer la posologie optimale de médicament à administrer à un patient victime d'un trouble de l'hémostase, c'est-à-dire prédire la dose minimale suffisante pour assurer la disparition des symptômes. À cet effet, l'un des objectifs de nos travaux est de développer un système capable de caractériser l'impact qu'une administration de médicament pourrait avoir sur le risque hémorragique ou thrombotique de ce patient. Compte tenu de notre contexte biologique, nous avons proposé de développer ce système par la mise en série d'un modèle conditionnel et d'un modèle de détection de nouveautés que nous souhaitons implémenter par le biais de deux AE.

Du fait de la place centrale que ce modèle d'apprentissage automatique occupe dans notre proposition de CDSS, c'est en toute logique que nous avons consacré cette section à l'étude de son principe fonctionnement. Par la présentation du principe de reconstruction non supervisée sur lequel repose leur structure générale et la définition des contraintes dimensionnelles qui résultent des architectures sous-complètes, nous avons tout d'abord mis en évidence la capacité qu'ont les AE à extraire des caractéristiques discriminantes de données d'apprentissage non étiquetées. En vue de les appliquer à notre proposition biologique, nous avons ensuite détaillé les diverses étapes de leur procédure d'optimisation. À travers cette énumération, nous avons expliqué le principe de pénalisation qui est associé à la régularisation des architectures sur-complètes. Cela a permis de souligner l'aptitude des AE parcimonieux à répondre à des tâches annexes supervisées.

Afin de développer notre modèle conditionnel, il nous semble pertinent d'envisager une extension de l'AE. Son rôle étant de répondre à un problème supervisé du type $p(y|x, c)$, nous proposons d'employer une architecture sur-complète régularisée par une pénalité de parcimonie. À l'instar des extensions conditionnelles du VAE, nous y intégrerons la variable c par l'ajout d'une nouvelle couche visible.

Au cours de cette section, nous avons également exposé l'applicabilité des AE aux tâches de classification uni-classe. Par conséquent, nous proposons d'implémenter notre modèle de détection de nouveautés par le biais d'un AE non supervisé. En ce qui concerne le seuillage de l'erreur de reconstruction, il conviendra d'adapter la valeur aux contraintes imposées par le contexte biologique.

2 Vers un plus haut degré d'abstraction : l'auto-encodeur profond

Dans la section précédente, nous avons présenté l'AE simple, c'est-à-dire composé d'une unique couche cachée. Tel que nous l'avons rapidement mentionné, les architectures associées aux fonctions paramétriques d'encodage et de décodage peuvent également être composées de plusieurs couches cachées. Dans ce cas, l'AE est dit profond (voir figure (I.8)). Dans cette partie, nous exposerons les multiples avantages que présentent ces architectures profondes avant d'évoquer la complexité associée à leur optimisation paramétrique et hyper-paramétrique. Nous détaillerons diverses solutions qui ont été proposées dans la littérature pour remédier à cette double difficulté et discuterons de leurs champs d'application.




FIGURE I.8 – Le graphique ci-dessous représente un AE profond composé de m couches cachées. n couches sont dédiées à l'encodeur et $(m - n + 1)$ au décodeur.

2.1 Intérêts théoriques de l'apprentissage profond

En vertu du caractère contractif des nombreuses couches cachées qu'elles possèdent, les architectures profondes (*deep architectures* en anglais) sont capables de représenter de manière compacte des fonctions hautement non-linéaires, fonctions difficilement représentables par le biais d'architectures simples (*shallow architectures*) (Geoffrey E HINTON et SALAKHUTDINOV, 2006; BENGIO et al., 2007; BENGIO, 2009).

D'après le théorème de l'approximation universelle (HORNIK et al., 1989), un AE simple possédant suffisamment d'unités cachées non-linéaires est en mesure de représenter toute fonction continue ou discrète allant d'un ensemble fermé à un autre. Le taux d'erreur qui lui est associé est cependant arbitraire. En d'autres termes, bien que des fonctions hautement non-linéaires puissent être approximées par le biais d'architectures simples, ces représentations impliquent généralement un nombre exponentiel d'unités cachées (GOODFELLOW et al., 2016). Dans le cas où l'algorithme d'apprentissage parvient à converger, l'erreur de généralisation est alors souvent très élevée.

Il convient alors d'utiliser des architectures profondes. Tel qu'indiqué dans Yoshua BENGIO et Yann LECUN, 2007 : "*shallow circuits are much less expressive than deep ones*". En effet, le nombre d'unités utiles à la représentation de fonctions complexes est inversement proportionnel à la profondeur des réseaux. Par conséquent, l'augmentation du nombre de couches cachées engendre une réduction exponentielle

des connexions inter-unités et donc une forte diminution de la quantité de données nécessaires aux phases d'apprentissage (Geoffrey E HINTON et SALAKHUTDINOV, 2006 ; LESHNO et al., 1993).

De ce fait, les performances théoriques des modèles profonds s'avèrent être largement supérieures à celles de leurs homologues à l'architecture simple (ERHAN et al., 2010).

2.2 Complexité liée à l'optimisation paramétrique

Les fonctions de coût des architectures profondes sont des fonctions fortement non convexes qui possèdent de nombreuses régions critiques. Tel qu'indiqué dans ERHAN et al., 2010, le nombre de minima locaux est proportionnel à la profondeur du réseau et s'avère être, en règle générale, extrêmement élevé. Bon nombre d'entre eux sont associés à un faible coût et ne posent donc pas de problème majeur. D'autres, *a contrario*, impactent drastiquement l'erreur de généralisation. DAUPHIN et al., 2014 ont également mis en avant la présence de points-selles à coût élevé (*saddle points* en anglais). Il s'agit de régions plates dans lesquelles le gradient est quasi nul. Enfin, ces fonctions objectives présentent généralement des non-linéarités nettes appelées « falaises ». Ces zones critiques sont illustrées en figure (I.9). Elles sont associées à des dérivées très élevées qui ont pour conséquence de générer des sauts indésirables dans la valeur des paramètres.

Compte tenu de la complexité de cette optimisation paramétrique, l'intérêt théorique des architectures profondes n'a pas toujours été vérifié en pratique. Ce champ d'études a donc connu une popularité fluctuante au cours des dernières décennies. Afin de faire face à ces défis, c'est-à-dire obtenir une bonne convergence de la méthode d'optimisation, il est possible d'initialiser le réseau proche d'une solution pertinente. Dans cette sous-section, nous présenterons des concepts théoriques issus de cette piste de recherche.




FIGURE I.9 – Cette figure, qui est issue de GOODFELLOW et al., 2016, illustre les zones critiques appelées « falaises ». On peut constater qu'une forte non-linéarité de la fonction de coût $J(W, b)$ engendre un saut indésirable des valeurs de la matrice de poids w et du biais b . Cela peut être perçu comme une réinitialisation involontaire des paramètres du réseau.

2.2.1 Initialisation aléatoire

Tout comme pour les architectures simples, il est également envisageable d'initialiser les AE profonds par le biais d'un générateur de nombres pseudo-aléatoires. Au vu de ces nombreuses couches cachées, il est cependant nécessaire de normaliser l'échelle de la distribution initiale. En effet, bien que des poids élevés favorisent la propagation du gradient, l'imbrication de telles transformations affines peut être responsable de l'explosion de sa valeur. De faibles poids, qui permettent quant à eux d'accroître la généralisation du modèle, peuvent potentiellement mener à une disparition du gradient.

Afin de trouver un compromis entre optimisation et régularisation, des heuristiques ont été proposées dans la littérature. Les plus couramment utilisées sont celles définies par GLOROT et YOSHUA BENGIO, 2010 et par HE et al., 2015b. Elles définissent un facteur d'échelle qui est fonction de la largeur des couches cachées. Cependant, comme tous compromis, elles ne permettent pas d'aboutir à des solutions optimales.

Par ailleurs, l'approche qui consiste à faire varier la graine du générateur de nombres pseudo-aléatoires semble également peu pertinente dans ce contexte. Outre le fait que sa valeur optimale soit étroitement liée à l'architecture du réseau, un fort écart type est associé à son optimisation. De ce fait, il semble plus cohérent d'envisager des stratégies d'initialisation basées sur l'apprentissage automatique (Geoffrey E HINTON et SALAKHUTDINOV, 2006).

2.2.2 Pré-entraînement non supervisé

Une autre manière de procéder, proposée par G. E. HINTON et al., 2006, consiste en un pré-entraînement (*pre-training*) de l'architecture profonde par le biais d'un algorithme glouton nommé "*Greedy Layer-Wise Unsupervised Algorithm*". Cette stratégie a pour but d'initialiser le réseau de manière itérative, couche après couche, en utilisant des briques de base que sont les AE simples régularisés ou non. L'intérêt de cette approche, du fait de la forme généralement faiblement non convexe des fonctions objectives des architectures simples, est qu'elle permet de contourner les diverses difficultés associées à l'optimisation des réseaux profonds. Le principe de fonctionnement de cette méthode d'initialisation est illustré en figure (I.10). À savoir que dans ce contexte d'initialisation, il est courant d'utiliser des matrices de poids communes aux deux fonctions paramétriques des AE simples. La matrice du décodeur W_B correspond alors à la transposée de celle de l'encodeur W_A (cf. équation (I.13)). Cette contrainte, appelée *tied weights*, limite le nombre de paramètres du réseau et favorise donc l'optimisation (Pascal VINCENT, 2011).

Cependant, son rôle est uniquement d'encoder de l'information utile dans la distribution des paramètres initiaux (Geoffrey E HINTON et SALAKHUTDINOV, 2006). Cette procédure d'initialisation doit donc être suivie d'une phase d'apprentissage classique. Cette seconde étape, appelée *finetuning* en anglais, consiste à affiner conjointement l'ensemble des paramètres du réseau en tenant compte d'un critère supervisé ou non supervisé.

$$W_B = W_A^T \tag{I.13}$$

Une étude présentée dans ERHAN et al., 2010 a montré que le pré-entraînement pouvait être perçu comme une forme de régularisation. En effet, cet algorithme non supervisé se base uniquement sur la distribution des données d'entrée $p(x)$ pour extraire des prédicats caractéristiques. Lorsqu'un critère supervisé doit être respecté, l'association aux données de sortie $p(y|x)$ est quant à elle réalisée lors de la phase d'affinage. De ce fait, un modèle ainsi entraîné peut s'avérer fortement généralisable malgré la présence d'une faible quantité de données d'apprentissage étiquetées. Les auteurs de Geoffrey E HINTON et SALAKHUTDINOV, 2006 ont également constaté une diminution des erreurs de reconstruction dans le cas des AE profonds purement non supervisés. Cette procédure d'initialisation permet donc de diminuer le risque de sur-ajustement des paramètres (régularisation) tout en améliorant la convergence de l'algorithme d'apprentissage (optimisation). Cette méthode d'initialisation présente cependant l'inconvénient qu'elle divise la phase d'apprentissage en deux étapes. Deux taux d'apprentissage doivent donc être optimisés.




FIGURE I.10 – Afin de pré-entraîner un AE composé de trois couches cachées, un AE simple est tout d'abord considéré. Il est entraîné de manière non supervisée à reconstruire la distribution des données d'entrée $p(x)$ (étape 1). Sa fonction d'encodage est alors appliquée dans le but d'obtenir la distribution $p(h^1|x)$ de sa couche cachée h^1 . Indépendamment de cet AE, une seconde brique de base est entraînée à reconstruire la distribution $p(h^1)$ (étape 2). Les paramètres de ces deux modèles sont ensuite exportés de sorte à initialiser l'architecture profonde (étape 3). Lorsque que le modèle considéré possède n couches cachées, ce principe peut être réitéré jusqu'à l'obtention de la distribution empirique $p(h^n|h^{n-1})$. À noter que le terme d'AE empilés (*Stacked AutoEncoder* ou SAE) est employé pour parler d'un AE profond ainsi obtenu.

2.2.3 Apprentissage par transfert

Il est également possible d'initialiser les paramètres d'un modèle supervisé en appliquant des techniques d'apprentissage par transfert. Ces dernières visent à réutiliser dans un contexte cible, l'information apprise dans un contexte source, afin de faciliter l'optimisation paramétrique. Lorsque ces contextes sont similaires et que le volume de données d'apprentissage de la source est grandement supérieur à celui de la cible, ces méthodes permettent d'améliorer considérablement la généralisation des modèles.

D'après le rapport bibliographique PAN et YANG, 2010, l'apprentissage par transfert peut être inductif, transductif ou non supervisé.

Lorsque les distributions des données d'entrée des contextes source et cible sont identiques mais que les tâches à réaliser sont légèrement différentes, il convient d'utiliser l'apprentissage par transfert inductif. Ce principe consiste à réutiliser l'ensemble des caractéristiques discriminantes extraites par le premier modèle (ses couches cachées) et à ne réentraîner que le lien supervisé. Tel qu'indiqué dans KHAN et al., 2019, des architectures profondes composées de plusieurs millions de paramètres sont proposées en libre accès sur internet. Les références comme AlexNet (KRIZHEVSKY et al., 2012), ResNet (HE et al., 2015a) ou encore VGG (SIMONYAN et ZISSERMAN, 2014) permettent de répondre efficacement à des problèmes de reconnaissance d'images.

A l'inverse, lorsque les tâches à réaliser sont identiques mais que les distributions des données d'entrée sont légèrement différentes, il est courant d'appliquer l'apprentissage par transfert transductif. Également appelé adaptation de domaine, il vise à affiner les paramètres du premier modèle avec le jeu d'apprentissage cible. Les auteurs de GLOT, BORDES et Y. BENGIO, 2011 ont effectué cette adaptation par l'intermédiaire de SAE. À travers cette approche, il est également possible de tirer profit de données issues de simulation dans l'optique d'accroître les performances d'un modèle sur des données expérimentales (BOUSMALIS et al., 2018).

La dernière technique d'apprentissage par transfert est dite non supervisée. Elle consiste à réutiliser dans un contexte cible, l'information qu'un modèle source a extraite d'une base de données d'apprentissage non-étiquetée. Par conséquent, elle est tout autant adaptée à des problèmes de partitionnement de données (DAI et al., 2008), qu'à des tâches supervisées. Dans le second cas, l'apprentissage est qualifié d'autodidacte (*self-taught learning* en anglais) (RAINA et al., 2007). Par ailleurs, il est possible d'appliquer cette approche malgré la présence de légères différences entre les distributions source et cible.

2.2.4 Discussion

Tel qu'énoncé précédemment, les modèles profonds sont capables de représenter de manière compacte des fonctions hautement non-linéaires. En comparaison avec leurs homologues à l'architecture simple, pour lesquels ces fonctions sont difficilement représentables, cela se traduit par une réduction exponentielle du nombre de paramètres. Le pouvoir contractif de ces modèles induit donc une forte diminution de la quantité de données nécessaire à leur apprentissage.

Compte tenu de la faible prévalence de certaines des maladies de l'hémostase et de la complexité d'interprétation des tests globaux, il nous semble pertinent d'envisager des architectures profondes pour développer notre proposition de CDSS.

Dans le cas du modèle de détection de nouveautés, nous devons donc réaliser l'optimisation paramétrique d'un AE profond purement non supervisé. Il sera possible d'initialiser ce modèle par application du pré-entraînement et de poursuivre l'apprentissage de manière non supervisée. Il nous semble également concevable d'appliquer des techniques d'apprentissage par transfert non supervisé afin de tirer profit de données obtenues par simulation.

L'optimisation paramétrique du modèle conditionnel semble néanmoins plus complexe. En effet, bien qu'il permette d'initialiser un AE profond semi-supervisé, le pré-entraînement n'est pas applicable aux problèmes du type $p(y|x, c)$ au sein desquels le critère supervisé est régi par une fonction fortement non-linéaire. Dans de tels cas, il est nécessaire de représenter efficacement les distributions des données d'entrée $p(x)$ et de sortie $p(y)$ par l'intermédiaire d'architectures profondes. À l'heure actuelle, aucune méthode d'initialisation pour ce type d'AE n'a cependant été proposée dans la littérature. Par ailleurs, l'approche qui consisterait à répondre à ce type de problème par application de l'apprentissage par transfert inductif ne semble pas envisageable compte tenu de notre contexte d'application. Nous faisons donc face à un premier verrou scientifique.

2.3 Complexité liée à l'optimisation hyper-paramétrique

La seconde difficulté associée à l'utilisation des réseaux profonds concerne la définition des hyper-paramètres. Tel que nous l'évoquions en partie (1.3), la dimension des architectures et le taux d'apprentissage sont des facteurs clés de la convergence de l'algorithme de descente de gradient. Afin d'obtenir une faible erreur de généralisation, c'est-à-dire éviter le sur-apprentissage et le sous-apprentissage, il est indispensable de les optimiser conjointement sur l'ensemble de validation. Dans le cas des AE simples, cela peut être réalisé en combinant la validation croisée avec des stratégies d'optimisation peu complexes telles que la recherche par grille ou la recherche aléatoire (BERGSTRA et BENGIO, 2012). Cependant, le nombre d'hyper-paramètres est logiquement proportionnel à la profondeur des réseaux. De ce fait, ces techniques s'avèrent peu pertinentes dans le cas d'AE possédant de nombreuses couches cachées (JONGMIN YU et al., 2015; G. ZHOU et al., 2012a; PRATAMA et al., 2018). Dans cette sous-section, nous exposons diverses solutions que les chercheurs du domaine ont envisagées pour faire face à cette grande combinatoire.

2.3.1 Approche basée sur la validation croisée

Afin d'estimer l'erreur de généralisation associée à une topologie, on divise communément la base de données en plusieurs sous-ensembles par l'intermédiaire de la validation croisée (ANDREW, 1997). De par cette approche, il est possible de concevoir l'optimisation hyper-paramétrique comme une simple méthode essai-erreur. Dans un contexte d'apprentissage profond ou de données massives (*big data*), il est donc nécessaire d'orienter cette recherche opérationnelle en employant des méthodes d'optimisation combinatoire telles que les métaheuristiques (REAL et al.,

2017).

Dans ce contexte, le pré-entraînement s'avère également être une solution intéressante. En effet, la combinatoire associée à l'optimisation hyper-paramétrique d'une série de n AE simples (SAE) est nettement plus faible que celle associée à l'optimisation conjointe n couches cachées (AE profond). Dans le cas trivial de la recherche par grille, cela revient à transformer un produit de combinaisons en une simple somme. GOODFELLOW et al., 2016 et RIFAI et al., 2011 énoncent que les résultats obtenus par ces deux approches sont différents mais que le pré-entraînement permet de converger efficacement vers des solutions cohérentes.

2.3.2 Approche basée sur l'apprentissage incrémental

Bien que des techniques de régularisation puissent être employées pour limiter le risque de sur-ajustement des paramètres, les modèles d'apprentissage automatique sont inéluctablement spécifiques aux caractéristiques représentatives des échantillons d'apprentissage. Par conséquent, la difficulté combinatoire que nous venons d'évoquer s'avère d'autant plus contraignante dans un contexte où la distribution des données d'apprentissage est susceptible d'évoluer au cours du temps (PATINO VILCHIS et al., 2010). Dans un tel cas, l'approche basée sur la validation croisée impliquerait de ré-optimiser continuellement l'intégralité des hyper-paramètres ce qui s'avère peu pertinent. Afin d'éviter ces coûts computationnels importants et inutiles, les chercheurs du domaine suggèrent d'employer l'apprentissage incrémental. Initiée par les travaux de FAHLMAN et LEBIERE, 1990, cette stratégie d'ajustement dynamique vise à l'optimisation conjointe des paramètres et des hyper-paramètres dans le but de pallier les difficultés induites par leur interdépendance. Cela permet d'adapter et d'enrichir progressivement le modèle au fil de la phase d'apprentissage de sorte qu'il respecte l'évolution du comportement des données sur le long terme. Cette approche se présente ainsi comme une solution ad hoc dans des contextes d'apprentissage en flux continu au sein desquels les ensembles d'entraînement et de validation sont progressivement disponibles (ZUNIGA, François BREMOND et al., 2009; ZUNIGA, François BREMOND et al., 2011). Étant moins coûteuse que les stratégies d'optimisation hyper-paramétrique basées sur des méthodes essai-erreur (G. ZHOU et al., 2012a), elle s'avère également pertinente dans des contextes de bases de données statiques. Tel que mentionné dans l'article SURESH et al., 2008, l'apprentissage incrémental semble ainsi être une solution prometteuse pour faire face aux difficultés induites par le contexte médical (enrichissement progressif des bases de données et problème de reproductibilité inter- et intra-laboratoire).

Cependant, l'ensemble des modèles d'apprentissage automatique n'est pas structurellement adapté à ce type d'ajustement dynamique (PATINO VILCHIS et al., 2010). De ce fait, divers algorithmes spécifiques ont été développés par les chercheurs du domaine. Dans l'optique d'éluder la difficulté combinatoire de l'optimisation hyper-paramétrique des architectures profondes, nous allons exposer les démarches que certaines équipes de recherche ont entrepris pour appliquer cette stratégie aux cas des FFNN et des AE.

Tel que nous venons de l'évoquer, cette stratégie visant à définir dynamiquement le réseau au cours de la phase d'apprentissage a été initiée par les travaux de FAHLMAN et LEBIERE, 1990. Au sein de ce papier, cette équipe de chercheurs a proposé un algorithme nommé *cascade-correlation*. Il vise à accroître itérativement l'architecture d'un FFNN initialement composé d'aucune unité cachée. À chaque étape, un critère d'arrêt basé sur la dynamique de la fonction de coût est évalué. Si ce dernier n'est pas satisfait, une unité cachée est alors ajoutée à l'architecture du réseau dans le but de diminuer le taux d'erreur résiduel. Telle qu'illustrée en figure (I.11), cette dernière est connectée à l'ensemble des unités du modèle de sorte à accroître progressivement la profondeur du réseau. Afin d'éviter les difficultés associées à l'entraînement des architectures profondes, seuls les paramètres de cette nouvelle unité et de celles de sortie sont optimisés, les autres sont quant à eux figés. Compte tenu de ce principe, cette approche permet d'accélérer considérablement les phases d'optimisation paramétrique et hyper-paramétrique. Cependant, elle est susceptible d'engendrer un sur-apprentissage du fait que la redondance de l'information et la pertinence des unités cachées n'y soient pas évaluées.




FIGURE I.11 – Graphe d'un FFNN composé de trois unités cachées qui a été optimisé par le biais de l'algorithme de *cascade-correlation*. Dans ce dernier, les nœuds correspondent aux couches du modèle et les flèches orientées illustrent les matrices de poids.

À cette même période, diverses propositions d'élagage des réseaux (*pruning* en anglais) ont été présentées dans la littérature (Y. LECUN, DENKER et al., 1990; REED, 1993). Sous-tendues par l'hypothèse selon laquelle les performances d'un modèle sur-ajusté peuvent être obtenues par une architecture de plus faible largeur, ces techniques visent à éliminer l'information superflue des réseaux. Pour ce faire, les contributions statistiques de l'ensemble des paramètres sont évaluées au cours la phase d'apprentissage par l'intermédiaire de la fonction de coût ou des diverses valeurs de pré-activations. Les éléments jugés inutiles, paramètres et/ou unités, sont alors supprimés du modèle ce qui induit une diminution du risque de sur-apprentissage ainsi qu'une facilitation des phases d'optimisation paramétrique (HAN et al., 2015).

En combinant ces principes d'ajout et de suppression d'unités, il est possible d'optimiser dynamiquement l'architecture d'un réseau. À titre d'exemple, les auteurs de BAK et al., 2009 ont appliqué cette stratégie à un contexte de suivi d'objet en flux vidéo. En vue de segmenter automatiquement et efficacement un objet présent dans

une image, c'est-à-dire le séparer de son arrière-plan, ces derniers ont ajusté incrémentalement la largeur d'un réseau de neurones composé d'une unique couche cachée. Le modèle qu'ils ont ainsi obtenu s'est avéré robuste aux variations dynamiques d'environnements, d'échelle et de luminosité.

G. ZHOU et al., 2012a ont adapté le fondement de cette stratégie au cas non supervisé des DAE simples. L'algorithme qu'ils proposent vise à ajuster dynamiquement la dimension de la couche cachée de ces réseaux par l'ajout et la fusion d'unités. De manière analogue à la *cascade-correlation*, il convient tout d'abord de définir un critère d'arrêt. Pour ce faire, un sous-ensemble B est constitué à partir des données d'apprentissage mal discriminées, données pour lesquelles la valeur de la fonction de coût est supérieure à un seuil μ . Lorsque le nombre d'éléments présents dans B est plus grand qu'un second seuil τ , il devient nécessaire d'actualiser la topologie du réseau. ΔN neurones sont alors ajoutés à l'architecture dans l'optique de limiter le sous-apprentissage. Les paramètres de ces derniers sont initialisés sur B par application de l'algorithme de descente de gradient. Au cours de cette étape, les connexions entrantes des autres unités cachées sont figées. Afin d'éviter que cette intégration ne génère un sur-apprentissage, $2\Delta M$ neurones sont fusionnés. Les paires de neurones sources de cette redondance d'information sont identifiées par calcul de la matrice de similarité cosinus. Elles sont alors mergées par un principe de pondération moyenne de sorte à obtenir ΔM nouveaux neurones. Enfin, l'algorithme d'apprentissage est appliqué sur le jeu d'entraînement de manière à ajuster conjointement l'ensemble des paramètres du réseau. Ce processus, qui est illustré en figure (I.12), est réitéré jusqu'à ce que la dimension de B soit inférieure à τ .

De par cette évaluation du sous-apprentissage et du sur-apprentissage, cet algorithme peut être perçu comme une forme de régularisation. Le protocole expérimental mené par les auteurs de cette étude a permis de démontrer la pertinence et la robustesse des DAE incrémentaux. Par ailleurs, ils ont également montré qu'il était possible d'empiler ces briques de base dans le but d'obtenir une architecture profonde incrémentale. Les performances ainsi obtenues se sont avérées supérieures à celles de DAE et SAE classiques sur diverses bases de données.

Néanmoins, cette méthode visant à déterminer l'architecture de ces réseaux non supervisés implique l'utilisation de nouveaux hyper-paramètres : μ , τ , ΔN , ΔM ainsi que la dimension initiale de la couche cachée. Bien que leurs influences soient moindres, ces derniers nécessitent tout de même d'être optimisés. Dans leur article additionnel (G. ZHOU et al., 2012b), diverses heuristiques sont alors proposées. Elles ont principalement pour but de définir dynamiquement la valeur de ΔN puis de déduire ΔM par application de l'équation (I.14) où k est une constante. Cependant, ces stratégies ne sont pas optimales dans le sens où une valeur $k < 1$ favorisera la croissance de l'architecture tandis que $k > 1$ encouragera son élagage. Elles augmentent ainsi l'importance de la dimension initiale de la couche cachée. Par ailleurs, elles s'appuient également sur d'autres hyper-paramètres, ce qui rend cette proposition d'optimisation peu pertinente d'un point de vue computationnel.

$$\Delta M = k\Delta N \tag{I.14}$$




FIGURE I.12 – Principe de fonctionnement de la proposition de G. ZHOU et al., 2012a.

Dans ce sens, PRATAMA et al., 2018 ont proposé un algorithme non hyper-paramétrique permettant d'ajuster dynamiquement la dimension de la couche cachée des DAE simples. Il consiste en un apprentissage en ligne sur un flux continu de données. Pour chaque échantillon x , la contribution statistique des différentes unités cachées du réseau est évaluée par l'intermédiaire de l'erreur de reconstruction. Pour rappel, la MSE est une mesure globale qui permet d'évaluer la variance et le biais du modèle (cf. équation (I.9)).

Afin de déterminer s'il y a présence de sous-apprentissage, il convient d'estimer le biais défini en équation (I.15) où E est l'espérance. Pour ce faire, les auteurs de cet article proposent d'évaluer l'inégalité (I.16) dans laquelle μ_{biais}^x et σ_{biais}^x représentent respectivement la valeur moyenne et l'écart type du biais associé à l'échantillon x . $\mu_{\text{biais}}^{\min}$ et $\sigma_{\text{biais}}^{\min}$ sont, quant à elles, les valeurs minimales obtenues sur l'ensemble des échantillons considérés. En ce qui concerne la variable K , sa valeur est calculée par l'équation (I.17). Basée sur la règle des trois sigmas, elle définit un intervalle permettant de réguler l'évolution de l'architecture quand la valeur minimale du biais est particulièrement faible. Lorsque cette inégalité est vérifiée, une unité est ajoutée à la couche cachée dans le but de supprimer l'erreur résiduelle du

réseau. Les valeurs de ses paramètres sont alors affectées par application des équations (I.18) où n est l'index de la nouvelle unité, et (I.19) (contrainte *tied weights*).

$$biais(r, x) = E[r] - E[x] \quad (I.15)$$

$$\mu_{biais}^x + \sigma_{biais}^x \geq \mu_{biais}^{min} + K\sigma_{biais}^{min} \quad (I.16)$$

$$K = 1.3exp(-(\mu_{biais}^{min})^2) + 0.7 \quad (I.17)$$

$$W_{encodeur_n} = -MSE(r, x) \quad (I.18)$$

$$W_{decodeur} = W_{encodeur}^T \quad (I.19)$$

De la même manière, le sur-apprentissage est estimé par l'intermédiaire de la variance qui est définie en équation (I.20). Dans ce cas, c'est l'inégalité (I.21) qui est évaluée, χ étant obtenue par l'équation (I.22). L'utilisation de 2χ permet de pallier l'accroissement temporaire de la variance qui est causée par l'ajout de la nouvelle unité cachée. Lorsque cette inégalité est respectée, il est nécessaire de diminuer le sur-apprentissage en éliminant l'information inutile. L'élément de la couche cachée présentant le plus faible degré d'activation est alors supprimé.

$$var(r) = E[r^2] - E[r]^2 \quad (I.20)$$

$$\mu_{var}^x + \sigma_{var}^x \geq \mu_{var}^{min} + 2\chi\sigma_{var}^{min} \quad (I.21)$$

$$\chi = 1.3exp(-(\mu_{var}^{min})^2) + 0.7 \quad (I.22)$$

Suite à ces deux étapes, l'algorithme de descente de gradient stochastique est appliqué sur l'échantillon x . Le principe de fonctionnement de cette proposition est illustré en figure (I.13).

Au sein de cette méthode non hyper-paramétrique, les phases d'ajout et de suppression de neurones sont indépendantes. De ce fait, elle s'avère robuste à la dimension initiale de la couche cachée. Cependant, l'apprentissage en ligne (stochastique) ne fournit pas une bonne évaluation du gradient (GOODFELLOW et al., 2016). L'application directe de cet algorithme à un contexte de bases de données statiques ne semble donc pas être une solution optimale.




FIGURE I.13 – Principe de fonctionnement de la proposition de PRATAMA et al., 2018

2.3.3 Des taux d'apprentissage aléatoires : ALRAO

La difficulté associée à l'optimisation hyper-paramétrique de l'AE profond concerne également la valeur du taux d'apprentissage. Compte tenu de son influence significative sur l'erreur de généralisation, cette constante s'avère interdépendante des autres hyper-paramètres de l'architecture. Afin de remédier à la grande combinatoire qui est associée à sa calibration, différents axes de solutions ont été envisagés par les chercheurs du domaine.

Nous avons précédemment mentionné les algorithmes à taux d'apprentissage adaptatif dont le but est d'adapter individuellement les lr des paramètres du modèle en tenant compte de l'évolution du gradient. Néanmoins, bien que la gestion dynamique de cet hyper-paramètre permette d'atténuer l'influence de sa valeur initiale, son optimisation demeure indispensable.

De ce fait, des stratégies de recherche opérationnelle ont également été proposées dans la littérature. C'est par exemple le cas de REAL et al., 2017 qui suggèrent de réaliser cette optimisation par une approche basée sur des algorithmes évolutionnaires

(il s'agit de métaheuristiques présentées en partie (3) de l'étude bibliographique) et de GUILLEMOT et al., 2019 qui s'appuient sur de l'optimisation bayésienne. Cependant, malgré le fait qu'elles soient plus optimales qu'une simple recherche par grille, ces stratégies impliquent la construction de bases d'observation et s'avèrent donc coûteuses en ressources. Ce constat a également été fait par les auteurs de BLIER et al., 2018, article dans lequel ils présentent leur proposition intitulée *All Learning Rates At Once* (ALRAO).

ALRAO est une solution alternative qui consiste en une modification des algorithmes d'optimisation classiquement utilisés en apprentissage profond. Tel que nous l'évoquons dans le paragraphe précédent, l'algorithme de descente de gradient s'appuie sur un taux d'apprentissage pour optimiser les différents paramètres du réseau. Cette constante est identique pour l'ensemble des paramètres et demeure statique tout au long de la phase d'entraînement. Les algorithmes à taux d'apprentissage adaptatif s'appuient quant à eux sur un vecteur de lr dont chacune des valeurs est respectivement associée à un paramètre du réseau. Initialisées par le biais d'une unique constante, ces valeurs évoluent de manière individuelle lors de l'apprentissage. Dans le cas d'ALRAO, qui pour rappel est une proposition de modification et non un algorithme d'optimisation à proprement parler, c'est également un vecteur de taux d'apprentissage qui est utilisé. Cependant, ses valeurs sont initialisées individuellement par le biais d'un générateur de nombres pseudo-aléatoires. L'intérêt de cette approche est qu'elle permet de supprimer les difficultés associées à l'optimisation du taux. L'inconvénient est qu'elle introduit deux hyperparamètres : les valeurs maximale et minimale de lr. Les inventeurs d'ALRAO se sont intéressés à l'influence de ces nouvelles variables. Ils ont prouvé expérimentalement que des valeurs cohérentes mais non optimales étaient suffisantes à l'obtention d'une bonne convergence de l'algorithme d'apprentissage. Ils ont également montré que leur proposition, qui s'avère particulièrement peu coûteuse en ressources, permettait d'obtenir des performances quasi équivalentes à celles associées à un taux d'apprentissage optimal.

D'un point de vue théorique, ALRAO est fondé sur le fait que la dimension réelle d'une architecture neuronale ne soit pas nécessairement identique à sa dimension effective. Cela signifie que la quantité d'information transmise par certaines unités cachées peut potentiellement être négligeable. Dans ce sens, des valeurs aberrantes dans le vecteur de taux d'apprentissage mènent simplement à une inactivité des caractéristiques concernées. Lorsqu'elles sont minoritaires, elles génèrent un potentiel sur-apprentissage mais n'affectent pas la dynamique de l'algorithme de descente de gradient. Afin d'assurer la convergence du modèle, il convient tout de même de les limiter. Pour ce faire, ALRAO raisonne avec des lr propres à chaque unité cachée et non à chaque paramètre.

De par son principe, cette stratégie est applicable à de nombreux algorithmes d'apprentissage. Son intérêt computationnel et sa fiabilité ont été prouvés expérimentalement pour le cas de l'algorithme de descente de gradient. En revanche, sa combinaison avec l'*optimiseur* Adam semble générer un fort sur-apprentissage et n'est donc pas conseillée.

2.3.4 Discussion

Afin de réaliser l’optimisation hyper-paramétrique de nos modèles profonds, il nous semble pertinent d’envisager une approche basée sur l’apprentissage incrémental et la procédure ALRAO. Cela nous permettrait de faire face à cette difficulté combinatoire par le biais d’une stratégie quasi autonome. Seuls deux hyper-paramètres seraient alors à définir : les valeurs minimale et maximale du taux d’apprentissage. Une telle approche nous permettrait également d’outrepasser les problèmes de normalisation associés aux tests globaux et ainsi d’enrichir notre modèle à partir de données d’apprentissage supplémentaires (SURESH et al., 2008). En d’autres termes, nous pourrions l’envisager comme une technique d’apprentissage par transfert.

Cependant, les diverses méthodes que nous venons d’énoncer présentent toutes des limites dans notre cas d’étude.

En effet, la proposition de G. ZHOU et al., 2012a qui permet de définir dynamiquement des architectures profondes dans des contextes de bases de données statiques, implique l’optimisation de nombreux d’hyper-paramètres et s’avère sensible aux dimensions initiales des couches cachées.

À l’inverse, l’approche non-paramétrique de PRATAMA et al., 2018, qui se présente comme une solution efficace pour optimiser des DAE simples sur des flux continus de données, n’est pas applicable aux cas des architectures profondes et de l’apprentissage par mini-lot. Nos propos sont appuyés par la récente réédition de leur papier (ASHFAHANI et al., 2020), dans laquelle les adaptations à l’apprentissage profond et à l’apprentissage par transfert sont énoncées à titre de perspectives.

Par ailleurs, dans l’optique de supprimer la problématique de sur-apprentissage rencontrée dans la proposition ALRAO (BLIER et al., 2018), il pourrait être cohérent de l’employer en combinaison avec l’apprentissage incrémental. Cela permettrait de favoriser l’élitage des réseaux (*pruning*) afin d’en supprimer les paramètres inutiles sans en dégrader les performances (Y. LECUN, DENKER et al., 1990; REED, 1993). Cependant, cette approche ne semble pas avoir été envisagée par les chercheurs du domaine.

Bien que les divers concepts théoriques associés à ces propositions soient pertinents, aucune d’entre elles ne se présente comme une solution clé en main pour répondre à notre problématique. Nous faisons donc face à un second verrou scientifique.

3 Optimisation en boucle fermée

Le but de notre CDSS est d’aider le clinicien à déterminer la posologie optimale de médicament à administrer au patient, c’est-à-dire prédire la dose minimale suffisante pour assurer la disparition des symptômes. Une telle optimisation permet d’éviter des surdosages inutiles ce qui a pour conséquences d’améliorer la qualité des soins et par la même occasion, de diminuer les coûts de traitements. Notre problématique se modélise sous la forme d’une optimisation multi-objectif qui consiste à minimiser un score ainsi que l’unique variable dont il dépend : la

dose de médicament. Ce score correspond au taux d'erreur d'un modèle de détection de nouveautés ayant été entraîné sur une base composée de résultats de tests de patients sains. Compte tenu de la nature prédictive des tests globaux, cette métrique est corrélée au phénotype clinique du patient. Étudier l'apport d'une dose de médicament se résume donc à évaluer le score associé à la cinétique résultante de cette administration.

Bien qu'une unique variable soit à optimiser dans ce problème de recherche opérationnelle, sa résolution n'est pas pour autant évidente. En effet, les différentes molécules de médicaments de l'hémostase ont des modèles PK/PD qui leur sont propres et par logique, des principes d'actions différents. L'influence d'une dose, qui est reflétée par le biais des tests globaux, est donc spécifique à chaque médicament. Par ailleurs, le score dépend également de la performance du modèle de détection de nouveautés et de celle du modèle conditionnel utilisé pour simuler cette administration. Par conséquent, la fonction résultante de l'imbrication des deux modèles d'apprentissage automatique envisagés est très certainement non convexe et spécifique à chaque cas d'étude. Afin de simplifier cette optimisation, nous raisonnerons sur un principe de classification uni-classe (*sain*, *sain*) plutôt que sur le taux d'erreur.

3.1 Intérêts des métaheuristiques bio-inspirées

D'après la littérature, il est usuel de répondre à ce type de problèmes par le biais d'algorithmes d'optimisation stochastique. Tels que décrits dans MÜLLER-MERBACH, 1981, ils se présentent comme une alternative aux méthodes exactes lorsque ces dernières ne permettent pas de converger en un temps de calcul raisonnable. Les métaheuristiques sont des méthodes de résolution qui consistent en une amélioration itérative des variables à optimiser afin de déterminer une solution approchée. Les stratégies mises en place pour parcourir l'espace des solutions sont principalement basées sur la randomisation et la recherche locale. De ce fait, elles permettent de répondre efficacement à des problèmes complexes malgré l'absence ou le manque de connaissances de l'espace de recherche *a priori*. Compte tenu du grand nombre de problèmes d'optimisation rencontrés dans le secteur de l'ingénierie, c'est un sujet de recherche particulièrement actif. BINITHA et SIVA SATHYA, 2012 énoncent que de par sa conception et ses capacités d'adaptation, la nature est l'exemple parfait pour l'optimisation. Les chercheurs du domaine ont donc tenté de mimer les diverses stratégies présentes dans la nature en proposant une pluralité de métaheuristiques bio-inspirées. Deux familles d'algorithmes prédominent parmi ces dernières.

La plus connue et plus couramment utilisée est celle des algorithmes évolutionnaires. Le fondement de ces méthodes de résolution repose sur la théorie de la sélection naturelle énoncée par Charles Darwin en 1859. Il s'agit d'algorithmes itératifs employant le principe de recherche par population. Cela signifie que diverses solutions, également appelées individus, sont évaluées successivement par le biais d'une fonction d'évaluation (ou objective). Leur stratégie d'optimisation est basée sur les principes de croisement, de mutations aléatoires et de sélection des

individus. De ce fait, les solutions les plus prometteuses sont recombinaisonnées afin d'en générer de nouvelles tandis que les moins performantes sont ignorées. Cette stratégie est à la base de l'algorithme génétique, méthode d'optimisation combinatoire proposée dans l'ouvrage HOLLAND, 1975 et considérée comme la référence des algorithmes évolutionnaires. Ces derniers sont conseillés dans le cas de problèmes présentant un espace de solutions vaste, complexe et peu connu. Cependant, ils ne s'avèrent pas optimaux dans le cas d'études en temps restreint, ce qui peut être problématique lors d'une interaction clinicien-patient.

La seconde famille regroupe, quant à elle, les algorithmes basés sur l'intelligence distribuée (également connue sous le terme d'intelligence en essaim). Proposée pour la première fois dans KENNEDY et EBERHART, 1995, elle est inspirée de la théorie du comportement social collectif. Ses méthodes emploient le principe de recherche par population dans l'optique de simuler une intelligence collective. Un groupe d'individus simplistes collaborent de manière itérative afin de se déplacer intelligemment dans l'espace des solutions. Au travers de ces interactions se forme une organisation globale complexe semblable à celle des colonies d'insectes. L'optimisation par essaims particulaires (abrégée PSO), dont la stratégie est basée sur la relation grégaire des oiseaux migrateurs, est considérée comme la référence de cette famille d'algorithmes. Son efficacité computationnelle et sa simplicité d'implémentation ont fortement contribué à sa généralisation dans le secteur de l'ingénierie et donc à la conception de nombreuses extensions de ce dernier. Certaines consistent en une optimisation de sa stratégie de recherche, c'est par exemple le cas de l'algorithme de colonie d'abeilles artificielles (KARABOGA, 2005). D'autres, tels que l'algorithme des lucioles (ŁUKASIK et ŽAK, 2009), permettent de répondre à des tâches d'optimisation sous contraintes. Au vu des avantages cités précédemment, nous souhaitons concentrer nos efforts de recherche sur cette famille d'algorithmes.

3.2 Optimisation multi-objectif par essaims particulaires

D'après la littérature et plus particulièrement l'article de COELLO et al., 2003, une extension des PSO nommée *Multiple Objective Particle Swarm Optimization* et abrégée MOPSO, permet de répondre à des tâches d'optimisation multi-objectif similaires à celle rencontrée dans nos travaux. Afin de comprendre son principe de fonctionnement, il est tout d'abord nécessaire d'en expliciter l'algorithme originel : le PSO.

Le PSO est une métaheuristique qui s'appuie sur une recherche par population afin d'estimer un optimum global. Cette population ou essaim est composé d'individus simplistes nommés particules. Chacune d'entre elles se présente sous la forme d'un vecteur de quatre paramètres : 1) une position x^i , qui se traduira dans notre cas d'étude par un couple $\{dose, score\}$ 2) la meilleure position rencontrée lors des itérations précédentes, notée p^i 3) la meilleure position des particules voisines, notée p^g et 4) une vitesse v^i permettant à la particule d'actualiser sa position pour les itérations suivantes. Ce quatrième paramètre est calculé par le biais de l'équation (I.23) dans laquelle k est l'itération considérée, c_1, c_2 sont des constantes représentant les comportements sociaux de l'essaim et r_1, r_2 des nombres aléatoires com-

pris dans l'intervalle $[0, 1]$. La formule permettant d'ajuster la position est décrite en équation (I.24). On constate alors un comportement panurgien des particules qui évoluent en tenant compte du meilleur élément de leur voisinage ainsi qu'un comportement conservateur, leurs performances passées étant prises en considération dans le calcul des positions futures. La stratégie de recherche du PSO est donc basée sur un principe d'intelligence collective induite par des instincts individuels et des interactions inter-voisinage. Ce voisinage peut être de différentes natures : soit géographique, il sera alors dynamique et dépendra des distances entre particules ; soit social, c'est-à-dire statique et défini à l'initialisation. D'un point de vue algorithmique, le PSO est assez simpliste. L'initialisation des positions est réalisée de manière aléatoire. A chaque itération et pour chaque particule, les scores sont calculés par évaluation de la fonction objective et les valeurs de x^i , p^i et p^g sont actualisées en conséquence. Les équations liées aux calculs de vitesse et de position sont alors appliquées en prévision de l'itération suivante. Ces opérations sont répétées jusqu'à ce que le critère de convergence ou d'arrêt soit vérifié.

$$v_{k+1}^i = v_k^i + c_1 r_1 (p_k^i - x_k^i) + c_2 r_2 (p_k^g - x_k^i) \quad (\text{I.23})$$

$$x_{k+1}^i = x_k^i + v_{k+1}^i \quad (\text{I.24})$$

Le PSO peut être appliqué en réponse à des problèmes d'optimisation mono-objectif qu'ils soient continus non linéaires ou discrets. Afin de résoudre un problème d'optimisation multi-objectif, il est possible d'utiliser le MOPSO. Le terme multi-objectif signifie que plusieurs fonctions d'évaluation sont prises en compte lors de l'optimisation. Il s'agit donc d'une extension du PSO permettant de parcourir des espaces de solutions multi-dimensionnels. Dans un tel cas, la position d'une particule x^i est exprimée par un système de coordonnées de dimension n où n correspond au nombre de fonctions objectives considérées. La différence entre cet algorithme et le PSO réside ainsi dans la détermination des meilleures positions p^i et p^g . Pour ce faire, COELLO et al., 2003 propose d'employer l'équilibre de Pareto. L'ouvrage ETNER, 2012 nous informe que ce concept a été proposé par l'économiste Vilfredo Pareto dans son « Manuel d'économie politique » paru en 1909. Une amélioration au sens de Pareto désigne une situation qui impacte positivement le sort d'au moins un individu sans pour autant dégrader celui des autres. L'équilibre est atteint lorsqu'aucune amélioration n'est possible. Appliquée à notre contexte, la meilleure position est alors celle qui améliore les valeurs de l'ensemble des fonctions objectives. Outre ce point, le principe de l'algorithme est inchangé.

3.3 Discussion

Tel que nous venons de l'évoquer, le MOPSO consiste en une extension du PSO employant l'équilibre de Pareto pour répondre à des problèmes d'optimisation multi-objectif. Au vu de sa simplicité, ce principe s'est vu appliquer à d'autres algorithmes d'intelligence en essaim. C'est par exemple le cas pour l'algorithme de colonie d'abeilles artificielles (AKBARI et al., 2012) et pour celui de colonie de fourmis

(ALAYA et al., 2007). Cependant, nous avons choisi de concevoir un système d'aide à l'individualisation de thérapies en boucle fermée en raison de l'absence de bases de données cliniques pour les tests globaux envisagés. De ce fait, nous ne serons pas en mesure d'évaluer la justesse clinique de la dose minimale suffisante estimée par la métaheuristique. Dans la suite de nos travaux, nous ne chercherons donc pas à confronter diverses méthodes d'optimisation multi-objectif mais uniquement à appliquer le MOPSO en réponse à notre problème.

4 Discussion générale

Au sein de cet état de l'art, nous avons concentré nos efforts de recherche sur les deux méthodes qui ont été envisagées pour développer notre proposition de CDSS, à savoir les AE profonds et les algorithmes d'optimisation multi-objectif.

En premier lieu, nous avons alors souhaité mettre en évidence l'applicabilité des AE simples à notre contexte biologique. Par l'étude de leur principe de fonctionnement, nous avons pu souligner leur aptitude à répondre à des tâches de détection de nouveautés. Nous avons également pu constater que par l'intégration d'une nouvelle couche visible à leur extension supervisée, nous pourrions les adapter à des problèmes conditionnels du type $p(y|x, c)$.

Compte tenu de la faible prévalence de certaines pathologies de l'hémostase et de la complexité d'interprétation des tests globaux, il nous a ensuite semblé pertinent d'étudier les AE profonds. Étant en mesure de représenter de manière compacte des fonctions hautement non-linéaires et nécessitant moins de données d'apprentissage que leurs homologues à l'architecture simple, ces derniers se sont présentés comme des candidats prometteurs pour répondre à notre problématique biologique. Néanmoins, nous avons également constaté qu'ils s'accompagnaient d'une double difficulté.

La première d'entre elles, qui concerne la procédure d'optimisation paramétrique, est due aux multiples régions critiques que possèdent les fonctions objectives des architectures profondes. Afin d'y faire face, nous avons détaillé deux techniques d'initialisation basées sur l'apprentissage automatique : le pré-entraînement non supervisé et l'apprentissage par transfert. Cependant, bien qu'elles soient toutes deux envisageables dans le cas de l'AE profond purement non supervisé utilisé aux fins de détection de nouveautés, celui du modèle conditionnel s'avère plus délicat. En effet, l'algorithme de pré-entraînement n'est pas applicable aux problèmes du type $p(y|x, c)$ au sein desquels le critère supervisé est régi par une fonction fortement non-linéaire. Au vu de notre contexte d'application, l'approche basée sur l'apprentissage par transfert semble également peu pertinente. Dans la mesure où la littérature du domaine ne recense aucune méthode d'initialisation de ces modèles, nous faisons face à un premier verrou scientifique.

La seconde difficulté concerne, quant à elle, la procédure d'optimisation hyperparamétrique. Afin de faire face à la grande combinatoire qui résulte de l'interdépendance de ces variables, il semble pertinent d'envisager une stratégie quasi autonome basée sur l'apprentissage incrémental et la procédure ALRAO. L'intérêt de cette dernière serait double : 1) limiter considérablement les coûts computationnels ; 2) enrichir progressivement les modèles en adoptant une stratégie d'appren-

tissage par transfert. Cependant, outre le fait que la combinaison de ces techniques n'ait pas encore été étudiée par les chercheurs du domaine, les deux propositions d'AE incrémentaux que nous avons détaillés présentent des avantages et des inconvénients. Nous faisons donc face à un second verrou scientifique.

Enfin, nous nous sommes intéressés au cas des algorithmes d'optimisation stochastique en nous concentrant sur les métaheuristiques bio-inspirées. De cette étude a résulté un algorithme bien connu du secteur de l'ingénierie : le PSO. Compte tenu de son efficacité computationnelle et de sa simplicité d'implémentation, il en existe de nombreuses extensions dans la littérature. L'une d'elles, basée sur l'équilibre de Pareto et nommée MOPSO, permet de répondre à des problèmes d'optimisation multi-objectif. Du fait de l'absence d'utilisation clinique des tests globaux, nous ne serons pas en mesure d'évaluer la justesse de la dose minimale suffisante estimée par le métaheuristique. Dans la suite de cette thèse, nous ne chercherons donc pas à confronter le MOPSO à d'autres algorithmes d'optimisation par essaim mais uniquement à l'appliquer en réponse à notre problème biologique.



Propositions

Résumé Par ce chapitre, nous avons souhaité apporter des solutions aux difficultés d'optimisation paramétrique et hyper-paramétrique qui ont émergé de l'état de l'art. À cet effet, nous avons spécifié la structure générale du modèle conditionnel profond nécessaire à notre CDSS avant d'en développer une stratégie d'initialisation par apprentissage. À l'instar du pré-entraînement non supervisé, cette dernière a présenté un intérêt pour l'optimisation paramétrique des architectures considérées et exposé un effet de régularisation. Dans l'intention d'ajuster dynamiquement et conjointement les paramètres et les hyper-paramètres d'AE profonds, nous avons ensuite proposé une architecture simple basée sur l'apprentissage incrémental et la procédure de génération aléatoire des taux d'apprentissage (ALRAO). Après en avoir souligné la robustesse et la propriété de régularisation sur une base de données de référence, nous avons envisagé ces modèles quasi autonomes comme des briques de base utiles à la définition d'architectures profondes. Nous avons alors adapté les techniques de pré-entraînement des modèles étudiés en vue de proposer deux stratégies d'optimisation incrémentale : l'une étant non supervisée, l'autre conditionnelle. Au vu de leur principe de fonctionnement, il nous a enfin semblé judicieux de les employer dans une approche d'apprentissage par transfert incrémental, proposition qui s'est avérée pertinente d'un point de vue computationnel.

Le but de nos travaux de recherche est de fournir aux cliniciens un outil capable de les accompagner dans l'analyse des résultats de tests globaux et dans l'élaboration de décisions thérapeutiques. Dans cette intention, nous avons proposé de développer un CDSS en boucle fermée utilisant un modèle d'apprentissage automatique de référence : l'AE profond. La finalité de l'emploi de ce dernier est alors double, à savoir qualifier l'impact d'une injection d'un médicament sur le résultat d'un test patient (tâche conditionnelle) et quantifier le risque d'accident hémorragique ou thrombotique associé (tâche de détection de nouveautés). Pour ce faire, nous devons tout d'abord faire face aux difficultés de l'optimisation paramétrique et hyper-paramétrique qui ont émergé de l'étude bibliographique.

Au sein de ce chapitre, nous présenterons les diverses propositions que nous avons envisagées pour répondre à cette double complexité. À cet effet, nous consacrerons une première section à la spécification de la structure générale de l'AE conditionnel profond. Ayant précédemment levé la non-applicabilité de l'algorithme de pré-entraînement non supervisé à ce type d'architecture, nous en développerons une stratégie d'initialisation par apprentissage au sein d'une seconde sous-section. De manière analogue à l'algorithme de pré-entraînement non supervisé, nous chercherons principalement à mettre à profit la procédure d'optimisation des architectures simples. Lors d'une troisième section, nous tenterons de remédier à la grande combinatoire qui est associée à l'optimisation hyper-paramétrique des AE profonds. Pour cela, nous tirerons tout d'abord parti de l'état de l'art pour concevoir une architecture simple basée sur l'apprentissage incrémental et la procédure de génération aléatoire des taux d'apprentissage (ALRAO). Par la définition d'un algorithme glouton fondé sur l'utilisation de ces briques de base incrémentales, nous proposerons ensuite une stratégie d'optimisation visant à ajuster dynamiquement les paramètres et les hyper-paramètres de ces architectures profondes.

Afin d'assurer la pertinence de ces diverses propositions théoriques, c'est-à-dire vérifier qu'elles partagent les propriétés attendues, nous les évaluerons sur une base de données de référence. Au fil de ce chapitre, nous présenterons alors les divers protocoles expérimentaux établis à cet effet et discuterons de la cohérence des résultats obtenus. Un bilan général sera enfin dressé à titre de conclusion.

5 Spécification de l'AE conditionnel

L'un des objectifs de nos travaux est de développer un modèle capable de qualifier l'impact d'une injection d'un médicament sur le résultat du test global d'un patient. En ce sens, nous faisons face à un problème conditionnel du type $p(y|x, c)$ où c est une dose de médicament, x est le résultat biologique initial du patient et y est celui du test réalisé *a posteriori* de cette administration. Afin d'y répondre, nous proposons d'employer une extension conditionnelle de l'AE ayant pour but d'approximer une fonction complexe $y = f^*(x, c)$ tel que $f : (\mathbb{R}^n, \mathbb{R}) \rightarrow \mathbb{R}^n$ où n est une valeur finie.

5.1 Une architecture simple : le CAE

Au cours de l'étude bibliographique, nous avons montré qu'il était possible de représenter des fonctions du type $y = f^*(x)$ par le biais d'AE parcimonieux simples entraînés de manière semi-supervisée. En raisonnant à l'instar du CVAE (D. KINGMA et al., 2014; SOHN et al., 2015), nous avons alors proposé de développer une variante conditionnelle de ces modèles en intégrant une nouvelle couche visible à leur architecture. Dans cette intention, deux solutions ont été envisagées : l'une vise à utiliser cette nouvelle information lors de la phase de reconstruction non supervisée, c'est-à-dire à considérer la probabilité $p_{\text{encodeur}}(h|x, c)$, tandis que l'autre consiste à orienter la prédiction de la donnée y de manière à ce que la probabilité du lien supervisé soit égale à $p_{\text{supervisé}}(y|h, c)$.

Bien que la première solution permette de faciliter l'optimisation paramétrique du

modèle et soit alors à favoriser dans de nombreux contextes (GOODFELLOW et al., 2016), elle s'avère peu pertinente dans notre cas d'étude. En effet, au vu de la disparité des espaces vectoriels associés aux deux données d'entrée ($x \in \mathbb{R}^n$ tandis que $c \in \mathbb{R}$), cette approche risquerait de limiter l'influence de la variable conditionnelle. Partant de ce constat, nous avons alors privilégié la seconde solution que nous avons intitulée auto-encodeur conditionnel (*Conditional AutoEncoder* abrégé CAE). L'architecture qui résulte de cette réflexion est présentée en figure (II.1).




FIGURE II.1 – Ce graphe représente l'architecture du CAE, modèle d'apprentissage automatique semi-supervisé qui possède deux couches de sortie. L'une est associée à la reconstruction de x . Elle permet de répondre à une tâche non supervisée $p_{\text{décodeur}}(x|h)$ telle que $r_x = W_a^T h + b_r$. L'autre permet de répondre au critère supervisé conditionnel $p_{\text{supervisé}}(y|h, c)$ tel que $y = W_b h + W_c c + b_y$. En ce qui concerne la couche cachée, son degré d'activation est obtenu par $h = f(W_a x + b_h)$ où f est la fonction d'activation sigmoïde. Dans ces formules, b_r , b_y et b_h sont les vecteurs de biais de ces différentes couches.

Dans la mesure où le couple de données $\{x, y\}$ est défini sur $(\mathbb{R}^n, \mathbb{R}^n)$, des fonctions d'activation linéaires sont utilisées pour les deux couches de sortie du modèle. En ce qui concerne les unités cachées, la fonction ReLU qui est classiquement recommandée dans le cas des FFNN s'avère incompatible avec le principe de fonctionnement des AE (GLOROT, BORDES et Yoshua BENGIO, 2011). La fonction d'activation sigmoïde est alors employée.

Au sujet de la phase d'apprentissage du CAE, elle a pour but de minimiser la fonction de coût hybride qui est définie en équation (II.1). Au sein de cette dernière, $J_{\text{reconstruction}}(\theta)$ évalue la tâche non supervisée (cf. équation (II.2)), $J_{\text{supervisé}}(\theta)$ quantifie l'erreur associée au critère supervisé conditionnel (cf. équation (II.3) où $\hat{y}$ correspond à la prédiction de y) et $\Omega(h)$ est à la pénalité de parcimonie (cf. équation (II.4)). La valeur λ présente dans ce terme de régularisation est une constante qui nécessite d'être traitée comme un hyper-paramètre.

$$J(\theta) = J_{\text{reconstruction}}(\theta) + J_{\text{supervisé}}(\theta) + \Omega(h) \quad (\text{II.1})$$

$$J_{\text{reconstruction}}(\theta) = \text{MSE}(r, x) \quad (\text{II.2})$$

$$J_{supervisé}(\theta) = MSE(\hat{y}, y) \quad (II.3)$$

$$\Omega(h) = \lambda \sum_i |h(i)| \quad (II.4)$$

5.2 Une architecture profonde : le DCAE

Tel que défini en introduction, l'objectif de notre proposition de CDSS est d'aider les cliniciens non experts du domaine à interpréter des résultats de tests globaux afin de les assister dans le processus d'individualisation de thérapies. Pour ce faire, nous avons envisagé de pallier la complexité de l'interprétation de ces tests biologiques en utilisant des architectures profondes.

Dans le cas du problème conditionnel $p(y|x, c)$, x et y sont tous deux des résultats de tests globaux. Il convient donc de représenter de manière compacte les distributions $p(x)$ et $p(y)$ en développant une variante profonde de notre proposition de CAE. Lors de l'étude bibliographique, nous avons montré que la non-linéarité qui est associée aux diverses couches cachées d'une architecture profonde lui permettait de représenter efficacement des fonctions complexes. En vue de doter notre modèle de ce pouvoir d'abstraction, nous avons alors proposé de répondre aux tâches non supervisée $p_{décodeur}(x|h)$ et supervisée conditionnelle $p_{supervisé}(y|h, c)$ par des imbrications de fonctions paramétriques. Comme illustré en figure (II.2), les prédicats caractéristiques de $p(x)$ sont extraits par le biais d'un encodeur et d'un décodeur profonds. La réponse au critère supervisé conditionnel consiste, quant à elle, en une juxtaposition de couches cachées formant une architecture similaire à celle d'un décodeur profond. Au vu de ces modifications, nous avons nommé ce modèle auto-encodeur conditionnel profond (*Deep Conditional AutoEncoder* abrégé DCAE).

Du fait que son contexte d'application soit identique à celui du CAE, les fonctions d'activation sont inchangées : les unités cachées et de sortie sont respectivement sigmoïdes et linéaires.




FIGURE II.2 – Graphe de l'architecture du DCAE au sein duquel h_x, h_y correspondent aux représentations compactes des données x et y et où r_x est la reconstruction de x .

Tel nous l'avons mentionné dans l'étude bibliographique (I.10), le pré-entraînement non supervisé est une solution pertinente pour remédier aux difficultés de l'optimisation paramétrique des AE profonds. Lors de ce procédé glouton, les fonctions paramétriques associées à l'extraction de caractéristiques de la distribution des données d'entrée $p(x)$ sont initialisées de manière itérative. Cette approche permet ainsi de tirer profit de la procédure d'optimisation des AE simples.

Lorsqu'un critère supervisé du type $p(y|x)$ doit être respecté (où y est une variable catégorielle ou continue définie dans $\mathbb{R}$), il convient de le considérer *a posteriori* de la phase d'initialisation. Les paramètres associés à la couche de sortie y sont alors optimisés au cours de la phase d'ajustement conjoint (*finetuning*) qui consiste en une application de l'algorithme d'apprentissage sur l'ensemble du réseau.

Dans le cas du DCAE, il convient de respecter un critère supervisé conditionnel du type $p(y|x, c)$ avec $\{x, c\} \in \{\mathbb{R}^n, \mathbb{R}\}$ et $y \in \mathbb{R}^n$. En appliquant l'algorithme de pré-entraînement non supervisé, nous pourrions alors initialiser les paramètres associés à l'extraction de prédicats caractéristiques de $p(x)$, c'est-à-dire ceux liés à $p_{\text{encodeur}}(h_x|x)$ et $p_{\text{décodeur}}(x|h_x)$. Les paramètres du critère supervisé conditionnel $p_{\text{supervisé}}(y|h_x, c)$ seraient quant à eux considérés *a posteriori* de la phase d'initialisation.

Bien que cette approche soit fonctionnelle dans le cas de l'AE profond semi-supervisé, la fonction de coût $J_{\text{supervisé}}(\theta)$ étant associée à une architecture simple, elle risque de mener à une mauvaise convergence de l'algorithme d'apprentissage dans le cas du DCAE. En effet, du fait que la réponse au critère supervisé conditionnel soit réalisée par une juxtaposition de couches cachées, la fonction de coût $J_{\text{supervisé}}(\theta)$ de ce modèle est susceptible de posséder de nombreuses régions critiques. Par conséquent, l'algorithme de pré-entraînement non supervisé ne semble pas être une stratégie d'initialisation pertinente dans le cas du DCAE.

Dans la mesure où la littérature ne recense aucune méthode d'initialisation par apprentissage pour ce type d'architecture, nous faisons face à un verrou scientifique. Afin d'y répondre, nous consacrerons la section suivante à l'élaboration d'un algorithme de pré-entraînement conditionnel.

6 Proposition d'un algorithme de pré-entraînement conditionnel

Au sein de cette section, nous présenterons l'algorithme de pré-entraînement conditionnel que nous proposons pour remédier à la complexité de l'optimisation paramétrique des DCAE. Par la décomposition de la structure générale de ce modèle en trois sous-architectures, nous chercherons tout d'abord à mettre en évidence le principe de fonctionnement de cette stratégie d'initialisation par apprentissage. Il conviendra alors d'explicitier les étapes qui constituent cet algorithme glouton, à savoir l'initialisation parallèle de deux AE profonds et l'optimisation paramétrique d'un CAE. En vue d'assurer le bon fonctionnement de cette proposition, c'est-à-dire vérifier qu'elle facilite l'optimisation du DCAE et qu'elle présente un effet de régularisation similaire au pré-entraînement non supervisé, nous avons souhaité l'évaluer sur une base de données de référence. Nous détaillerons alors le protocole

expérimental que nous avons défini à cet effet avant de discuter de la cohérence des résultats obtenus.

6.1 Principe de fonctionnement

Dans l'intention de tirer profit de la procédure d'optimisation des AE simples, nous avons scindé l'architecture du DCAE en diverses briques de base. Comme l'illustre la figure (II.3), trois architectures indépendantes ont résulté de cette décomposition. Deux d'entre elles sont respectivement associées aux distributions des données d'entrée $p(x)$ et de sortie $p(y)$ tandis que la troisième correspond au lien conditionnel supervisé $p(h_y|h_x, c)$ où h_x et h_y sont les représentations compactes de x et y .




FIGURE II.3 – Décomposition du DCAE en trois sous-architectures.

Tel que l'illustre la figure (II.4), nous proposons alors de réaliser l'initialisation du DCAE en adoptant une stratégie gloutonne composée de deux étapes. En premier lieu, nous traiterons les fonctions paramétriques associées à l'extraction des caractéristiques des distributions de données $p(x)$ et $p(y)$, en les considérant comme deux AE profonds. Tel que nous l'avons précédemment souligné, il est possible d'initialiser ces réseaux par apprentissage en appliquant l'algorithme de pré-entraînement non supervisé. Étant indépendants, ces deux modèles peuvent être traités en parallèle (étape 1 : pré-entraînements parallèles). À l'issue de cette première étape, nous sommes en mesure d'extraire les probabilités des couches cachées h_y et h_{x1} par inférence. L'initialisation des paramètres associés au lien conditionnel supervisé est alors réalisée par le biais d'un CAE entraîné à répondre au problème $p(h_y|h_{x1}, c)$ (étape 2 : lien conditionnel supervisé). Ces deux étapes successives permettent d'initialiser l'intégralité des couches cachées du DCAE. Il convient alors d'exporter les diverses matrices de poids au sein de l'architecture profonde en vue d'ajuster conjointement l'ensemble des paramètres du réseau (étape 3 : recopie des paramètres).




FIGURE II.4 – Illustration du principe de fonctionnement de notre proposition de pré-entraînement conditionnel.

6.1.1 Pré-entraînements parallèles

En premier lieu, nous proposons de considérer les distributions des données d'entrée et de sortie. Ces dernières étant indépendantes, nous pourrions les traiter en parallèle. En ce qui concerne $p(x)$, nous avons pour objectif d'initialiser les paramètres associés à $p_{encodeur}(h_x|x)$ et $p_{décodeur}(x|h_x)$. Pour ce faire, nous avons précédemment montré qu'il était possible d'appliquer l'algorithme de pré-entraînement non supervisé. Dans le cas de $p(y)$, ce sont les paramètres associés à

$p_{\text{décodeur}}(y|h_y)$ que nous cherchons à initialiser de manière cohérente. À cet effet, nous envisageons de définir un AE profond de même dimension, ayant pour but d'extraire la représentation h_y de la donnée y . En raisonnant par analogie, le pré-entraînement non supervisé de ce modèle s'avère suffisant à l'obtention des valeurs recherchées.

Tel que l'illustre la figure (II.5), cette approche nous permet d'initialiser les deux sous-architectures associées à $p(x)$ et $p(y)$. Par inférence, nous pouvons alors déduire les distributions $p_{\text{encodeur}}(h_x|x)$ et $p_{\text{encodeur}}(h_y|y)$.

Étape 1 : Pré-entraînements parallèles




FIGURE II.5 – Illustration de l'étape de pré-entraînements parallèles.

6.1.2 Lien conditionnel supervisé

À la suite de cette première étape, il convient de considérer les paramètres associés au lien conditionnel supervisé. Au vu de la place centrale que ces derniers occupent dans l'architecture du DCAE, il n'est pas concevable de les initialiser de manière aléatoire. Cela générerait une rupture dans la chaîne de descente de gradient, ce qui aurait pour effet d'annuler l'initialisation des paramètres associés à $p_{\text{décodeur}}(y|h_y)$. Il est donc primordial de prendre en compte ces paramètres dans la phase de pré-entraînement.

Pour ce faire, nous pouvons considérer un CAE dont le but est de répondre au problème $p(h_y|h_{xn-1}, c)$ où h_{xn-1} est la couche antérieure à h_x . À l'issue de l'étape de pré-entraînements parallèles, nous avons connaissance des distributions des couches cachées h_{xn-1} , h_y ainsi que des paramètres associés à la reconstruction de

$h_{x_{n-1}}$. Il convient alors d'initialiser aléatoirement les autres paramètres de cette architecture simple avant d'appliquer l'algorithme de descente de gradient. La représentation compacte h_x est alors ajustée au cours de la phase d'apprentissage de manière à acquérir des propriétés supplémentaires nécessaires au respect du critère conditionnel supervisé.

6.1.3 Ajustement conjoint des paramètres

Le rôle des deux précédentes étapes étant uniquement d'encoder l'information utile dans la distribution des paramètres initiaux, il convient alors de poursuivre l'entraînement du modèle en appliquant l'algorithme d'apprentissage. Lors de cette phase, les paramètres des trois sous-architectures précédemment considérées seront ajustés de manière conjointe.

La fonction de coût du DCAE est présentée en équation (II.1). Néanmoins, compte tenu des propriétés de la stratégie de pré-entraînement non supervisé, il est envisageable d'annuler le terme de régularisation $\Omega(h)$ présent dans cette dernière. En effet, l'étude ERHAN et al., 2010 présente cette technique d'initialisation comme une forme de régularisation à part entière. Comme indiqué dans GOODFELLOW et al., 2016; RIFAI et al., 2011, la prise en compte de pénalités de parcimonie lors de la phase de pré-entraînement s'avère être une condition suffisante à l'obtention d'un modèle profond régularisé. Dans l'optique d'omettre ce terme $\Omega(h)$, nous devons nous assurer que notre proposition de pré-entraînement conditionnel dispose de ces mêmes propriétés.

Par ailleurs, tel que nous l'avons souligné en section (2.2.3) de l'étude bibliographique, la stratégie de pré-entraînement non supervisé s'avère également être une solution pertinente pour réaliser de l'adaptation de domaine. Cette technique d'apprentissage par transfert permet de diminuer considérablement l'erreur de généralisation d'un modèle lorsque les volumes de données d'apprentissage sont très inégaux et que leurs distributions sont sensiblement similaires. Dans cette optique, il conviendra d'ajuster dans un contexte cible, les paramètres d'un DCAE ayant été pré-entraîné dans un contexte source.

6.2 Évaluation sur une base de données de référence

Afin d'assurer le bon fonctionnement de notre proposition, c'est-à-dire vérifier qu'elle facilite l'optimisation du DCAE et qu'elle présente un effet de régularisation similaire au pré-entraînement non supervisé, nous avons souhaité l'appliquer sur une base de données de référence nommée MNIST (LECUN et al., 1998). Composée de plusieurs dizaines de milliers de chiffres manuscrits étiquetés, elle est parfois qualifiée de « drosophile de l'apprentissage automatique » (GOODFELLOW et al., 2016). De ce fait, elle s'avère être une base de données idéale pour évaluer notre stratégie de pré-entraînement conditionnel.

En ce qui concerne ses individus, ils sont représentés par des couples de données $\{x, y\}$ au sein desquels x est une image composée de 28×28 pixels (définie en niveaux de gris) et y est une variable catégorielle ($\{y \leq 9 | y \in \mathbb{N}\}$).

6.2.1 Modélisation du problème

Ayant pour objectif d'évaluer notre proposition, il convient de définir un problème conditionnel du type $p(y|x, c)$ à partir des données présentes dans MNIST. Pour ce faire, nous pouvons considérer une tâche de reconstruction d'images détériorées (*inpainting* en anglais). Tel qu'illustré en figure (II.6), l'image est alors divisée en quadrants. K d'entre eux sont utilisés en entrée du modèle et $(4 - K)$ en sortie. La valeur de K , qui est comprise dans l'intervalle $\{1 \leq K \leq 3 | K \in \mathbb{N}\}$, régit la complexité du problème. Plus K est grand, plus l'image est détériorée et donc difficile à reconstruire. En ce qui concerne la variable catégorielle, elle est quant à elle utilisée à titre de condition. Son rôle est d'orienter la reconstruction de manière à minimiser les risques de confusion entre chiffres. À titre d'exemple, les quadrants $\{1, 2\}$ du chiffre 3 (cf. figure (II.6)) sont logiquement similaires à ceux des chiffres 1, 2 et 7. En ce sens, l'utilisation d'une condition permet de faciliter l'optimisation du lien supervisé. Afin d'estimer la performance du modèle, nous devons vérifier que les pixels reconstruits sont en cohérence avec le chiffre et le style d'écriture associés au(x) quadrant(s) injecté(s) en entrée. Pour ce faire, nous utiliserons l'erreur de reconstruction.




FIGURE II.6 – Division de la base de données MNIST en quadrants. Dans cet exemple, le DCAE est entraîné à prédire les quadrants $\{2, 3, 4\}$ (donnée de sortie) à partir du quadrant $\{1\}$ (donnée d'entrée x) et de l'étiquette (donnée d'entrée c).

6.2.2 Configurations

L'implémentation des divers concepts théoriques associés à notre proposition de pré-entraînement conditionnel a été réalisée par l'intermédiaire de la librairie Tensorflow. Très largement utilisée par la communauté scientifique de l'apprentissage automatique, il s'agit d'une librairie de calculs numériques *open source*. Elle permet de définir des architectures profondes par la construction de graphes au sein desquels les nœuds sont représentés par des objets mathématiques nommés tenseurs. Définis à partir d'espaces vectoriels, ces derniers sont utilisés pour représenter différents ensembles de valeurs telles que les unités cachées ou les paramètres des modèles. L'intérêt de cette librairie est double, à savoir : 1) elle offre la possibilité de définir efficacement nos propres topologies de réseaux, ce qui s'avère indispensable au vu de notre proposition ; 2) elle optimise les phases d'apprentis-

sage et d'inférence des modèles développés. Par ailleurs, cette librairie est également adaptée aux calculs distribués. Le code développé peut alors être exécuté sur différentes grappes de machines (CPU(s) ou GPU(s)) (GÉRON, 2017).

Pour l'ensemble des validations expérimentales présentées dans ce manuscrit, nous utiliserons la configuration matérielle suivante :

- Mémoire : 15 GiB
- Processeur : Intel®Core™I7-6700 CPU@3.40 GHz x8
- Python : 2.7.12
- Tensorflow : 1.8.0
- Numpy : 1.16.6

6.2.3 Expérimentation

Par cette expérimentation, nous avons souhaité vérifier le bon fonctionnement de notre proposition, c'est-à-dire s'assurer qu'elle facilite l'optimisation paramétrique et qu'elle présente un effet de régularisation. Dans cette intention, nous avons adopté un protocole expérimental similaire à celui de l'étude ERHAN et al., 2010. Quatre DCAE ont alors été optimisés en réponse au problème précédemment modélisé au sein duquel nous avons envisagé le cas le plus complexe (le nombre de quadrants a été défini à $K = 1$). Concernant l'architecture de ces modèles, diverses profondeurs ont été envisagées (cf. table (II.1)). De manière à limiter les difficultés combinatoires associées à la procédure d'optimisation hyper-paramétrique, la largeur de l'ensemble des couches cachées a été définie à L unités (L ayant été considérée comme un hyper-paramètre).

	Sous-architecture associée à :		
	$p(x)$	$p(h_y h_x, c)$	$p(y)$
n° 1	$x \rightarrow h_{x1} \rightarrow h_x \rightarrow \hat{h}_{x1} \rightarrow r_x$	$(h_x, c) \rightarrow h_y$	$h_y \rightarrow h_{y1} \rightarrow y$
n° 2	$x \rightarrow h_{x1} \rightarrow h_x \rightarrow \hat{h}_{x1} \rightarrow r_x$	$(h_x, c) \rightarrow h_y$	$h_y \rightarrow h_{y1} \rightarrow h_{y2} \rightarrow y$
n° 3	$x \rightarrow h_{x1} \rightarrow h_x \rightarrow \hat{h}_{x1} \rightarrow r_x$	$(h_x, c) \rightarrow h_y$	$h_y \rightarrow h_{y1} \rightarrow h_{y2} \rightarrow h_{y3} \rightarrow y$
n° 4	$x \rightarrow h_{x1} \rightarrow h_x \rightarrow \hat{h}_{x1} \rightarrow r_x$	$(h_x, c) \rightarrow h_y$	$h_y \rightarrow h_{y1} \rightarrow h_{y2} \rightarrow h_{y3} \rightarrow h_{y4} \rightarrow y$

TABLE II.1 – Description des 4 architectures utilisées lors de l'expérimentation

En vue d'optimiser cette valeur ainsi que celles des autres hyper-paramètres du modèle (pénalité de parcimonie et taux d'apprentissage), nous avons tout d'abord réalisé une recherche par grille¹. Pour ce faire, l'ensemble des réseaux considérés a été initialisé par le biais des trois méthodes suivantes :

- initialisation aléatoire en utilisant l'heuristique proposée par GLOROT et Yoshua BENGIO, 2010;

1. Largeur des couches cachées : $L \in \{400, 800, 1200\}$, taux d'apprentissage utilisé lors du pré-entraînement : $lr_{pretrain} \in \{1e^{-2}, 1e^{-3}, 1e^{-4}\}$, taux d'apprentissage dédié à l'ajustement conjoint des paramètres : $lr \in \{1e^{-2}, 1e^{-3}, 1e^{-4}\}$ et pénalité de parcimonie : $\lambda \in \{1e^{-3}, 1e^{-4}, 1e^{-5}\}$

- pré-entraînement non supervisé² ;
- notre proposition : pré-entraînement conditionnel².

Puis, ils ont été optimisés par application de l'algorithme de descente de gradient par mini-lots (la taille des lots utilisés étant de $2^8 = 256$)². Pour chaque configuration ainsi obtenue, 5 valeurs de graines ont été évaluées. Au vu de notre objectif et du nombre important de données que présente MNIST, nous n'avons pas jugé utile d'employer la validation croisée. Le jeu de validation a alors été obtenu par une séparation de la base d'apprentissage en deux sous-ensembles (ratio 80%/20%). Nous avons néanmoins pris soin d'assurer un équilibre dans la répartition des différentes classes.

Suite à cette étape d'optimisation hyper-paramétrique, nous avons souhaité évaluer l'influence des trois méthodes d'initialisation précédemment énoncées. Afin de montrer l'intérêt que présente notre proposition pour faire face au caractère non-déterministe de l'algorithme d'apprentissage, c'est-à-dire vérifier son effet de régularisation, 50 valeurs de graines ont alors été évaluées. Ayant également pour souhait de vérifier si la prise en compte de pénalités de parcimonie lors de la phase de pré-entraînement conditionnel est une condition suffisante à l'obtention d'un modèle profond régularisé, les deux fonctions objectives (II.5) et (II.6) ont été envisagées pour l'ajustement conjoint des paramètres initialisés par notre proposition. Les résultats obtenus après application de l'algorithme de descente de gradient par mini-lots sont présentés en figure (II.7), (II.8) et (II.9).

$$J(\theta) = J_{reconstruction}(\theta) + J_{supervisé}(\theta) + \Omega(h) \quad (II.5)$$

$$J(\theta) = J_{reconstruction}(\theta) + J_{supervisé}(\theta) \quad (II.6)$$




FIGURE II.7 – Représentation des taux d'erreur associés aux figures (II.8) et (II.9).

2. De manière analogue à ERHAN et al., 2010, 50 *epochs* ont été utilisées pour le pré-entraînement et l'entraînement. Bien que cette approche ne soit pas optimale, elle se présente comme une alternative à la technique d'arrêt précoce. En effet, cette dernière est assimilée à une forme de régularisation et risquerait par conséquent de générer un biais dans l'expérimentation.




FIGURE II.8 – Diagramme en boîte illustrant les taux d’erreur obtenus par les quatre modèles sur le jeu de test. (1) signifie une initialisation aléatoire; (2) un pré-entraînement non supervisé; (3) un pré-entraînement conditionnel suivi d’une optimisation de fonction objective (II.5); (4) un pré-entraînement conditionnel suivi d’une optimisation de fonction objective (II.6)

6.2.4 Discussion

Tel que nous pouvons aisément l’observer en figure (II.8), les moyennes et les écarts types des distributions d’erreur sont plus faibles dans le cas de notre proposition. La véracité de ce propos s’avère par ailleurs être corrélée à la profondeur des architectures. Dans le cas où le DCAE possède de nombreuses couches cachées (cf. architecture 4), nous pouvons constater qu’un entraînement réalisé *a posteriori* d’une initialisation aléatoire s’avère non déterministe et converge vers des régions différentes de la fonction objective à chaque exécution. Outre ces écarts types conséquents, nous pouvons également noter, par le biais de la figure (II.7), que ces régions sont associées à de mauvaises performances. Cette constatation, qui s’avère être en adéquation avec la littérature (cf. sous-section (2.2)), est également valable dans le cas du pré-entraînement non supervisé. Ces résultats sont donc en accord avec les suppositions théoriques énoncées précédemment (sous-section (5.2)) et justifient l’intérêt de notre proposition. En effet, les DCAE initialisés par un pré-entraînement conditionnel convergent vers des régions plus petites qui sont associées à de meilleures performances. Par conséquent, notre méthode d’initialisation

par apprentissage permet de faciliter l'optimisation paramétrique des DCAE profonds.

Par ailleurs cette réduction de la variance du processus d'estimation suggère également une diminution du risque de sur-apprentissage. Cette propriété de régularisation est mise en évidence en figure (II.9). Au travers du graphique b) nous pouvons notamment affirmer que les fonctions objectives (II.5) et (II.6) mènent à des taux d'erreur très similaires³. De ce fait, nous omettrons désormais le terme de parcimonie ($\Omega(h)$) lors de la phase d'ajustement conjoint des paramètres de DCAE initialisés par notre technique de pré-entraînement conditionnel. Par cette approche, nous pourrions nous abstraire d'un hyper-paramètre, ce qui aura pour conséquence de simplifier la procédure d'optimisation hyper-paramétrique du modèle.

En définitive, notre proposition partage les propriétés attendues, à savoir faciliter l'optimisation paramétrique et présenter un effet de régularisation. Elle s'avère donc être une méthode d'initialisation par apprentissage pertinente dans le cas du DCAE. En ce qui concerne cette expérimentation, il est néanmoins possible de critiquer la procédure d'optimisation hyper-paramétrique utilisée. Cette approche simpliste s'est avérée être l'unique solution envisageable pour faire face à la grande combinatoire de cette recherche opérationnelle. Par conséquent, il nous semble pertinent de concevoir une stratégie d'optimisation hyper-paramétrique plus aboutie basée sur l'apprentissage incrémental.




FIGURE II.9 – Le graphique a) représente les taux d'erreur d'apprentissage et de test obtenus par l'architecture n° 4. Les valeurs résultent : (1) d'une initialisation aléatoire; (2) d'un pré-entraînement non supervisé; (3) d'un pré-entraînement conditionnel suivi d'une optimisation de fonction objective (II.5); (4) d'un pré-entraînement conditionnel suivi d'une optimisation de fonction objective (II.6). Le graphique b), consiste quant à lui en un zoom sur les valeurs issues de (3) et (4).

3. Les coefficients de corrélation linéaire calculés sur les taux d'erreur d'apprentissage et de test sont de $R^2 = 0.82$ dans le cas de la fonction objective (II.5) et de $R^2 = 0.84$ dans celui de la fonction (II.6)

7 Proposition d'une stratégie d'optimisation basée sur l'apprentissage incrémental

Pour faire face à la complexité d'interprétation des résultats de tests globaux et à la faible prévalence de certaines maladies de l'hémostase, nous avons proposé de développer notre CDSS en utilisant des techniques d'apprentissage profond. Nous devons donc être en mesure de remédier à la grande combinatoire qui est associée à l'optimisation hyper-paramétrique des AE profonds et des DCAE.

Comme présenté lors de l'étude bibliographique, les chercheurs du domaine suggèrent de réaliser cette tâche de recherche opérationnelle en ajustant conjointement et dynamiquement les paramètres et les hyper-paramètres des réseaux. Dans cette intention, nous avons développé une stratégie d'optimisation quasi autonome basée sur l'apprentissage incrémental et la procédure ALRAO. En vue d'en expliciter le principe de fonctionnement, nous considérerons tout d'abord le cas de l'AE incrémental simple. À cet effet, nous détaillerons les diverses étapes de sa procédure d'optimisation avant de l'exposer comme une brique de base utile à la définition d'architectures profondes. Il conviendra alors de présenter l'algorithme glouton que nous avons envisagé pour optimiser les deux modèles qui composent notre CDSS et de souligner son intérêt pour l'apprentissage par transfert. Par ailleurs, dans l'optique d'assurer la pertinence de ces propositions théoriques, nous avons souhaité les valider sur la base de données MNIST. Nous présenterons alors les protocoles expérimentaux que nous avons établis à cet effet et discuterons de la cohérence des résultats obtenus.

7.1 Une brique de base : l'AE incrémental

Tel que nous l'avons précédemment souligné, les deux AE incrémentaux qui ont émergé de notre recherche dans la littérature présentent des avantages et des inconvénients. Le premier est en phase avec notre cas d'application, mais s'avère complexe à optimiser (G. ZHOU et al., 2012a), tandis que le second est non-paramétrique, mais spécifique à l'apprentissage en flux continu (PRATAMA et al., 2018). Par conséquent, nous avons souhaité développer notre propre modèle en tirant profit de leurs intérêts ainsi que de la procédure de génération aléatoire des taux d'apprentissage (ALRAO). Notre proposition sera détaillée dans la suite de cette sous-section.

7.1.1 Principe de fonctionnement

Le principe de fonctionnement macroscopique de notre proposition est illustré en figure (II.10). En premier lieu, il convient de considérer la topologie initiale du réseau. Bien qu'il soit possible d'en diminuer l'importance en utilisant des techniques d'élagage, il s'agit d'un point de départ indispensable à toute procédure d'optimisation. Par conséquent, nous devons élaborer une stratégie d'initialisation des hyper-paramètres. D'autre part, au vu de notre contexte d'application, la procédure d'optimisation de ce modèle incrémental devra être adaptée à l'apprentissage de bases de données statiques. À l'instar de la proposition de G. ZHOU et al., 2012a, nous devons donc définir un critère d'arrêt ainsi qu'une méthode de sélection des échan-

tillons d'apprentissage mal discriminés. Ayant pour souhait de développer un modèle quasi autonome, nous tâcherons d'y parvenir en adoptant une approche non-paramétrique. Par ailleurs, dans l'intention d'ajuster dynamiquement les hyper-paramètres de ce dernier, nous devons être en mesure d'évaluer la présence de sous-apprentissage et de sur-apprentissage. Pour ce faire, nous proposons d'estimer la contribution statistique des diverses unités cachées en procédant de manière analogue à PRATAMA et al., 2018, c'est-à-dire par une mesure de la variance et du biais. Nous devons néanmoins repenser leurs stratégies d'ajout et de suppression d'unités pour les adapter à un contexte d'apprentissage par mini-lots et de génération aléatoire des taux. À chaque itération de cet algorithme d'optimisation, il conviendra d'harmoniser l'ensemble des paramètres du réseau. Nous les ajusterons alors conjointement en appliquant l'algorithme de descente de gradient sur le jeu d'apprentissage.

Dans l'intention de fournir une présentation microscopique du principe de fonctionnement de notre proposition, chacune de ces étapes sera explicitée dans la suite de cette sous-section.




FIGURE II.10 – Principe de fonctionnement de notre proposition d'AE incrémental simple.

7.1.2 Initialisation de la topologie

Au même titre que pour les méthodes d'optimisation traditionnelles, l'apprentissage incrémental implique de définir une situation initiale. Dans le cas présent,

il s'agit d'initialiser les hyper-paramètres du modèle que sont la dimension de sa couche cachée et ses taux d'apprentissage. Pour ce faire, deux approches sont envisageables : l'une consiste en une initialisation manuelle faite par l'utilisateur, l'autre repose sur la réutilisation d'un modèle entraîné au préalable.

Dans le premier cas, il est important de noter que la dimension initiale de la couche cachée influencera la vitesse de convergence de l'algorithme. En effet, une faible dimension générera un sous-apprentissage tandis qu'une dimension trop élevée induira un net sur-apprentissage. Afin d'éviter qu'un nombre important d'itérations soit nécessaire à la résolution de ces problèmes d'optimisation, il est envisageable d'utiliser des stratégies d'ajout et de suppression d'unités cachées plus abouties que celles proposées par PRATAMA et al., 2018. Sous-tendus par l'hypothèse selon laquelle les performances d'un modèle sur-ajusté peuvent être obtenues par une architecture de plus faible largeur (Y. LECUN, DENKER et al., 1990), nous favoriserons la définition d'architectures sur-complètes lors de cette phase d'initialisation. Nous devrons par conséquent développer une technique d'élagage capable d'éliminer efficacement l'information superflue des réseaux. En ce qui concerne la définition des taux d'apprentissage, nous utiliserons la procédure de génération aléatoire ALRAO. Il conviendra alors de réaliser une rapide recherche par grille au cours de cette étape d'initialisation pour déterminer l'ordre de grandeur des deux hyper-paramètres que cette méthode intègre (taux d'apprentissage maximal et minimal). Par ailleurs, nous devrons également définir le type de régularisation que nous souhaitons employer. Au sein de leurs travaux, G. ZHOU et al., 2012a et PRATAMA et al., 2018 ont utilisé des DAE. En ce qui nous concerne, nous avons pour objectif d'optimiser dynamiquement des AE profonds ainsi que des DCAE. Par conséquent, nous étudierons l'applicabilité de cette stratégie incrémentale aux cas des DAE, des AE parcimonieux et des AE non régularisés.

Dans le second cas, nous souhaitons poursuivre l'optimisation paramétrique et hyper-paramétrique d'un modèle qui a été entraîné en amont. Par cette approche, nous serons en mesure d'enrichir incrémentalement son réseau pour l'adapter à un contexte similaire, c'est-à-dire réaliser de l'apprentissage par transfert non supervisé ou de l'adaptation de domaine.

Quelle que soit l'approche envisagée, il conviendra de clôturer cette étape d'initialisation en appliquant l'algorithme de descente de gradient sur la totalité de la base d'apprentissage.

7.1.3 Évaluation du critère d'arrêt

En guise de critère d'arrêt, G. ZHOU et al., 2012a proposent de confronter le cardinal de l'ensemble d'échantillons d'apprentissage mal discriminés à un seuil τ . Bien que cette approche soit cohérente, elle implique l'optimisation d'un nouvel hyper-paramètre. Dans un contexte d'apprentissage en flux continu, elle pourrait être perçue comme un critère d'attente. Sa valeur serait alors allouée à la taille des mini-lots utilisés par l'algorithme d'apprentissage. Dans un contexte de base de données statiques, sa valeur est cependant corrélée à la quantité et à la qualité des échantillons d'apprentissage. Il est alors nécessaire de l'optimiser par le biais d'une recherche opérationnelle en utilisant l'erreur de généralisation obtenue *a posteriori* de la phase d'apprentissage. En d'autres termes, l'ajustement de cette valeur im-

plique d'exécuter plusieurs fois ce protocole incrémental.

En ce qui nous concerne, nous souhaitons développer une stratégie d'optimisation quasi autonome dont la finalité est l'obtention de modèles ne présentant ni sur-apprentissage ni sous-apprentissage. Le rôle du critère d'arrêt est donc de stopper l'algorithme une fois cet objectif atteint. Sans ce dernier, l'étape d'ajustement conjoint des paramètres serait alors réitérée en boucle jusqu'à l'apparition d'un sur-apprentissage. L'étape de suppression des unités cachées prendrait alors le relais au risque de dégrader les performances du modèle. Afin d'éviter une telle situation, nous devons donc vérifier l'impact que présente cet élagage sur les performances du modèle. Dans le cas où il s'avèrerait négatif, les unités considérées devront être conservées. Par ailleurs, il sera également nécessaire de stopper l'algorithme avant l'apparition de cette divergence. Pour ce faire, nous proposons d'utiliser le principe d'arrêt précoce (*early stopping*) qui a été défini lors de l'étude bibliographique (PRECHELT, 1996). Nous devons donc estimer l'erreur de généralisation au cours des itérations sur un jeu de validation annexe.

7.1.4 Sélection automatique du sous-ensemble

Concernant la sélection du sous-ensemble de données d'apprentissage mal discriminées (noté B), il convient de tenir compte de la convergence de l'algorithme d'apprentissage. Pour ce faire, nous utiliserons la valeur de la fonction de coût $J(\theta)$. En première intention, nous avons envisagé de réaliser cette tâche par l'intermédiaire d'un algorithme de partitionnement de données nommé k -moyennes (ou *k-means* en anglais). Par cette approche, nous aurions pu séparer les échantillons d'apprentissage en deux sous-ensembles sans avoir recours à une valeur seuil. Cependant, cet algorithme s'avère être fortement sensible à son initialisation (choix des centroïdes).

De ce fait, nous procéderons de manière analogue à G. ZHOU et al., 2012b en utilisant l'espérance de $J(\theta)$ comme valeur seuil. Étant, par définition, fortement sensible aux valeurs extrêmes, cet indicateur se présente comme une solution pertinente pour sélectionner le sous-ensemble B .

7.1.5 Stratégie de réduction du sous-apprentissage

Bien qu'il soit possible de remédier efficacement au sur-apprentissage par le biais de techniques d'élagage, le nombre d'unités cachées nécessaires à la réduction d'un sous-apprentissage s'avère complexe à déterminer. Par conséquent, nous procéderons de manière analogue à PRATAMA et al., 2018 en ajoutant au maximum une unité par itération. La proposition de ces derniers, qui consiste à affecter la valeur opposée du taux d'erreur résiduel aux paramètres de cette nouvelle unité, est néanmoins adaptée à un contexte d'apprentissage en ligne sur un flux continu de données. Outre le fait qu'elle ne soit pas compatible avec un apprentissage par mini-lots, l'application de cette dernière à un contexte de bases de données statiques induirait une forte sensibilité aux valeurs aberrantes. Par conséquent, nous proposons d'optimiser ces paramètres sur le sous-ensemble B en appliquant l'algorithme de descente de gradient (sur une unique *epoch*). Au cours de cette étape, les autres paramètres du modèle seront quant à eux figés.

Ayant pour souhait d'utiliser la procédure ALRAO, le taux d'apprentissage associé à cette nouvelle unité sera initialisé par l'intermédiaire d'un générateur de nombres pseudo-aléatoires.

7.1.6 Stratégie de réduction du sur-apprentissage

Tel qu'énoncé précédemment, il est envisageable d'utiliser des stratégies d'élagage plus abouties que celles avancées par PRATAMA et al., 2018 et G. ZHOU et al., 2012b. Pour rappel, la première permet de supprimer un maximum d'une unité par itération, tandis que la seconde n'est pas en mesure de limiter l'influence de la topologie initiale.

De ce fait, nous proposons d'employer une stratégie non-paramétrique basée sur une méthode de partitionnement de données nommée propagation d'affinité (*Affinity propagation* en anglais). Cet algorithme itératif s'appuie sur un principe de partage de ressemblances, appelées affinités, dans le but de construire un arbre entre les observations jugées semblables (FREY et DUECK, 2007). À l'inverse de l'algorithme des k-moyennes, ce dernier détermine automatiquement le nombre de classes présentes dans l'ensemble d'observation. Appliqué à notre contexte, il permettrait de sélectionner le sous-ensemble d'unités cachées possédant les plus faibles degrés d'activation. Nous aurions alors $1 \leq \Delta M \leq (L - 1)$ où ΔM est le nombre d'unités à supprimer et L la largeur de la couche cachée.

Afin d'éviter une dégradation involontaire des performances du modèle, nous devons estimer l'erreur de généralisation *a priori* et *a posteriori* de la suppression des unités. Cette étape d'élagage sera validée à l'unique condition qu'elle soit bénéfique pour le réseau.

7.1.7 Extension conditionnelle

De par son principe de fonctionnement, notre proposition pourra également être appliquée au cas des CAE. En effet, la probabilité de la couche cachée de ce modèle est égale à $p_{\text{encodeur}}(h|x)$. Elle s'avère donc indépendante de la variable conditionnelle. Par conséquent, nous utiliserons la tâche non supervisée $p_{\text{décodeur}}(x|h)$ pour estimer la présence de sur-apprentissage ou de sous-apprentissage. L'unique différence résidera dans les étapes d'évaluation du critère d'arrêt et de sélection du sous-ensemble B , qui utiliseront quant à elles la fonction de coût hybride présentée en équation (II.1).

7.1.8 Évaluation sur une base de données de référence

Ayant pour souhait de développer un modèle quasi autonome, il nous semble pertinent d'évaluer l'influence des divers hyper-paramètres qu'il possède. À cet effet, nous appliquerons notre proposition à la base de données MNIST. Deux expérimentations seront menées : l'une aura pour objectif d'étudier l'intérêt des pénalités de régularisation, tandis que l'autre permettra d'évaluer la sensibilité de l'AE incrémental à sa topologie initiale.

Configurations Concernant les configurations logicielle et matérielle, elles sont identiques à celles présentées en sous-section (6.2).

Au regard du principe de fonctionnement de Tensorflow, nous avons fait face à deux difficultés lors de l'implémentation de cette proposition. En effet, les méthodes d'optimisation de cette librairie ne sont pas adaptées à l'utilisation de vecteurs de taux d'apprentissage. Par conséquent, nous avons dû développer une spécialisation de la classe *optimizer.Optimizer* afin d'y intégrer la procédure de génération aléatoire de taux d'apprentissage ALRAO. Par ailleurs, la gestion interne des tenseurs n'est pas compatible avec une évolution dynamique de l'architecture des réseaux. Nous avons alors favorisé l'utilisation d'accesseurs et de mutateurs en redéfinissant les graphes Tensorflow à chaque évolution de l'architecture neuronale.

Au sujet de l'algorithme de propagation par affinité, nous nous sommes appuyés sur la librairie de référence : *Scikit-learn*.

Expérience n° 1 : régularisation Dans un premier temps, nous avons souhaité évaluer l'intérêt de la pénalité de parcimonie et de la corruption des données d'entrée, c'est-à-dire étudier si notre proposition d'apprentissage incrémental se présente comme une forme de régularisation à part entière. Pour ce faire, nous avons entraîné de manière incrémentale des DAE, des AE parcimonieux ainsi que des AE non régularisés, à reconstruire les chiffres manuscrits présents dans la base de données MNIST.

En ce qui concerne les DAE, nous avons réalisé une corruption des données d'entrée en y sommant un bruit gaussien $\epsilon \sim \mathcal{N}(0, \sigma^2)$ avec $\sigma \in \{0.1, 0.2, 0.5\}$ (valeurs inspirées des travaux de P. VINCENT et al., 2008). Le terme de régularisation des AE parcimonieux a quant à lui été fixé aux valeurs $\lambda \in \{1e^{-4}, 1e^{-3}, 1e^{-2}\}$ (*Documentation Tensorflow* 2020).

Tel que l'avons précédemment mentionné, nous avons opté pour l'utilisation d'architectures initiales sur-complètes dans notre proposition. De ce fait, nous avons arbitrairement défini la largeur initiale de ces réseaux à 1584 unités, c'est-à-dire au double de la dimension de la donnée d'entrée⁴. Les vecteurs de taux d'apprentissage ont quant à eux été initialisés par la procédure ALRAO⁵. Par ailleurs, afin d'éviter que l'aléatoire ne biaise cette évaluation, des vecteurs de taux identiques ont été utilisés pour initialiser les trois modèles étudiés. Dans cette même intention, cinq relances ont été effectuées. Les erreurs de reconstruction associées à ces optimisations sont présentées en table (II.2) et en figure (II.12).

	DAE			AE parcimonieux			AE non-régularisé
	$\sigma = 0.1$	$\sigma = 0.2$	$\sigma = 0.5$	$\lambda = 1e^{-4}$	$\lambda = 1e^{-3}$	$\lambda = 1e^{-2}$	
Erreur de reconstruction (MSE)	$1.66e^{-3}$ $\pm 5.61e^{-5}$	$6.07e^{-3}$ $\pm 1.96e^{-4}$	$1.02e^{-1}$ $\pm 6.52e^{-3}$	$4.21e^{-2}$ $\pm 1.33e^{-2}$	$4.77e^{-2}$ $\pm 4.00e^{-3}$	$5.40e^{-2}$ $\pm 1.91e^{-3}$	$1.43e^{-4}$ $\pm 1.66e^{-5}$

TABLE II.2 – Valeurs moyennes et écarts types des erreurs de reconstruction obtenues sur le jeu de test par les divers AE incrémentaux considérés.

4. Les images contenues dans MNIST sont composée de 784 pixels

5. Les valeurs minimales et maximales des taux d'apprentissage ont été optimisées par une recherche par grille lors de la phase d'initialisation de la topologie telles que $(lr_{min}, lr_{max}) = \{(5e^{-4}, 1e^{-3}), (1e^{-3}, 5e^{-3}), (5e^{-3}, 1e^{-2})\}$




FIGURE II.11 – Cette figure présente neuf exemples de prédictions obtenues par un AE incrémental non régularisé et un AE incrémental parcimonieux sur le jeu de test.




FIGURE II.12 – Ce graphique représente les taux d'erreur d'apprentissage et de test obtenus par les divers AE incrémentaux considérés.

Discussion Tel que nous pouvons l'observer en table (II.2), les moyennes et les écarts types des taux d'erreur de test s'avèrent être plus faibles dans le cas de l'AE non régularisé. En ce qui concerne la corruption des données d'entrée par un bruit gaussien (DAE), elle présente un effet négatif sur l'optimisation du modèle. Dans le cas de fortes valeurs ($\sigma = 0.5$), nous pouvons également constater que cette altération des performances s'accompagne d'une diminution de l'effet de régularisation (cf. figure (II.12)). Au regard de la figure (II.11), les AE parcimonieux optimisés de manière incrémentale sont également associés à de mauvaises performances. En d'autres termes, l'utilisation de pénalités annexes (σ ou λ) a pour conséquence de rompre l'équilibre entre l'optimisation et la régularisation qui est nécessaire à l'apprentissage des paramètres des modèles (cf. sous-section (2.2.1)). En tenant compte des performances obtenues par l'AE non régularisé, nous pouvons en déduire que

notre proposition d'apprentissage incrémental présente un effet de régularisation. Cette propriété peut notamment être expliquée par les stratégies d'évaluation et de réduction du sur-apprentissage que nous avons adoptées. Par conséquent, des AE non régularisés seront désormais utilisés. Cela aura pour conséquence d'améliorer la convergence de l'apprentissage tout en facilitant la phase d'optimisation hyper-paramétrique (suppression d'un hyper-paramètre).

Expérience n° 2 : topologies initiales À l'issue de cette première expérience, nous avons souhaité évaluer l'influence de la largeur initiale de la couche cachée. Pour ce faire, nous avons optimisé de manière incrémentale des AE non régularisés en envisageant diverses topologies initiales. Au vu de la dimension des images contenues dans MNIST (784 pixels) et du fait que nous ayons opté pour l'utilisation d'architectures initiales sur-complètes, nous avons évalué l'influence des trois largeurs suivantes : 1600, 2400 et 3200 unités cachées. En ce qui concerne la valeur de taux d'apprentissage, nous avons procédé de manière analogue à l'expérimentation précédente en réalisant une recherche par grille lors de la phase d'initialisation. Afin de limiter l'influence de l'aléatoire dans cette évaluation, cinq relances ont été effectuées. Les résultats qui découlent de ce protocole expérimental sont présentés en table (II.3).

Largeur initiale	Largeur finale	Erreur d'apprentissage	Erreur de test	Nombre d' <i>epochs</i>
1600	1139.4 ±116.1	$1.33e^{-4}$ ± $1.10e^{-5}$	$1.34e^{-4}$ ± $1.06e^{-5}$	115.4 ±18.4
2400	1733.0 ±103.5	$1.28e^{-4}$ ± $6.98e^{-6}$	$1.29e^{-4}$ ± $6.67e^{-6}$	107.0 ±12.9
3200	2387.4 ±94.6	$1.32e^{-4}$ ± $1.31e^{-5}$	$1.31e^{-4}$ ± $1.28e^{-5}$	103.8 ±10.6

TABLE II.3 – Cette table représente l'influence de la largeur initiale sur la largeur finale de l'architecture, sur les taux d'erreur (dont les MSE peuvent être imagées par le biais de la figure (II.11)) et sur le temps d'optimisation (*epochs*). Compte tenu des cinq relances, les valeurs y sont exprimées en termes de moyennes et d'écarts types.

Discussion Bien que ces trois modèles aient convergé vers des régions différentes de l'espace fonctionnel (largeur finale), les erreurs de reconstruction qui leur sont associées s'avèrent sensiblement identiques. Le nombre d'*epochs* nécessaires à l'apprentissage incrémental est également similaire pour l'ensemble des configurations considérées. Au vu de ces constatations, notre stratégie d'élagage semble être en mesure de réduire efficacement la présence de sur-apprentissage. L'approche qui consiste à définir des architectures initiales sur-complètes est donc pertinente.

7.1.9 Discussion

Au sein de cette sous-section, nous avons développé un AE simple basé sur l'apprentissage incrémental et la procédure de génération aléatoire des taux d'apprentissage (ALRAO), dont le principe de fonctionnement mésoscopique est présenté

en figure (II.13). Ayant pour souhait de concevoir un modèle quasi autonome, nous avons cherché à évaluer l'influence de ses hyper-paramètres sur la base de données MNIST. Outre le fait que l'approche visant à définir des architectures initiales sur-complètes se soit montrée pertinente, notre proposition d'apprentissage incrémental a présenté un effet de régularisation permettant d'omettre les pénalités d'apprentissage associées aux DAE et aux AE parcimonieux. Au vu de ces résultats et de ceux obtenus lors de l'évaluation de notre proposition de pré-entraînement conditionnel, à savoir utiliser des fonctions objectives non régularisées, il nous semble pertinent d'envisager les AE incrémentaux comme des briques de base utiles à la définition d'architectures profondes.




FIGURE II.13 – Principe de fonctionnement détaillé de notre proposition d'AE incrémental simple.

7.2 Vers un plus haut degré d'abstraction : l'AE incrémental profond

Afin de faire face à la complexité associée à l'optimisation hyper-paramétrique des AE profonds, nous avons envisagé de développer une stratégie quasi autonome basée sur l'apprentissage incrémental et la procédure ALRAO. Dans ce contexte, nous avons précédemment détaillé le principe de fonctionnement de notre proposition d'AE incrémental simple et de son extension conditionnelle. Dans la suite de cette sous-section, nous présenterons la démarche que nous avons entreprise pour adapter notre stratégie au cas des AE profonds. Nous montrerons qu'il est alors envisageable d'utiliser ces briques de base incrémentales pour optimiser les paramètres et les hyper-paramètres des deux architectures profondes qui sont employées dans notre CDSS.

7.2.1 Principe de fonctionnement

Au cours de l'étude bibliographique, nous avons mis en avant le fait que l'algorithme de pré-entraînement non supervisé soit une solution pertinente pour faire face aux fonctions de coût fortement non convexes des AE profonds. En citant l'étude de RIFAI et al., 2011, nous avons également souligné qu'il est moins coûteux d'optimiser indépendamment une série de n AE simples (SAE) que de traiter conjointement les n couches cachées d'un AE profond. En d'autres termes, le pré-entraînement peut également être utilisé pour réduire la combinatoire qui est associée à l'optimisation hyper-paramétrique de ces modèles.

Par conséquent, nous envisageons de définir dynamiquement la topologie d'AE profonds en utilisant un algorithme glouton sensiblement similaire à la méthode de pré-entraînement non supervisé. Pour ce faire, nous considérerons les AE incrémentaux simples comme des briques de base. Le principe de fonctionnement de notre proposition, que nous avons nommée stratégie d'optimisation incrémentale non supervisée, est illustré en figure (II.14).

Topologie initiale Dans l'intention de définir la situation initiale de cette procédure, nous proposons d'optimiser un unique AE incrémental. La topologie initiale de ce modèle simple peut alors être spécifiée par le biais des deux approches précédemment décrites, à savoir par l'utilisateur ou par la réutilisation d'un modèle entraîné au préalable. Suite à cette définition, il convient d'optimiser ce modèle quasi autonome avant d'en estimer l'erreur de généralisation sur un jeu de validation annexe.

Évaluation du critère d'arrêt Ayant pour objectif d'ajuster les paramètres et les hyper-paramètres d'une architecture profonde de manière incrémentale, nous devons définir un critère d'arrêt à notre algorithme. Dans ce contexte, nous proposons d'évaluer la contribution statistique des unités cachées qui ont été optimisées lors de la dernière itération. Les paramètres de l'ensemble des couches sont alors exportés au sein d'une unique architecture puis optimisés conjointement par application de l'algorithme d'apprentissage. L'erreur de généralisation du modèle résultant est ensuite estimée et confrontée aux erreurs des itérations précédentes. Lorsqu'une

diminution du taux d'erreur est constatée, les valeurs de ces paramètres et de ces hyper-paramètres sont sauvegardées. Dans le cas contraire, la contribution de la couche centrale est jugée négative. L'algorithme est alors stoppé et les valeurs précédemment sauvegardées sont restaurées.

Ajout d'une nouvelle couche cachée Pour accroître le degré d'abstraction du modèle, nous proposons de procéder de manière analogue au pré-entraînement classique. À cet effet, la distribution de la couche cachée de la brique précédemment considérée est obtenue par application des fonctions d'encodage. Elle est alors utilisée lors de l'itération suivante pour optimiser un nouvel AE incrémental.




FIGURE II.14 – Principe de fonctionnement de notre proposition d'optimisation incrémentale non supervisée où n représente l'itération considérée.

7.2.2 Application au DCAE

Compte tenu de l'algorithme de pré-entraînement conditionnel que nous avons proposé en section (6), nous sommes en mesure d'adapter cette stratégie d'optimisation au cas des DCAE.

En première intention, nous avons envisagé de suivre le plus fidèlement possible son principe de fonctionnement. Pour ce faire, nous proposons d'optimiser en parallèle les deux AE profonds associés aux distributions $p(x)$ et $p(y)$ en adoptant la stratégie présentée en figure (II.14). Puis, après obtention des représentations compactes par application des fonctions d'encodage, nous aurions optimisé les paramètres et les hyper-paramètres du lien conditionnel supervisé par l'intermédiaire d'un CAE incrémental. L'algorithme de descente de gradient aurait alors été appliqué de manière à ajuster conjointement l'ensemble des matrices de poids qui composent le DCAE ainsi obtenu.

7. Proposition d'une stratégie d'optimisation basée sur l'apprentissage incrémental

Néanmoins, par cette approche, les hyper-paramètres des AE profonds associés aux distributions $p(x)$ et $p(y)$ sont optimisés par le biais de notre proposition incrémentale non supervisée. Par conséquent, la fonction de coût $J(\theta)$ du DCAE n'est pas prise en considération lors de l'évaluation de la contribution statistique de ces diverses couches cachées. Afin d'y remédier, c'est-à-dire de tenir compte de la fonction $y = f * (x, c)$ à approximer lors de cette phase d'optimisation, nous avons envisagé un second protocole. Ce dernier, que nous avons nommé stratégie d'optimisation incrémentale conditionnelle, est illustré en figure (II.15).




FIGURE II.15 – Principe de fonctionnement de notre proposition d'optimisation incrémentale conditionnelle.

Topologie initiale En premier lieu, il convient d'évaluer les performances d'une architecture simple ayant pour objectif de répondre à la tâche conditionnelle supervisée $p(y|x, c)$. Pour ce faire, nous proposons d'entraîner un CAE de manière incrémentale avant d'en estimer l'erreur de généralisation sur un jeu de validation annexe.

Optimisations séquentielles Afin d'assurer la pertinence de cette optimisation hyper-paramétrique, nous souhaitons prendre en considération la fonction de coût du DCAE lors de l'évaluation du critère d'arrêt. À cet effet, nous avons reconsidéré le principe de fonctionnement du pré-entraînement conditionnel en vue de traiter les distributions $p(x)$ et $p(y)$ de manière séquentielle.

Lors de la première étape, nous proposons de définir l'architecture profonde qui est associée à la donnée d'entrée. À chaque itération, un AE incrémental est alors entraîné à reconstruire la représentation compacte de $p(x)$ puis un CAE incrémental

est entraîné à son tour à répondre au problème $p(y|h_x, c)$. Afin d'évaluer la contribution statistique de cette nouvelle couche cachée h_x , l'ensemble des paramètres associés à la reconstruction de $p(x)$ et au lien supervisé est ensuite exporté au sein d'un DCAE. Par application de l'algorithme de descente de gradient, la dynamique de l'erreur de généralisation de ce modèle conditionnel profond est alors estimée sur un jeu de validation annexe. Lorsqu'une amélioration des performances est constatée, le modèle ainsi obtenu est sauvegardé. Dans le cas contraire, il convient d'écarter cette nouvelle couche cachée. La précédente version du DCAE est alors restaurée.

Une seconde étape consiste à réitérer ce protocole pour la distribution $p(y)$. Des CAE incrémentaux sont alors entraînés de manière itérative à répondre au problème $p(h_y|h_x, c)$ jusqu'à ce que le critère d'arrêt soit vérifié, h_y étant la représentation compacte de y .

7.2.3 Intérêt pour l'apprentissage par transfert

Lors de l'étude bibliographique et de la section (6), nous avons souligné qu'il était possible d'utiliser le pré-entraînement non supervisé ou conditionnel pour réaliser de l'apprentissage par transfert. Pour ce faire, nous avons indiqué qu'il convenait de poursuivre dans un contexte cible, l'optimisation paramétrique d'un modèle ayant été pré-entraîné dans un contexte source. Lorsque les volumes de données d'apprentissage sont très inégaux et que les tâches à réaliser sont sensiblement similaires, cette approche permet de réduire considérablement l'erreur de généralisation. Cependant, pour être applicable, cette dernière implique également que les prédicats caractéristiques des distributions sources soient en mesure de discriminer les distributions cibles. Compte tenu des problèmes de standardisation que présentent les protocoles de mesure des tests globaux, il est fort probable que cette condition soit un facteur limitant dans notre cas d'étude.

En effet, le problème de reproductibilité qui est associé à ces tests biologiques risque d'induire une dissimilarité entre les distributions cibles et sources. Il est alors probable que le pré-entraînement ne soit pas une technique pertinente pour réaliser de l'apprentissage par transfert dans notre contexte d'application. Par conséquent, nous proposons d'employer nos stratégies incrémentales (non supervisée et conditionnelle) pour poursuivre, dans des contextes cibles, l'optimisation paramétrique et hyper-paramétrique de modèles ayant été précédemment considérés dans des contextes sources.

Comme l'illustre la figure (II.16) pour le cas de la stratégie d'optimisation incrémentale conditionnelle, nous proposons dans cette intention d'utiliser la distribution de données sources pour ajuster dynamiquement les topologies initiales des architectures simples considérées. En d'autres termes, chaque brique de base sera entraînée incrémentalement dans le contexte source avant d'être considérée dans le contexte cible. En ce qui concerne l'évaluation du critère d'arrêt, seule la distribution de données cibles sera utilisée pour estimer la contribution statistique des unités cachées. Par cette approche, que nous qualifierons d'apprentissage par transfert incrémental, nous serons donc en mesure de tirer profit de larges volumes de données tout en respectant les distributions associées au contexte cible.

7. Proposition d'une stratégie d'optimisation basée sur l'apprentissage incrémental




FIGURE II.16 – Principe de fonctionnement de notre stratégie d'apprentissage par transfert incrémental conditionnel.

7.2.4 Évaluation sur une base de données de référence

Bien que cette proposition d'apprentissage par transfert incrémental soit cohérente d'un point de vue théorique, elle s'avère plus complexe que les méthodes traditionnelles. De ce fait, il nous paraît pertinent d'en évaluer l'intérêt sur la base de données MNIST en considérant le cas du DCAE.

Modélisation du problème Afin de vérifier que par l'utilisation de distributions sources, notre proposition facilite l'optimisation de DCAE sur des bases de données cibles jugées défavorables à l'apprentissage, nous avons souhaité définir une tâche d'adaptation de domaine à partir des données présentes dans MNIST. Pour ce faire, nous avons scindé ces dernières en deux sous-ensembles. Les images associées aux étiquettes y tel que $y \in \{0, 1, 2, 3, 4\}$ ont été attribuées au contexte source. Les autres, c'est-à-dire celles représentant des chiffres supérieurs ou égales à cinq ($y \in \{5, 6, 7, 8, 9\}$), ont été associées au contexte cible.

Dans l'intention d'assurer une hétérogénéité dans la taille des bases d'apprentissage, seul 1% des données cibles a été conservé (soit 267 images). Nous les avons distribuées dans les jeux d'entraînement et de validation (ratio 80%/20%) en prenant soin d'assurer un équilibre dans la répartition des classes. L'intégralité des données de tests a quant à elle été conservée (4861 images).

Ayant pour souhait d'appliquer cette tâche au cas des DCAE, nous avons réutilisé

le problème de reconstruction d'images détériorées défini en sous-section (6.2) au sein duquel, le cas le plus complexe a été envisagé (le nombre de quadrants a été défini à $K = 1$).

Expérimentation Dans l'intention de répondre à ce problème, c'est-à-dire optimiser un DCAE sur le jeu de données cibles, nous avons adopté les trois approches suivantes :

- approche n° 1 : stratégie d'optimisation incrémentale conditionnelle sur les données d'apprentissage cibles;
- approche n° 2 : stratégie d'optimisation incrémentale conditionnelle sur les données d'apprentissage sources suivie d'une application de l'algorithme de descente de gradient sur les données d'apprentissage cibles;
- approche n° 3 : apprentissage par transfert incrémental conditionnel.

En ce qui concerne les largeurs initiales des diverses briques de base internes à ces stratégies d'optimisation, elles ont été définies de manière à être deux fois supérieures à celles de leurs données d'entrées. Les taux d'apprentissage maximal et minimal de ces architectures simples sur-complètes ont, quant à eux, été optimisés par l'intermédiaire d'une recherche par grille⁶ au cours de la phase d'initialisation des topologies. En ce qui concerne l'approche n° 2, un principe d'arrêt précoce a été utilisé pour l'algorithme de descente de gradient. Afin de limiter l'influence de l'aléatoire dans cette évaluation, cinq relances ont été effectuées. Les résultats qui découlent de ce protocole expérimental sont présentés en table (II.4) et en figure (II.17).

Approche	Erreur d'apprentissage	Erreur de test	Temps total d'optimisation
n° 1	$3.70e^{-2}$ $\pm 9.59e^{-4}$	$4.59e^{-2}$ $\pm 8.02e^{-4}$	1142.85 ± 328.05
n° 2	$2.37e^{-2}$ $\pm 2.34e^{-3}$	$3.55e^{-2}$ $\pm 5.76e^{-4}$	11678.96 ± 2671.87
n° 3	$2.39e^{-2}$ $\pm 1.77e^{-3}$	$3.59e^{-2}$ $\pm 5.23e^{-4}$	7845.36 ± 1766.79

TABLE II.4 – Cette table représente les taux d'erreur (dont les MSE peuvent être imagées par le biais de la figure (II.17)) et les temps d'optimisation (exprimés en secondes) qui ont été obtenus par les trois approches envisagées. Compte tenu des cinq relances, les valeurs y sont exprimées en termes de moyennes et d'écarts types.

6. Les valeurs maximale et minimale du taux d'apprentissage ont été optimisées par le biais de la recherche par grille suivante : $(lr_{min}, lr_{max}) = \{(5e^{-4}, 1e^{-3}), (1e^{-3}, 5e^{-3}), (5e^{-3}, 1e^{-2})\}$.




FIGURE II.17 – Cette figure présente neuf exemples de prédictions de données tests cibles qui ont été obtenues par chacune des trois approches précédemment énoncées.

Discussion Tel que nous pouvons le constater par les résultats présentés en table (II.4), les taux d'erreur de test associés aux stratégies d'apprentissage par transfert traditionnel (approche n° 2) et incrémental (approche n° 3) s'avèrent plus faibles que ceux issus d'une optimisation réalisée exclusivement sur les données cibles (approche n° 1). Dans ce contexte expérimental, la poursuite de l'optimisation hyper-paramétrique sur les données d'apprentissage cibles ne présente pas de réels intérêts pour la généralisation des modèles, les erreurs moyennes obtenues par les approches n°s 2 et 3 étant sensiblement identiques. Néanmoins, cette dernière permet d'accélérer le processus d'optimisation d'environ 33%, valeur qui s'avère non négligeable au vu des temps computationnels associés. En définitive, bien que notre proposition d'apprentissage par transfert incrémental soit pertinente, il conviendrait d'en vérifier les propriétés sur un autre cas d'application. Dans le prochain chapitre, nous chercherons donc à l'évaluer dans le contexte des tests globaux.

7.2.5 Discussion

Dans l'intention de remédier à la grande combinatoire qui est associée à l'optimisation hyper-paramétrique des modèles présents dans notre proposition de CDSS, nous avons considéré les AE incrémentaux classiques et conditionnels (CAE) comme des briques de base utiles à la définition d'architectures profondes. En tirant profit du principe de fonctionnement des techniques de pré-entraînement, nous avons alors développé deux stratégies d'optimisation gloutonnes. La première, que nous avons nommée stratégie d'optimisation incrémentale non supervisée, vise à définir dynamiquement les paramètres et les hyper-paramètres d'AE profonds. La seconde, intitulée stratégie d'optimisation incrémentale conditionnelle, applique quant à elle cette recherche opérationnelle au cas des DCAE. Au vu des problèmes de standardisation et de reproductibilité qui sont associés aux tests globaux, nous avons ensuite songé à adapter ces dernières de manière à proposer des techniques de transfert d'apprentissage incrémental. Par le biais d'une validation expérimentale réalisée sur la base de données MNIST, nous avons constaté que la poursuite de l'apprentissage incrémental des DCAE dans des contextes cibles permet d'en

améliorer l'erreur de généralisation et présente un intérêt computationnel face au principe d'apprentissage par transfert traditionnel.

8 Discussion générale

Au sein de ce chapitre, nous avons présenté les diverses stratégies que nous avons développées pour faire face aux difficultés induites par les optimisations paramétriques et hyper-paramétriques des deux modèles profonds qui composent notre proposition de CDSS.

Dans cette intention, nous avons tout d'abord spécifié la structure générale du DCAE, modèle conditionnel profond visant à qualifier l'impact de l'administration d'une dose de médicament sur le résultat du test global d'un patient. Compte tenu de la non-applicabilité de l'algorithme de pré-entraînement non-supervisé à ce dernier, nous avons ensuite cherché à développer une stratégie d'initialisation par apprentissage spécifique au DCAE en mettant à profit la procédure d'optimisation des architectures simples. L'algorithme de pré-entraînement conditionnel qui en a résulté se compose de deux étapes successives, à savoir l'initialisation parallèle d'AE profonds et l'optimisation paramétrique d'un CAE. Par l'intermédiaire d'une validation expérimentale réalisée sur la base de données MNIST, nous avons pu souligner la pertinence de cette proposition face aux complexités de l'optimisation paramétrique des DCAE tout en mettant en évidence sa propriété de régularisation. Nous avons alors statué sur l'omission du terme de parcimonie présent dans la fonction objective de ces modèles.

Dans l'intention de remédier à la grande combinatoire qui est associée à l'optimisation hyper-paramétrique des AE profonds, nous avons ensuite cherché à tirer parti de l'état de l'art pour concevoir une architecture simple basée sur l'apprentissage incrémental et la procédure de génération aléatoire des taux d'apprentissage (AL-RAO). De par les stratégies d'évaluation et de réduction du sur-apprentissage employées, le modèle développé s'est avéré robuste à sa topologie initiale et propice à l'utilisation d'AE sur-complets non régularisés. Au vu de ces résultats, nous avons alors envisagé ces modèles quasi autonomes comme des briques de base utiles à la définition d'architectures profondes. Pour ce faire, nous avons adapté le principe de fonctionnement des techniques de pré-entraînement en vue de proposer deux stratégies d'optimisation gloutonnes : la première, que nous avons nommée stratégie d'optimisation incrémentale non supervisée, permet de définir dynamiquement les paramètres et les hyper-paramètres d'AE profonds tandis que la seconde, intitulée stratégie d'optimisation incrémentale conditionnelle, applique cette technique de recherche opérationnelle au cas des DCAE. Au vu du manque de standardisation des tests globaux, nous avons enfin songé à employer les deux stratégies sus-citées dans un principe d'apprentissage par transfert incrémental. Par une évaluation sur la base de données MNIST, cette proposition a présenté un intérêt computationnel non négligeable face à la méthode traditionnelle.

En définitive, nous avons donc développé diverses stratégies d'optimisation en vue de remédier aux verrous scientifiques qui ont émergé de l'étude bibliographique. Dans le prochain chapitre, il conviendra alors d'en évaluer les apports pour les systèmes d'aide à l'individualisation de thérapies.



Application à la prise en charge personnalisée du patient hémophile

Résumé Ce chapitre présente l'application de nos travaux de recherche à la prise en charge personnalisée du patient hémophile. Après avoir souligné la nécessité d'un test biologique révélateur de l'état de la balance hémostatique, nous avons exposé la pertinence que revêt le test global de génération de thrombine (GT). En vue d'accompagner les professionnels de santé dans l'interprétation des résultats de ce dernier, et par suite, dans la détermination de la posologie minimale suffisante à la disparition du risque d'accident hémorragique, nous avons proposé d'appliquer notre CDSS à ce contexte d'individualisation de thérapies. Compte tenu des forts coûts temporels et économiques que représentent la construction d'une cohorte spécifique et la génération de données cliniques, nous avons développé le modèle conditionnel et le modèle de détection de nouveautés qui composent ce système en tirant profit de données simulées *in silico* et générées *in vitro*. Par l'utilisation des diverses stratégies que nous avons formulées en chapitre (II), nous avons été en mesure de remédier à la double difficulté de l'optimisation paramétrique et hyperparamétrique qui a émergé de l'état de l'art. Par conséquent, nous avons pu mettre en lumière les intérêts que présentent les AE profonds, conditionnels ou non, pour les systèmes d'aide à l'individualisation de thérapies. Par ailleurs, les temps d'optimisation qui ont résulté de l'évaluation de la vitesse de convergence du MOPSO ont permis de statuer sur la cohérence computationnelle de notre proposition de CDSS et sur sa parfaite compatibilité avec une utilisation dans un contexte clinique.

Au sein de ce chapitre, nous présenterons l'application de nos travaux de recherche à la prise en charge personnalisée du patient hémophile, c'est-à-dire à la détermination automatique de la dose de médicament minimale suffisante à la disparition des symptômes délétères chez un patient victime d'une maladie hémorragique. Dans cette intention, nous consacrerons une première section à l'introduc-

tion du contexte biologique. Il conviendra alors de mettre en évidence la spécificité de ce trouble de l'hémostase, de souligner les limites de l'approche d'optimisation thérapeutique actuellement utilisée en clinique et d'exposer le test global de GT comme un candidat prometteur pour la prise en compte des caractéristiques physiologiques et physiopathologiques de chaque patient. Du fait du manque de standardisation des tests globaux et de leur forte sensibilité aux étapes pré-analytiques, nous proposerons ensuite d'employer notre CDSS en vue d'accompagner les professionnels de santé dans l'interprétation des résultats du test de GT. Au sein d'une seconde section, nous définirons alors le rôle de chacun des trois sous-systèmes de notre proposition biologique avant de présenter la pharmacocinétique/pharmacodynamie des divers traitements de l'hémophilie. Compte tenu de l'absence d'utilisation clinique des tests globaux, nous avons envisagé de développer cette proposition en utilisant des données simulées *in silico* et *in vitro*. Ces deux modèles d'étude seront définis dans une troisième section et présentés de manière approfondie en annexes (A) et (B). Au sein des quatrième et cinquième sections, nous traiterons respectivement du modèle conditionnel et du modèle de détection de nouveautés. Par l'application des diverses propositions que nous avons formulées en chapitre (II), nous viserons à remédier aux difficultés de l'optimisation paramétrique et hyper-paramétrique des AE profonds afin de mettre en exergue les intérêts qu'ils présentent pour les systèmes d'aide à l'individualisation de thérapies. Par ailleurs, bien que l'utilisation de données simulées ne nous offre pas la possibilité d'estimer la pertinence clinique de notre proposition de CDSS, nous chercherons à évaluer sa compatibilité avec une utilisation dans un contexte clinique. Une sixième section sera alors dédiée à l'étude de la vitesse de convergence de l'algorithme d'optimisation stochastique utilisé : le MOPSO. Afin de conclure ce chapitre, une dernière section nous permettra de dresser un bilan général sur les apports de nos diverses stratégies d'optimisation et sur la cohérence de notre proposition biologique.

9 Contexte biologique

Telle que définie dans l'introduction de ce manuscrit, la coagulation sanguine est le phénomène biologique qui aboutit à la formation d'un caillot afin de limiter et de stopper une hémorragie causée par une brèche vasculaire. Il s'agit d'un système complexe qui repose sur un judicieux équilibre entre les voies pro-coagulantes, responsables de la formation du caillot sanguin, et les voies anti-coagulantes qui régulent et inhibent sa formation. Un déséquilibre dans cette balance hémostatique peut causer deux types de pathologies : les maladies thrombotiques qui sont dues à une suractivité du processus de coagulation et les maladies hémorragiques qui sont, quant à elles, induites par une sous-activité de ce phénomène biologique. L'hémophilie est une maladie hémorragique rare qui concerne environ 0.01% des hommes (CHELLE, 2017). Elle est causée par une absence ou un déficit d'une protéine de la coagulation du sang (le facteur VIII dans le cas de l'hémophilie A et le facteur IX dans celui de l'hémophilie B). Le principal traitement de cette pathologie consiste en une thérapie de remplacement, c'est-à-dire en des injections régulières de concentrés de facteurs VIII ou IX. Chez certains patients, ces molécules théra-

peutiques sont reconnues comme des substances étrangères par l'organisme. Ils développent alors des anticorps spécifiques aux facteurs concernés, ce qui a pour effet d'inhiber l'activité coagulante de ces traitements substitutifs. Dans le cadre de ces travaux, nous limiterons néanmoins notre étude aux cas des patients hémophiles sans inhibiteurs.

Dans l'intention de traiter ces déficits, il est possible de quantifier les concentrations unitaires des facteurs concernés par l'intermédiaire de tests de laboratoire spécifiques. Cependant, bien que cette approche soit couramment utilisée, elle ne fournit qu'une information limitée sur l'état de la balance hémostatique et ne permet pas d'estimer rigoureusement le risque d'accident hémorragique. Par conséquent, l'individualisation des traitements de l'hémophilie s'appuie actuellement sur des caractéristiques physiologiques telles que la persistance de la douleur ressentie par le patient ou encore la réduction de mobilité articulaire.

Ce type d'évaluation subjective traduit le besoin indéniable d'un test biologique capable de prédire le phénotype clinique du patient et notamment son risque de saignement. Étant à même de fournir une évaluation macroscopique du fonctionnement du système de coagulation, les tests globaux se présentent comme des candidats prometteurs pour répondre à ce besoin (YOUNG et al., 2013). Il est notamment possible d'envisager quatre applications distinctes pour lesquelles les résultats de ces tests permettraient d'aider à la prise de décision dans le domaine de l'hémophilie :

- prédiction du phénotype patient ;
- individualisation de thérapies pour le traitement prophylactique de patients hémophiles sans inhibiteurs ;
- individualisation de thérapies par agents de contournement afin d'éviter un épisode hémorragique au cours d'une intervention chirurgicale ;
- évaluation de l'activité hémostatique des nouveaux traitements contre l'hémophilie actuellement en cours de développement clinique.

Les tests globaux s'avèrent donc être en phase avec notre objectif, à savoir faciliter l'individualisation de thérapies de patients hémophiles A sévères (taux de facteur VIII inférieur à 1%) sans inhibiteurs. Par conséquent, nous utiliserons le test de génération de thrombine (GT) qui a été proposé par MACFARLANE et BIGGS, 1953 puis amélioré par HEMKER et al., 2003. Tels qu'illustrés en figure (III.1), les résultats de ce dernier se présentent sous la forme de thrombinogrammes, des cinétiques donnant l'évolution de la concentration de la thrombine (une enzyme clé de la coagulation) au cours du temps.

À l'instar de nombreux tests globaux, le test de GT manque de standardisation. Au vu de sa forte sensibilité aux étapes pré-analytiques et compte tenu des variabilités intra- et inter-laboratoires, la problématique de la reproductibilité de ses résultats est alors primordiale (LOEFFEN et al., 2012). Par conséquent, le test de GT nécessite d'être standardisé avant de pouvoir être employé à grande échelle en études cliniques (LANCÉ, 2015). De cette absence d'utilisation résulte une méconnaissance de ce type de résultats biologiques (BRINKMAN, 2015). Dans l'optique d'exploiter pleinement ces sources d'information décrites comme révélatrices des phénotypes

patients, les biologistes ont alors cherché à en extraire des caractéristiques discriminantes telles que le potentiel de thrombine endogène, le temps de latence ou encore la hauteur du pic. Toutefois, bien que cette extraction de caractéristiques permette de simplifier les thrombinogrammes, ceux-ci demeurent difficilement interprétables par des médecins non experts du domaine.

Afin de faire face à cette complexité, nous proposons d'accompagner les professionnels de santé dans l'analyse de ces résultats. Dans le cadre d'une étude préliminaire réalisée à titre de preuve de concept (Francois LASSON et al., 2019), nous avons proposé un système d'aide au diagnostic utilisant le test de GT. Bien qu'il n'y ait pas d'intérêt clinique à diagnostiquer l'hémophilie par l'intermédiaire des tests globaux, cette étude avait néanmoins permis de mettre en évidence l'apport des modèles d'apprentissage automatique dans l'interprétation de ces résultats biologiques. Au sein de ce chapitre, nous tenterons alors de répondre à un réel besoin clinique en concentrant nos efforts de recherche sur les systèmes d'aide à l'individualisation de thérapies.




FIGURE III.1 – Illustration de deux thrombinogrammes et représentation graphique des principales caractéristiques biologiques associées. La cinétique bleue correspond au résultat d'un patient sain tandis que celle en orange est issue d'un patient hémophile A sévère.

10 Proposition biologique

Par cette application, nous souhaitons concevoir un modèle capable de déterminer la posologie optimale d'un concentré de facteur VIII à administrer à un patient hémophile A sévère sans inhibiteur. En d'autres termes, nous souhaitons prédire de manière automatique la dose minimale suffisante pour écarter le risque hémorragique chez ce patient. Les enjeux d'une telle optimisation sont doubles, à savoir améliorer la qualité des soins et des résultats thérapeutiques tout en diminuant

les coûts de traitements. Pour ce faire, nous envisageons d'adapter notre CDSS à ce contexte en mettant à profit le caractère prédictif du test global de GT.

Cette proposition se voit confortée par les travaux de thèse de P. Chelle (CHELLE, 2017; CHELLE et al., 2018). Dans l'optique d'obtenir une définition patient-spécifique du taux cible de facteur anti-hémophilique à partir du test global de GT, ce chercheur a étudié les spécificités du système de coagulation des patients hémophiles. Par la surcharge des taux de facteurs déficients de plusieurs patients victimes de ce trouble hémostatique, il a ensuite pu mettre en évidence la linéarité de la relation existante entre la concentration des traitements et trois caractéristiques biologiques des cinétiques de GT. Ayant connaissance des taux basaux de ces derniers, il a alors pu prédire la réponse individuelle des patients aux traitements anti-hémophiliques et par conséquent en optimiser les thérapies.

Bien que ce principe de fonctionnement soit sensiblement similaire à celui de notre proposition biologique, il s'avère néanmoins limité aux caractéristiques discriminantes que les chercheurs du domaine ont identifiées dans les résultats de ces tests globaux. Afin d'exploiter pleinement ces sources d'information décrites comme révélatrices des phénotypes cliniques des patients, nous envisageons d'en extraire des caractéristiques fortement abstraites par le biais d'AE profonds et de DCAE.

10.1 Présentation du CDSS




FIGURE III.2 – Présentation de notre proposition de CDSS appliquée au contexte de l'hémophilie A.

La figure (III.2) présente l'application de notre proposition de CDSS au contexte de l'hémophilie A. Pour rappel, cette dernière consiste en un système d'optimisation en boucle fermée dont la structure peut être divisée en deux parties.

La première d'entre elles, qui correspond à la mise en série d'un modèle conditionnel et d'un modèle de détection de nouveautés, a pour but de qualifier l'impact de l'administration d'une dose de médicament sur le risque d'accident d'un patient. Appliquée à notre cas d'étude, elle vise donc à prédire le risque de saignement résultant d'une injection de facteur VIII. Au vu de la complexité d'interprétation des tests globaux, nous avons proposé de l'implémenter par le biais de deux AE profonds. Un DCAE est alors utilisé pour répondre à la tâche conditionnelle du type $p(y|x, c)$ où c est une dose de facteur VIII, x est le thrombinogramme initial du patient et y est

celui du test de GT réalisé *a posteriori* de l'administration du médicament. Le but de ce modèle est donc de prédire le thrombinogramme résultant d'une injection de concentré de facteur VIII. La tâche de détection de nouveautés est, quant à elle, traitée par l'intermédiaire d'un AE non supervisé utilisé dans un principe de classification uni-classe. Suite à son optimisation sur un ensemble de thrombinogrammes de patients sains, l'erreur de reconstruction de ce modèle permettra de quantifier le risque de saignements associé à un thrombinogramme. Par la juxtaposition de ces deux modèles, nous sommes donc en capacité de prédire le risque d'accident hémorragique qui résulte de l'injection d'une dose de facteur VIII à un patient hémophile A.

En ce qui concerne la seconde partie de notre proposition de CDSS, elle consiste en un algorithme d'optimisation multi-objectif que nous proposons d'implémenter par l'intermédiaire d'un MOPSO (cf. section (3)). Son rôle est d'ajuster itérativement la dose de facteur VIII afin de déterminer la posologie minimale suffisante pour écarter le risque d'accident hémorragique chez ce patient. Dans cette intention, il convient également de prendre en considération l'effet du médicament sur l'organisme (pharmacodynamie abrégée PD) et l'action de l'organisme sur le médicament (pharmacocinétique abrégée PK). Par souci de simplification, nous avons délibérément omis le modèle PK/PD lors de la présentation initiale de notre proposition de CDSS. Nous allons alors chercher à le définir dans la suite de cette section.

10.2 Présentation du modèle PK/PD

Dans l'intention d'assister le clinicien dans la démarche d'individualisation de thérapies, il convient également de prendre en considération la pharmacocinétique du médicament, c'est-à-dire d'étudier le devenir du principe actif après son administration dans l'organisme.

Ce processus est composé de quatre étapes successives : l'absorption, qui décrit le passage du médicament vers la circulation générale (compartiment central) en recensant la quantité de principes actifs présents *in fine* (notion de biodisponibilité) et en indiquant la vitesse de transmission ; la distribution, qui caractérise la formation des complexes médicament-protéine dans la circulation systémique ; la métabolisation, qui consiste en la biotransformation du médicament par le système enzymatique afin de favoriser son élimination ; et enfin l'élimination du médicament par l'organisme qui est représentée par la notion de clairance (volume sanguin totalement débarrassé d'une substance par unité de temps).

En toute logique, la pharmacocinétique est influencée par la variabilité inter-individuelle des patients. Les caractéristiques physiopathologiques impactent notamment la méthode d'administration du médicament et donc son absorption (franchissement des membranes cellulaires ou résorption). Les caractéristiques physiologiques, telles que l'âge ou le poids corporel du patient agissent, quant à elles, sur le débit de perfusion des organes ainsi que sur l'activité enzymatique hépatique (responsable de la biotransformation associée à la métabolisation). En outre, le taux de fixation du médicament libre aux protéines plasmatiques dépend essentiellement des effets du principe actif sur l'organisme. La distribution est donc étroitement liée à la pharmacodynamie.

Dans l'optique d'analyser et de prédire les propriétés de pharmacocinétique d'un médicament, il est possible d'utiliser des modèles mathématiques. Pour cela, il convient de définir un ensemble d'espaces virtuels de distribution (qualifiés de compartiments), au sein duquel le médicament est réparti de manière homogène et respecte une cinétique d'élimination identique en tous points. Dans le cas d'administration par injection, la distribution du médicament est jugée quasi instantanée. L'évolution de la concentration résiduelle du principe actif est alors assimilable à un comportement de fuite et est exprimée par une décroissance K -exponentielle où K correspond au nombre de compartiments utilisés.

En ce qui concerne les traitements des patients hémophiles A sans inhibiteurs, ils consistent en des thérapies de substitution réalisées par l'intermédiaire d'injections de concentrés de facteur VIII. Deux types de molécules thérapeutiques sont présentes sur le marché : les dérivés de plasma humains, tels que le FACTANE®, et les molécules recombinantes (ADVATE® par exemple) qui consistent en des cellules génétiquement modifiées porteuses du gène du facteur VIII. Bien que ces secondes molécules soient moins utilisées (~ 40% des prescriptions), elles assurent une sécurité plus importante sur le plan viral et certaines d'entre elles présentent une demi-vie prolongée (BAUNSGAARD et al., 2018).

Au regard de la pharmacodynamie, ces traitements substitutifs sont identiques. Ils corrigent temporairement le déficit en facteur VIII en agissant comme cofacteur du facteur IX activé, ce qui permet d'accélérer l'activation du facteur X nécessaire à la génération de thrombine.

La pharmacocinétique de ces molécules a quant à elle été étudiée par BJÖRKMAN et al., 2012 et MCENENY-KING et al., 2019. De ces travaux résulte un modèle bicompartimental exprimé mathématiquement par l'équation (III.1). Au sein de cette décroissance bi-exponentielle, les valeurs des constantes A , B , α et β sont déduites de l'âge des patients, de leur poids, du type de molécule utilisée, de la dose administrée et de la clairance (dont la fonction a été estimée sur un panel de patients hémophiles A sévères). Le taux d'erreur résiduel additif est quant à lui régi par une loi normale telle que $\epsilon \sim \mathcal{N}(0, 80)$. Des explications mathématiques et biologiques de ce modèle sont données dans les deux articles précédemment cités.

$$C(t) = A.e^{-\alpha.t} + B.e^{-\beta.t} + \epsilon \quad (\text{III.1})$$

Comme illustrée en figure (III.3), cette décroissance bi-exponentielle fournit des statistiques sur l'activité du facteur VIII thérapeutique au cours du temps et donc sur le devenir du principe actif après son administration dans l'organisme. Par conséquent, elle permettra aux cliniciens de prendre en considération la notion de temporalité qui est indispensable à l'optimisation de ces traitements substitutifs.




FIGURE III.3 – Représentation de l'activité du facteur VIII (ADVATE®) au cours du temps. Compte tenu de l'étude (BJÖRKMAN et al., 2012), la concentration $C(t)$ est exprimée en termes de valeurs médiane, maximale, minimale et quartiles. Ces statistiques sont associées à un patient hémophile A sévère, âgé de 22 ans, pesant 68 kilogrammes et ayant reçu une injection de 1000 UI (Unité Internationale) de facteur VIII recombinant.

11 Base de données

De par leur principe de fonctionnement, la performance des modèles d'apprentissage automatique est étroitement corrélée à la qualité et à la quantité des données à disposition. Dans un contexte clinique, la construction de cohortes est une tâche complexe qui représente un fort coût économique et temporel. Cette difficulté est par ailleurs accrue dans notre cas d'étude, du fait de la faible prévalence de la pathologie considérée, de la rareté des patients hémophiles A sévères non médicamenteux et de la forte variabilité pré-analytique qui est associée au test de GT. Afin d'y remédier, nous avons songé à tirer profit du caractère prédictif des tests globaux en proposant le CDSS que nous venons de détailler. L'intérêt de ce dernier est qu'il permet d'assister les médecins dans leurs démarches d'individualisation de thérapies malgré l'absence d'évaluation physiologique des patients. En d'autres termes, il peut donc être développé à partir de données simulées numériquement (méthode dite *in silico*) et/ou générées en laboratoire (approche dite *in vitro*).

Les diverses bases de données que nous avons constituées à cet effet seront exposées dans la suite de cette section. Nous les utiliserons pour entraîner et évaluer indépendamment les deux sous-systèmes que présente notre proposition de CDSS, à savoir le modèle conditionnel et le modèle de détection de nouveautés. L'évaluation des performances globales de notre proposition biologique nécessitera, quant à elle, l'avis de cliniciens experts du domaine. Au vu de la complexité associée à la construction d'une cohorte spécifique, nous ne pourrons mener cette étude dans

le cadre de nos travaux de thèse. Néanmoins, nous tâcherons d'utiliser les données simulées pour évaluer la vitesse de convergence du MOPSO, algorithme indispensable à l'optimisation thérapeutique.

11.1 Modèle *in silico*

Les méthodes dites *in silico* (dans le silicium), qui sont apparues à la suite des nombreuses avancées technologiques du début de la révolution numérique, consistent en une étude informatique du système biologique. Par la simulation de modèles mathématiques construits *a priori*, elles permettent l'extrapolation de résultats biologiques. Dès lors que le modèle simulé s'avère être en phase avec le système étudié, elles se présentent comme des solutions pertinentes pour passer outre les difficultés associées à la construction de bases de données médicales, le coût de simulation étant uniquement computationnel.

Dans cette intention, nous nous sommes intéressés au modèle numérique de GT initialement proposé par KERDELO, 2006 et perfectionné par CRÉPIN, 2013. 42 réactions biochimiques existantes entre 35 protéines de la coagulation y sont prises en compte afin de construire un système d'équations différentielles ordinaires dont la résolution permet d'obtenir l'évolution de la thrombine au cours du temps, c'est-à-dire un thrombinogramme simulé numériquement. Concernant l'intégration de ce système, il est réalisé sur 60 minutes avec un pas de 20 secondes. Chaque cinétique simulée est donc composée de 180 variables.

Afin d'assurer la pertinence de ce modèle mathématique, nous avons souhaité le valider expérimentalement sur une base de données biologiques. Les travaux réalisés, que nous explicitons en annexe (A), ont consisté en la mise en place de correctifs visant à limiter les disparités temporelles constatées. Suite à leur application, nous avons pu valider le comportement biologique de ce modèle numérique. Néanmoins, au vu des variabilités intra- et inter-laboratoires qui sont associées au test de GT, il est important de noter la potentielle non-généralisabilité de cette validation à d'autres cohortes. Par ailleurs, il convient également de mentionner le fait que les lois cinétiques prises en compte par ce modèle numérique ne s'avèrent valables qu'en présence de Pefabloc®, un inhibiteur de la polymérisation de la fibrine permettant d'éviter une modification de propriété physique de l'échantillon.

Suite à cette étude préliminaire, nous avons utilisé ce modèle numérique pour constituer les deux bases de données subséquentes.

11.1.1 Base de données dédiée au modèle conditionnel

Cette base a été constituée par une simulation numérique de 1000 patients hémophiles A sévères (taux de facteur VIII inférieur à 1%) sans inhibiteur ayant artificiellement reçu 50 injections de concentrés de facteur VIII thérapeutique (dont la concentration a été uniformément répartie dans l'intervalle [3%,150%]). Elle est donc composée de 50000 triplets de données $\{x, c, y\}$ au sein desquels, x est le résultat du test de GT d'un patient simulé, c est une dose de facteur VIII thérapeutique et y est le thrombinogramme résultant de l'injection. 32000 triplets ont été asso-

ciés au jeu d'entraînement (640 patients), 8000 à celui de validation (160 patients), tandis que les 10000 restants ont été réservés à la base de test (200 patients). À titre d'exemple, un triplet est illustré en figure (III.4).




FIGURE III.4 – Exemple de triplet de données $\{x, c, y\}$. L'abscisse représente le temps d'intégration (exprimé en minutes) tandis l'ordonnée illustre la concentration de la thrombine (normalisée sur $[0,1]$). La dose étant également exprimée sur l'ensemble $[0,1]$, $c = 0.42$ correspond à l'injection d'une concentration de 63% de facteur VIII thérapeutique.

11.1.2 Base de données dédiée au modèle de détection de nouveautés

Cette base a été constituée par la simulation de deux ensembles de patients :

- 10000 patients sains, pour lesquels les taux de facteur VIII ont été distribués par le biais de la loi normale $\mathcal{N}(\mu = 148, \sigma = 42.86)$ (KERDELO, 2006) ;
- 10000 patients hémophiles A, pour lesquels les taux de facteur VIII ont été distribués uniformément dans l'ensemble $]0\%,40\%]$ (CHELLE, 2017).

Les thrombinogrammes des patients sains sont destinés à l'apprentissage et à l'évaluation des modèles. 5600 cinétiques ont alors été associées au jeu d'entraînement, 2400 à celui de validation et 2000 à la base de test. Les courbes des patients hémophiles ne doivent, quant à elles, être utilisées que dans l'intention d'évaluer un modèle entraîné *a priori*. Par conséquent, elles sont réservées à la base de données de test (patients non sains). À titre d'illustration, la distribution de taux de facteur VIII de la base de test est représentée en figure (III.5).




FIGURE III.5 – Distribution des taux de facteur VIII présents dans la base de test.

11.2 Modèle *in vitro*

Les méthodes *in silico* ne sont pas les seules approches envisageables. D'un point de vue historique, le premier type d'expérimentation des systèmes biologiques complexes qui a été proposé est le modèle d'étude *in vivo* (dans le vivant). Tel que son nom l'indique, il consiste en une expérimentation au sein d'un organisme vivant, qu'il soit humain ou animal. Plus tardivement sont apparues les études dites *in vitro* (dans le verre) qui, quant à elles, permettent de réaliser des expérimentations en dehors de l'organisme par le biais de tests en tubes ou de modèles en éprouvettes.

Du fait de l'étroite collaboration scientifique que notre entreprise d'accueil (Diagnostica Stago) entretient avec la société *Synapse Research Institute*, institut de recherche spécialisé en GT, une base de données *in vitro* a été générée spécifiquement pour nos travaux. Compte tenu des difficultés induites par la prévalence de l'hémophilie, sa conception s'est fondée sur l'hypothèse biologique suivante : la simulation d'échantillons provenant de patients hémophiles A sévères recevant des doses croissantes de facteur VIII thérapeutique peut être réalisée par la surcharge de plasmas de patients sains en anticorps anti-VIII. 120 plasmas vrais de patients sains ont alors été approvisionnés auprès de la banque de sang de Maastricht. Pour chacun de ces derniers, 20 surcharges en anticorps ont été effectuées. Les taux de facteurs VIII résultants ont alors été quantifiés et les tests de GT nécessaires à notre étude ont été réalisés. Ces derniers ont par ailleurs été mesurés sur 60 minutes avec une cadence moyenne $5e^{-2}$ Hz. Chaque thrombinogramme présent dans cette base est donc composé de 180 variables.

Au vu de la complexité de ce protocole expérimental, de nombreux tests biologiques n'ont pas abouti. Comme présenté en annexe (B), nous avons alors cherché à démontrer la relation existante entre le facteur VIII et son anticorps polyclonal par le

biais d'un modèle mathématique. En définitive, 2107 cinétiques provenant de 115 plasmas vrais ont pu être exploitées pour constituer les deux bases de données subséquentes.

11.2.1 Base de données dédiée au modèle conditionnel

Cette base a été constituée par la simulation *in vitro* de 115 plasmas de patients hémophiles A sévères sans inhibiteur, pour lesquels des doses croissantes de concentrés de facteur VIII thérapeutique ont été artificiellement injectées. Elle est donc composée de 1992 triplets de données $\{x, c, y\}$ au sein desquels, x est le résultat du test de GT d'un patient simulé, c est une dose de facteur VIII thérapeutique et y est le thrombinogramme résultant de l'injection. 1297 triplets ont été associés au jeu d'entraînement (73 plasmas), 325 à celui de validation (19 plasmas), tandis que les 370 restants ont été réservés à la base de test (23 plasmas). À titre d'exemple, un triplet est illustré en figure (III.6).




FIGURE III.6 – Exemple de triplet de données $\{x, c, y\}$. L'abscisse représente le temps de mesure (exprimé en minutes) tandis l'ordonnée illustre la concentration de la thrombine (normalisée sur $[0,1]$). La dose étant également exprimée sur l'ensemble $[0,1]$, $c \approx 0.67$ correspond à l'injection d'une concentration de 83.62% de facteur VIII thérapeutique.

11.2.2 Base de données dédiée au modèle de détection de nouveautés

Du fait que la quantification du taux de facteur VIII ne fournisse qu'une information limitée sur l'état de la balance hémostatique, nous n'avons pas connaissance du risque de saignement résultant de l'administration d'anticorps anti-VIII. Par conséquent, seuls les thrombinogrammes issus de plasmas vrais ont été associés à la base

d'apprentissage. 73 courbes de GT ont alors été attribuées au jeu d'entraînement, 19 à celui de validation et 23 à la base de test. En ce qui concerne les 1992 cinétiques restantes, elles ont été considérées comme des résultats issus de patients non sains et ont donc été associées à la base de test. Les taux de facteur VIII mesurés permettront, quant à eux, d'estimer la pertinence des modèles lors de la phase d'évaluation. Leur distribution est représentée en figure (III.7).




FIGURE III.7 – Distribution des taux de facteur VIII présents dans la base de test.

11.3 Discussion

Compte tenu de la diversité des tests de laboratoire que la validation du modèle numérique de GT implique et des coûts temporels et économiques qui en résultent, le protocole expérimental mis en place dans le cadre de la collaboration avec l'institut de recherche Synapse ne nous a pas offert la possibilité d'harmoniser les modèles d'étude *in silico* et *in vitro*. Bien qu'un travail conséquent ait été fourni en vue de réaliser cette validation sur une base de données biologiques subsidiaires (cf. annexe (A)), le manque de standardisation du test de GT risque d'impacter la généralisabilité de cette étude préliminaire. Par ailleurs, cette crainte se voit inéluctablement renforcer par le fait que les courbes de GT *in vitro* aient été mesurées sans administration de Pefabloc®, mesures ne pouvant être modélisées par les lois cinétiques prises en compte au sein du modèle numérique. Toutefois, nonobstant la présence potentielle de dissimilarités temporelles, nous tenterons de faire face aux faibles volumes de données que présentent les deux bases *in vitro* en tirant profit des données simulées numériquement et de notre stratégie d'apprentissage par transfert incrémentale.

12 Modèle conditionnel

Dans le cadre de cette section, nous étudierons le cas du modèle conditionnel, modèle ayant pour rôle de caractériser l'influence qu'une injection d'un concentré de facteur VIII pourrait avoir sur le thrombinogramme d'un patient. Dans cette intention, nous évaluerons la pertinence des diverses stratégies d'optimisation conditionnelle que nous avons proposées en chapitre (II) en les appliquant aux bases de données *in silico* et *in vitro* que nous venons de détailler. Afin d'assurer l'intérêt que présentent les DCAE pour les systèmes d'aide à l'individualisation de thérapies, nous avons également souhaité évaluer les performances des réseaux antagonistes génératifs (*Generative Adversarial Networks* en anglais, abrégé GAN), des modèles d'apprentissage profond qui ont suscité un engouement récent auprès de la communauté scientifique du domaine. Nous expliciterons alors le principe de fonctionnement général de leur extension conditionnelle avant d'exposer les objectifs de cette évaluation et le protocole expérimental qui en résulte. Les résultats obtenus seront ensuite présentés et un bilan sur nos propositions sera dressé à titre de discussion générale.

12.1 GAN et génération conditionnelle

Les GAN sont des modèles génératifs qui ont été proposés en réponse à des problèmes d'augmentation de la taille des bases de données. Il s'agit de modèles d'apprentissage profond au sein desquels deux réseaux sont mis en compétition : un générateur, qui par l'intermédiaire d'un vecteur de bruit, vise à créer des données semblables à celles de la base d'apprentissage et un discriminant qui, quant à lui, est entraîné à distinguer les données réelles de celles générées. En ce sens, le fondement de ces modèles repose sur un scénario de la théorie des jeux (GOODFELLOW et al., 2014). Dans notre cas d'étude, nous souhaitons les employer comme modèles de référence en les appliquant à un problème conditionnel du type $p(y|x, c)$ où c est une dose de facteur VIII, x est le thrombinogramme initial du patient et y est celui du test de GT réalisé *a posteriori* de l'injection. Il conviendra alors d'employer des GAN conditionnels (MIRZA et OSINDERO, 2014), une extension présentée en figure (III.8), qui vise à contraindre les entrées de ces deux réseaux par l'ajout d'unités visibles.




FIGURE III.8 – Application des GAN à une tâche conditionnelle du type $p(y|x, c)$. Dans cet exemple d'architecture, le vecteur de bruit a été remplacé par la donnée d'entrée x . En interagissant avec le discriminant, le générateur est entraîné à reconstruire la donnée de sortie y par l'intermédiaire de la donnée synthétique h_2 .

12.2 Objectifs

Dans l'intention de mettre en évidence les intérêts que présentent les DCAE pour notre proposition de CDSS, nous souhaitons évaluer les apports de nos diverses stratégies d'optimisation conditionnelle sur les bases de données *in silico* et *in vitro*. À cet effet, il conviendra tout d'abord d'estimer la pertinence du CAE incrémental que nous avons développé en réponse au premier verrou scientifique. Pour ce faire, nous devons comparer la convergence de notre proposition à celle d'une stratégie plus classique telle que la recherche aléatoire. Par les valeurs moyennes et les écarts types des erreurs de reconstruction, nous aurons connaissance de la robustesse du CAE incrémental et, par conséquent, de notre contribution pour l'optimisation hyper-paramétrique des architectures conditionnelles simples. Suite à cette première évaluation, il conviendra de considérer la double difficulté de l'optimisation paramétrique et hyper-paramétrique des DCAE. En premier lieu, nous chercherons alors à évaluer la justesse de notre réponse au second verrou scientifique, à savoir : réaliser l'initialisation par apprentissage des architectures conditionnelles profondes. À ce titre, nous confronterons les taux d'erreur moyens obtenus par le pré-entraînement conditionnel à ceux résultant d'une initialisation aléatoire par l'heuristique de GLOROT et Yoshua BENGIO, 2010, c'est-à-dire en opposant notre proposition à l'unique méthode d'initialisation envisageable au regard de la littérature. Par l'utilisation de ces deux dernières au sein de recherches aléatoires, nous mettrons ensuite en lumière la grande combinatoire de l'optimisation hyper-paramétrique des DCAE. Il conviendra alors d'évaluer la convergence de notre stratégie d'optimisation incrémentale conditionnelle, proposition que nous avons développée en réponse à la double difficulté de l'optimisation de ces architectures profondes. Enfin, nous confronterons les erreurs de reconstruction ainsi obtenues à celles d'un modèle de référence : le GAN conditionnel. Cette évaluation nous permettra de justifier notre choix initial pour les AE profonds et, de ce fait, de souligner leurs intérêts pour les systèmes d'aide à l'individualisation de thérapies. Par ailleurs, malgré la présence potentielle de disparités temporelles entre les deux modèles d'étude utilisés, il sera pertinent d'évaluer les apports des méthodes *in silico* pour l'optimisation de DCAE dans des contextes *in vitro*. Nous étudierons alors la dynamique de la convergence de notre stratégie d'apprentissage par transfert incrémental conditionnel, approche que nous devons confronter à la méthode traditionnelle.

12.3 Processus d'estimation

Concernant les thrombinogrammes, la hauteur du pic (l'amplitude maximale) est inversement proportionnelle à la sévérité de l'hémophilie. Au vu de la constitution des bases de données considérées, il semble donc pertinent d'estimer l'erreur de reconstruction par le biais d'une erreur quadratique normalisée. En effet, à comportements identiques, la MSE associée à la prédiction d'une courbe de patient sain sera logiquement plus élevée que celle issue de la reconstruction du résultat d'un patient hémophile sévère. Afin d'évaluer le plus fidèlement possible les performances des CAE, des DCAE et des GAN, nous utiliserons la racine carrée de l'erreur quadratique moyenne normalisée (abrégiée NRMSE). Cette métrique, qui est défi-

nie en équation (III.2), sera également utilisée au sein des fonctions objectives des modèles précédemment énoncés. Cela permettra d'éviter un déséquilibre, ou favoritisme, lors des phases d'optimisation.

$$NRMSE = \frac{1}{n} \frac{\sqrt{\sum_{i=1}^n (x_i - \hat{x}_i)^2}}{\max(x) - \min(x)} \quad (\text{où } \hat{x} \text{ est la prédiction de } x) \quad (\text{III.2})$$

12.4 Protocole expérimental

En premier lieu, il conviendra de considérer indépendamment les bases de données *in silico* et *in vitro*. Pour chacune d'entre elles, nous traiterons tout d'abord le cas des architectures simples en adoptant les deux approches suivantes :

- approche n° 1 : application d'un CAE incrémental à la base de données considérée¹. La durée de son optimisation sera notée $durée_{n°1}$;
- approche n° 2 : optimisation hyper-paramétrique d'un CAE par l'intermédiaire d'une recherche aléatoire². La durée de cette dernière sera limitée à la $durée_{n°1}$.

Afin d'étudier la convergence de ces deux approches d'optimisation, elles seront toutes deux relancées dix fois. Suite à cette première évaluation, nous nous intéresserons au cas des DCAE en envisageant les trois stratégies d'optimisation suivantes :

- approche n° 3 : utilisation de notre proposition d'optimisation incrémentale conditionnelle¹. La durée de son application sera notée $durée_{n°3}$;
- approche n° 4 : optimisation hyper-paramétrique d'un DCAE réalisée par l'intermédiaire d'une recherche aléatoire³ limitée à la $durée_{n°3}$. Les paramètres de ce modèle seront initialisés par l'heuristique de GLOROT et Yoshua BENGIO, 2010 et optimisés en respect de la fonction objective régularisée (cf. équation (II.5)) ;

1. Les valeurs minimales et maximales des taux d'apprentissage sont optimisées par une recherche par grille lors de la phase d'initialisation de la topologie telles que $(lr_{min}, lr_{max}) = \{(5e^{-4}, 1e^{-3}), (1e^{-3}, 5e^{-3}), (5e^{-3}, 1e^{-2})\}$. La largeur initiale a quant à elle été définie à $L = 360$, c'est-à-dire deux fois supérieure à la dimension de la donnée d'entrée.

2. Les hyper-paramètres sont sélectionnés de manière aléatoire dans les ensembles suivants : largeur de la couche interne $L \in [1, 360]$, taux d'apprentissage $lr \in \{1e^{-2}; 5e^{-3}; 1e^{-3}; 5e^{-4}\}$ et pénalité de parcimonie $\lambda \in \{1e^{-3}; 1e^{-4}; 1e^{-5}\}$.

3. Les profondeurs des réseaux associés à $p(x)$ et $p(y)$ sont aléatoirement définies entre 1 et 4 couches cachées. En ce qui concerne les largeurs de ces dernières, elles sont spécifiées de manière aléatoire dans l'intervalle $L \in [1, 360]$. Un ordonnancement décroissant pour $p(x)$ et croissant pour $p(y)$ est néanmoins assuré. Les taux d'apprentissage nécessaires à l'algorithme de descente de gradient et au pré-entraînement sont sélectionnés dans l'ensemble $lr \in \{1e^{-2}; 5e^{-3}; 1e^{-3}; 5e^{-4}\}$. Quant à la pénalité de parcimonie, elle est égale à $\lambda \in \{1e^{-3}; 1e^{-4}; 1e^{-5}\}$.

- approche n° 5 : optimisation hyper-paramétrique d'un DCAE réalisée par l'intermédiaire d'une recherche aléatoire³ limitée à la *durée*_{n°3}. Les paramètres de ce modèle seront initialisés par notre proposition de pré-entraînement conditionnel puis optimisés en respect de la fonction objective non régularisée (cf. équation (II.6)).

Dans l'intention d'étudier la grande combinatoire de l'optimisation hyper-paramétrique des DCAE et la convergence de nos propositions, ces trois approches seront également relancées 10 fois. En outre, afin de justifier notre choix initial pour les AE profonds, nous tâcherons d'appliquer les GAN à cette tâche conditionnelle. Au vu de la spécificité et de la complexité de leur procédure d'apprentissage, il ne serait pas pertinent d'adopter une stratégie d'optimisation hyper-paramétrique en temps contraint. Par conséquent, un ajustement progressif des topologies sera réalisé par le biais de diverses recherches par grille⁴. Enfin, il conviendra de tirer profit des techniques d'apprentissage par transfert en adoptant les deux approches suivantes :

- approche n° 6 : poursuite de l'optimisation paramétrique sur la base de données *in vitro* des DCAE obtenus par l'approche n° 3 dans le contexte *in silico*;
- approche n° 7 : application de la stratégie d'apprentissage par transfert incrémental¹.

12.5 Cas des données *in silico*

12.5.1 Architectures simples

L'application de la procédure d'optimisation des CAE incrémentaux (approche n° 1) sur la base de données *in silico* a duré 3245 secondes en moyenne. Compte tenu des dix relances effectuées, 119 CAE ont été optimisés par le biais de l'approche n° 2. Les taux d'erreur de reconstruction (NRMSE) qui leur sont associés, sont exposés en table (III.1) et illustrés en figure (III.9).




FIGURE III.9 – Exemples de prédictions obtenues par les approches n°s 1 et 2 pour lesquels les NRMSE sont sensiblement similaires aux taux d'erreur moyens présentés en table (III.1)

4. En vue d'optimiser la profondeur de ces deux réseaux ($L \in [1, 3]$), leurs largeurs ainsi que leurs fonctions d'activation (unités sigmoïdes ou tangentes hyperboliques), diverses recherches par grille ont été réalisées. Compte tenu des relances, 663 configurations ont été évaluées.

Approche	Erreur d'apprentissage	Erreur de test
n° 1	$1.55e^{-2}$ $\pm 1.44e^{-4}$	$1.55e^{-2}$ $\pm 1.45e^{-4}$
n° 2	$2.41e^{-2}$ $\pm 5.16e^{-3}$	$2.41e^{-2}$ $\pm 4.95e^{-3}$

TABLE III.1 – Cette table recense les taux d'erreur obtenus par les deux approches envisagées dans le cadre des CAE. Compte tenu des dix relances, les valeurs y sont exprimées en termes de moyennes et d'écart types.

12.5.2 Architectures profondes

L'application de notre proposition de stratégie d'optimisation incrémentale conditionnelle (approche n° 3) sur la base de données *in silico* a, quant à elle, duré 5181 secondes en moyenne. De par les dix relances, un total de 1068 DCAE ont été optimisés par l'approche n° 4 et de 301 DCAE par l'approche n° 5. Les taux d'erreur de reconstruction (NRMSE) qui leur sont associés, sont exposés en table (III.2) et illustrés en figure (III.10).




FIGURE III.10 – Exemples de prédictions obtenues par les approches n°s 3 à 5 pour lesquels les NRMSE sont sensiblement similaires aux taux d'erreur moyens présentés en table (III.2)

Approche	Erreur d'apprentissage	Erreur de test
n° 3	$5.63e^{-3}$ $\pm 1.59e^{-4}$	$6.36e^{-3}$ $\pm 1.68e^{-4}$
n° 4	$2.03e^{-2}$ $\pm 1.04e^{-2}$	$2.05e^{-2}$ $\pm 1.01e^{-2}$
n° 5	$1.53e^{-2}$ $\pm 7.72e^{-3}$	$1.56e^{-2}$ $\pm 7.48e^{-3}$

TABLE III.2 – Cette table présente les taux d'erreur obtenus par les trois approches envisagées dans le cadre des DCAE. Compte tenu des dix relances, les valeurs y sont exprimées en termes de moyennes et d'écart types.

Par ailleurs, malgré les faibles écarts types des taux d'erreur obtenus par l'approche n° 3, deux types de topologies finales ont résulté de l'optimisation dynamique des paramètres et des hyper-paramètres. Elles sont détaillées en table (III.3).

	Sous-architecture associée à :		
	$p(x)$	$p(h_y h_x, c)$	$p(y)$
A	$x \rightarrow h_x \rightarrow r_x$	$(h_x, c) \rightarrow h_y$	$h_y \rightarrow h_{y1} \rightarrow h_{y2} \rightarrow y$
B	$x \rightarrow h_{x1} \rightarrow h_x \rightarrow \hat{h}_{x1} \rightarrow r_x$	$(h_x, c) \rightarrow h_y$	$h_y \rightarrow y$

TABLE III.3 – Cette table présente les deux types d'architectures qui ont résulté de l'approche n° 3 dans le contexte *in silico*. Le type A a été obtenu dans 80% des cas, le type B dans 20%.

12.5.3 Discussion

Tel que nous pouvons le constater au sein de ces résultats, dont une synthèse est présentée en figure (III.11), les moyennes et les écarts types des taux d'erreur sont plus faibles dans le cas du CAE incrémental (approche n° 1) que dans celui de la recherche aléatoire (approche n° 2). Outre le fait que cette faible variance souligne la robustesse de nos briques de base incrémentales à leur topologie initiale (valeurs des paramètres et des taux d'apprentissage), cela met en évidence leur propriété de régularisation et leur intérêt pour l'optimisation paramétrique et hyper-




FIGURE III.11 – Diagramme en boîte résumant les taux d'erreur obtenus par les approches n° 1 à 5 sur la base de données *in silico*. La ligne verticale de couleur orange illustre la performance du GAN conditionnel (NRMSE=0.0133).

paramétrique des architectures conditionnelles simples. En ce qui concerne les DCAE, nous pouvons tout d'abord noter l'intérêt de notre proposition de pré-entraînement conditionnel (approche n° 5) qui, de par son effet de régularisation, permet également de réduire la combinatoire de cette recherche opérationnelle. L'application de notre stratégie d'optimisation incrémentale conditionnelle (approche n° 3), dont le principe de fonctionnement résulte de la combinaison de ces deux premières propositions, permet d'outrepasser les performances du GAN et présente une forte répétabilité. Au vu de ces résultats, nous sommes en mesure de faire face aux difficultés de l'optimisation paramétrique et hyper-paramétrique des DCAE. Néanmoins, bien que ces derniers s'avèrent alors être pertinents pour notre proposition de CDSS, nous pouvons noter la faible profondeur des architectures obtenues par le biais de l'approche n° 3 (cf. table (III.3)). Ce point peut potentiellement être expliqué par l'absence de bruit expérimental qui résulte du modèle d'étude *in silico*. Afin d'assurer la pertinence de l'apprentissage profond pour l'interprétation des résultats des tests de GT, il convient d'appliquer ce protocole expérimental au cas des données *in vitro*.

12.6 Cas des données *in vitro*

12.6.1 Architectures simples

L'application de la procédure d'optimisation des CAE incrémentaux (approche n° 1) sur la base de données *in vitro* a duré 730 secondes en moyenne. Compte tenu des dix relances effectuées, 324 CAE ont été optimisés par le biais de l'approche n° 2. Les taux d'erreur de reconstruction (NRMSE) qui leur sont associés sont exposés en table (III.4) et illustrés en figure (III.12).




FIGURE III.12 – Exemples de prédictions obtenues par les approches n°s 1 et 2 pour lesquels les NRMSE sont sensiblement similaires aux taux d'erreur moyens présentés en table (III.4)

Approche	Erreur d'apprentissage	Erreur de test
n° 1	$9.03e^{-2}$ $\pm 5.54e^{-4}$	$9.35e^{-2}$ $\pm 4.61e^{-4}$
n° 2	$1.49e^{-1}$ $\pm 6.42e^{-2}$	$1.50e^{-1}$ $\pm 7.04e^{-2}$

TABLE III.4 – Cette table représente les taux d'erreur obtenus par les deux approches envisagées dans le cadre des CAE. Compte tenu des dix relances, les valeurs y sont exprimées en termes de moyennes et d'écarts types.

12.6.2 Architectures profondes

L'application de notre proposition de stratégie d'optimisation incrémentale conditionnelle (approche n° 3) sur la base de données *in vitro* a, quant à elle, duré 1176 secondes en moyenne. De par les dix relances, un total de 304 DCAE ont été optimisés par l'approche n° 4 et de 101 DCAE par l'approche n° 5. Les taux d'erreur de reconstruction (NRMSE) qui leur sont associés sont exposés en table (III.5) et illustrés en figure (III.13).




FIGURE III.13 – Exemples de prédictions obtenues par les approches n°s 3 à 5 pour lesquels les NRMSE sont sensiblement similaires aux taux d'erreur moyens présentés en table (III.5)

Approche	Erreur d'apprentissage	Erreur de test
n° 3	$6.19e^{-2}$ $\pm 7.41e^{-4}$	$6.11e^{-2}$ $\pm 6.13e^{-4}$
n° 4	$9.25e^{-2}$ $\pm 4.46e^{-2}$	$1.00e^{-1}$ $\pm 3.96e^{-2}$
n° 5	$6.46e^{-2}$ $\pm 3.20e^{-2}$	$8.14e^{-2}$ $\pm 2.58e^{-2}$

TABLE III.5 – Cette table représente les taux d'erreur (dont les NRMSE peuvent être imagées par le biais de la figure (III.13)) obtenus par les trois approches envisagées dans le cadre des DCAE. Compte tenu des dix relances, les valeurs y sont exprimées en termes de moyennes et d'écarts types.

Par ailleurs, malgré les faibles écarts types des taux d'erreur obtenus par l'approche n° 3, quatre types de topologies finales ont résulté de l'optimisation dynamique des paramètres et des hyper-paramètres. Leur architecture est détaillée en table (III.6).

	Sous-architecture associée à :		
	$p(x)$	$p(h_y h_x, c)$	$p(y)$
A	$x \rightarrow h_{x1} \rightarrow h_{x2} \rightarrow h_x \rightarrow \hat{h}_{x2} \rightarrow \hat{h}_{x1} \rightarrow r_x$	$(h_x, c) \rightarrow h_y$	$h_y \rightarrow h_{y1} \rightarrow h_{y2} \rightarrow y$
B	$x \rightarrow h_{x1} \rightarrow h_{x2} \rightarrow h_x \rightarrow \hat{h}_{x2} \rightarrow \hat{h}_{x1} \rightarrow r_x$	$(h_x, c) \rightarrow h_y$	$h_y \rightarrow h_{y1} \rightarrow h_{y2} \rightarrow h_{y3} \rightarrow y$
C	$x \rightarrow h_{x1} \rightarrow h_{x2} \rightarrow h_{x3} \rightarrow h_x \rightarrow \hat{h}_{x3} \rightarrow \hat{h}_{x2} \rightarrow \hat{h}_{x1} \rightarrow r_x$	$(h_x, c) \rightarrow h_y$	$h_y \rightarrow h_{y1} \rightarrow h_{y2} \rightarrow y$
D	$x \rightarrow h_{x1} \rightarrow h_{x2} \rightarrow h_{x3} \rightarrow h_x \rightarrow \hat{h}_{x3} \rightarrow \hat{h}_{x2} \rightarrow \hat{h}_{x1} \rightarrow r_x$	$(h_x, c) \rightarrow h_y$	$h_y \rightarrow h_{y1} \rightarrow h_{y2} \rightarrow h_{y3} \rightarrow y$

TABLE III.6 – Cette table présente les quatre types d'architectures qui ont résulté de l'approche n° 3 dans le contexte *in vitro*. Leur répartition est la suivante : {A,B,C,D}={20%,10%,50%,20%}.

12.6.3 Discussion

Bien que le comportement global des approches n°s 1 à 5 soit sensiblement similaire dans les contextes *in vitro* et *in silico* (cf. figure (III.14)), nous sommes forcés de constater une augmentation drastique des taux d'erreur. Par la comparaison des figures (III.10) et (III.13), où nous pouvons noter une homogénéité de la qualité




FIGURE III.14 – Diagramme en boîte résumant les taux d'erreur obtenus par les approches n°s 1 à 5 sur la base de données *in vitro*. La ligne verticale de couleur orange illustre la performance du GAN (NRMSE=0.066).

des prédictions, il est possible d'affirmer la présence de disparités entre les modèles d'études utilisés. En effet, la largeur des pics des thrombinogrammes générés *in vitro* s'avère être plus importante que celles des cinétiques simulées par l'approche *in silico*. Au vu de l'équation de la NRMSE, cet accroissement des taux d'erreur ne reflète donc pas une diminution des performances des CAE et des DCAE. Par conséquent, il est possible de s'interroger sur la pertinence de cette métrique dans un contexte de signaux temporels. Par ailleurs, nous pouvons également constater l'influence que présentent les variables pré-analytiques et le bruit expérimental sur la difficulté d'interprétation des résultats des tests de GT. En effet, les profondeurs des architectures présentées en table (III.6) sont plus grandes que celles des topologies exposées en table (III.3). Au vu de cette différence de complexité, que nous supposons induite par la non-utilisation de Pefabloc® dans le contexte *in vitro* mais également de par la qualité des prédictions, il semble peu pertinent d'envisager des techniques d'apprentissage par transfert. Néanmoins, dans l'intention d'évaluer de notre proposition d'apprentissage par transfert incrémental conditionnel, cette expérimentation sera menée à titre d'exercice intellectuel.

12.7 De *in silico* vers *in vitro*

Malgré la présence de disparités entre les deux modèles d'étude utilisés, nous avons souhaité évaluer l'apport des méthodes *in silico* pour l'optimisation de DCAE dans des contextes *in vitro*. À cet effet, nous avons réalisé de l'apprentissage par transfert en appliquant les approches n° 6 et 7. Les taux d'erreur de reconstruction (NRMSE) que nous avons ainsi obtenus sont exposés en table (III.7) et illustrés en figure (III.15).

Approche	Erreur d'apprentissage	Erreur de test	Temps d'optimisation moyen (en secondes)
n° 3 (<i>in vitro</i>)	$6.19e^{-2}$ $\pm 7.41e^{-4}$	$6.11e^{-2}$ $\pm 6.13e^{-4}$	1176
n° 6	$7.34e^{-2}$ $\pm 2.44e^{-2}$	$7.83e^{-2}$ $\pm 2.53e^{-2}$	5192
n° 7	$6.14e^{-2}$ $\pm 4.47e^{-3}$	$6.48e^{-2}$ $\pm 3.53e^{-3}$	5232

TABLE III.7 – Cette table recense les temps d'optimisation moyens et les taux d'erreur associés aux approches n° 3 (*in vitro*), n° 6 et n° 7.

12.7.1 Discussion

La poursuite de l'optimisation paramétrique sur les données *in vitro*, de DCAE ayant été précédemment considérés dans le contexte *in silico* (approche n° 6), ne permet pas d'améliorer l'erreur de généralisation qui résulte de l'approche n° 3. Il en est de même pour notre proposition d'apprentissage par transfert incrémental conditionnel (approche n° 7), qui bien que plus performante que la méthode traditionnelle, présente une variance supérieure à celle de l'approche n° 3. En d'autres

termes, notre proposition n'est pas en mesure de faire face aux différences qui résident entre les distributions cible et source. Cette limite souligne la faiblesse des approches statiques (DCAE optimisés en respect de la NRMSE) face aux disparités temporelles de nos deux modèles d'étude. De surcroît, du fait de l'absence de bruit expérimental au sein des données générées numériquement, certaines topologies sources ont convergé vers des architectures sous-complètes. Au vu de leur faible capacité à discriminer les données cible et de la simplicité de notre stratégie de réduction du sous-apprentissage, il n'est pas anormal que les approches n° 3 (*in vitro*) et n° 7 aient convergé vers des régions différentes de l'espace fonctionnel. En définitive, il est donc difficile de conclure sur la pertinence de la stratégie d'apprentissage par transfert incrémental dans le cadre de cette application. Son intérêt semble limité au vu des résultats de l'approche n° 3 *in vitro* mais non nul compte tenu des approches n° 4 et 5 *in vitro*. Des expérimentations supplémentaires nécessiteraient donc d'être menées à cet effet.




FIGURE III.15 – Diagramme en boîte résumant les taux d'erreur obtenus par les approches n° 3 (*in vitro*), n° 6 à n° 7.

12.8 Discussion générale

Au sein de cette section, nous avons souhaité évaluer les intérêts des CAE et des DCAE pour les systèmes d'aide à l'individualisation de thérapies. À cet effet, deux modèles d'étude ont été utilisés : l'un étant basé sur des méthodes *in silico*, l'autre sur des approches *in vitro*. Pour chacun d'entre eux, l'utilisation de l'apprentissage incrémental et de la procédure de génération aléatoire des taux d'apprentissage (ALRAO) a permis de réduire la combinatoire de l'optimisation hyperparamétrique des architectures conditionnelles simples et dans une moindre me-

sure, d'en améliorer la convergence. Dans l'intention de faire face aux difficultés d'interprétation des tests de GT, nous avons ensuite étudié le cas des architectures profondes. De par ses propriétés (cf. expérimentation (6.2)), notre algorithme de pré-entraînement conditionnel a présenté une plus faible variance des taux d'erreur que l'heuristique d'initialisation aléatoire de GLOT et Yoshua BENGIO, 2010. Ce comportement, qui s'avère être en phase avec la littérature du pré-entraînement non supervisé (RIFAI et al., 2011), souligne la pertinence de cette proposition. La prise en considération des briques de base incrémentales au sein de ce protocole d'initialisation par apprentissage (stratégie d'optimisation incrémentale conditionnelle) s'est alors avérée être une solution pertinente pour faire face à la double difficulté qui a émergé de notre étude bibliographique, à savoir faciliter l'optimisation paramétrique et hyper-paramétrique des architectures profondes. Son application a permis d'outrepasser les performances des GAN sur les deux bases de données considérées, et ce, malgré des temps d'optimisation relativement faibles (respectivement 5181 secondes et 1176 secondes dans les contextes *in silico* et *in vitro*). Par ailleurs, bien que l'utilisation de techniques d'apprentissage par transfert nous ait semblé pertinente de prime abord, le coût des données simulées numériquement n'étant que computationnel, elles n'ont pas eu d'apport pour la convergence des DCAE. Cette limite, que nous supposons liée aux disparités temporelles de ces deux modèles d'études, s'est présentée comme un frein à l'évaluation de notre proposition de transfert d'apprentissage incrémental. Malgré une première expérience sur la base de données MNIST (cf. évaluation (7.2.4)), il conviendra de poursuivre cette évaluation dans d'autres contextes d'application, une perspective que nous considérerons pour des travaux futurs. Par ailleurs, ces dissimilarités ont également souligné la faiblesse de la NRMSE face à l'analyse de cinétiques. Il pourra donc être intéressant d'envisager une fonction objective de substitution de façon à prendre en compte l'aspect temporel des courbes de GT.

13 Modèle de détection de nouveautés

Dans l'intention de développer de notre proposition de CDSS, il convient désormais de s'intéresser au cas du modèle de détection de nouveautés, modèle ayant pour rôle de qualifier le risque de saignements associé à un thrombinogramme. À cet effet, nous évaluerons la pertinence de nos stratégies d'optimisation incrémentale non supervisée dans les contextes *in silico* et *in vitro*. Au vu des résultats que nous avons précédemment obtenus par le biais des techniques d'apprentissage par transfert, ces deux modèles d'études seront uniquement considérés de manière indépendante. Par ailleurs, ayant pour objectif de souligner les intérêts que présentent les AE profonds pour les systèmes d'aide à l'individualisation de thérapies, nous appliquerons également les GAN en réponse à cette tâche de détection de nouveautés. Au sein de cette section, nous expliciterons le principe de fonctionnement de ces derniers avant d'exposer les objectifs de cette évaluation et de détailler le protocole expérimental qui en résulte. Les résultats obtenus seront ensuite présentés et un bilan sur nos propositions sera dressé à titre de discussion générale.

13.1 GAN et détection de nouveautés

Tel que nous l'avons précédemment souligné, le principe de fonctionnement des GAN repose sur un scénario de la théorie des jeux (GOODFELLOW et al., 2014). Lors de la phase d'apprentissage, deux réseaux sont mis en compétition : un générateur, qui par l'intermédiaire d'un vecteur de bruit, vise à créer des données semblables à celles de la base d'apprentissage et un discriminant qui, quant à lui, est entraîné à distinguer les données réelles de celles générées. À l'issue de la phase d'apprentissage, il est alors possible de tirer profit du réseau discriminant afin de répondre à un problème de détection de nouveautés (KLIGER et FLEISHMAN, 2018). Dans l'intention d'employer les GAN comme modèles de référence, il conviendra de les appliquer à notre contexte d'étude. Pour ce faire, nous devons entraîner ces deux réseaux en utilisant des thrombinogrammes issus de patients sains (cf. figure (III.16)). La probabilité de sortie du discriminant, $p(\text{sain})$, sera ensuite seuillée de manière à résonner dans un principe de classification uni-classe.




FIGURE III.16 – Application des GAN à une tâche de détection de nouveautés. Dans cet exemple d'architecture, z est un vecteur de bruit tandis que x représente un thrombinogramme. Lors de la phase d'apprentissage, il est indispensable que ce dernier soit issu d'un patient sain.

13.2 Objectifs

Dans l'intention de mettre en évidence les intérêts que présentent les AE profonds pour notre proposition de CDSS, nous souhaitons évaluer les apports de nos deux stratégies d'optimisation incrémentale non supervisée sur les bases de données *in silico* et *in vitro*. À cet effet, il conviendra tout d'abord d'estimer la pertinence de l'AE incrémental que nous avons développé en réponse au premier verrou scientifique. Pour ce faire, nous devons comparer la convergence de notre proposition à celle d'une stratégie plus classique telle que la recherche aléatoire. Par les valeurs moyennes et les écarts types du processus d'estimation, nous aurons connaissance de la robustesse de l'AE incrémental et, par conséquent, de notre contribution pour l'optimisation hyper-paramétrique des architectures simples.

Suite à cette première évaluation, il conviendra de considérer la double difficulté de l'optimisation paramétrique et hyper-paramétrique des AE profonds. À ce titre, nous évaluerons la convergence de notre stratégie d'optimisation incrémentale non supervisée. Compte tenu de l'état de l'art et du consensus visant à adopter les stra-

tégies d'initialisation par apprentissage, il est peu pertinent de considérer l'heuristique d'initialisation normalisée de GLOROT et Yoshua BENGIO, 2010. Par conséquent, nous mettrons en évidence les apports de notre stratégie en la confrontant à une recherche aléatoire utilisant l'algorithme de pré-entraînement non supervisé. Enfin, en vue de justifier notre choix initial pour les AE profonds et, de ce fait, de souligner leurs intérêts pour les systèmes d'aide à l'individualisation de thérapies, il conviendra de comparer les performances ainsi obtenues à celles de modèles de référence : les GAN.

13.3 Processus d'estimation

Comme nous l'avons présenté lors de l'étude bibliographique (cf. sous-section (1.4)), l'application de l'AE à un principe de classification uni-classe nécessite la définition d'une valeur seuil. Pour ce faire, nous appliquerons la règle des trois sigmas à la répartition des taux d'erreur de validation en utilisant les 2èmes et 3èmes percentiles (soit respectivement 95% et 99.7% de la distribution; CHANDOLA et al., 2009). Par ces valeurs, nous serons en mesure de calculer les deux matrices de confusion qui s'avèrent nécessaires à l'estimation des performances du modèle considéré. Au vu de la constitution des bases de données, et plus particulièrement de la répartition des classes, il conviendra néanmoins d'utiliser des matrices de confusion normalisées (exprimées en pourcentage). De ces dernières, il est commun d'extraire les valeurs de précision et de rappel (FAWCETT, 2006), deux indicateurs de performances que nous illustrons en figure (III.17).




FIGURE III.17 – Représentation d'une matrice de confusion et des indicateurs de performance associés (précision, rappel).

Le rappel, qui par son équation est étroitement corrélé à la valeur seuil, ne présente pas d'intérêt dans notre cas d'étude. *A contrario*, la précision définit la proportion de patients réellement sains parmi l'ensemble des patients à avoir été prédits comme tel. Dans un contexte d'individualisation de thérapies, il est indispensable de minimiser la présence de faux positifs (patients à risque prédits comme sains) et, par conséquent, de maximiser la précision. Il s'agit donc d'un indicateur pertinent pour cette évaluation.

Par ailleurs, telle que nous l'évoquions dans le cas du modèle conditionnel, l'erreur quadratique non normalisée d'un patient sain est logiquement plus élevée que celle d'un patient hémophile sévère. Bien que les bases de données d'apprentissage dédiées au modèle de détection de nouveautés soient exclusivement composées de patients sains, la sélection des valeurs seuils est établie sur la distribution des taux d'erreur de validation. Afin de limiter la présence de recouvrement inter-classes, il est donc indispensable de conserver une cohérence dans l'estimation des erreurs de reconstruction. Par conséquent, la NRMSE sera utilisée au sein des fonctions objectives des divers modèles envisagés.

13.4 Protocole expérimental

Pour chaque modèle d'étude, nous traiterons tout d'abord le cas des architectures simples en adoptant les deux approches suivantes :

- approche n° 1 : application d'un AE incrémental à la base de données considérée⁵. La durée de son optimisation sera notée $durée_{n°1}$;
- approche n° 2 : optimisation hyper-paramétrique d'un AE simple par l'intermédiaire d'une recherche aléatoire⁶. La durée de cette dernière sera limitée à la $durée_{n°1}$.

Afin d'étudier la convergence de ces deux approches d'optimisation, elles seront toutes deux relancées dix fois. Suite à cette première évaluation, nous nous intéresserons au cas des AE profonds en relançant dix fois les deux stratégies d'optimisation suivantes :

- approche n° 3 : utilisation de notre proposition d'optimisation incrémentale non supervisée⁵. La durée de son application sera notée $durée_{n°3}$;

5. Les valeurs minimales et maximales des taux d'apprentissage sont optimisées par une recherche par grille lors de la phase d'initialisation de la topologie telles que $(lr_{min}, lr_{max}) = \{(5e^{-4}, 1e^{-3}), (1e^{-3}, 5e^{-3}), (5e^{-3}, 1e^{-2})\}$. La largeur initiale a quant à elle été définie à $L = 360$, c'est-à-dire deux fois supérieure à la dimension de la donnée d'entrée.

6. Les hyper-paramètres sont sélectionnés de manière aléatoire dans les ensembles suivants : largeur de la couche interne $L \in [1, 360]$, taux d'apprentissage $lr \in \{1e^{-2}; 5e^{-3}; 1e^{-3}; 5e^{-4}\}$ et pénalité de parcimonie $\lambda \in \{1e^{-3}; 1e^{-4}; 1e^{-5}\}$.

- approche n° 4 : optimisation hyper-paramétrique d'un AE profond réalisée par l'intermédiaire d'une recherche aléatoire⁷ limitée à la *durée*_{n° 3}. Les paramètres de ce modèle seront initialisés par l'algorithme de pré-entraînement non supervisé puis optimisés en respect de la fonction objective non régulée ($J(\theta) = J_{reconstruction}(\theta)$).

En outre, nous tâcherons également d'appliquer les GAN à ce contexte de détection de nouveautés. Compte tenu de la spécificité et de la complexité de leur procédure d'apprentissage, l'optimisation hyper-paramétrique de ces derniers sera réalisée par le biais de recherches par grilles successives⁸.

13.5 Cas des données *in silico*

13.5.1 Architectures simples

L'application de la procédure d'optimisation des AE incrémentaux (approche n° 1) sur la base de données *in silico* a duré 150 secondes en moyenne. Compte tenu des dix relances effectuées, 123 AE ont été optimisés par le biais de l'approche n° 2. Les précisions à 2σ et 3σ de ces diverses architectures simples sont exposées en table (III.8) et illustrées en figure (III.18).




FIGURE III.18 – Exemples de distributions des taux d'erreur de test obtenus par les approches n°s 1 et 2 pour lesquelles, les précisions à 2σ et 3σ sont sensiblement similaires aux valeurs moyennes présentées en table (III.8)

7. La profondeur du réseau est aléatoirement définie entre 2 et 5 couches cachées. En ce qui concerne les largeurs de ces dernières, elles sont spécifiées de manière aléatoire dans l'intervalle $L \in [1, 360]$. Un ordonnancement de ces dernières est néanmoins assuré. Les taux d'apprentissage nécessaires à l'algorithme de descente de gradient et au pré-entraînement sont sélectionnés dans l'ensemble $lr \in \{1e^{-2}; 5e^{-3}; 1e^{-3}; 5e^{-4}\}$. Quant à la pénalité de parcimonie, elle est égale à $\lambda \in \{1e^{-3}; 1e^{-4}; 1e^{-5}\}$.

8. En vue d'optimiser la profondeur de ces deux réseaux ($L \in [1, 3]$), leurs largeurs ainsi que leurs fonctions d'activation (unités sigmoïdes ou tangentes hyperboliques), diverses recherches par grille ont été réalisées. Compte tenu des relances, 1884 configurations ont été évaluées dans le contexte *in silico* et 12501 dans le contexte *in vitro*.

Approche	Précision à 2σ	Précision à 3σ
n° 1	0.825 $\pm 1.25e^{-2}$	0.575 $\pm 1.13e^{-2}$
n° 2	0.670 $\pm 8.02e^{-2}$	0.558 $\pm 3.59e^{-2}$

TABLE III.8 – Cette table recense les valeurs de précision qui ont été obtenues par les approches n° 1 et 2 sur la base de données *in silico*. Compte tenu des dix relances réalisées, ces dernières sont exprimées en termes de moyennes et d'écart types.

13.5.2 Architectures profondes

L'application de notre proposition de stratégie d'optimisation incrémentale non supervisée (approche n° 3) sur la base de données *in silico* a, quant à elle, duré 408 secondes en moyenne. De par les dix relances, un total de 47 AE profonds ont été optimisés par l'approche n° 4. Les performances qui leur sont associées sont exposées en table (III.9) et illustrées en figure (III.19).




FIGURE III.19 – Ces deux exemples de distribution des taux d'erreur ont été obtenus par les approches n° 3 et 4. Les valeurs de précision qui leur sont associées sont sensiblement similaires aux valeurs moyennes présentées en table (III.9)

Approche	Précision à 2σ	Précision à 3σ
n° 3	0.829 $\pm 4.03e^{-3}$	0.603 $\pm 2.05e^{-2}$
n° 4	0.757 $\pm 3.41e^{-2}$	0.593 $\pm 1.33e^{-2}$

TABLE III.9 – Cette table détaille les valeurs de précision qui ont été obtenues sur la base de données *in silico* par les deux approches envisagées dans le cadre des AE profonds. Compte tenu des dix relances, ces dernières sont exprimées en termes de moyennes et d'écart types.

Par ailleurs, deux types de topologies finales ont résulté de l'optimisation dynamique des paramètres et des hyper-paramètres (approche n° 3). Ces architectures et les performances qui leur sont associées sont présentées en table (III.10).

	Architecture	Précision à 2σ	Précision à 3σ
A	$x \rightarrow h_1 \rightarrow r_x$	0.828 $\pm 3.93e^{-3}$	0.598 $\pm 1.95e^{-2}$
B	$x \rightarrow h_1 \rightarrow h_2 \rightarrow \hat{h}_1 \rightarrow r_x$	0.831 $\pm 3.51e^{-3}$	0.624 $\pm 6.38e^{-3}$

TABLE III.10 – Cette table présente les deux types d’architectures qui ont résulté de l’approche n° 3. Le type A a été obtenu dans 80% des cas, le type B dans 20%.

13.5.3 Discussion

En premier lieu, il convient de noter la faible profondeur des architectures obtenues par le biais de notre proposition d’optimisation incrémentale non supervisée (cf. table (III.10)). Au vu de ces topologies finales, qui s’avèrent être en phase avec les résultats présentés dans le cadre de l’évaluation du modèle conditionnel (cf. table (III.3)), nous pouvons affirmer qu’un faible degré d’abstraction est suffisant à la discrimination des données simulées *in silico*. Par ailleurs, une hétérogénéité des comportements obtenus à 2σ et 3σ peut être constatée dans la synthèse de ces résultats qui sont exposés en figure (III.20). En effet, l’intérêt des approches n°s 1 et 3 est manifeste à 2σ . Les valeurs moyennes et les écarts types des précisions soulignent la répétabilité de ces approches et leurs apports pour l’optimisation hyperparamétrique des AE. Elles permettent, de surcroît, d’outrepasser les performances du GAN dont la distribution de probabilité est représentée en figure (III.21). Néanmoins, la pertinence de ces deux approches est discutable à 3σ . En effet, nous pouvons notamment constater une forte variabilité dans le cas de l’approche n° 3 qui semble résulter des deux types de topologies finales obtenues. Ce point, qui résulte de la distribution uniforme des taux de facteur VIII présents dans cette base de données (cf. figure (III.5)), souligne également la faiblesse de la NRMSE dans une problématique de détection de nouveautés. Nous pouvons appuyer cet argument par l’intermédiaire des figures (III.18) et (III.19) au sein desquelles, des recouvrements similaires sont obtenus malgré une disparité importante des taux d’erreur de reconstruction. Toutefois, malgré la présence de ces variances, les recouvrements associés aux AE s’avèrent être plus cohérents que ceux du GAN d’un point de vue biologique. De par les matrices de confusion présentées en figure (III.22), nous pouvons effectivement constater que la médiocre précision des AE obtenue à 3σ résulte de la prédiction de faibles risques de saignement pour les patients hémophiles légers (environ 75% des cas). *A contrario*, un unique patient hémophile modéré a été classé comme sain tandis que l’ensemble des patients hémophiles sévères a été prédit comme étant non sain. Concernant les GAN, les patients hémophiles légers, modérés et sévères ont été prédits sains dans 57%, 57% et 7% des cas. Au regard de la clinique, bien que le taux de facteur VIII ne soit pas un bon prédicteur de l’état de la balance hémostatique, les saignements sont généralement proportionnels à la sévérité de l’hémophilie (CHELLE et al., 2018). Par conséquent, les AE s’avèrent être plus pertinents que les GAN dans ce contexte de détection de nouveautés, et ce, malgré une plus faible précision. En définitive, bien que nous n’ayons pas pu mettre en exergue la pertinence de nos propositions d’optimisation incrémentale du fait de la

simplicité d'interprétation des données générées *in silico*, nous avons pu démontrer l'intérêt que présentent les AE pour les systèmes d'aide à l'individualisation de thérapies. Afin de poursuivre cette évaluation, il convient désormais d'appliquer ce protocole expérimental au cas des données *in vitro*.




FIGURE III.20 – Diagramme en boîte résumant les performances obtenues à 2σ et 3σ par les approches n° 1 à 4 sur la base de données *in silico*. Les lignes verticales de couleur orange illustrent les performances du GAN.




FIGURE III.21 – Ce graphique, qui illustre les performances du GAN, représente la distribution de probabilité $p(x = \text{sain})$ soit $1 - p(x = \text{sain})$.

Approche n° 3		GAN	
Classe réelle	Classe prédite	Classe prédite	
	sain	sain	sain
	sain	1994	6
	léger	6584	2166
	modéré	1	990
	sévère	0	259

FIGURE III.22 – Ces deux matrices de confusion non normalisées recensent les prédictions obtenues par un GAN et un AE profond pour une valeur seuil à 3σ dans le contexte *in silico*. Les performances de ce dernier sont par ailleurs sensiblement similaires aux valeurs moyennes présentées en table (III.19).

13.6 Cas des données *in vitro*

13.6.1 Architectures simples

L'application de la procédure d'optimisation des AE incrémentaux (approche n° 1) sur la base de données *in vitro* a duré 57 secondes en moyenne. Compte tenu des dix relances effectuées, 477 AE ont été optimisés par le biais de l'approche n° 2. Les performances qui leur sont associées sont exposées en table (III.11) et illustrées en figure (III.23).




FIGURE III.23 – Ces deux exemples de distribution des taux d'erreur ont été obtenus par les approches n°s 1 et 2. Les valeurs de précision qui leur sont associées sont sensiblement similaires aux valeurs moyennes présentées en table (III.11)

Approche	Précision à 2σ	Précision à 3σ
n° 1	0.829 $\pm 7.13e^{-3}$	0.819 $\pm 4.77e^{-3}$
n° 2	0.830 $\pm 1.48e^{-2}$	0.793 $\pm 2.07e^{-2}$

TABLE III.11 – Cette table recense les valeurs de précision qui ont été obtenues par les approches n° 1 et 2 sur la base de données *in vitro*. Compte tenu des dix relances réalisées, ces dernières sont exprimées en termes de moyennes et d'écarts types.

13.6.2 Architectures profondes

L'application de notre proposition de stratégie d'optimisation incrémentale non supervisée (approche n° 3) sur la base de données *in silico* a, quant à elle, duré 284 secondes en moyenne. De par les dix relances, un total de 742 AE profonds ont été optimisés par l'approche n° 4. Les performances qui leur sont associées sont exposées en table (III.12) et illustrées en figure (III.24).




FIGURE III.24 – Ces deux exemples de distribution des taux d'erreur ont été obtenus par les approches n° 3 et 4. Les valeurs de précision qui leur sont associées sont sensiblement similaires aux valeurs moyennes présentées en table (III.12)

Approche	Précision à 2σ	Précision à 3σ
n° 3	0.891 $\pm 3.94e^{-3}$	0.885 $\pm 6.19e^{-3}$
n° 4	0.830 $\pm 2.67e^{-2}$	0.778 $\pm 3.55e^{-2}$

TABLE III.12 – Cette table recense les valeurs de précision qui ont été obtenues sur la base de données *in vitro* par les deux approches envisagées dans le cadre des AE profonds. Compte tenu des dix relances, ces dernières sont exprimées en termes de moyennes et d'écarts types.

Par ailleurs, un unique type de topologies finales a résulté de l'optimisation dynamique des paramètres et des hyper-paramètres (approche n° 3). Ce dernier est présenté en table (III.13).

	Architecture
A	$x \rightarrow h_1 \rightarrow h_2 \rightarrow \hat{h}_1 \rightarrow r_x$

TABLE III.13 – Cette table présente l'architecture qui a résulté de l'approche n° 3 sur la base de données *in vitro*.

13.6.3 Discussion

À l'image du modèle conditionnel, nous pouvons tout d'abord remarquer une augmentation de la profondeur des architectures dans le contexte *in vitro* (cf. table (III.13)) ce qui souligne les disparités que présentent les deux modèles d'étude considérés. Par la synthèse des résultats, qui est illustrée en figure (III.25), nous pouvons ensuite noter une homogénéité des comportements obtenus à 2σ et 3σ . Ce constat peut être expliqué par la composition de la base de données *in vitro* et plus particulièrement, par la distribution des taux de facteur VIII (cf. figure (III.7)). En outre, bien que la faiblesse de la NRMSE puisse être constatée dans le cas de l'approche n° 1, les résultats obtenus par le biais de l'approche n° 3 mettent en évidence l'intérêt de notre stratégie d'optimisation incrémentale non supervisée dans des contextes d'apprentissage profond. En effet, les fortes valeurs moyennes et les faibles écarts types des précisions soulignent l'apport de notre proposition face à la difficulté de l'optimisation hyper-paramétrique qui a émergé de l'étude bibliographique. En comparaison avec les performances obtenues par l'approche n° 4





FIGURE III.25 – Diagramme en boîte résumant les taux d'erreur obtenus par les approches n° 1 à 4 sur la base de données *in vitro*. Les lignes verticales de couleur orange illustrent les performances du GAN.

(pré-entraînement non supervisé), la répétabilité de notre algorithme glouton démontre également son intérêt pour l'optimisation paramétrique des AE profonds. Par ailleurs, les résultats obtenus par les GAN mettent en lumière leurs limites dans un contexte de détection de nouveautés, les fortes valeurs de précisions sur la base de données *in silico* étant principalement induites par la constitution de cette dernière. Au vu de la cohérence biologique des résultats présentés en figure (III.27) où moins de 1% des plasmas présentant de forts déficits en facteurs VIII ont été prédits sains, nous pouvons affirmer que les AE profonds ont un intérêt non négligeable pour les modèles de détection de nouveautés et, par conséquent, pour les systèmes d'aide à l'individualisation de thérapies.

FIGURE III.26 – Ce graphique, qui illustre les performances du GAN, représente la distribution de probabilité $p(x = \overline{sain})$ soit $1 - p(x = sain)$.



		Approche n° 3		GAN	
		Classe prédite		Classe prédite	
Classe réelle	sain	22	1	22	1
	40% < FVIII	117	44	151	10
	5% < FVIII <= 40%	125	778	628	275
	1% < FVIII <= 5%	8	911	309	610
	1% <= FVIII	0	9	6	3

FIGURE III.27 – Ces deux matrices de confusion non normalisées recensent les prédictions obtenues par un GAN et un AE profond pour une valeur seuil à 3σ dans le contexte *in vitro*. Les performances de ce dernier sont par ailleurs sensiblement similaires aux valeurs moyennes présentées en table (III.24).

13.7 Discussion générale

Par l'intermédiaire de cette section, nous avons souhaité évaluer les intérêts des AE pour les modèles de détection de nouveautés en vue de développer notre système d'aide à l'individualisation de thérapies. Dans cette intention, nous les avons appliqués aux données simulées *in silico* avant de considérer le contexte *in vitro*. Pour chacun de ces modèles d'étude, nous avons adopté la règle des trois sigmas en envisageant deux valeurs seuils, à savoir les 2èmes et 3èmes percentiles de la distribution des taux d'erreur de validation. Bien que la simplicité d'interprétation des données générées numériquement n'ait pas permis de mettre en évidence l'apport de notre stratégie d'optimisation incrémentale non supervisée, les résultats obtenus dans cette première évaluation ont tout de même souligné la pertinence des AE simples pour cette tâche de détection de nouveautés. Compte tenu des variabilités plus importantes que présentent les données *in vitro*, le second cas d'étude a quant à lui mis en exergue les intérêts de nos propositions pour les AE profonds. L'utilisation de nos briques de base incrémentales dans une stratégie d'optimisation gloutonne a notamment abouti à de plus faibles variances des prédictions que l'algorithme de pré-entraînement non supervisé. Au vu de ces résultats, nous pouvons donc affirmer que notre stratégie d'optimisation incrémentale non supervisée a la faculté de réduire la combinatoire de l'optimisation hyper-paramétrique des AE profonds. D'un point de vue biologique, les prédictions obtenues à l'issue de l'application de notre proposition ont également respecté la relation de proportionnalité existante entre le risque de saignement et la sévérité de l'hémophilie, comportement qui n'a pas été révélé dans le cas des GAN. En conclusion, l'apport des AE profonds pour les modèles de détection de nouveautés est donc manifeste. Néanmoins, à titre de perspectives, il serait pertinent de déterminer le risque de saignements en utilisant un estimateur de vraisemblance plus robuste que l'erreur de reconstruction.

14 Algorithme d'optimisation stochastique

Bien que l'utilisation de données simulées ne nous offre pas la possibilité d'estimer la pertinence clinique des doses patients-spécifiques définies par notre proposition de CDSS, nous pouvons néanmoins vérifier que le temps nécessaire à l'optimisation de ce résultat thérapeutique soit en cohérence avec un contexte d'individualisation de thérapies. Au sein de cette section, nous nous intéresserons donc à la vitesse de convergence de l'algorithme d'optimisation stochastique envisagé : le MOPSO. À cet effet, nous appliquerons notre proposition biologique aux contextes *in silico* et *in vitro* en suivant le protocole expérimental subséquent.

14.1 Protocole expérimental

Dans l'intention de déterminer les doses optimales d'un concentré de facteur VIII thérapeutique à administrer à des patients hémophiles A sévères simulés *in silico* ou *in vitro*, nous utiliserons les données d'entrée des bases dédiées au modèle conditionnel (données x des triplets $\{x, c, y\}$). Nous considérerons arbitrairement

que l'ensemble de ces patients sont âgés de 22 ans et pèsent 68 kg. Par le biais du modèle PK/PD que nous avons introduit en sous-section (10.2), nous chercherons à déterminer les doses minimales d'ADVATE® suffisantes pour écarter les risques hémorragiques sur un intervalle de 2 jours. À cet effet, nous ne tiendrons compte que de la valeur médiane de la pharmacocinétique de cette molécule. En ce qui concerne le modèle conditionnel et le modèle de détection de nouveautés, nous réutiliserons les AE profonds et les DCAE que nous avons précédemment définis par le biais de nos stratégies d'optimisation incrémentale non supervisée et conditionnelle. Nous tâcherons d'employer des modèles pour lesquels les performances (précision ou taux d'erreur) sont sensiblement similaires aux valeurs moyennes présentées dans les tables (III.2, III.5, III.9 et III.12). En outre, nous utiliserons l'implémentation du MOPSO qui est proposée dans la librairie jMetalPy (BENITEZ-HIDALGO et al., 2019). L'objectif de cet algorithme d'optimisation stochastique sera double, à savoir minimiser la dose ainsi que la fonction d'évaluation définie en équation (III.3). Dans cette dernière, y est le thrombinogramme résultant de l'administration de la dose d'ADVATE® (sortie du modèle conditionnel) tandis que $\hat{y}$ est sa prédiction par le modèle de détection de nouveautés. La valeur $K\sigma$ correspond quant à elle à la valeur seuil utilisée. Dans le cadre de cette évaluation, nous réutiliserons les valeurs des 2èmes et 3èmes percentiles que nous avons précédemment calculées. En somme, pour chacune des données *in silico* et *in vitro*, nous évaluerons le temps nécessaire à la convergence du MOPSO.

$$risque(dose) = \begin{cases} 0, & \text{si } NRMSE(y, \hat{y}) \leq K\sigma \\ NRMSE(y, \hat{y}), & \text{sinon.} \end{cases} \quad (III.3)$$

14.2 Cas des données *in silico*

Les valeurs moyennes et les écarts types des temps de convergence et des doses optimales obtenues à 2σ et 3σ sont détaillés en table (III.14). À titre d'illustration, les thrombinogrammes résultants de l'administration de ces deux doses optimales à un patient hémophile A sévère sont exposés en figure (III.28).

Valeur seuil	Dose (UI)	Temps de convergence (en secondes)
2σ	31378 ± 12144	25.93 ± 0.19
3σ	4324 ± 2624	26.00 ± 0.29

TABLE III.14 – Valeurs moyennes et écarts types des temps de convergence et des doses optimales qui ont résulté de l'application de notre proposition de CDSS sur la base de données *in silico*.




FIGURE III.28 – Exemple de thrombinogrammes *in silico* obtenus *a posteriori* de l'optimisation. L'abscisse représente le temps (exprimé en minutes) tandis l'ordonnée illustre la concentration de la thrombine (en nM)

14.3 Cas des données *in vitro*

De manière analogue, les résultats obtenus dans le contexte *in vitro* sont détaillés en table (III.15) et illustrés en figure (III.29).




FIGURE III.29 – Exemple de thrombinogrammes *in vitro* obtenus *a posteriori* de l'optimisation. L'abscisse représente le temps (exprimé en minutes) tandis l'ordonnée illustre la concentration de la thrombine (en nM).

Valeur seuil	Dose (UI)	Temps de convergence (en secondes)
2σ	12521 ± 3368	27.59 ± 0.15
3σ	11692 ± 3619	27.74 ± 0.17

TABLE III.15 – Valeurs moyennes et écarts types des temps de convergence et des doses optimales qui ont résulté de l’application de notre proposition de CDSS sur la base de données *in vitro*.

14.4 Discussion

Au regard des temps de convergence que nous venons de détailler, lesquels étant inférieurs à la trentaine de secondes, notre proposition de CDSS s’avère être pertinente dans un contexte d’individualisation de thérapies. À titre de travaux de futurs subsidiaires, il serait intéressant d’évaluer les apports computationnels d’autres algorithmes d’optimisation multi-objectif tels que l’algorithme des colonies d’abeilles artificielles (AKBARI et al., 2012) ou encore celui des colonies de fourmis (ALAYA et al., 2007). Par ailleurs, bien que nous ne puissions conclure sur la pertinence clinique des doses ainsi obtenues, nous pouvons néanmoins constater de fortes différences entre les valeurs seuils à 2σ et 3σ dans le contexte *in silico*. Dans l’intention de limiter ces écarts, il serait pertinent d’enrichir les bases de données de patients sains (dédiées au modèle de détection de nouveautés) avec des thrombogrammes de patients hémophiles ne présentant aucun risque de saignement. Dans cette intention et dans celle d’évaluer notre proposition biologique, il conviendra de construire une cohorte spécifique et de générer des données cliniques, une perspective que nous pouvons envisager à long terme.

15 Conclusion

Dans le cadre de ce chapitre, nous avons présenté l’application de nos travaux de recherche à la prise en charge personnalisée du patient hémophile A sévère sans inhibiteur. Après avoir souligné la pertinence que revêt le test global de GT dans ce cadre d’individualisation thérapeutique, nous avons envisagé d’employer notre CDSS en vue d’accompagner les professionnels de santé dans l’interprétation des résultats de ce dernier. Au vu des forts coûts économiques et temporels que représentent la construction d’une cohorte spécifique et la génération de données cliniques, nous avons songé à développer cette proposition biologique en tirant profit de modèles d’étude *in silico* et *in vitro*.

En premier lieu, nous avons alors traité le cas du modèle conditionnel en évaluant les performances des CAE et des DCAE dans ce contexte d’individualisation de thérapies. Par l’utilisation de l’apprentissage incrémental et de la procédure de génération aléatoire des taux d’apprentissage (ALRAO), nous avons tout d’abord pu réduire la combinatoire de l’optimisation hyper-paramétrique des architectures conditionnelles simples. Concernant les DCAE, notre algorithme de pré-entraînement conditionnel a obtenu une plus faible variance des taux d’erreur que l’heuris-

tique proposée par GLOT et Yoshua BENGIO, 2010 et s'est donc présenté comme une approche pertinente pour réaliser l'initialisation par apprentissage de ces réseaux. Par la combinaison de ces deux propositions, dont résulte notre stratégie d'optimisation incrémentale conditionnelle, nous avons remédié à la double difficulté qui a émergé de l'état de l'art, à savoir faciliter l'optimisation paramétrique et hyper-paramétrique des architectures profondes. Les DCAE ainsi définis ont présenté de faibles taux d'erreur et ont outrepassé les performances des GAN sur les deux bases de données considérées, des résultats qui témoignent de leurs intérêts pour les systèmes d'aide à l'individualisation de thérapies. Par ailleurs, au vu de la constitution de la base de données *in vitro* et des moindres coûts que représente la génération de données *in silico*, nous avons ensuite souhaité évaluer l'intérêt de notre proposition d'apprentissage par transfert incrémental. Néanmoins, en raison des disparités temporelles qui subsistent entre ces deux modèles d'études, cette approche n'a pas présenté d'apport pour la convergence des DCAE.

Dans un second temps, nous nous sommes intéressés aux AE profonds en considérant le cas du modèle de détection de nouveautés. Dans cette intention, nous les avons appliqués aux données simulées *in silico* avant d'envisager le contexte *in vitro*. Pour chacun de ces modèles d'étude, nous avons adopté la règle des trois sigmas en utilisant deux valeurs seuils, à savoir les 2èmes et 3èmes percentiles de la distribution des taux d'erreur de validation. Bien que la simplicité d'interprétation des données générées numériquement n'ait pas permis de mettre en évidence l'apport de nos propositions, les résultats ainsi obtenus ont tout de même souligné la pertinence des AE simples pour cette tâche de détection de nouveautés. Compte tenu des variabilités plus importantes que présentent les données *in vitro*, le second cas d'étude a quant à lui mis en exergue les apports de notre stratégie d'optimisation incrémentale non supervisée pour la définition des hyper-paramètres des AE profonds. Les modèles ainsi obtenus ont été en mesure de respecter la relation de proportionnalité existante entre le risque de saignement et la sévérité de l'hémophilie, comportement qui n'a pas été révélé dans le cas des GAN. Ces résultats témoignent donc de l'intérêt que présentent les AE profonds pour les systèmes d'aide à l'individualisation de thérapies.

Enfin, bien que l'utilisation de données simulées ne nous offre pas la possibilité d'estimer la pertinence clinique des doses définies par notre proposition de CDSS, nous avons souhaité évaluer la vitesse de convergence du MOPSO. Dans les deux contextes d'étude, les temps moyens nécessaires au rendu de résultats ont été inférieurs à la trentaine de secondes. Au vu de la complexité d'interprétation du test de GT, notre proposition biologique s'avère donc cohérente dans un contexte d'individualisation de thérapies.

En définitive, les diverses stratégies d'optimisation que nous avons proposées en chapitre (II) ont permis de remédier aux difficultés qui ont émergé de l'état de l'art et par conséquent, de mettre en lumière les intérêts que présentent les AE profonds, conditionnels ou non, pour les systèmes d'aide à l'individualisation de thérapies. Néanmoins, cette application a soulevé la faiblesse de la NRMSE, tant pour l'analyse de signaux temporels que pour l'optimisation hyper-paramétrique du modèle de détection de nouveautés. À titre de travaux futurs, il pourra donc être intéressant

de se pencher sur la définition de fonctions objectives de substitution et sur l'emploi d'estimateurs de vraisemblance complémentaires. Par ailleurs, en vue d'évaluer l'intérêt clinique de notre proposition de CDSS et d'enrichir les bases de données de notre modèle de détection de nouveautés, il sera nécessaire de construire une cohorte spécifique; une perspective que nous pouvons envisager à long terme.

Conclusion

Dans ce mémoire, nous soutenons la thèse que les auto-encodeurs (AE) profonds présentent des intérêts pour l'interprétation des tests globaux de l'hémostase et par conséquent pour les systèmes d'aide à l'individualisation de thérapies. À cet égard, nos contributions scientifiques concernent principalement l'optimisation hyper-paramétrique de ces modèles et l'initialisation par apprentissage de leur extension conditionnelle. Ce chapitre de conclusion nous permet de dresser un bilan de nos travaux de recherche et d'envisager quelques perspectives.

Bilan

L'individualisation de thérapies est une approche qui implique l'utilisation de tests biologiques proches de la réalité physiologique. Dans le cadre de l'hémostase, les tests dits globaux se présentent comme des candidats prometteurs puisqu'ils s'avèrent être révélateurs du phénotype clinique du patient. Néanmoins, ils ne sont que rarement utilisés en études cliniques du fait de la complexité qui est associée à l'analyse de leurs résultats et du manque de standardisation de leur protocole de mesure. Dans l'intention d'assister les cliniciens non experts du domaine à faire face à ces difficultés, nous avons proposé de concevoir un système d'aide à la prise de décisions cliniques (CDSS) permettant la mise en place et le suivi de traitements médicamenteux de troubles de la coagulation du sang. En d'autres termes, nous avons envisagé de prédire de manière automatique la dose minimale suffisante pour diminuer le risque hémorragique ou thrombotique chez un patient atteint d'une pathologie de l'hémostase. Au vu des forts coûts temporels et économiques nécessaires à la construction d'une base de données cliniques, nous avons proposé de répondre à ce problème de régression par la conception d'un système d'optimisation en boucle fermée dont le principe de fonctionnement peut être divisé en deux parties. La première d'entre elles, qui correspond à la mise en série d'un modèle conditionnel et d'un modèle de détection de nouveautés, a pour but de caractériser l'impact de l'administration d'une dose de médicament sur le résultat du test global du patient et, par suite, sur son risque d'accident. La seconde, qui consiste en un algorithme d'optimisation stochastique a, quant à elle, pour rôle d'assurer la disparition des symptômes délétères par un ajustement itératif de la posologie. Par conséquent, cette proposition biologique repose sur le caractère prédictif des tests globaux. En vue d'exploiter pleinement ces sources d'information malgré la complexité de leur interprétation, il est pertinent d'en extraire des caractéristiques fortement abstraites par l'intermédiaire de techniques d'apprentissage profond. En outre, du fait que les

modèles non supervisés soient à privilégier dans des contextes où les données sont coûteuses, les AE profonds se sont présentés comme un choix judicieux pour développer notre proposition de CDSS.

Au sein du premier chapitre, nous avons d'abord concentré nos efforts de recherche bibliographique sur les trois sous-systèmes qui composent notre proposition de CDSS. Dans ce dessein, nous avons détaillé le principe de fonctionnement des AE simples avant de mettre en évidence leur applicabilité à notre contexte biologique. En vue de faire face à la faible prévalence de certaines pathologies de l'hémostase et à la complexité d'interprétation des tests globaux, nous avons ensuite introduit les AE profonds. Pour ce faire, nous avons exposé l'intérêt théorique de ces modèles mais également souligné les difficultés associées à leurs optimisations paramétriques et hyper-paramétriques. Dans l'intention d'obvier à ces dernières, nous nous sommes alors intéressés aux diverses stratégies qui ont été envisagées par les chercheurs du domaine. De leurs études ont émergé deux verrous scientifiques : premièrement, aucune méthode d'initialisation par apprentissage n'est applicable au cas du modèle conditionnel et, deuxièmement, les AE incrémentaux issus de la littérature présentent des limites dans notre cas d'étude. Suite à ces constatations, nous avons traité le cas des algorithmes d'optimisation stochastique et, plus particulièrement, celui des métaheuristiques bio-inspirées. Ayant pour objectif de prédire la dose minimale suffisante à la disparition des symptômes, il en a résulté l'optimisation multi-objectif par essais particuliers (MOPSO), un algorithme basé sur l'intelligence distribuée et l'équilibre de Pareto.

Dans le second chapitre, nous avons souhaité apporter des solutions aux difficultés d'optimisation paramétrique et hyper-paramétrique qui ont émergé de l'état de l'art. À cet effet, nous avons tout d'abord spécifié la structure générale du modèle conditionnel nécessaire à notre proposition CDSS : l'auto-encodeur conditionnel profond (DCAE). Nous en avons alors développé une stratégie d'initialisation par apprentissage qui, à l'instar du pré-entraînement non supervisé, a présenté un intérêt pour l'optimisation paramétrique et exposé un effet de régularisation. Dans l'intention d'ajuster dynamiquement et conjointement les paramètres et les hyper-paramètres d'AE profonds, nous avons ensuite proposé une architecture simple basée sur l'apprentissage incrémental et la procédure de génération aléatoire des taux d'apprentissage (ALRAO). Après en avoir souligné la robustesse et la propriété de régularisation sur la base de données de référence MNIST, nous avons envisagé ces modèles quasi autonomes comme des briques de base utiles à la définition d'architectures profondes. Nous avons alors adapté les techniques de pré-entraînement des modèles étudiés en vue de proposer deux stratégies d'optimisation incrémentale : l'une étant non supervisée, l'autre conditionnelle. Au vu de leur principe de fonctionnement, il nous a enfin semblé judicieux de les employer dans une approche d'apprentissage par transfert incrémental, proposition qui s'est avérée pertinente d'un point de vue computationnel.

Le chapitre trois présente, quant à lui, l'application de nos travaux de recherche à la prise en charge personnalisée du patient hémophile A sévère sans inhibiteur.

Après avoir souligné la pertinence du test de génération de thrombine (GT) dans ce contexte d'individualisation de thérapies, nous avons envisagé d'employer notre CDSS en vue d'accompagner les professionnels de santé dans l'interprétation des résultats de ce test global. Pour ce faire, nous avons songé à développer cette proposition biologique en tirant profit de modèles d'étude *in silico* et *in vitro*. En premier lieu, nous avons traité le cas du modèle conditionnel en confrontant les performances des AE conditionnels (CAE) et des DCAE à celles de réseaux de neurones particulièrement en vogue à l'heure actuelle : les réseaux antagonistes génératifs (GAN). Par l'utilisation de l'apprentissage incrémental et de la procédure AL-RAO, nous avons tout d'abord pu réduire la combinatoire de l'optimisation hyper-paramétrique des architectures conditionnelles simples et, dans une moindre mesure, d'en améliorer la convergence. Ces résultats ont alors permis de conclure sur la pertinence de notre proposition d'AE incrémental au regard du premier verrou scientifique identifié lors de l'état de l'art. Par ailleurs, l'application de notre algorithme de pré-entraînement conditionnel a présenté une plus faible variance des taux d'erreur que l'heuristique d'initialisation normalisée (approche aléatoire). Il s'est donc révélé être une méthode pertinente pour répondre au second verrou scientifique rencontré, à savoir : réaliser l'initialisation par apprentissage des DCAE. Par la combinaison de ces deux propositions, dont résulte notre stratégie d'optimisation incrémentale conditionnelle, nous avons alors remédié à la double difficulté de l'optimisation paramétrique et hyper-paramétrique des architectures profondes. Les DCAE ainsi définis ont présenté de faibles taux d'erreur et ont outrepassé les performances des GAN sur les deux bases de données considérées. Dans un second temps, nous nous sommes intéressés au cas du modèle de détection de nouveautés. En réalisant une étude comparative similaire, nous avons à nouveau pu souligner la pertinence de notre proposition d'AE incrémental avant de mettre en exergue les apports de notre stratégie d'optimisation incrémentale non supervisée pour la définition des hyper-paramètres des AE profonds. Les modèles ainsi obtenus ont été en mesure de respecter la relation de proportionnalité existante entre le risque de saignement et la sévérité de l'hémophilie, comportement qui n'a pas été exposé dans le cas des GAN. Enfin, bien que l'emploi de données simulées ne nous offre pas la possibilité d'estimer la pertinence de cette individualisation de thérapies, nous avons tout de même pu en évaluer la vitesse de convergence. Les temps d'optimisation du MOPSO s'étant révélés inférieurs à la trentaine de secondes, nous avons alors pu statuer sur la cohérence computationnelle de notre proposition de CDSS qui s'avère être parfaitement compatible avec une utilisation dans un contexte clinique.

En définitive, les stratégies d'optimisation que nous avons proposées dans le second chapitre de ce manuscrit ont permis de remédier aux verrous scientifiques qui ont émergé de l'état de l'art et, par conséquent, de faire face à la double difficulté de l'optimisation paramétrique et hyper-paramétrique des architectures profondes. Nous avons alors pu soutenir notre thèse en mettant en lumière les intérêts que présentent les AE profonds, conditionnels ou non, pour les systèmes d'aide à l'individualisation de thérapies. Le grand regret de ces travaux de recherche concerne l'évaluation de notre stratégie d'apprentissage par transfert incrémental. En effet, bien qu'un travail de validation conséquent ait été réalisé en vue d'assurer la pertinence du modèle numérique de GT (cf. annexe (A)), l'absence d'administration

de Pefabloc® lors des mesures de cinétiques *in vitro* a induit de fortes disparités temporelles entre les deux modèles d'étude considérés. De ce fait, malgré l'intérêt théorique notable que présente la simulation numérique pour l'enrichissement de bases de données générées en laboratoire, notre proposition n'a pas été en mesure d'améliorer la généralisation des modèles. Afin d'y remédier et de pallier les diverses limites rencontrées lors de l'application de nos travaux, plusieurs perspectives peuvent être envisagées.

Perspectives

Les réflexions menées au cours de ce manuscrit ouvrent de nombreuses perspectives que nous pouvons envisager à titre de travaux futurs. Elles sont détaillées au sein de cette dernière sous-section.

Analyse temporelle : fonction objective de substitution Afin d'optimiser la distribution de sortie des réseaux de neurones à propagation avant, il convient de minimiser l'entropie croisée entre les données provenant de la base d'apprentissage et celles prédites par le modèle, c'est-à-dire en maximiser la vraisemblance. Dans le cas des AE, où l'apprentissage est non supervisé, l'équation de log-vraisemblance négative s'apparente à celle de l'erreur quadratique moyenne (MSE). Afin de faire face aux différences spatiales que présentent les données d'apprentissage, il est alors possible d'en utiliser la forme normalisée (SHCHERBAKOV et al., 2013). Néanmoins, tel que nous avons pu le constater lors de l'évaluation du modèle conditionnel, cette métrique n'est pas optimale dans un contexte de séries temporelles. Afin de prendre en considération les déphasages et les homothéties, il serait pertinent d'envisager une fonction objective de substitution telle que la distance de Fréchet (FRÉCHET, 1957). Cette dernière, qui est couramment employée dans le cas des GAN (SHMELKOV et al., 2018), permet notamment de mesurer les similarités inter-cinétiques (DOWSON et LANDAU, 1982). À cet égard, il conviendra néanmoins de reconsidérer les stratégies d'évaluation du sous-apprentissage et du sur-apprentissage sur lesquelles s'appuie notre proposition d'AE incrémental.

Analyse temporelle : Partage des paramètres Étant donné que toute fonction $f : \mathbb{R}^n \rightarrow \mathbb{R}^n$ où n est une valeur finie peut être considérée comme un réseau de neurones à propagation avant (GOODFELLOW et al., 2016), nous avons répondu à notre problématique en omettant l'aspect temporel (approche statique). Néanmoins, il pourrait être intéressant de redévelopper notre proposition biologique en employant des modèles spécialisés dans le traitement de données séquentielles tels que les réseaux de neurones récurrents (abrégiés RNN; RUMELHART et al., 1986) ou leurs successeurs, les réseaux à mémoire court et long terme (abrégiés LSTM; HOCHREITER et SCHMIDHUBER, 1997). Par l'intermédiaire d'un graphe de calcul très profond, ces derniers partagent les mêmes paramètres pour l'ensemble des caractéristiques d'entrée. Ils sont alors en capacité de traiter des données de taille variable et de passer outre les difficultés de déphasage que nous avons pu rencontrer (GOODFELLOW et al., 2016). Dans cette même intention, nous pourrions également envisager d'en-

richir l'architecture des AE et des CAE par l'ajout d'une mémoire temporelle (F. LASSON et al., 2017). Combinée à un principe de fenêtre glissante, cette approche permet également de partager les paramètres du réseau entre l'ensemble des caractéristiques d'entrée. Nous pourrions alors prendre en compte l'aspect temporel des cinétiques tout en tirant profit des stratégies d'optimisation proposées dans ce manuscrit.

Optimisation du modèle de détection de nouveautés Bien qu'en théorie, les distributions des erreurs de reconstruction des données normales et anormales obtenues par le biais d'un AE régularisé sont censées être très différentes (HAWKINS et al., 2002), un manque de corrélation entre l'erreur quadratique et le recouvrement a pu être constaté lors de l'application présentée en chapitre (III). En effet, les auteurs de BEGGEL et al., 2019 soulignent la limite de cette approche lorsque la base d'apprentissage est contaminée par des valeurs aberrantes ou que les comportements des données normales et anormales sont sensiblement similaires. Pour y remédier, ces derniers proposent d'employer une extension générative de l'AE nommée AE antagoniste. Par leurs travaux, nous pouvons notamment constater que la comparaison des distributions des variables latentes s'avère être un meilleur estimateur de la vraisemblance que l'erreur de reconstruction. Malgré la pertinence biologique des résultats obtenus par cette dernière lors de l'application à la prise en charge personnalisée du patient hémophile, il pourra s'avérer pertinent d'adopter l'approche de ces chercheurs dans d'autres contextes d'études. À cet effet, il conviendra alors d'évaluer l'applicabilité de nos stratégies d'optimisation au cas de l'AE antagoniste.

Évaluation clinique de notre proposition biologique L'évaluation de la pertinence clinique de notre proposition de CDSS nécessitera la construction d'une cohorte spécifique et la mesure de données *in vivo*. De cette étude, nous aurons connaissance des caractéristiques physiologiques nécessaires au modèle PK/PD, à savoir : l'âge et le poids des patients. Dans le cas d'une nouvelle application à la prise en charge personnalisée du patient hémophile, nous pourrions également enrichir la base d'apprentissage du modèle de détection de nouveautés avec des thrombogrammes de patients hémophiles ne présentant aucun signe de saignement (patients asymptomatiques). Par cette approche, nous souhaiterons accroître la pertinence biologique du modèle concerné et par suite, améliorer l'optimisation de la dose patient-spécifique. En outre, cette évaluation clinique sera également l'occasion de réévaluer les intérêts que présentent les modèles d'étude *in silico* dans une optique d'apprentissage par transfert, incrémental ou non. Néanmoins, au vu des forts coûts temporels et économiques que l'élaboration de ce type de base de données implique, il s'agit d'une perspective que nous envisageons qu'à long terme.

Application à la prise en charge personnalisée des maladies thrombotiques

Dans ce manuscrit, nous avons souhaité illustrer l'application de notre CDSS à la prise en charge personnalisée du patient hémophile A. Toutefois, compte tenu du

principe de fonctionnement de notre proposition biologique, nous pourrions également envisager de tirer profit du caractère prédictif du test de GT afin d'assister les cliniciens dans l'optimisation des traitements antivitamine K (abrégée AVK) de patients victimes de troubles thrombotiques. Par la mise en série du modèle conditionnel et du modèle de détection de nouveautés, nous pourrions alors caractériser l'impact de l'administration d'une dose de médicament sur le risque d'accident du patient. L'algorithme d'optimisation stochastique aurait, quant à lui, pour rôle d'assurer la disparition de ces symptômes délétères par un ajustement itératif de la posologie. En évitant de potentiels sur-dosages, cette approche permettrait de réduire le risque d'événements hémorragiques résultants et, par conséquent, d'améliorer la qualité des soins tout en limitant les coûts associés aux erreurs médicales. Cependant, bien que le développement de mesures relatives à la prise de décisions cliniques soit à favoriser pour les médicaments jugés à haut risque tels que les anticoagulants (COMMISSION, 2019), le temps de Quick est actuellement considéré comme le test de référence pour l'individualisation des AVK. La pertinence de cette proposition semble donc complexe à démontrer d'un point de vue réglementaire.

Outre les intérêts de nos stratégies d'optimisation pour la définition d'AE profonds, nous espérons que ces travaux de recherche favoriseront le développement de systèmes d'aide à l'individualisation de thérapies et qu'ils permettront d'améliorer la qualité des soins des patients victimes de troubles de l'hémostase.

Base de données *in silico*

A.1 Contexte

Tel que nous avons pu l'évoquer dans l'étude bibliographique présentée en chapitre (I), la performance des algorithmes d'apprentissage automatique est étroitement liée à la qualité et à la quantité des données à disposition. Dans un contexte clinique, la construction d'une cohorte est un processus complexe, coûteux et particulièrement long. Cela s'avère être d'autant plus vrai dans le cas de l'hémophilie du fait de la rareté de cette pathologie (prévalence ≈ 1 homme sur 10 000). Afin d'obtenir des modèles performants et généralisables malgré de faibles quantités de données, la littérature conseille d'optimiser les phases d'entraînement en utilisant les techniques de pré-entraînement non supervisé ou de transfert d'apprentissage (Yann LECUN et al., 2015). Bien que nous ayons adopté ces stratégies au cœur de nos travaux, nous avons également souhaité faire face à cette difficulté en nous focalisant sur la donnée en tant que telle. Pour ce faire, nous nous sommes intéressés aux méthodes dites *in silico*.

Il existe différents types d'expérimentation des systèmes biologiques complexes. D'un point de vue historique, le premier d'entre eux est le modèle d'étude *in vivo* (dans le vivant) qui consiste en une expérimentation au sein d'un organisme vivant, qu'il soit humain ou animal. Plus tardivement sont apparues les études dites *in vitro* (dans le verre). Elles permettent de réaliser des expérimentations en dehors de l'organisme par le biais de tests en tubes ou de modèles en éprouvettes. Suite aux nombreuses avancées technologiques du début de la révolution numérique est apparu le terme *in silico* (dans le silicium) dans ELL et al., 1991. Par analogie aux deux précédents types d'expérimentation, cette approche consiste en une analyse informatique du système biologique. Comme expliqué dans CRÉPIN, 2013, elle consiste en la simulation numérique d'un modèle mathématique construit *a priori*, dans l'optique d'en extrapoler des résultats *a posteriori*. L'intérêt de celle-ci, lorsque le modèle simulé s'avère être en phase avec la réalité biologique du système étudié,

est qu'elle permet de passer outre les difficultés associées à la construction de bases de données *in vivo* et *in vitro*. Une fois le modèle mathématique défini, le coût associé à la génération de données *in silico* n'est plus que computationnel.

A.2 Modèle numérique de GT

De ce fait, nous nous sommes intéressés au modèle numérique de génération de thrombine proposé initialement par KERDELO, 2006 et perfectionné par CRÉPIN, 2013. Comme indiqué en table (A.1), 42 réactions biochimiques existantes entre 35 protéines de la coagulation y sont prises en compte afin de construire un système d'EDO. Le résultat de sa résolution numérique se présente sous la forme d'une cinétique traçant l'évolution de la thrombine au cours du temps, c'est-à-dire une courbe de GT. Par ailleurs, les distributions des concentrations dites "normales" des différents facteurs de la coagulation sont également renseignées. La simulation d'un patient atteint d'un déficit en facteur(s) de la coagulation se traduit donc, au sein de ce modèle, par un simple abaissement d'une ou de plusieurs de ces concentrations.

Dans l'optique de générer des bases de données *in silico* permettant d'entraîner et d'évaluer l'intégralité des sous-modèles d'apprentissage automatique qui composent notre proposition de CDSS, nous avons réimplémenté ce modèle numérique de GT au langage Python. En ce qui concerne la résolution du système d'EDO, nous nous sommes appuyés sur la méthode *integrate.odeint* de la librairie de calcul scientifique Scipy. À noter que cette dernière utilise *odepack*, une collection de solveurs codés en Fortran.

A.3 Évaluation

A.3.1 Une recherche biomédicale : HémoTIV

Bien que les méthodes *in silico* présentent un intérêt théorique certain, leur apport réel est déterminé par la qualité des données générées. Afin d'évaluer la pertinence d'un modèle numérique, c'est-à-dire vérifier qu'il soit en phase avec la réalité biologique du système complexe étudié, il est possible de le valider expérimentalement. C'est dans cette optique qu'est née en 2011 la recherche biomédicale « Hémostase et Tests in Virtuo », abrégée HémoTIV. Cette dernière, qui est le fruit d'une collaboration entre l'entreprise Diagnostica Stago et le CHRU de Brest, avait pour but d'évaluer les modèles numériques du test de GT et des divers tests de routine en hémostase présentés dans CRÉPIN, 2013. Pour ce faire, une cohorte de 72 patients avait été étudiée. Elle comprenait des profils hémorragiques, des profils thrombotiques, des patients sous anticoagulants ainsi que des donneurs sains. Pour chacun de ces patients, des échantillons sanguins avaient été prélevés afin de réaliser les différents tests *in vitro* énoncés précédemment ainsi que les dosages en facteurs nécessaires à l'initialisation des modèles numériques. En étudiant les résultats présentés dans cette étude, nous avons pu constater que la validation du modèle de

GT n'a pas été clôturée. Dans la suite de cette annexe, nous allons donc exposer la démarche que nous avons mise en place pour évaluer la pertinence de ce dernier.

n°	Réaction
1	$\text{TF}\cdot\text{VIIa} + \text{TF}\cdot\text{VII} \rightarrow \text{TF}\cdot\text{VIIa} + \text{TF}\cdot\text{VIIa}$
2	$\text{TF}\cdot\text{VIIa} + \text{IX} \rightarrow \text{TF}\cdot\text{VIIa} + \text{IXa}$
3	$\text{TF}\cdot\text{VIIa} + \text{X} \rightarrow \text{TF}\cdot\text{VIIa} + \text{Xa}$
4	$\text{IXa} + \text{VII} \rightarrow \text{IXa} + \text{VIIa}$
5	$\text{IXa} + \text{TF}\cdot\text{VII} \rightarrow \text{IXa} + \text{TF}\cdot\text{VIIa}$
6	$\text{IXa} + \text{X} \rightarrow \text{IXa} + \text{Xa}$
7	$\text{VIIIa}\cdot\text{IXa} + \text{X} \rightarrow \text{VIIIa}\cdot\text{IXa} + \text{Xa}$
8	$\text{Xa} + \text{VII} \rightarrow \text{Xa} + \text{VIIa}$
9	$\text{Xa} + \text{TF}\cdot\text{VII} \rightarrow \text{Xa} + \text{TF}\cdot\text{VIIa}$
10	$\text{Xa} + \text{II} \rightarrow \text{Xa} + \text{IIa}$
11	$\text{Va}\cdot\text{Xa} + \text{II} \rightarrow \text{Va}\cdot\text{Xa} + \text{IIa}$
12	$\text{IIa} + \text{VII} \rightarrow \text{IIa} + \text{VIIa}$
13	$\text{IIa} + \text{TF}\cdot\text{VII} \rightarrow \text{IIa} + \text{TF}\cdot\text{VIIa}$
14	$\text{IIa} + \text{V} \rightarrow \text{IIa} + \text{Va}$
15	$\text{IIa} + \text{VIII} \rightarrow \text{IIa} + \text{VIIIa}$
16	$\text{IIa} + \text{I} \rightarrow \text{IIa} + \text{Fibrin}$
17	$\text{IIa} + \text{Z-Gly-Gly-Arg-AMC} \rightarrow \text{IIa} + \text{AMC}$
18	$\text{IIa}\cdot\alpha_2\text{M} + \text{Z-Gly-Gly-Arg-AMC} \rightarrow \text{IIa}\cdot\alpha_2\text{M} + \text{AMC}$
19	$\text{TF} + \text{VII} \rightarrow \text{TF}\cdot\text{VII}$
20	$\text{TF} + \text{VIIa} \rightarrow \text{TF}\cdot\text{VIIa}$
21	$\text{A2} + \text{A1/A3-C1-C2} \rightarrow \text{VIIIa}$
22	$\text{A2} + \text{A1/A3-C1-C2}\cdot\text{IXa} \rightarrow \text{VIIIa}\cdot\text{IXa}$
23	$\text{VIIIa} + \text{IXa} \rightarrow \text{VIIIa}\cdot\text{IXa}$
24	$\text{A1/A3-C1-C2} + \text{IXa} \rightarrow \text{A1/A3-C1-C2}\cdot\text{IXa}$
25	$\text{Va} + \text{Xa} \rightarrow \text{Va}\cdot\text{Xa}$
26	$\text{Xa} + \text{TFPI} \rightarrow \text{Xa}\cdot\text{TFPI}$
27	$\text{TF}\cdot\text{VIIa} + \text{Xa}\cdot\text{TFPI} \rightarrow \text{TF}\cdot\text{VIIa}\cdot\text{Xa}\cdot\text{TFPI}$
28	$\text{VIIa} + \text{AT} \rightarrow \text{VIIa}\cdot\text{AT}$
29	$\text{TF}\cdot\text{VIIa} + \text{AT} \rightarrow \text{TF}\cdot\text{VIIa}\cdot\text{AT}$
30	$\text{IXa} + \text{AT} \rightarrow \text{IXa}\cdot\text{AT}$
31	$\text{Xa} + \text{AT} \rightarrow \text{Xa}\cdot\text{AT}$
32	$\text{IIa} + \text{AT} \rightarrow \text{IIa}\cdot\text{AT}$
33	$\text{IIa} + \alpha_2\text{M} \rightarrow \text{IIa}\cdot\alpha_2\text{M}$
34	$\text{TF}\cdot\text{VII} \rightarrow \text{TF} + \text{VII}$
35	$\text{TF}\cdot\text{VIIa} \rightarrow \text{TF} + \text{VIIa}$
36	$\text{VIIIa} \rightarrow \text{A2} + \text{A1/A3-C1-C2}$
37	$\text{VIIIa}\cdot\text{IXa} \rightarrow \text{A2} + \text{A1/A3-C1-C2}\cdot\text{IXa}$
38	$\text{VIIIa}\cdot\text{IXa} \rightarrow \text{VIIIa} + \text{IXa}$
39	$\text{A1/A3-C1-C2}\cdot\text{IXa} \rightarrow \text{A1/A3-C1-C2} + \text{IXa}$
40	$\text{Va}\cdot\text{Xa} \rightarrow \text{Va} + \text{Xa}$
41	$\text{Xa}\cdot\text{TFPI} \rightarrow \text{Xa} + \text{TFPI}$
42	$\text{TF}\cdot\text{VIIa}\cdot\text{Xa}\cdot\text{TFPI} \rightarrow \text{TF}\cdot\text{VIIa} + \text{Xa}\cdot\text{TFPI}$

TABLE A.1 – Liste des 42 réactions biochimiques prises en compte par le modèle présenté dans CRÉPIN, 2013

A.3.2 Cohorte étudiée

Tel que nous l'avons explicité en partie (III), le test de GT vise à mesurer la quantité de thrombine générée au cours du temps par un échantillon plasmatique dont la coagulation a été activée par une faible quantité de facteurs tissulaires (TF). De par sa nature dite "globale", ce test permet de discriminer les maladies hémorragiques ainsi que les maladies thrombotiques. En d'autres termes, il s'avère être sensible aux déficits en facteurs de la coagulation, aux déficits en inhibiteurs ainsi qu'à

la prise de certains médicaments tels que les antivitamines K, les héparines ou encore les contraceptifs oraux. De ce fait, un large panel de profils de patients doit être utilisé pour valider le modèle numérique d'un tel test. Cependant, compte tenu du sujet de nos travaux de recherche, nous avons limité notre étude aux patients hémophiles A sans inhibiteurs et aux donneurs sains. La sous-cohorte ainsi étudiée est composée de 8 patients hémophiles A et de 7 donneurs sains, soit un ensemble de 15 patients.

En ce qui concerne les courbes de GT mesurées dans cette étude, elles ont été réalisées avec des concentrations en TF égales à 1 pM et 5 pM. Tel qu'explicité dans DUCHEMIN et al., 2008, ces concentrations en activateur de la cascade de coagulation influent sur la sensibilité du test. Par exemple, 5 pM est la valeur de référence qui est historiquement utilisée. Elle rend le test plus rapide et plus spécifique. Une concentration plus faible, typiquement 1 pM, permet d'accroître la sensibilité aux facteurs de coagulation de la voie intrinsèque et donc aux pathologies telles que l'hémophilie. *A contrario*, une forte concentration est utilisée lorsqu'il y a présence d'anticoagulants. Par ailleurs, la formation du caillot sanguin engendre une modification de la viscosité du milieu et donc une complexification des lois cinétiques. Le modèle proposé par CRÉPIN, 2013 ne tenant pas compte de cette modification de propriété physique, un peptide nommé Pefabloc® a été ajouté lors de la mesure de ces cinétiques. Il s'agit d'un inhibiteur de la polymérisation de la fibrine, protéine clé de la formation du caillot. Son utilisation permet ainsi de s'affranchir de la complexité précédemment énoncée. Au final, quatre mesures de GT ont été réalisées par patient en croisant les configurations suivantes : $[TF] = \{1 \text{ pM}; 5 \text{ pM}\}$ et $Pefabloc® = \{Avec; Sans\}$. Les dosages des 35 protéines prises en compte dans le modèle ont également été réalisés.

A.3.3 Protocole de validation

Afin d'estimer au mieux la justesse de ce modèle numérique, l'évaluation a été réalisée de manière absolue puis relative. Du fait des lois cinétiques utilisées pour construire ce dernier, seules les courbes de GT mesurées avec administration de Pefabloc® ont été utilisées lors de cette étude.

A.3.3.1 Validation absolue

Une validation absolue consiste en une évaluation par le biais d'une comparaison élément à élément. Dans notre cas d'étude, il s'agit donc de déterminer le degré de similarité existant entre les courbes de GT mesurées *in vitro* et leurs homologues générés numériquement. À noter que ces cinétiques *in silico* résultent du modèle numérique pour lequel les variables associées aux concentrations initiales en facteur ont été affectées aux valeurs des dosages réalisés *in vitro*. Pour réaliser une telle comparaison, il est nécessaire de tenir compte de l'aspect temporel des cinétiques. De ce fait, l'erreur quadratique ne peut pas être utilisée dans cette étude. Nous avons donc extrait les caractéristiques classiquement étudiées par les biologistes du domaine, à savoir le LT, le TTP, la hauteur du pic et l'ETP. Afin de mesurer le degré de similarité, nous avons calculé les écarts entre les valeurs calculées *in vitro* et *in silico* en appliquant l'équation (A.1) dans laquelle c est la caractéristique concernée et

cin la cinétique étudiée. Les résultats obtenus sont présentés dans le tableau (A.2) et illustrés graphiquement par le biais de la figure (A.1). De par ces derniers, nous pouvons constater que le modèle numérique n'est pas en parfaite adéquation avec le comportement biologique du système complexe qu'est la cascade de coagulation du sang. Cependant, tel que le stipule l'article LOEFFEN et al., 2012, le test global de GT est particulièrement sensible aux étapes pré-analytiques et donc aux variabilités intra et inter-laboratoires. Par conséquent, la validation absolue ne semble donc pas être l'approche la plus adéquate pour notre cas d'étude.

$$\text{écart}_c = |c_{cin_{in\ vitro}} - c_{cin_{in\ silico}}| \quad (\text{A.1})$$

	[TF] = 1 pM	[TF] = 5 pM
écart_{LT}	556.8 ± 127.4	362.1 ± 55.1
écart_{TP}	571.0 ± 240.3	323.6 ± 128.1
écart_{Peak}	$2.0e^{-07} \pm 6.8e^{-08}$	$2.7e^{-07} \pm 9.0e^{-08}$
écart_{ETP}	$3.9e^{-05} \pm 1.5e^{-05}$	$2.9e^{-05} \pm 8.7e^{-06}$

TABLE A.2 – Valeurs moyennes et écarts types résultants de l'application de l'équation (A.1) à l'ensemble des cinétiques étudiées.




FIGURE A.1 – Représentation graphique d'un couple de cinétiques *in vitro/in silico* pour lequel les écarts issus de l'équation (A.1) sont similaires aux valeurs moyennes présentées dans le tableau (A.2).

A.3.3.2 Validation relative

Dans l'optique d'évaluer un modèle numérique, il est également possible d'employer la validation relative. De par son principe de fonctionnement, elle permet de s'abstraire de la propriété de normalisation classiquement requise par la mesure de similarité. Dans le cas de la GT, l'amplitude des courbes impacte les calculs de LT et d'ETP et par définition, de hauteur de pic. Une telle approche permet donc de concentrer l'évaluation sur le comportement du modèle numérique à proprement parler. Pour ce faire, il est tout d'abord nécessaire de déterminer une valeur de référence. Dans le cas de la recherche biomédicale HémOTIV, nous avons choisi le patient dont les taux en facteur de la coagulation sont les plus proches des valeurs dites "normales". Il convient ensuite d'évaluer le degré de similarité existant entre une courbe mesurée *in vitro* et sa paire générée *in silico* en les confrontant toutes deux à leur référence respective. En d'autres termes, il s'agit ici de déterminer si la position relative d'une cinétique par rapport à sa référence est identique

dans les modèles d'étude *in vitro* et *in silico*. Les métriques utilisées sont le LT, le TTP, la hauteur du pic et l'ETP. Pour chacune des courbes de GT et chacune de ces quatre caractéristiques, nous calculons la distance (A.2) où c est la caractéristique concernée, cin la cinétique étudiée et ref la référence. De manière analogue à la validation absolue, les valeurs moyennes et les écarts types de ces distances sont présentés en table (A.3). Tenant compte de ces résultats et de la figure (A.2), nous constatons que le comportement du modèle numérique, bien que globalement en phase avec le système étudié, présente des écarts en termes de TTP et LT.

$$\text{écart}_c = |(c_{cin_{in vitro}} - c_{ref_{in vitro}}) - (c_{cin_{in silico}} - c_{ref_{in silico}})| \quad (\text{A.2})$$

	$[TF] = 1 \text{ pM}$	$[TF] = 5 \text{ pM}$
écart_{LT}	118.9 ± 98.8	46.3 ± 40.0
écart_{TTP}	199.3 ± 217.5	106.5 ± 109.8
écart_{Peak}	$6.9e^{-08} \pm 6.6e^{-08}$	$8.9e^{-08} \pm 7.0e^{-08}$
écart_{ETP}	$1.2e^{-05} \pm 9.4e^{-06}$	$6.2e^{-06} \pm 6.2e^{-06}$

TABLE A.3 – Valeurs moyennes et écarts types résultants de l'application de l'équation (A.2) à l'ensemble des cinétiques étudiées.




FIGURE A.2 – Représentation graphique d'un couple de cinétiques *in vitro/in silico* pour lequel les écarts issus de l'équation (A.2) sont similaires aux valeurs moyennes présentées dans le tableau (A.3).

A.4 Proposition de corrections

Afin de déterminer la cause de ce décalage temporel, nous avons observé l'influence des différents facteurs de la coagulation par le biais du modèle numérique. Pour ce faire, nous avons successivement fait fluctuer les concentrations initiales de chacun de ces facteurs entre zéro et le double de leur valeur "normale" en utilisant une échelle logarithmique. Les taux des protéines non étudiées ont par cohérence été affectés aux valeurs "normales". Par ailleurs, compte tenu de l'influence du facteur tissulaire sur le test de GT (DUCHEMIN et al., 2008), cette analyse a été réalisée avec $TF \in \{1 \text{ pM}; 5 \text{ pM}\}$. Les résultats ainsi obtenus indiquent que les concentrations initiales des facteurs II, V, VIIa et X sont fortement corrélées au LT, l'influence des autres facteurs sur cette caractéristique étant moindre ou négligeable. Par comparaison avec DUCHEMIN et al., 2008, nous pouvons constater que le comportement du modèle numérique semble cohérent. À titre d'exemple, l'influence du facteur II a été représentée en figure (A.3). Cependant, les auteurs de ce papier n'ont pas étudié l'influence du facteur VIIa. Cela peut être expliqué par le fait que le kit de dosage de cette protéine soit uniquement destiné à des fins de recherche et non de diagnostic. De ce fait, la littérature faisant écho de ce dosage s'avère être particulièrement pauvre. Nous avons donc émis l'hypothèse que la concentration initiale en facteur VIIa était la cause de ces écarts de LT. Afin de corriger son influence, deux propositions ont été réalisées.




FIGURE A.3 – Comparaison de l'influence du facteur II sur le modèle numérique (a) et celui étudié *in vitro* dans DUCHEMIN et al., 2008 (b). Le LT est représenté en axe des abscisses et les concentrations initiales en axe des ordonnées. Dans les deux cas, $[TF] = 1 \text{ pM}$.

A.4.1 Régression linéaire

En première intention, nous avons étudié la possibilité de corriger le taux de facteur VIIa par le biais d'une régression linéaire. Comme illustré en figure (A.4), nous avons tout d'abord déterminé le lien entre la concentration initiale en facteur VIIa et le LT. Le modèle, que nous avons obtenu par le biais d'une régression non-linéaire, se présente sous la forme d'une fonction exponentielle d'équation (A.3). Nous avons donc calculé le LT associé à chaque courbe *in vitro* puis appliqué notre modèle

non-linéaire dans l'optique de déterminer les concentrations en facteur VIIa estimées. Dans la suite de cette section, nous nommerons ces valeurs $[VIIa]_{in\ silico}$. Le but de cette étude étant d'obtenir une règle de correction, nous avons employé la méthode des moindres carrés afin de déterminer la relation existante entre le taux dosé $[VIIa]_{in\ vitro}$ et la valeur $[VIIa]_{in\ silico}$. La fonction linéaire obtenue pour le cas $[TF] = 1\ pM$ est représentée en figure (A.5). Tel que l'on peut facilement le constater, le coefficient de détermination qui lui est associé est particulièrement faible ($R^2 = 0.26$). Cette mauvaise explicabilité est potentiellement induite par : 1) la précision du kit de dosage du VIIa; 2) la faible quantité de patients présents dans la cohorte étudiée; 3) le fait que la concentration initiale en facteur VIIa ne soit pas l'unique source des écarts de LT. Malgré ces faits, nous avons tout de même souhaité évaluer l'apport de cette proposition de correction. Pour cela, nous avons réitéré le protocole de validation relative décrit précédemment. Les résultats sont présentés en table (A.4) et illustrés en figures (A.6) et (A.7).




FIGURE A.4 – Diagramme de dispersion où chaque point associe une concentration initiale en facteur VIIa à un LT pour $[TF] = 1\ pM$. La courbe rouge d'équation (A.3) est le modèle exponentiel résultant de la régression non-linéaire décrite en partie (A.4.1).




FIGURE A.5 – Diagramme de dispersion où chaque point associe un taux de VIIa dosé *in vitro* à sa valeur estimée par le biais du LT. La ligne pointillée d'équation $y = a.x + b$ où $[a, b] = [6.06, 173.95]$, est le modèle résultant de l'équation linéaire présentée en partie (A.4.1).

$$y = a.exp(-b.x) + c$$

$$[a, b, c] = [1.51e^3, 5.13e^{-3}, 2.81] \text{ à } [TF] = 1 \text{ pM}$$

$$[a, b, c] = [2.39e^3, 1.02e^{-2}, 2.21] \text{ à } [TF] = 5 \text{ pM}$$
(A.3)




FIGURE A.6 – Représentation graphique d'un couple de cinétiques *in vitro/in silico corrigé* pour lequel les écarts issus de (A.2) sont similaires aux valeurs moyennes présentées dans le tableau (A.4).




FIGURE A.7 – Illustration du couple de cinétiques *in vitro/in silico corrigé* pour ABD-BO, patient également représenté en figure (A.2)

	$[TF] = 1 \text{ pM}$	$[TF] = 5 \text{ pM}$
écart_{LT}	59.89 ± 41.11	14.05 ± 13.29
écart_{TTP}	93.79 ± 73.26	60.64 ± 49.33
écart_{peak}	$8.8e^{-8} \pm 8.8e^{-8}$	$1.01e^{-7} \pm 9.2e^{-8}$
écart_{ETP}	$1.2e^{-5} \pm 9.5e^{-6}$	$6.3e^{-6} \pm 6.2e^{-6}$

TABLE A.4 – Valeurs moyennes et écarts types résultants de l’application de l’équation (A.2) à l’ensemble des cinétiques corrigées par la proposition (A.4.1).

A.4.2 Coefficient multiplicateur

En seconde intention, nous avons ajouté un coefficient multiplicateur du taux de facteur VIIa au sein du modèle numérique. Afin d’en optimiser la valeur, nous l’avons fait fluctuer sur l’intervalle $[1; 150]$ dont les bornes ont été déterminées de manière empirique. Pour chacune des configurations évaluées, les courbes numériques ont été générées et confrontées à leurs paires *in vitro* en termes de LT et TTP. Ces écarts ont été calculés de manière relative par le biais de l’équation (A.2). L’utilisation du TTP en complément du LT a pour but d’éviter une déformation du pic et donc une altération de l’ETP. Du fait que ces deux valeurs soient alors à minimiser, nous avons appliqué l’équation (A.4) où c_{opt} est le coefficient optimal, c la liste des coefficients évalués, écart_{LT} l’écart relatif associé au LT et écart_{TTP} celui associé au TTP. Cette équation permet d’obtenir l’optimum de Pareto, principe que nous avons défini en section (3) de l’étude bibliographique. La valeur ainsi obtenue est égale à 71. Ces propos sont illustrés en graphique (A.8). Dans l’optique d’évaluer l’apport de cette proposition de correction, nous avons réitéré le protocole de validation relative décrit précédemment. Les résultats sont présentés en table (A.5) et en figures (A.9) et (A.10).




FIGURE A.8 – Représentation graphique des écarts moyens en LT et TTP pour l’ensemble des valeurs de coefficient multiplicateur évaluées. La valeur optimale est illustrée par le biais d’un axe d’équation $x = 71$

$$c_{opt} = c[\arg_min(\max(d_r - \min(d_r), d_a - \min(d_a)))] \quad (A.4)$$




FIGURE A.9 – Représentation graphique d’un couple de cinétiques *in vitro/in silico corrigé* pour lequel les écarts issus de (A.2) sont similaires aux valeurs moyennes présentées dans (A.5).




FIGURE A.10 – Illustration du couple de cinétiques *in vitro/in silico corrigé* pour ABD-BO, patient également représenté en figure (A.2)

	$[TF] = 1 \text{ pM}$	$[TF] = 5 \text{ pM}$
écart_{LT}	49.76 ± 38.10	12.96 ± 11.46
écart_{TTP}	70.78 ± 61.98	43.54 ± 37.73
écart_{Peak}	$9.7e^{-8} \pm 1.1e^{-7}$	$9.7e^{-8} \pm 9.2e^{-8}$
écart_{ETP}	$1.2e^{-5} \pm 9.5e^{-6}$	$6.3e^{-6} \pm 6.2e^{-6}$

TABLE A.5 – Valeurs moyennes et écarts types résultants de l’application de l’équation (A.2) à l’ensemble des cinétiques corrigées par la proposition (A.4.2).

A.4.3 Évaluation et discussion

En étudiant les résultats obtenus par le biais de ces propositions, nous pouvons constater une assez nette correction des disparités temporelles dans les deux cas. Bien que la régression linéaire soit plus intéressante sur le plan théorique, les validations relatives mettent en avant la proposition de coefficient multiplicateur. Nous utiliserons donc cette dernière pour corriger la concentration initiale en facteur VIIa. À titre de conclusion, nous pouvons statuer sur le fait que le modèle numérique soit pertinent d’un point de vue relatif. En ce qui concerne la validation absolue, il serait également possible de corriger les hauteurs de pics. Pour ce faire, nous pourrions simplement poursuivre ces corrections en normalisant les ensembles *in vitro* et *in silico* par le biais de leurs références respectives.

Malgré ces efforts, il ne faut pas omettre les variabilités inter et intra-laboratoire associées au test de GT. En d’autres termes, le fait que le modèle numérique soit pertinent dans le cas de la recherche biomédicale HémotIV n’est pas nécessairement généralisable à d’autres cohortes. Cet argument peut être appuyé par le fait que : 1) la base de données étudiée ne contienne qu’un faible nombre de cinétiques; 2) les lois cinétiques prises en compte ne s’avèrent valables que s’il y a inhibition de la polymérisation de la fibrine.

Compte tenu de la faible quantité de données, nous n’avons pas envisagé de correctif basé sur l’apprentissage automatique. Cependant, la structure de cette recherche biomédicale est propice à ce type d’étude ainsi qu’au développement d’un modèle pouvant être perçu comme une matrice de passage entre les milieux avec et sans Pefabloc®.

Base de données *in vitro*

B.5 Contexte

Du fait de l'étroite collaboration scientifique que Diagnostica Stago entretient avec la société Synapse Research Institute, institut de recherche spécialisé en génération de thrombine, une base de données *in vitro* a été générée spécifiquement pour nos travaux. Compte tenu de la faible prévalence de l'hémophilie et de fait, de la difficulté associée à l'obtention de plasmas de patients hémophiles A sévères et/ou modérés non médicamenteux, la conception de cette dernière s'est fondée sur une ingénieuse hypothèse biologique. Elle a notamment permis la simulation *in vitro* de plasmas déficients en facteur VIII par le biais de plasmas vrais de patients sains.

B.6 Hypothèse et preuve expérimentale

D'un point de vue théorique, il est envisageable d'administrer une dose d'anticorps anti-VIII au plasma d'un patient sain dans l'optique de simuler un plasma déficient en facteur VIII. De ce fait, il semble possible de mimer l'administration de concentrations croissantes en médicament anti-hémorragique au plasma d'un patient hémophile A sévère ou modéré, en injectant des concentrations décroissantes d'anticorps anti-VIII au plasma d'un patient sain. L'intérêt de cette hypothèse, dans la mesure où elle serait confirmée expérimentalement, est qu'elle simplifierait fortement le processus d'acquisition des plasmas vrais nécessaires à la construction de la base. Cette dernière pourrait donc être plus volumineuse, nous permettant ainsi de mieux entraîner et évaluer les différents sous-modèles qui composent notre proposition de CDSS.

Afin de vérifier cette hypothèse, un protocole expérimental a été mis en place. Nous

avons cherché à le valoriser sous la forme d'un résumé scientifique¹ actuellement en cours de soumission dans un congrès international. La suite de cette section, qui est consacrée à la présentation de cette étude, est donc rédigée en anglais.

Background : Thrombin generation (TG) is frequently measured in haemophilia patients to evaluate their baseline TG level, to monitor their response to therapy and to follow up patients in time. TG is also being used to compare efficacy and potency of potentially new treatment drugs. Many research groups use plasma from healthy controls spiked in vitro with an antibody (Ab) in order to mimic haemophilia plasma.

Aim : Our goal was to evaluate whether these in vitro mimicked samples have the same TG kinetics as haemophilia A samples and therefore are suitable for research purposes.

Methods : The Calibrated Automated Thrombogram was used to measure TG in plasma samples from healthy controls and haemophilia patients. Samples were spiked in vitro with recombinant FVIII (Kogenate, Bayer) and/or FVIII-Ab (PAHFVIII-S, HaemTech). Haemophilia A plasma was spiked with a buffer or with 100% FVIII and 15 µg/ml FVIII-Ab (to mimic haemophilia A again in the presence of the Ab). Plasma from healthy controls was spiked with 6 and 15 µg/ml FVIII-Ab. FVIII was measured using the STA R of Stago (France).

Results : When TG was measured in haemophilia A samples with and without FVIII-Ab, no differences could be observed between both plasma samples. A doses-response of FVIII could be observed for peak height, ETP, time-to-peak and velocity index but not for lagtime, that seemed to be independent of the FVIII level. The FVIII doses-response in healthy controls with 6 and 15 µg/ml were parallel to each other, indicating that the differences between the two curves were dependent of the remaining FVIII level (94%, 34% and >4% for the samples with 0, 6 and 15 µg/ml FVIII-Ab, respectively).

Conclusion : No substantial differences were observed in TG kinetics, indicating that in vitro induced haemophilia samples can be used to determine the response to FVIII treatment in haemophilia A.

B.7 Élaboration de la base de données

Suite à cette étude préliminaire, l'institut de recherche Synapse a amorcé la construction de la base de données *in vitro*. Pour ce faire, 120 plasmas vrais ont été approvisionnés auprès de la banque de sang de Maastricht. Afin de les surcharger en

1. Lasson F¹, Bai C.², De Laat B.², Ninivaggi M.² (2020). "*Prediction of the response to FVIII treatment in haemophilia A*". ¹ Diagnostica Stago S.A.S., Asnières sur Seine, France. ² Synapse Research Institute, Maastricht, the Netherlands. En cours de soumission au congrès *International Society on Thrombosis and Haemostasis* (ISTH).

anticorps anti-VIII, chacun de ces derniers a été divisé en 21 échantillons. Des doses d'anticorps de volumes identiques et dont les concentrations c appartiennent respectivement à l'ensemble E ont alors été administrées dans chaque échantillon. L'ensemble E exprimé en $\mu\text{g}/\text{mL}$ est tel que $E \in [0; 20] \cap \mathbb{N}$. Après obtention de l'équilibre, des dosages de facteur VIII ainsi que des tests de GT ont été réalisés. Les caractéristiques principales, à savoir l'ETP, la hauteur du pic, le TTP et le LT ont été extraits de ces résultats. À noter que les groupes sanguins associés à chacun de ces 120 plasmas sont également connus. Les figures (B.1) et (B.2) et le tableau (B.1) illustrent les différents résultats obtenus pour le plasma vrai n° 001.




FIGURE B.1 – Les deux graphiques ci-dessus représentent les résultats des tests de GT associés au plasma vrai n° 001. Les courbes présentes dans le graphique en première ligne sont issues de tests réalisés avec une concentration en facteur tissulaire à 1 pM, celles de la seconde ligne avec une concentration à 5 pM. Une légende permet de faire l'association entre ces courbes, les concentrations en anticorps et les noms présents dans la base.




FIGURE B.2 – Ces quatre graphiques illustrent les valeurs des différentes caractéristiques extraites des courbes de GT en fonction de la concentration des doses d'anticorps anti-VIII administrées au plasma n° 001. L'association à [TF]={1 pM; 5 pM} est réalisée par le biais de couleurs, respectivement {bleu; rouge}.

$FVIII_{Ab}$ (µg/ml)	0	1	2	3	4	5	6	7	8	9	10	11	12	13	14	15	16	17	18	19	20
$FVIII$ (%)	49	43	37	34	28	25	22	18	18	15	13	7	7	5	5	4	3	ND	ND	ND	ND

TABLE B.1 – Le tableau ci-dessus représente les résultats des dosages en facteur VIII pour les différentes concentrations en anticorps qui ont été administrées au plasma vrai n° 001. "ND" signifie que le taux n'est pas détectable.

Tel que nous pouvons le constater dans le tableau (B.1), de nombreux dosages n'ont pas abouti. Afin de mesurer les différents taux en facteur VIII, l'institut de recherche Synapse a réalisé des dosages en calibration standard dont les limites de détection appartiennent à l'ensemble [3%; 150%]. Cependant, au vu des fortes concentrations en anticorps administrées dans certains échantillons, il est concevable que certains taux soient inférieurs à la limite basse. Pour y remédier, des dosages en courbes basses auraient dû être réalisés. Cette solution expérimentale n'ayant pas été effectuée, nous avons cherché à estimer ces valeurs par le biais d'un modèle mathématique. Par ailleurs, nous pouvons constater en figure (B.1), que certains tests de GT ont également échoué.

Après analyse complète de la base de données, nous avons constaté que 37% des dosages de facteur VIII n'ont pas abouti. Par ailleurs, plusieurs plasmas vrais ont dû être écartés. Les causes principales étaient l'absence de courbe de contrôle


et la présence d'un fort bruit expérimental ou de valeurs aberrantes. En définitive, la base de données constituée à partir des tests de GT réalisés à $[TF]=1$ pM est composée de 2107 cinétiques, lesquelles étant associées à 115 plasmas vrais. En ce qui concerne la base issue des tests à $[TF]=5$ pM, seuls trois plasmas ont dû être écartés. Elle contient 2315 cinétiques associées à 117 plasmas vrais. Dans le cadre de l'application présentée en chapitre (III), seules les courbes à $[TF]=1$ pM seront exploitées. Les cinétiques à $[TF]=5$ pM serviront néanmoins pour des travaux futurs.

B.8 Modélisation mathématique

Comme énoncé précédemment, une majeure partie des dosages de facteur VIII n'ont pas abouti du fait du type de calibration utilisé lors des manipulations expérimentales. Les résultats de ces dosages sont cependant indispensables à la construction de la sous-base de données destinée au développement du modèle conditionnel. En l'absence de ces taux, l'intégralité des courbes de GT qui leur sont associées devra être écartée. Cela représente 37% de la base soit approximativement 900 cinétiques. Au vu de leur importance, tant pour nos modèles d'apprentissage automatique que de par la quantité de travail imposée par leurs générations, les ignorer ne semble pas concevable. De ce fait, nous avons donc cherché à démontrer la relation existante entre le facteur VIII et son anticorps polyclonal par le biais d'un modèle mathématique.

B.8.1 Mise en équation

La réaction entre le facteur VIII de la coagulation (noté $VIII$) et son anticorps polyclonal (noté $VIII_{Ab}$) est donnée par :



Cette réaction est décrite par le système d'EDO suivant :

$$\begin{cases} \frac{d[VIII_{Ab}]}{dt} = -k_{on}[VIII_{Ab}][VIII] + k_{off}[VIII_{Ab} \cdot VIII] \\ \frac{d[VIII]}{dt} = -k_{on}[VIII_{Ab}][VIII] + k_{off}[VIII_{Ab} \cdot VIII] \\ \frac{d[VIII_{Ab} \cdot VIII]}{dt} = +k_{on}[VIII_{Ab}][VIII] - k_{off}[VIII_{Ab} \cdot VIII] \end{cases}$$

À l'équilibre, soit quand t tend vers $+\infty$, on a :

$$\frac{d[VIII_{Ab}]}{dt} = \frac{d[VIII]}{dt} = \frac{d[VIII_{Ab} \cdot VIII]}{dt} = 0$$

On obtient alors :

$$K_D = \frac{[VIII_{Ab}]_{\infty}[VIII]_{\infty}}{[VIII_{Ab} \cdot VIII]_{\infty}} \quad (B.1)$$

Où :

$$K_D = \frac{k_{off}}{k_{on}} \quad \text{avec } k_{on} \geq 0 \text{ et } k_{off} \geq 0 \quad (B.2)$$

Les lois de conservation de la masse donnent :

$$\begin{cases} [VIII_{Ab}]_0 = [VIII_{Ab}]_{\infty} + [VIII_{Ab} \cdot VIII]_{\infty} \\ [VIII]_0 = [VIII]_{\infty} + [VIII_{Ab} \cdot VIII]_{\infty} \end{cases}$$

soit :

$$\begin{cases} [VIII_{Ab}]_{\infty} = [VIII_{Ab}]_0 - [VIII_{Ab} \cdot VIII]_{\infty} \\ [VIII]_{\infty} = [VIII]_0 - [VIII_{Ab} \cdot VIII]_{\infty} \end{cases} \quad (B.3)$$

L'équation (B.1) devient alors :

$$K_D = \frac{([VIII_{Ab}]_0 - [VIII_{Ab} \cdot VIII]_{\infty})([VIII]_0 - [VIII_{Ab} \cdot VIII]_{\infty})}{[VIII_{Ab} \cdot VIII]_{\infty}}$$

soit :

$$\begin{aligned} & [VIII_{Ab} \cdot VIII]_{\infty}^2 - ([VIII_{Ab}]_0 + [VIII]_0 + K_D)[VIII_{Ab} \cdot VIII]_{\infty} \\ & + [VIII_{Ab}]_0[VIII]_0 = 0 \end{aligned}$$

Afin de résoudre cette équation du second degré, il est tout d'abord nécessaire de calculer son déterminant :

$$\Delta = ([VIII_{Ab}]_0 + [VIII]_0 + K_D)^2 - 4[VIII_{Ab}]_0[VIII]_0$$

soit :

$$\Delta = ([VIII_{Ab}]_0 - [VIII]_0)^2 + K_D^2 + 2K_D([VIII_{Ab}]_0 + [VIII]_0)$$

Tenant compte de l'équation (B.2) et du fait qu'une concentration soit par définition positive, $\Delta > 0$, on obtient ainsi :

$$[VIII_{Ab} \cdot VIII]_\infty = \frac{[VIII_{Ab}]_0 + [VIII]_0 + K_D}{2} \pm \frac{\sqrt{([VIII_{Ab}]_0 + [VIII]_0 + K_D)^2 - 4[VIII_{Ab}]_0[VIII]_0}}{2}$$

(B.3) nous permet alors d'obtenir les deux solutions suivantes :

$$[VIII]_\infty = [VIII]_0 - \frac{[VIII_{Ab}]_0 + [VIII]_0 + K_D}{2} \pm \frac{\sqrt{([VIII_{Ab}]_0 + [VIII]_0 + K_D)^2 - 4[VIII_{Ab}]_0[VIII]_0}}{2} \quad (B.4)$$

Considérons désormais le cas où la concentration d'anticorps administrée dans l'échantillon est nulle, c'est-à-dire où $[VIII_{Ab}]_0 = 0$. L'équation (B.4) se simplifie alors de la façon suivante :

$$[VIII]_\infty = \frac{[VIII]_0 - K_D}{2} \pm \frac{[VIII]_0 + K_D}{2}$$

Considérons alors les solutions distinctes de (B.4) :

$$\begin{cases} [VIII]_\infty = [VIII]_0 & (solution\ 1) \\ [VIII]_\infty = -K_D & (solution\ 2) \end{cases}$$

La *solution 1* est en adéquation avec la réalité biologique du cas considéré. La *solution 2* quant à elle n'est pas concevable puisque $K_D > 0$ et $[VIII]_\infty \geq 0$. La relation $[VIII]_\infty = f([VIII_{Ab}]_0)$ est alors représentée par l'équation subséquente.

$$[VIII]_{\infty} = [VIII]_0 - \frac{[VIII_{Ab}]_0 + [VIII]_0 + K_D}{2} + \frac{\sqrt{([VIII_{Ab}]_0 + [VIII]_0 + K_D)^2 - 4[VIII_{Ab}]_0[VIII]_0}}{2} \quad (B.5)$$

B.8.2 Conversion des unités

Dans l'optique d'appliquer l'équation (B.5), nous devons tout d'abord homogénéiser les unités des concentrations du facteur VIII et de son anticorps polyclonal.

B.8.2.1 Protocole expérimental de dosage

Afin de réaliser le dosage de ce facteur, 30 μL de $VIII_{Ab}$ sont ajoutés à 1770 μL de PPP. Une solution de 1800 μL de plasma est ainsi obtenue. L'anticorps utilisé est le *Sheep anti-Human Factor VIII* de la société *Haematologic Technologies* dont la masse moléculaire est de 150 kDa . Ces dosages ont été réalisés sur un instrument STA-R de Diagnostica STAGO en suivant le protocole STA-ImmunoDefVIII-C.K.Prest.

B.8.2.2 Conversion des taux de FVIII

Tel qu'indiqué dans BUTENAS et al., 2002 :

$$[FVIII]_{\%} = 100\% \Leftrightarrow [FVIII]_{nM} = 0.7 nM$$

Or, le PPP est dilué dans le cadre de ce dosage. On a donc :

$$[FVIII]_{nM} = \frac{[FVIII]_{\%}}{100} * 0.7 * \frac{1770}{1800} \quad (B.6)$$

B.8.2.3 Conversion des concentrations d'anticorps

On sait que :

$$[FVIII_{Ab}]_{\mu g/mL} = [FVIII_{Ab}]_{g/L} * \frac{10^{-3}}{10^{-6}} = [FVIII_{Ab}]_{g/L} * 10^3$$

D'où :

$$[FVIII_{Ab}]_{g/L} = [FVIII_{Ab}]_{\mu g/mL} * 10^{-3}$$

Pour ce dosage, 30 μL de $VIII_{Ab}$ sont ajoutés à 1770 μL de PPP. La masse d'anticorps associée à ce volume est :

$$masse_g = [FVIII_{Ab}]_{\mu g/mL} * 10^{-3} * 30.10^{-6} = [FVIII_{Ab}]_{\mu g/mL} * 30.10^{-9}$$

Or, la masse moléculaire de l'anticorps est de 150 kDa , c'est-à-dire 150000 g/mol .
Donc :

$$quantité_{mol} = [FVIII_{Ab}]_{\mu g/mL} * \frac{30.10^{-9}}{150000}$$

Le volume de plasma total étant de 1800 μL , la concentration en anticorps après dilution est alors :

$$[FVIII_{Ab}]_M = [FVIII_{Ab}]_{\mu g/mL} * \frac{30.10^{-9}}{150000 * 1800.10^{-6}} = \frac{[FVIII_{Ab}]_{\mu g/mL}}{9} * 10^{-9}$$

soit :

$$\boxed{[FVIII_{Ab}]_{nM} = \frac{[FVIII_{Ab}]_{\mu g/mL}}{9}} \quad (B.7)$$

B.8.3 Application du modèle

Ayant l'ensemble des éléments nécessaires à disposition, nous avons alors appliqué ce modèle mathématique (B.5) aux différents dosages présents dans la base de données. Pour ce faire, nous avons tout d'abord utilisé les équations (B.6) et (B.7) afin d'homogénéiser les unités des concentrations. Suite à cela, nous avons souhaité déterminer la valeur de K_D en s'appuyant sur une librairie Python de calcul scientifique nommée Scipy. Plus précisément, nous avons appliqué la méthode "*curve_fit*" qui permet de réaliser des régressions non-linéaires au sens des moindres carrés. Deux approches ont alors été envisagées : 1) déterminer une valeur de K_D spécifique à chaque plasma; 2) déterminer une valeur de K_D globale à l'ensemble des plasmas vrais.

Du fait de la variabilité expérimentale induite par la précision des dosages, tant sur l'aspect reproductibilité que répétabilité, les valeurs des $[VIII]_0$ ont également été déterminées par la méthode de régression non linéaire. Les $[VIII]_0$ dosés ont uniquement été utilisés à titre de conditions initiales.

B.8.3.1 Détermination d'un K_D spécifique

Afin de déterminer la justesse du modèle proposé, nous avons calculé pour chaque plasma l'erreur quadratique moyenne (MSE) entre les dosages expérimentaux et les dosages estimés. Ne souhaitant pas introduire de biais dans cette étude, nous avons exclu l'intégralité des dosages dont les résultats n'appartenaient pas l'intervalle de détection [3%, 150%]. Ayant connaissance de l'historique de la base, nous avons également écarté les plasmas 1 à 13 inclus du fait d'une incertitude sur les concentrations d'anticorps qui y ont été administrées. Tel que nous pouvons le constater dans l'exemple présenté en figure (B.3), le modèle semble être en phase avec la réalité expérimentale. En ce qui concerne le taux d'erreur obtenu, il est particulièrement faible puisque la MSE globale est égale à $1,58.10^{-4}$ et ce, malgré l'échelle exprimée en nanomolaire (nM).




FIGURE B.3 – Régression non-linéaire et détermination d'un K_D spécifique pour le plasma vrai n° 026

B.8.3.2 Détermination d'un K_D global

L'intérêt d'obtenir un K_D global est notable puisqu'une telle valeur permettrait de démontrer la robustesse du modèle mathématique et la fiabilité des manipulations expérimentales. Pour ce faire, nous avons tout d'abord représenté la distribution des valeurs de K_D spécifiques à chaque plasma. Elle est illustrée par le biais d'un histogramme en figure (B.4). La valeur moyenne de K_D est de $6,46.10^{-2}$ et l'écart type est égal à $2,32.10^{-2}$, soit un coefficient de variabilité de 0,36. En utilisant cette valeur moyenne comme valeur globale de K_D , nous obtenons une MSE égale à $4,82.10^{-2}$.




FIGURE B.4 – Distribution des valeurs de K_D





FIGURE B.5 – K_D spécifique au plasma n° 026 versus K_D global.

FIGURE B.6 – K_D spécifique au plasma n° 024 versus K_D global.

B.8.3.3 Discussion

Afin de confronter ces deux approches, nous les avons représentées en figure (B.5) et (B.6). Bien que la MSE soit plus élevée dans le cas du K_D global que dans le cas du K_D spécifique, le modèle ainsi obtenu n'est pas pour autant aberrant. Néanmoins, dans l'optique d'obtenir la meilleure précision possible, les différents taux de VIII qui n'ont pas pu être déterminés expérimentalement seront estimés par le biais de l'approche spécifique à chaque plasma.

Bibliographie

- AKBARI, Reza, Ramin HEDAYATZADEH, Koorush ZIARATI et Bahareh HASSANIZADEH (2012). « A multi-objective artificial bee colony algorithm ». In : *Swarm and Evolutionary Computation* 2, p. 39-52. ISSN : 2210-6502. DOI : <https://doi.org/10.1016/j.swevo.2011.08.001> (cf. p. 32, 106).
- ALAYA, I., C. SOLNON et K. GHEDIRA (oct. 2007). « Ant Colony Optimization for Multi-Objective Optimization Problems ». In : *19th IEEE International Conference on Tools with Artificial Intelligence (ICTAI 2007)*. T. 1, p. 450-457. DOI : 10.1109/ICTAI.2007.108 (cf. p. 33, 106).
- ANDREW, Y. Ng (1997). « Preventing "Overfitting" of Cross-Validation Data ». In : *In Proceedings of the Fourteenth International Conference on Machine Learning*. Morgan Kaufmann, p. 245-253 (cf. p. 12, 21).
- ASHFAHANI, Andri, Mahardhika PRATAMA, Edwin LUGHOFFER et Yew Soon ONG (2020). *DEV DAN : Deep Evolving Denoising Autoencoder* (cf. p. 29).
- BAK, Slawomir, Sundaram SURESH, François BREMOND et Monique THONNAT (fév. 2009). « FUSION OF MOTION SEGMENTATION WITH ONLINE ADAPTIVE NEURAL CLASSIFIER FOR ROBUST TRACKING ». In : *Int. Joint Conf. on Computer Vision, Imaging and Computer Graphics Theory and Applications (VISAPP)*. Lisbon, Portugal. URL : <https://hal.inria.fr/inria-00496120> (cf. p. 23).
- BAUNSGAARD, D., A. D. NIELSEN, P. F. NIELSEN, A. HENRIKSEN, A. K. KRISTENSEN, H. W. BAGGER et M. EZBAN (2018). « A comparative analysis of heterogeneity in commercially available recombinant factor VIII products ». In : *Haemophilia* 24.6, p. 880-887. DOI : 10.1111/hae.13497 (cf. p. 73).
- BEGGEL, Laura, Michael PFEIFFER et Bernd BISCHL (2019). « Robust Anomaly Detection in Images using Adversarial Autoencoders ». In : *CoRR* abs/1901.06355. URL : <http://arxiv.org/abs/1901.06355> (cf. p. 113).
- BENGIO, Y (jan. 2009). « Learning Deep Architectures for AI ». In : *Found. Trends Mach. Learn.* 2.1, p. 1-127 (cf. p. xxi, 16).
- BENGIO, Y, L PASCAL, P DAN et H LAROCHELLE (2007). « Greedy Layer-Wise Training of Deep Networks ». In : *Advances in Neural Information Processing Systems 19*. Sous la dir. de P. B. SCHÖLKOPF, J. C. PLATT et T. HOFFMAN. MIT Press, p. 153-160 (cf. p. 16).
- BENGIO, Yoshua et Yann LECUN (2007). « Scaling Learning Algorithms Towards AI ». In : *Large Scale Kernel Machines*. Sous la dir. de Léon BOTTOU, Olivier CHAPPELLE, D. DECOSTE et J. WESTON. Cambridge, MA : MIT Press. URL : http://www.iro.umontreal.ca/~lisa/pointeurs/bengio+lecun_chapter2007.pdf (cf. p. 16).

- BENITEZ-HIDALGO, Antonio, Antonio J. NEBRO, José GARCIA-NIETO, Izaskun OREGI et Javier Del SER (2019). « jMetalPy : a Python Framework for Multi-Objective Optimization with Metaheuristics ». In : *CoRR* abs/1903.02915. arXiv : 1903.02915. URL : <http://arxiv.org/abs/1903.02915> (cf. p. 104).
- BERGSTRA, J et Y BENGIO (fév. 2012). « Random Search for Hyper-parameter Optimization ». In : *J. Mach. Learn. Res.* 13, p. 281-305. URL : <http://dl.acm.org/citation.cfm?id=2188385.2188395> (cf. p. 12, 21).
- BERKSON, Joseph (1956). « Estimation by Least Squares and by Maximum Likelihood ». In : *Proceedings of the Third Berkeley Symposium on Mathematical Statistics and Probability, Volume 1 : Contributions to the Theory of Statistics*. University of California Press, p. 1-11. URL : <https://projecteuclid.org/euclid.bsmsp/1200501642> (cf. p. 10).
- BINITHA, S. et S. SIVA SATHYA (2012). « A Survey of Bio inspired Optimization Algorithms ». In : (cf. p. xxi, 30).
- BJÖRKMAN, Sven, MyungShin OH, Gerald SPOTTS, Phillip SCHROTH, Sandor FRITSCH, Bruce M. EWENSTEIN, Kathleen CASEY, Kathelijn FISCHER, Victor S. BLANCHETTE et Peter W. COLLINS (jan. 2012). « Population pharmacokinetics of recombinant factor VIII : the relationships of pharmacokinetics to age and body weight ». In : *Blood* 119.2, p. 612-618. ISSN : 0006-4971. DOI : 10.1182/blood-2011-07-360594. URL : <https://doi.org/10.1182/blood-2011-07-360594> (cf. p. 73, 74).
- BLIER, Léonard, Pierre WOLINSKI et Yann OLLIVIER (2018). « Learning with Random Learning Rates ». In : *CoRR* abs/1810.01322. arXiv : 1810.01322. URL : <http://arxiv.org/abs/1810.01322> (cf. p. 28, 29).
- BOUSMALIS, K., A. IRPAN, P. WOHLHART, Y. BAI, M. KELCEY, M. KALAKRISHNAN, L. DOWNS, J. IBARZ, P. PASTOR, K. KONOLIGE, S. LEVINE et V. VANHOUCKE (mai 2018). « Using Simulation and Domain Adaptation to Improve Efficiency of Deep Robotic Grasping ». In : *2018 IEEE International Conference on Robotics and Automation (ICRA)*, p. 4243-4250. DOI : 10.1109/ICRA.2018.8460875 (cf. p. 20).
- BRAUN, PJ, TB GIVENS, AG STEAD, LR BECK, SA GOOCH, RJ SWAN et TJ FISCHER (sept. 1997). « Properties of optical data from activated partial thromboplastin time and prothrombin time assays ». In : *Thrombosis and haemostasis* 78.3, p. 1079-1087. ISSN : 0340-6245. URL : <http://europepmc.org/abstract/MED/9308757> (cf. p. xviii).
- BRINKMAN, Herm Jan (déc. 2015). « Global assays and the management of oral anticoagulation ». In : *Thrombosis Journal* 13. DOI : 10.1186/s12959-015-0037-1 (cf. p. xviii, 69).
- BUTENAS, S., K. G. MANN et BUTENAS (jan. 2002). « Blood Coagulation ». In : *Biochemistry (Moscow)* 67.1, p. 3-12. ISSN : 1608-3040. DOI : 10.1023/A:1013985911759. URL : <https://doi.org/10.1023/A:1013985911759> (cf. p. 134).
- CATE, Hugo ten, Yvonne HENSKENS et Marcus LANCÉ (déc. 2017). « Practical guidance on the use of laboratory testing in the management of bleeding in patients receiving direct oral anticoagulants ». In : *Vascular Health and Risk Management* Volume 13, p. 457-467. DOI : 10.2147/VHRM.S126265 (cf. p. xviii).
- CHANDOLA, V., A. BANERJEE et V. KUMAR (2009). « Anomaly Detection : A Survey ». In : 15 :30 (cf. p. 13, 14, 93).

- CHELLE, Pierre (juin 2017). « Vers une définition patient-spécifique du taux cible de facteur anti-hémophilique à partir de la génération de thrombine : Apports des approches expérimentales et des modèles dynamiques de la cascade de la coagulation ». Theses. Université de Lyon. URL : <https://tel.archives-ouvertes.fr/tel-01848726> (cf. p. xvii, 68, 71, 76).
- CHELLE, Pierre, Aurélie MONTMARTIN, Michelle PIOT, L. ARDILLON, B. WIBAUT, B. FROTSCHER, M. COUNIL, Claire MORIN et Brigitte PONCET (juin 2018). « Prediction of individual factor VIII or IX level for the correction of thrombin generation in haemophilic patients ». In : *Haemophilia* 24. DOI : 10.1111/hae.13539 (cf. p. 71, 97).
- CLEVERT, Djork-Arné, Thomas UNTERTHINER et Sepp HOCHREITER (2015). *Fast and Accurate Deep Network Learning by Exponential Linear Units (ELUs)*. arXiv : 1511.07289 [cs.LG] (cf. p. 5).
- COELLO, Carlos, Depto ING et Maximino LECHUGA (juil. 2003). « MOPSO : A Proposal for Multiple Objective Particle Swarm ». In : (cf. p. 31, 32).
- COMMISSION, Clinical Excellence (2019). *High-Risk Medicines Management Policy*. URL : https://www1.health.nsw.gov.au/pds/ActivePDSDocuments/PD2019_058.pdf (cf. p. xvii, 114).
- CRÉPIN, Laurent (oct. 2013). « Population and individual-based model coupling for the parallel simulation of biological systems : application to blood coagulation ». Theses. Université de Bretagne occidentale - Brest. URL : <https://tel.archives-ouvertes.fr/tel-00880516> (cf. p. 75, 115-118).
- DAI, Wenyuan, Qiang YANG, Gui-Rong XUE et Yong YU (2008). « Self-Taught Clustering ». In : *Proceedings of the 25th International Conference on Machine Learning. ICML '08*. Helsinki, Finland : Association for Computing Machinery, p. 200-207. ISBN : 9781605582054. DOI : 10.1145/1390156.1390182. URL : <https://doi.org/10.1145/1390156.1390182> (cf. p. 20).
- DAUPHIN, Yann N., Razvan PASCANU, Çağlar GÜLÇEHRE, Kyunghyun CHO, Surya GANGULI et Yoshua BENGIO (2014). « Identifying and attacking the saddle point problem in high-dimensional non-convex optimization ». In : *CoRR* abs/1406.2572. URL : <http://arxiv.org/abs/1406.2572> (cf. p. 17).
- Documentation Tensorflow* (2020). URL : https://www.tensorflow.org/api_docs/python/tf/keras/regularizers/l1 (cf. p. 54).
- DOERSCH, Carl (2016). *Tutorial on Variational Autoencoders* (cf. p. 8).
- DOWSON, D.C et B.V LANDAU (1982). « The Fréchet distance between multivariate normal distributions ». In : *Journal of Multivariate Analysis* 12.3, p. 450-455. ISSN : 0047-259X. DOI : [https://doi.org/10.1016/0047-259X\(82\)90077-X](https://doi.org/10.1016/0047-259X(82)90077-X) (cf. p. 112).
- DUCHEMIN, Jérôme, Brigitte PAN-PETESCH, Bertrand ARNAUD, Marie-Thérèse BLOUCH et Jean-François ABGRALL (mai 2008). « Influence of coagulation factors and tissue factor concentration on the thrombin generation test in plasma ». In : *Thrombosis and haemostasis* 99, p. 767-73. DOI : 10.1160/TH07-09-0581 (cf. p. 118, 121).
- DUCHI, John, Elad HAZAN et Yoram SINGER (juil. 2011). « Adaptive Subgradient Methods for Online Learning and Stochastic Optimization ». In : *Journal of Machine Learning Research* 12, p. 2121-2159 (cf. p. 10).

- ELL, Danchin, C. MDIGUE, O. Gascuel T et H. SOLDANO (1991). *From data banks to data bases* (cf. p. 115).
- ERHAN, D, Y BENGIO, A COURVILLE, P-A MANZAGOL, P VINCENT et S BENGIO (2010). « Why Does Unsupervised Pre-training Help Deep Learning? » In : *JMLR* (cf. p. 17, 19, 43, 45, 46).
- ETNER, François (2012). *Microéconomie*. Presses Universitaires de France, p. 251-269 (cf. p. 32).
- FAHLMAN, Scott E. et Christian LEBIERE (1990). « The Cascade-Correlation Learning Architecture ». In : *Advances in Neural Information Processing Systems 2*. Sous la dir. de D. S. TOURETZKY. Morgan-Kaufmann, p. 524-532. URL : <http://papers.nips.cc/paper/207-the-cascade-correlation-learning-architecture.pdf> (cf. p. 22, 23).
- FAWCETT, T (juin 2006). « An Introduction to ROC Analysis ». In : *Pattern Recogn. Lett.* 27.8, p. 861-874. ISSN : 0167-8655. DOI : 10.1016/j.patrec.2005.10.010. URL : <http://dx.doi.org/10.1016/j.patrec.2005.10.010> (cf. p. 15, 93).
- FRÉCHET, Maurice (1957). « Sur la distance de deux lois de probabilité ». In : *COMPTES RENDUS HEBDOMADAIRES DES SEANCES DE L ACADEMIE DES SCIENCES* 244.6, p. 689-692 (cf. p. 112).
- FREY, Brendan et Delbert DUECK (mar. 2007). « Clustering by Passing Messages Between Data Points ». In : *Science (New York, N.Y.)* 315, p. 972-6. DOI : 10.1126/science.1136800 (cf. p. 53).
- GÉRON, A. (2017). *Deep Learning avec TensorFlow*. Hors Collection. Dunod. ISBN : 9782100767472. URL : <https://books.google.fr/books?id=Aa0-DwAAQBAJ> (cf. p. 5, 45).
- GLOROT, Xavier et Yoshua BENGIO (13-15 May 2010). « Understanding the difficulty of training deep feedforward neural networks ». In : *Proceedings of the Thirteenth International Conference on Artificial Intelligence and Statistics*. T. 9. Proceedings of Machine Learning Research. Chia Laguna Resort, Sardinia, Italy : PMLR, p. 249-256 (cf. p. 18, 45, 81, 82, 91, 93, 107).
- GLOROT, Xavier, Antoine BORDES et Y. BENGIO (juin 2011). « Domain Adaptation for Large-Scale Sentiment Classification : A Deep Learning Approach ». In : (cf. p. 20).
- GLOROT, Xavier, Antoine BORDES et Yoshua BENGIO (2011). « Deep Sparse Rectifier Neural Networks ». In : *Proceedings of the Fourteenth International Conference on Artificial Intelligence and Statistics*. T. 15. Proceedings of Machine Learning Research. PMLR, p. 315-323 (cf. p. 37).
- GOODFELLOW, Ian, Yoshua BENGIO et Aaron COURVILLE (2016). *Deep Learning*. <http://www.deeplearningbook.org>. MIT Press (cf. p. xxi, 3, 6, 9, 10, 12, 16, 17, 22, 26, 37, 43, 112).
- GOODFELLOW, Ian J., Jean POUGET-ABADIE, Mehdi MIRZA, Bing XU, David WARDEFARLEY, Sherjil OZAIR, Aaron COURVILLE et Yoshua BENGIO (2014). *Generative Adversarial Networks* (cf. p. 80, 92).
- GUILLEMOT, Mathilde, Sylvianne SCHNEBERT, Catherine HEUSÈLE, Maxime PETIT, Rodolphe KORICHI et Liming CHEN (mai 2019). « Tuning Neural network hyperparameters through Bayesian optimization and Application to cosmetic formulation data ». In : *ORASIS 2019 - Journées francophones des jeunes chercheurs en*

- vision par ordinateur*. Saint-Dié-des-Vosges, France. URL : <https://orasis2019.sciencesconf.org/254213/document> (cf. p. 28).
- HAN, Song, Jeff POOL, John TRAN et William J. DALLY (2015). « Learning both Weights and Connections for Efficient Neural Networks ». In : *CoRR* abs/1506.02626. URL : <http://arxiv.org/abs/1506.02626> (cf. p. 23).
- HARKANEN, Marja, Katri VEHVILAINEN-JULKUNEN, Trevor MURRELLS, Anne Marie RAFFERTY et Bryony Dean FRANKLIN (2019). « Medication administration errors and mortality : Incidents reported in England and Wales between 2007—2016 ». In : *Research in Social and Administrative Pharmacy* 15.7, p. 858-863. ISSN : 1551-7411. DOI : <https://doi.org/10.1016/j.sapharm.2018.11.010> (cf. p. xvii).
- HARTERT, H (1948). « Coagulation analysis with thromboelastography, a new method ». In : *Klin Wochenschr* 26, p. 577-658 (cf. p. xviii).
- HAWKINS, Simon, Hongxing HE, Graham WILLIAMS et Rohan BAXTER (2002). « Outlier Detection Using Replicator Neural Networks ». In : *Data Warehousing and Knowledge Discovery*. Sous la dir. d'Yahiko KAMBAYASHI, Werner WINIWARDER et Masatoshi ARIKAWA. Berlin, Heidelberg : Springer Berlin Heidelberg, p. 170-180 (cf. p. 14, 113).
- HE, Kaiming, Xiangyu ZHANG, Shaoqing REN et Jian SUN (2015a). « Deep Residual Learning for Image Recognition ». In : *CoRR* abs/1512.03385. URL : <http://arxiv.org/abs/1512.03385> (cf. p. 20).
- (2015b). « Delving Deep into Rectifiers : Surpassing Human-Level Performance on ImageNet Classification ». In : *CoRR* abs/1502.01852 (cf. p. 5, 18).
- HEMKER, H, P GIESEN, R ALDIERI, V REGNAULT, E SMEDT, R WAGENVOORD, T LE-COMPTE et S BEGUIN (2003). « Calibrated Automated Thrombin Generation Measurement in Clotting Plasma ». In : *Pathophysiol Haemos Thromb*, p. 4-15 (cf. p. xviii, 69).
- HINTON, G. E., S. OSINDERO et Y. W. TEH (2006). « A Fast Learning Algorithm for Deep Belief Nets ». In : *Neural Computation* 18, p. 1527-1554 (cf. p. 7, 18).
- HINTON, Geoffrey E et Ruslan R SALAKHUTDINOV (2006). « Reducing the dimensionality of data with neural networks ». In : *science* 313.5786, p. 504-507 (cf. p. 6, 16-19).
- HOCHREITER, Sepp et Jürgen SCHMIDHUBER (déc. 1997). « Long Short-term Memory ». In : *Neural computation* 9, p. 1735-80. DOI : 10.1162/neco.1997.9.8.1735 (cf. p. 112).
- HOLLAND, John H. (1975). *Adaptation in Natural and Artificial Systems : An Introductory Analysis with Applications to Biology, Control and Artificial Intelligence*. Ann Arbor, MI : University of Michigan Press (cf. p. 31).
- HORNIK, Kurt, Maxwell STINCHCOMBE et Halbert WHITE (1989). « Multilayer feed-forward networks are universal approximators ». In : *Neural Networks* 2.5, p. 359-366. ISSN : 0893-6080. DOI : [https://doi.org/10.1016/0893-6080\(89\)90020-8](https://doi.org/10.1016/0893-6080(89)90020-8) (cf. p. 16).
- JACOBS, Robert A. (1988). « Increased rates of convergence through learning rate adaptation ». In : *Neural Networks* 1.4, p. 295-307. ISSN : 0893-6080. DOI : [https://doi.org/10.1016/0893-6080\(88\)90003-2](https://doi.org/10.1016/0893-6080(88)90003-2). URL : <http://www.sciencedirect.com/science/article/pii/0893608088900032> (cf. p. 10).

- JAPKOWICZ, Nathalie, Catherine MYERS et Mark GLUCK (1995). « A Novelty Detection Approach to Classification ». In : *Proceedings of the 14th International Joint Conference on Artificial Intelligence - Volume 1*. IJCAI'95. Montreal, Quebec, Canada : Morgan Kaufmann Publishers Inc., p. 518-523. ISBN : 1558603638 (cf. p. 14).
- JASTRZKEBSKI, Stanislaw, Zachary KENTON, Devansh ARPIT, Nicolas BALLAS, Asja FISCHER, Yoshua BENGIO et Amos J. STORKEY (2017). « Three Factors Influencing Minima in SGD ». In : *CoRR* abs/1711.04623. arXiv : 1711 . 04623. URL : [http : //arxiv.org/abs/1711.04623](http://arxiv.org/abs/1711.04623) (cf. p. 10).
- JONGMIN YU, JEONGHWAN GWAK, SEJEONG LEE et MOONGU JEON (oct. 2015). « An incremental learning approach for restricted boltzmann machines ». In : *2015 International Conference on Control, Automation and Information Sciences (ICCAIS)*, p. 113-117. DOI : 10.1109/ICCAIS.2015.7338643 (cf. p. 21).
- KAPLAN, B (2001). « Evaluating informatics applications—clinical decision support systems literature review ». In : *Int J Med Inform*, p. 15-37 (cf. p. xix).
- KARABOGA, Dervis (jan. 2005). « An Idea Based on Honey Bee Swarm for Numerical Optimization, Technical Report - TR06 ». In : *Technical Report, Erciyes University* (cf. p. 31).
- KAWAMOTO, Kensaku, Caitlin A HOULIHAN, E Andrew BALAS et David F LOBACH (2005). « Improving clinical practice using clinical decision support systems : a systematic review of trials to identify features critical to success. » In : *BMJ* 330, p. 765 (cf. p. xvii, xix).
- KENNEDY, James et Russell C. EBERHART (1995). « Particle swarm optimization ». In : *Proceedings of the IEEE International Conference on Neural Networks*, p. 1942-1948 (cf. p. 31).
- KERDELO, Sébastien (jan. 2006). « Computer methods for the in virtuo experimentation of biochemical kinetics. Application to the blood coagulation system. » Theses. Université Rennes 1. URL : [https : //tel . archives - ouvertes . fr / tel-00012117](https://tel.archives-ouvertes.fr/tel-00012117) (cf. p. 75, 76, 116).
- KHAN, Asifullah, Anabia SOHAIL, Umme ZAHOORA et Aqsa Saeed QURESHI (2019). « A Survey of the Recent Architectures of Deep Convolutional Neural Networks ». In : *CoRR* abs/1901.06032. URL : [http : //arxiv.org/abs/1901.06032](http://arxiv.org/abs/1901.06032) (cf. p. 20).
- KINGMA, D, S MOHAMED, D JIMENEZ REZENDE et M WELLING (2014). « Semi-supervised Learning with Deep Generative Models ». In : *Advances in Neural Information Processing Systems 27*. Sous la dir. de Z. GHAHRAMANI, M. WELLING, C. CORTES, N. D. LAWRENCE et K. Q. WEINBERGER. Curran Associates, Inc., p. 3581-3589. URL : [http : //papers.nips.cc/paper/5352-semi-supervised-learning-with-deep-generative-models.pdf](http://papers.nips.cc/paper/5352-semi-supervised-learning-with-deep-generative-models.pdf) (cf. p. 8, 36).
- KINGMA, Diederik P. et Jimmy BA (2014). *Adam : A Method for Stochastic Optimization*. arXiv : 1412.6980 [cs.LG] (cf. p. 10).
- KLIGER, Mark et Shachar FLEISHMAN (2018). « Novelty Detection with GAN ». In : *CoRR* abs/1802.10560. URL : [http : //arxiv.org/abs/1802.10560](http://arxiv.org/abs/1802.10560) (cf. p. 92).
- KRIZHEVSKY, Alex, Ilya SUTSKEVER et Geoffrey E. HINTON (2012). « ImageNet Classification with Deep Convolutional Neural Networks ». In : *Advances in Neural Information Processing Systems 25*. Sous la dir. de F. PEREIRA, C. J. C. BURGESS, L. BOTTOU et K. Q. WEINBERGER. Curran Associates, Inc., p. 1097-1105. URL : [http : //papers.nips.cc/paper/4812-imagenet-classification-with-deep-convolutional-neural-networks.pdf](http://papers.nips.cc/paper/4812-imagenet-classification-with-deep-convolutional-neural-networks.pdf)

- [//papers.nips.cc/paper/4824-imagenet-classification-with-deep-convolutional-neural-networks.pdf](https://papers.nips.cc/paper/4824-imagenet-classification-with-deep-convolutional-neural-networks.pdf) (cf. p. 20).
- LANCÉ, Marcus D. (jan. 2015). « A general review of major global coagulation assays : thrombelastography, thrombin generation test and clot waveform analysis ». In : *Thrombosis Journal* 13. DOI : 10.1186/1477-9560-13-1 (cf. p. xviii, 69).
- LASSON, F., M. POLCEANU, C. BUCHE et P. DE LOOR (mai 2017). « Temporal Deep Belief Network for Online Human Motion Recognition ». In : *30th International Florida Artificial Intelligence Research Society Conference (FLAIRS)*. Marco Island, United States, p. 80-85. URL : <https://hal.archives-ouvertes.fr/hal-01522986> (cf. p. 113).
- LASSON, Francois, Alban DELAMARRE, Pascal REDOU et Cédric BUCHE (mai 2019). « A Clinical Decision Support System to Help the Interpretation of Laboratory Results and to Elaborate a Clinical Diagnosis in Blood Coagulation Domain ». In : *International Work-Conference on Artificial Neural Networks (IWANN)*. Gran Canaria, Spain, p. 109-122. URL : <https://hal.archives-ouvertes.fr/hal-02163567> (cf. p. xxi, 12, 70).
- LECUN, Y., L. BOTTOU, Y. BENGIO et P. HAFNER (nov. 1998). « Gradient-based learning applied to document recognition ». In : *Proceedings of the IEEE* 86.11, p. 2278-2324. ISSN : 1558-2256. DOI : 10.1109/5.726791 (cf. p. 43).
- LECUN, Y., J. S. DENKER et S. A. SOLLA (1990). « Optimal brain damage ». In : *Advances in Neural Information Processing Systems 2*. Sous la dir. de D. S. TOUTRETZKY. Morgan Kaufmann, p. 598-605 (cf. p. 23, 29, 51).
- LECUN, Y. et F. FOGELMAN-SOULIE (mar. 1987). « Modeles connexionnistes de l'apprentissage ». In : *Intellectica, special issue apprentissage et machine* (cf. p. 3, 5, 6, 8).
- LECUN, Yann, Yoshua BENGIO et Geoffrey E. HINTON (2015). « Deep learning ». In : *Nature* 521.7553, p. 436-444. DOI : 10.1038/nature14539. URL : <https://doi.org/10.1038/nature14539> (cf. p. xxi, 115).
- LESHNO, Moshe, Vladimir Ya. LIN, Allan PINKUS et Shimon SCHOCKEN (1993). « Multilayer feedforward networks with a nonpolynomial activation function can approximate any function ». In : *Neural Networks* 6.6, p. 861-867. ISSN : 0893-6080. DOI : [https://doi.org/10.1016/S0893-6080\(05\)80131-5](https://doi.org/10.1016/S0893-6080(05)80131-5) (cf. p. 17).
- LOEFFEN, R., M.-C. F. KLEINEGRIS, S. T. B. G. LOUBELE, P. H. M. PLUIJMEN, D. FENS, R. van OERLE, H. ten CATE et H. M. H. SPRONK (2012). « Preanalytic variables of thrombin generation : towards a standard procedure and validation of the method ». In : *Journal of Thrombosis and Haemostasis* 10.12, p. 2544-2554. DOI : 10.1111/jth.12012. URL : <https://onlinelibrary.wiley.com/doi/abs/10.1111/jth.12012> (cf. p. xviii, 69, 119).
- ŁUKASIK, Szymon et Sławomir ŻAK (oct. 2009). « Firefly Algorithm for Continuous Constrained Optimization Tasks ». In : t. 5796, p. 97-106. DOI : 10.1007/978-3-642-04441-0_8 (cf. p. 31).
- MACFARLANE, R. G. et Rosemary BIGGS (1953). « A Thrombin Generation Test ». In : *Journal of Clinical Pathology* 6.1, p. 3-8. ISSN : 0021-9746. DOI : 10.1136/jcp.6.1.3. eprint : <https://jcp.bmj.com/content/6/1/3.full.pdf>. URL : <https://jcp.bmj.com/content/6/1/3> (cf. p. xviii, 69).

- MAKARY, Martin A et Michael DANIEL (2016). « Medical error—the third leading cause of death in the US ». In : 353. DOI : 10.1136/bmj.i2139. URL : <https://www.bmj.com/content/353/bmj.i2139> (cf. p. xvii).
- MCENENY-KING, Alanna, Pierre CHELLE, Gary FOSTER, Arun KEEPANASSERIL, Alfonso IORIO et Andrea EDGINTON (mai 2019). « Development and evaluation of a generic population pharmacokinetic model for standard half-life factor VIII for use in dose individualization ». In : *Journal of Pharmacokinetics and Pharmacodynamics* 46, p. 1-16. DOI : 10.1007/s10928-019-09634-7 (cf. p. 73).
- MIRZA, Mehdi et Simon OSINDERO (nov. 2014). « Conditional Generative Adversarial Nets ». In : (cf. p. 80).
- MÜLLER-MERBACH, Heiner (1981). « Heuristics and their design : a survey ». In : *European Journal of Operational Research* 8.1, p. 1-23. ISSN : 0377-2217. DOI : [https://doi.org/10.1016/0377-2217\(81\)90024-2](https://doi.org/10.1016/0377-2217(81)90024-2). URL : <http://www.sciencedirect.com/science/article/pii/0377221781900242> (cf. p. xxi, 30).
- NAIR, Vinod et Geoffrey E. HINTON (2010). « Rectified Linear Units Improve Restricted Boltzmann Machines ». In : *Proceedings of the 27th International Conference on International Conference on Machine Learning*. ICML'10. Omnipress, p. 807-814 (cf. p. 4).
- NG, A. (2003). *Lecture Notes. CS 229 : Machine Learning*. Rapp. tech. Stanford, CA (cf. p. 13).
- (2017). *Lecture Notes. CS 294A : Sparse autoencoder*. Rapp. tech. Stanford, CA (cf. p. 4, 7).
- PAN, S. J. et Q. YANG (oct. 2010). « A Survey on Transfer Learning ». In : *IEEE Transactions on Knowledge and Data Engineering* 22.10, p. 1345-1359. ISSN : 2326-3865. DOI : 10.1109/TKDE.2009.191 (cf. p. 20).
- PATINO VILCHIS, Jose Luis, François BREMOND et Monique THONNAT (déc. 2010). « Incremental learning on trajectory clustering ». In : *Intelligent Paradigms in Safety and Security*. Sous la dir. de Dr. Paolo REMAGNINO. Springer-Verlag. URL : <https://hal.inria.fr/inria-00503059> (cf. p. 22).
- PIMENTEL, M., D. CLIFTON, L. CLIFTON et L. TARASSENKO (2014). « A review of novelty detection ». In : (cf. p. xxi, 13).
- POLI, Attilio A. et Mario C. CIRILLO (1993). « On the use of the normalized mean square error in evaluating dispersion model performance ». In : *Atmospheric Environment - Part A General Topics* 27.15, p. 2427-2434. DOI : 10.1016/0960-1686(93)90410-Z (cf. p. 11).
- PRATAMA, Mahardhika, Andri ASHFAHANI, Yew ONG, Savitha RAMASAMY et Edwin LUGHOFFER (sept. 2018). « Autonomous Deep Learning : Incremental Learning of Denoising Autoencoder for Evolving Data Streams ». In : (cf. p. 21, 25, 27, 29, 49-53).
- PRECHTEL, Lutz (1996). « Early Stopping-But When? » In : *Neural Networks : Tricks of the Trade*. Sous la dir. de Genevieve B. ORR et Klaus-Robert MÜLLER. T. 1524. Lecture Notes in Computer Science. Springer, p. 55-69. ISBN : 3-540-65311-2 (cf. p. 9, 52).
- PRESS, Richard, Kenneth BAUER, Jody KUJOVICH et John HEIT (déc. 2002). « Clinical utility of Factor V Leiden (R506Q) testing for the diagnosis and management of

- thromboembolic disorders ». In : *Archives of pathology laboratory medicine* 126, p. 1304-18 (cf. p. xvii).
- RAINA, Rajat, Alexis BATTLE, Honglak LEE, Benjamin PACKER et Andrew Y. NG (2007). « Self-Taught Learning : Transfer Learning from Unlabeled Data ». In : *Proceedings of the 24th International Conference on Machine Learning*. ICML '07. Corvallis, Oregon, USA : Association for Computing Machinery, p. 759-766. ISBN : 9781595937933. DOI : 10 . 1145/1273496 . 1273592. URL : <https://doi.org/10.1145/1273496.1273592> (cf. p. 20).
- REAL, Esteban, Sherry MOORE, Andrew SELLE, Saurabh SAXENA, Yutaka Leon SUEMATSU, Quoc V. LE et Alex KURAKIN (2017). « Large-Scale Evolution of Image Classifiers ». In : *CoRR* abs/1703.01041. arXiv : 1703 . 01041. URL : <http://arxiv.org/abs/1703.01041> (cf. p. 21, 27).
- REED, R. (sept. 1993). « Pruning algorithms-a survey ». In : *IEEE Transactions on Neural Networks* 4.5, p. 740-747. ISSN : 1941-0093. DOI : 10 . 1109/72 . 248452 (cf. p. 23, 29).
- RIFAI, Salah, Pascal VINCENT, Xavier MULLER, Xavier GLOROT et Yoshua BENGIO (2011). « Contractive Auto-Encoders : Explicit Invariance during Feature Extraction ». In : *Proceedings of the 28th International Conference on International Conference on Machine Learning*. ICML'11. Omnipress, p. 833-840 (cf. p. 7, 22, 43, 58, 91).
- RUMELHART, David E., Geoffrey E. HINTON et Ronald J. WILLIAMS (1986). « Learning Representations by Back-propagating Errors ». In : *Nature* 323.6088, p. 533-536. DOI : 10 . 1038/323533a0. URL : <http://www.nature.com/articles/323533a0> (cf. p. 8, 112).
- SAKURADA, Mayu et Takehisa YAIRI (déc. 2014). « Anomaly Detection Using Autoencoders with Nonlinear Dimensionality Reduction ». In : p. 4-11. DOI : 10 . 1145/2689746 . 2689747 (cf. p. 14).
- SHCHERBAKOV, Maxim, Adriaan BREBELS, Anton TYUKOV, Timur JANOVSky et Valeriy ANATOL (2013). « A Survey of Forecast Error Measures ». In : (cf. p. 11, 112).
- SHEIKH, Aziz, Neelam DHINGRA-KUMAR, Edward KELLEY, Marie KIENY et Liam DONALDSON (août 2017). « The third global patient safety challenge : tackling medication-related harm ». In : *Bulletin of the World Health Organization* 95, 546-546A. DOI : 10 . 2471/BLT . 17 . 198002 (cf. p. xvii).
- SHMELKOV, Konstantin, Cordelia SCHMID et Karteek ALAHARI (2018). « How good is my GAN? » In : *CoRR* abs/1807.09499 (cf. p. 112).
- SIMONYAN, Karen et Andrew ZISSERMAN (2014). *Very Deep Convolutional Networks for Large-Scale Image Recognition*. URL : <http://arxiv.org/abs/1409.1556> (cf. p. 20).
- SOHN, K, X YAN et H LEE (2015). « Learning Structured Output Representation Using Deep Conditional Generative Models ». In : *Proceedings of the 28th International Conference on Neural Information Processing Systems*. NIPS'15. Montreal, Canada : MIT Press, p. 3483-3491. URL : <http://dl.acm.org/citation.cfm?id=2969442.2969628> (cf. p. 8, 36).
- SURESH, S., N. SUNDARARAJAN et P. SARATCHANDRAN (2008). « A sequential multi-category classifier using radial basis function networks ». In : *Neurocomputing* 71.7. Progress in Modeling, Theory, and Application of Computational Intelli-

- genc, p. 1345-1358. ISSN : 0925-2312. DOI : <https://doi.org/10.1016/j.neucom.2007.06.003> (cf. p. 22, 29).
- TIELEMAN, T. et G. HINTON (2012). *Lecture 6.5—RmsProp : Divide the gradient by a running average of its recent magnitude*. COURSERA : Neural Networks for Machine Learning (cf. p. 10).
- VINCENT, P., H. LAROCHELLE, Y. BENGIO et P.-A. MANZAGOL (2008). « Extracting and composing robust features with denoising autoencoders ». In : *International Conference on Machine Learning proceedings* (cf. p. 7, 54).
- VINCENT, Pascal (2011). « A Connection Between Score Matching and Denoising Autoencoders ». In : *Neural Computation* 23.7, p. 1661-1674. DOI : 10.1162/NECO_a_00142 (cf. p. 18).
- YAO, Zhewei, Amir GHOLAMI, Kurt KEUTZER et Michael MAHONEY (oct. 2018). « Large batch size training of neural networks with adversarial training and second-order information ». In : (cf. p. 9).
- YOUNG, G, B SORENSEN, Y DARGAUD, C NEGRIER, K BRUMMEL-ZIEDINS et NS KEY (2013). « Thrombin generation and whole blood viscoelastic assays in the management of hemophilia : current state of art and future perspectives ». In : *Blood*, p. 1944-1950 (cf. p. 69).
- ZHOU, Chong et Randy C. PAFFENROTH (2017). « Anomaly Detection with Robust Deep Autoencoders ». In : *Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining*. KDD '17. Halifax, NS, Canada : Association for Computing Machinery, p. 665-674. ISBN : 9781450348874. DOI : 10.1145/3097983.3098052 (cf. p. 14).
- ZHOU, Guanyu, Kihyuk SOHN et Honglak LEE (21-23 Apr 2012a). « Online Incremental Feature Learning with Denoising Autoencoders ». In : *Proceedings of the Fifteenth International Conference on Artificial Intelligence and Statistics*. Sous la dir. de Neil D. LAWRENCE et Mark GIROLAMI. T. 22. Proceedings of Machine Learning Research. La Palma, Canary Islands : PMLR, p. 1453-1461 (cf. p. 12, 21, 22, 24, 25, 29, 49, 51).
- (jan. 2012b). « Supplementary Material : Online Incremental Feature Learning with Denoising Autoencoders ». In : *Journal of Machine Learning Research* 22 (cf. p. 24, 52, 53).
- ZUNIGA, Marcos, Francois BREMOND et Monique THONNAT (2011). « Hierarchical and Incremental Event Learning Approach based on Concept Formation Models ». In : *Neurocomputing*. Special Issue : Behaviours in Video. DOI : 10.1016/j.neucom.2012.02.038. URL : <https://hal.inria.fr/hal-00696354> (cf. p. 22).
- ZUNIGA, Marcos, François BREMOND et Monique THONNAT (oct. 2009). « Incremental Video Event Learning ». In : *7th International Conference on Computer Vision Systems, ICVS*. Liege, Belgium. URL : <https://hal.inria.fr/inria-00512502> (cf. p. 22).

Titre : Intérêts des auto-encodeurs profonds pour les systèmes d'aide à l'individualisation de thérapies. Application à la prise en charge personnalisée du patient hémophile.

Mot clés : Auto-encodeur, Apprentissage profond, Optimisation incrémentale, Pré-entraînement conditionnel, Systèmes d'aide à la prise de décisions cliniques, Tests globaux.

Résumé : L'individualisation de thérapies est une approche qui implique l'utilisation de tests biologiques proches de la réalité physiologique. Dans le contexte de la coagulation du sang, où les tests de laboratoires de routine ne fournissent qu'une étude partielle de la formation du caillot, les tests globaux se présentent comme des candidats prometteurs pour améliorer la prise en charge personnalisée de patients victimes de troubles de l'hémostase. Néanmoins, bien que pertinents, ces outils de mesure manquent de standardisation et leurs résultats s'avèrent difficilement interprétables par des cliniciens non experts du domaine. Dans ce travail, nous défendons la thèse qu'un système d'aide à la prise de décisions cliniques (CDSS) permet d'obvier à cette complexité d'analyse et de faciliter la définition de traitements patient-spécifiques. En vue d'exploiter pleinement le caractère prédictif

des résultats de tests globaux, il est pertinent d'en extraire des caractéristiques fortement abstraites par l'intermédiaire d'architectures profondes. À cet effet, nous avons alors apporté des solutions à la double difficulté de l'optimisation paramétrique et hyper-paramétrique des auto-encodeurs (AE) profonds. Caractérisées par un algorithme de pré-entraînement conditionnel et des stratégies d'optimisation incrémentale, ces solutions réduisent la variance du processus d'estimation et améliorent la convergence de l'algorithme d'apprentissage. Leurs applications dans un contexte de prise en charge personnalisée du patient hémophile ont alors permis d'outrepasser les performances des réseaux antagonistes génératifs et de mettre en exergue les intérêts des AE profonds pour les CDSS.

Title: Interests of deep autoencoders for clinical decision support systems. Application to the personalized management of hemophilic patient.

Keywords: Autoencoder, Deep learning, Incremental optimisation, Conditional pre-training, Clinical decision support systems, Global assays.

Abstract: Therapeutic individualization is a method that entails the use of biological assays close to physiological reality. In the context of blood coagulation, routine laboratory tests only supply a partial study of the formation of a blood clot, whereas global assays have proved to be promising contenders in improving personalized care for patients suffering from hemostasis disorders. However, despite their relevance, these tests lack standardization, and their results have proved difficult for non-specialized clinicians to interpret. In this work, we are arguing that a Clinical Decision Support System (CDSS) allows us to overcome these analytical difficulties, as well as help set patient-specific treatments. In order to fully exploit the

predictive behavior of the global assay results, strongly abstract characteristics can be extracted through deep architecture. In this respect, we have provided solutions to the challenge of both parametric and hyperparametric optimization of deep autoencoders (AE). These solutions, characterized by a conditional pre-training algorithm and incremental optimization strategies, reduce the variance of the estimation process and enhance the convergence of the learning algorithm. Applying these in the context of personalized care of hemophilic patients has therefore made it possible to exceed the performance of generative adversarial networks and to highlight the benefits of AE for CDSS.