



Recalls about neural networks

Pierre De Loor


Basics about neural networks



Gradient descent on neural networks



Loss function of E
Example: MSE




Some versions of Gradient Descent

- Problem : size of the training set
- **Stochastic Gradient Descent:** Picked up randomly one example, compute the error and optimize the loss
- **Batch Gradient Descent :** Computation of the mean of all individual losses of the dataset before optimization
- **Mini-Batch Gradient Descent :** takes a batch (a subset of the dataset) and computes the mean of losses of each example of the Batch.

Optimizers


- Problem : loss function with local minima and learning rate choice
- The main objective is to adapt the learning rate for each parameter according to the variation of the losses due to this parameter
- **Some variantes:** Adagrad, RMSProp, ADAM, AdaMax, Adadelata, Nadam, AMSGrad
- Adam often give the best results, depending of the sparticity of the data

What is ROC Curve



Which is the best value of y_1 to consider that an example is on a class ?


Example with a logistic function



at which class belong this input




Depending of the value of thr, it is in the class or not
So depending of thr it is a true positive or not

ROC Curve (Receiver operating characteristic)



Neural network yes but ..




- Les neurones : loin d'être des systèmes entrées -> sorties



Le Cortex Humain

- Partout pareil

3 méthodes de teinture 6 couches



Mais que « voit » le cerveau ?

- L'exemple de la rétine





FIGURE 23-5

The human retina. The retina contains three principle layers: (1) the rod and cone light receptors, (2) an intermediate layer for data reduction and image processing, and (3) the optic nerve fibers that lead to the brain. The structure of these layers is seemingly *backward*, requiring light to pass through the other layers before reaching the light receptors.

The Retina



Mais que « voit » le cerveau ?

- Que perçoit-on du monde réel ?





FIGURE 23-2
Focusing by a lens. A lens gathers light expanding from a point source, and force it to return to a point at another location. This allows a lens to project an image onto a surface.




Mais que « voit » le cerveau ?




Les neurones s'activent .. Quand ça bouge

- Exemple d'une zone du cerveau liée à la vision

V1 physiology: orientation selectivity





Mais « qu'entend » le cerveau ?



Connections entre aires corticales


- Le « cablage » implique une sorte de hiérarchie




Signaux afférents Signaux efferents

Les « régions » corticales

- Surface d'une pièce de monnaie
- Quelques milliers de « micro-colonnes »



Organisées hiérarchiquement




Origines des réseaux et cartes de Kohonen

- Vision et ouïe du chat
- Topologie : les neurones activés par les hautes fréquences sont localisés à l'opposé des neurones sensibles aux basses fréquences
- Un neurone va représenter une classe
 - Identification de relief
 - Identification de couleurs
 - Deux neurones proches représentent des informations similaires

Apprentissage compétitif


- Pas de supervision : systèmes auto-organisés
- Exemple : Kohonen (inhibition latérale)

- M entrées, N sorties, = $N \times M$ poids
Vecteur d'entrée
(attributs d'un élément à classer)



« Winner take all »

- Les poids entre couches entrée-sorties reflètent une distance (euclidienne) entre un neurone de la couche de Kohonen et l'entrée




$$\sqrt{di} = \sum_{j=1}^M (X_j - w_{ij})^2$$


Si les poids valent les entrées
la distance est nulle
Il existe un neurone ayant
une distance minimum avec
une entrée

Vers un ré-équilibrage entrées/Kohonen

- Le neurone élu « m » a des voisins « j » (au sens de la distance à l'entrée)




Objectif :



Rééquilibrage pour une entrée

- Modification des poids des arcs menant aux neurones « j » voisins de « m » :
 - $w_j = w_j + n * [X - w_j]$
- Par conséquent
 - Si $w < x$ alors w augmente
 - Si $w > x$ alors w diminue
 - Les neurones « j » se « rapprochent » de « m »

Rééquilibrage sur toutes les entrées



- Convergence vers un voisinage minimal
- Répartition des entrées sur les neurones de la couche de Kohonen


Notion de carte (de Kohonen)

- Représentation des neurones de la couche de Kohonen S sur une topologie T (par exemple une grille) impliquant une notion de voisinage défini par une distance d .
- (S, d, T) est une carte topologique de Kohonen

Démo 1


- [Classification de couleurs](#)
 - 1000 neurones possédant chacun 3 poids
 - Pour visualiser la convergence, ces poids sont représentés par les composantes RGB
 - L'apprentissage consiste à classer des couleurs tirées aléatoirement et représentées par 3 valeurs RGB.
 - A la fin, les couleurs proches activeront des neurones proches
 - La carte finale est organisée mais cette organisation sera différente à chaque session d'apprentissage

Démo 1



initialisation


Entraînement



résultats



carte d'erreur



neurones
gagnants

Choix des entrées


- Classification d'images
- Les entrées sont des images représentées par
 - Un calcul de leur brillance (1 entrée)
 - 9 valeurs RGB correspondant à la couleur moyenne de 9 zones de l'image (27 entrées)




[demo](#)

Images similaires représentées par des neurones proches

- 205 images



4	0	5	1	3	4	0	1	6	4
0	0	0	1	0	0	3	0	11	1
3	1	0	2	1	1	0	1	1	1
1	0	1	0	6	0	1	1	5	1
2	2	0	1	2	9	2	4	4	2
1	0	1	0	1	3	1	0	1	5
2	0	1	1	1	2	3	0	0	1
1	0	3	5	2	3	2	2	2	3
2	4	3	1	5	3	0	1	0	0
1	3	4	0	3	3	2	0	0	3



Mémoires auto-associatives

Quelques exemples de nos capacités auto-associative

- Le percent c'est ...
- Vievemnt la pasue parec qeu ce cuors m'érneve
- Pom pom pom pom

Une mémoire auto-associative

- Est capable de retrouver une « information » à partir de « morceaux » plus ou moins bien organisés.
- Ces morceaux activeraient les morceaux manquants.
- John Hopfield est un physicien de formation et a proposé un modèle de mémoire auto-associative inspiré du cerveau

Règle de Hebb (1949)


- Hebb était neuro-psychologue

Quand un axone de la cellule A est suffisamment proche pour exciter la cellule B de façon répétitive ou persistante, il se produit un processus de croissance ou un changement métabolique tel que l'efficacité de A, en tant que cellule excitant B s'en trouve augmentée.

Des groupes de neurones qui tendent à s'exciter simultanément forment un ensemble de cellules dont l'activité peut persister à la suite du déclenchement d'un événement et peut servir à le représenter

La pensée est l'activation séquentielle de plusieurs groupes d'ensemble de cellules

Réseaux de Hopfield ou réseau à attracteur mono couche



- Activation d'un neurone

$$I = \sum_{k=1}^n w_k * i_k$$

$$y = f(I) = I \text{ si } I_{\min} < I < I_{\max}$$

$$y = I_{\min} \text{ si } I < I_{\min}$$

$$y = I_{\max} \text{ si } I > I_{\max}$$

- Modèle simplifié :

$$y = 0 \text{ si } I \leq 0$$

$$y = 1 \text{ si } I > 0$$


Exemple

Ce réseau connaît :

1 -1 -1 1 -1 -1


-1 1 -1 -1 1 -1

-1 -1 1 -1 -1 1



Entrées ou
sorties (t-1)

Sorties (t)



Exemple

- Si l'entrée vaut «1 -1 -1 1 -1 -1 »,
 - la sortie vaut « 7 -3 -3 7 -2 -3 »
 - Si écrépage à -1 / +1
 - « 1 -1 -1 1 -1 -1 » : stabilité
- Si l'entrée vaut « -1 -1 1 -1 -1 -1 » -> « -1 -1 1 -1 -1 7 » -> « -1 -1 1 -1 -1 1 » : stabilité
- Si l'entrée vaut « 1 1 -1 1 -1 1 »
 - « 3 -5 1 3 1-5 » -> « 1 -1 1 1 1 -1 »
 - « 3 1 -5 3 -5 1 » -> « 1 1 -1 1 -1 1 »
 - « 1 -5 1 3 1 -5 » -> « 1 -1 1 1 1 -1 »
 - « 3 1 1 3 -5 1 » -> « 1 1 1 1 -1 1 »
 - « 1 -7 1 1 -1 1 » -> « 1 -1 1 1 -1 1 »
 - « 3 -7 3 3 -7 3 » -> « 1 -1 1 1 -1 1 » : stabilité

Exemples

Image originale



Image dégradée



Image reconstruite



Apprentissage des poids

- Loi de Hebb
 - Sur p exemples

$$w_{ij} = \sum_{k=1}^p x_i^k * x_j^k$$

- Sur un modèle simplifié, w_{ij} est le nombre de fois où les bits sont égaux – le nombre de fois où ils sont différents
- Sur modèle simplifié à n neurones on peut apprendre $0.15 * n$ prototypes

Deep Learning




Ou apprentissage profond

Origine

- L'idée d'accumuler des couches de neurones cachés date des débuts [Pitts 1943]
- Mais les algorithmes classiques (BP, Gradient) ne fonctionnent pas.
- En 2006 Hinton propose d'utiliser des auto-encodeurs (RBM) pour préentraîner les réseaux sans supervision, et ça marche !!
- En 2010 Glorot & Bengio proposent une technique d'initialisation des poids associée à l'usage d'une fonction logistique ou ReLu, qui évitent le problème de la disparition du gradient en supervisé
- La quantité des données disponibles (en particulier grâce à internet) associées à la puissance des GPU, permettent l'essor de ces approches
 - Google : TensorFlow, Deepmind
 - Facebook : Torch
 - Microsoft : CNTK
- Le découpage hiérarchique en couches successives chargées d'une tâche est plus efficace que l'usage d'une 'grosse' couche de neurones : Ils convergent plus vite et généralisent mieux.

Exemples de structures 'Deep'

- Des centaines de neurones
- De nombreuses couches
- Différentes organisations





Principaux composants d'une architecture 'Deep'

- Données partiellement labellisées (apprentissage non supervisé mais pouvant être supervisable)
- Fonctions d'activation des couches cachées : 'Rectified Linear Units' ou 'restricted Boltzmann machine' (probabilités)
- Fonction d'activation des couches de sortie : softmax
- Réseaux convolutionnels
- Neuron Dropout

Fonction d'activation ReLU

- Rectified Linear Units


$$\phi(x) = \max(0, x)$$



Tiré de [Nair, V., & Hinton, G. E. (2010). Rectified linear units improve restricted boltzmann machines. In *Proceedings of the 27th International Conference on Machine Learning (ICML-10)* (pp. 807-814).

RBM : Restricted Boltzmann Machine

- Meilleures propriétés que les réseaux de Hopfield



Arcs non orientés

Cellules binaires :

$$v \in \{0,1\}^D$$

$$h \in \{0,1\}^K$$


État d'activation probabiliste

$$p_i = on = \frac{1}{1 + \exp(-\frac{\Delta E_i}{T})}$$

$$\Delta E_i = \sum_j w_{ij} s_j + \theta_i$$

Objectif de l'apprentissage

- Trouver des poids tels qu'une entrée (activation de la couche visible)
 - active les couches cachées
 - de façon à ce que la couche cachées réactive la couche visible de façon identique aux entrées




Le « Sampling » (échantillonnage)

- Estimer les probabilités moyennes d'activation de certains neurones à partir de la valeur des neurones auquel il est connecté
- Choisir une valeur pour ces neurones, à partir de la probabilité d'activation qui vient d'être calculée (sampling)

Le « Sampling » (echantillonnage)

- Exemple : la probabilité moyenne d'activation d'un neurone caché en fonction de V1,V2 et V3 est

$$\bar{h}_i^+ = \text{sigmoid}(\sum_j w_j v_j + b_i)$$



Le sampling d'un neurone de la couche cachée est

$$h_i^+ = \begin{cases} 1 & r < \bar{h}_i^+ \\ 0 & r \geq \bar{h}_i^+ \end{cases}$$

r est une valeur aléatoire entre 0 et 1

Gibbs sampling

- A partir d'une entrée donnée
- Echantillonner les neurones cachés h_i^+
- En déduire un échantillonnage des neurones visibles v_j^-
- En déduire un échantillonnage des neurones cachés h_i^-
- Les symboles + et – désigne la phase de l'algorithme (positive sampling puis négative sampling)

Apprentissage

- Poids des arcs

$$\Delta_{ij} = \frac{\epsilon(\bar{h}_i^+ x_j - \bar{h}_i^- v_j^-)}{|x|}$$

Taux d'apprentissage



Taille d'une donnée d'entrée

- Biais des neurones

$$\Delta b_i = \frac{\epsilon(h_i^+ - \bar{h}_i^-)}{|x|}$$

Deep Belief Network


- Empilement de RBM
- Apprentissage couche par couche par la méthode du Gibbs Sampling
- Généralement la couche du haut peut-être apprise de façon supervisée par un apprentissage classique (retropropagation) avec un neurone par classe à apprendre



Deep Belief network


- Les différentes couches sont supposées construire une abstraction des données d'entrées qui sera ensuite utilisée pour la couche supérieure.
- Le nombre de neurones par RBM est de plusieurs centaines (voir milliers)

Exemple : reconnaissance et génération



Reconnaissance


Génération



Réseaux convolutionnels

- Inspiré de la vision biologique
- Résistant aux rotations et décalages des images
- Idée proposée dans les années 80 par Fukushima mais amélioré par l'équipe Canadienne de Bengio en 1998.
- LeNET-5 (LeCun) fut un précurseur des algorithmes utilisés désormais par les GAFA*
- Exemples : <http://yann.lecun.com/exdb/lenet/index.html>


Architecture de LeNet-5



D'après « LeCun, Y., Bottou, L., Bengio, Y., & Haffner, P. (1998). Gradient-based learning applied to document recognition. *Proceedings of the IEEE*.


<http://doi.org/10.1109/5.726791>

Principe de la convolution



Le filtre est souvent associé à une fonction non linéaire : $h_{ij}^k = \tanh((W^k * x)_{ij} + b_k)$.

Couche de convolution



Détection de « features »



Original




Emboss



Couche de convolution


- On applique plusieurs filtres qui vont former les différentes 'profondeurs' de la couche de convolution



couche de convolution


Couche de 'Max Pooling' (mise en commun)

- Garder les 'features' maximums
- Avoir une vision plus 'grossière' de leur position




Couche dense

- Repérer des corrélations entre features




Aller jusqu'à la classe



Empiler plusieurs 'convolution-max pooling'

- LeNet-5




De droite à gauche, la position exact d'une 'feature' est 'perdue' mais pas les positions relatives entre les features

Exemple : « il y a du blanc à coté d'un trait »

Autres possibilités

<http://cs231n.github.io/convolutional-networks/#case>




Autres éléments de compréhension


- L'intérêt des filtres des couches convolutionnels est de n'avoir que peu de poids à apprendre
- LeNet-5 : Environ 100 000 neurones pour seulement 2600 paramètres à apprendre
- Ces filtres sont calculés par retro-propagation classique

Exemple

Avant apprentissage



Après apprentissage




Execution sous convnetjs

C'est un 7

Alpha Go : 5-0 contre Lee-Sedol (octobre 2015)

- Réseaux convolutionnels pour abstraire la représentation du jeu
- Monte-carlo pour faire des arbres de coups avec poids
- Renforcement pour calculer ces poids et élager l'arbre



Bilan


- Les capacités des machines permettent de se rapprocher des mécanismes biologiques de perception (réseau conv)
- Les avancées théoriques permettent d'accumuler des couches (RBM)
- Le temps d'apprentissage est très très très long
- Le nombre de données doit être très grand
- Il existe des librairies de réseaux « model zoo » qui ont déjà été entraînés pour les tâches de bas niveau et sont réutilisables
- Mixer RBM et Convolution est une perspective prometteuse : Convolutional RBM
- Les recherches portent surtout sur l'introduction des aspects temporels avec des réccurences inspirées de la compréhension du cerveau

Outils

- **Python**
 - ~~Theano (Outils mathématiques de base, optimisation GPU), <http://deeplearning.net/software/theano>~~
 - Plusieurs librairies d'appuient sur Theano : Keras, Pylearn2, Lasagne, Blocks
 - Caffe (Python interface d'un code C++, Base de Google DeepDream)
 - TensorFlow, l'outil de base de google.
 - Keras – sur Tensor Flow
 - Nolearn, Gensim, Chainer, deepnet, Hebel, CXXnet, DeepPy, DeepLearning, Neon
- **Matlab**
 - ConvNet, DeepLearnToolBox, cida-convnet, MatConvnet
- **C++**
 - Eblearn, SINGA, NVIDIA DIGITS, Intel Deep Learning Framework
- **JAVA**
 - N-Dimensional Arrays for Java, DeepLearning4j, Encog
- **JavaScript**
 - Convnet.js
- **Lua**
 - Torch
- **Julia**
 - Mocha
- **Lisp**
 - Lush
- **Haskell**
 - DNNGraph
- **.NET**
 - Accord.NET
- **R**
 - Darch
 - deepnet

Autre approche

- Jeff Hawkins
- Ingénieur informatique, passionné de neuroscience.
- Constate qu'il n'existe pas de « théorie générale » du fonctionnement du cerveau.
- En propose une



Polémiques

- Singularité
- Trans-humanisme
- Big Brother

Questions

- Comment des choses si similaires permettent-elles de percevoir des choses si différentes
- Qu'est ce que la mémoire, l'apprentissage et la compréhension au niveau neuronal ?
- Il doit y avoir quelques principes de bases
- Peut-on les simuler ?
- Si oui, cela peut-il donner lieu à de nouvelles formes d'apprentissage artificiel, de mémoire voir de compréhension artificielle ?
- Pourra-ton un jour faire le lien avec l' expérience subjective vécue ?

Perception et sens ... artificiels

Pierre De Loor

www.enib.fr/~deloor



- Le mystère du passage de la lumière au sens ...



Le propre de la cognition biologique

- Le Darwinisme
- L'Ontogenèse
- Le Corps

l' « embodied cognition »

- **Conceptualisation** : Les propriétés du corps d'un organisme limitent ou contraignent les concepts qu'il peut acquérir.
- **Remplacement** : L'interaction entre le corps et l'environnement remplace le besoin de recourir au fait que le traitement de représentations soit au coeur de la cognition.
- **Constitution** : Le monde et le corps jouent un rôle constitutif et non causal dans les processus cognitifs.

Shapiro, L. (2011). Travelling in Style from Standard Cognitive Science to Embodied Cognition. *Constructivist*, 231–233.

Shaun Gallagher (2006), *How the Body Shapes the Mind*, Clarendon Press

Semi-Passive Dynamics Locomotion

- Le monde est une perturbation à laquelle le robot résiste –compliance- Pas de calcul/contrôle de la réponse aux perturbations



Ly, O., Lapeyre, M., & Oudeyer, P.-Y. (2011). Bio-inspired vertebral column, compliance and semi-passive dynamics in a lightweight humanoid robot. *IEEE/RSJ International Conference on Intelligent Robots and Systems*, (1), 1465–1472.

Action ou perception ?

- Réduction et 1^{er} personne
- Interdépendance de deux entités
- Le monde que je perçois me permet de savoir que j'y suis
- Externalisme et phénoménologie





Charles Lenay, (2002), Ignorance et suppléance: la question de l'espace.


Alva Noë, (2006), Action in perception.

L'invariance sensorimotrice

- Paul Bach-y-Rita (1969)




En neuroscience



2 patients
aveugles,
capables de
localiser une
cible grâce à

1'






L'écholocalisation active
les zones du cerveau
activées pour la vision

Neural Correlates of Natural Human Echolocation in Early and Late Blind Echolocation Experts, Lore Thaler¹, Stephen R. Arnott², Melvyn A. Goodale, 2011

Approche dynamique en psychologie

- Couplage agent / environnement
- Couplage intra – inter personnel




Warren, W. H. (2006). The dynamics of perception and action. *Psychological Review*, 113, 358-389.

Richardson, M. J., Marsh, K. L., & Schmidt, R. C. (2005). Effects of visual and verbal interaction on unintentional interpersonal coordination. *Journal of Experimental Psychology: Human Perception and Performance*, 31(1), 62-79.

Paradigme dynamique


- Inspiration phénoménologique de la perception
- Lien avec la notion de cognition incarnée : mettre l'accent sur l'importance du corps et du sensorimoteur dans la reconnaissance




Travaux récents (voir balbutiants)

- Fort ancrage avec la cognition incarnée
 - David Vernon, *Cognitive Vision, the case of embodied perception*, **Image and Vision Computing** Volume 26 , Issue 1 (January 2008).
 - Mototaka Suzuki, Dario Floreano, *Enactive Robot Vision*, **Adaptive Behavior** , **2008**, Volume 16 .
 - Negrello, M. & Pasemann, F. *Attractor Landscapes and Active Tracking: The Neurodynamics of Embodied Action*. **Adaptive Behavior**, **2008**, 16, 196-216 .
- Loin d'une vision artificielle efficace
- N'aborde pas encore la genèse mais propose des modèles candidats au programme dynamique

Exemple (d'après Negrello & Pasemann 2008)




Réseau de neurones



Configuration du réseaux

- Algorithme génétique recherchant les poids des connexions
- Une expérimentation consiste à faire se déplacer une balle devant l'oeil et à observer son comportement .
- Fitness :





Présence de la
balle devant l'oeil

Absence d'oscillations
du moteur

Cognition dynamique artificielle



- CTRNN : Récurrences – Variables continues

$$\tau_i \frac{dy_i}{dt} = -y_i + \sum_{j=1}^N w_{ji} \sigma_j(y_j) + I_i(t)$$






Propriétés

- Pas de représentations
- Interaction = perturbations
- Resistance
- Surprise et Nouveauté
- Régularité
- Autonomie



Perturbation d'un CTRNN


- Ultra-stabilité, Homéostasie et principes homéodynamique





self. *Bio Systems*, 91(2), 388–400. doi:10.1016/j.biosystems.2007.05.014

Ontogenèse comportementale

- Couplage
- Guidage Interactif : de l' exafférence à l'efférence
- Evolution d'invariants sensorimoteur



Ontogenèse comportementale



Réseaux Récurrents Continus + Algorithmes génétiques

- Equation d'évolution des neurones

$$\tau_i \dot{y}_i = -y_i + \sum_{j=1}^k w_{ij} \sigma[y_j + b_j] + I_i$$

- Guidage

$$S_B(t) \begin{cases} S_B(t-1) * (1 + \Delta(t)) & \text{if } (\Delta(t) < 0) \\ S_B(t) = (d_{new}(t) - d_{LA}(t)) & \text{else} \end{cases} \quad \Delta(t) = \frac{d(\vec{d}_{new}(t) - d_{LA}(t))}{dt}$$


Réseaux Récurrents Continus + Algorithmes génétiques

- Fitness de l'AG

$$fitness_i = 1 - \sum_{t=250}^{t=K(i)} \left\{ \frac{|d_{new}(t) - d_{LA}(t)|}{20 * (K(i) - 250)} \right\}$$


Résultats

- Quelque soit la distance à maintenir, l'agent apprend à respecter cette distance




Recherche de « règles »

- Quelques soient les tailles des réseaux, il existe des principes de régulation cachés dans les poids des connexions.




Le réseaux apprendrait le guidage

- Lorsque le guidage est stoppé, son effet semble être simulé ...



Le réseaux apprendrait le guidage

- Simulation interne du guidage suite à une perturbation




- De Loor, P.; Manac'h, K. & *sensorimotor invariants: to*
Life and Robotics 19(2), 127-135. DOI: <http://dx.doi.org/10.1007/s10015-014-0143-3> *official*

HTM - CLA

Une architecture inspirée du cerveau


Ontogenèse comportementale



Réseaux attracteurs à deux couches

BAM : Bidirectional Associative Memory

- Bart Kosko
- Mémoire hétéro associative



Associe $A1 \leftrightarrow B1$; $A2 \leftrightarrow B2$; , ...etc dans les deux sens

Tous les liens ne sont pas représentés

ART : Adaptive Resonance Theorie

- Théorie développée par Grosberg et Carpenter en 1986 (ART1, ART2, ARTMAP)

*Voie par laquelle nous pourrions vraiment
autonomiser des machines ...*

Objectif de l'ART : gérer le dilemme Stabilité/Plasticité


Stabilité : les patterns reconnus sont insensibles au bruit

Plasticité : Le système doit être capable d'apprendre de nouveaux patterns


Les réseaux ART

- Combinent apprentissage supervisé et non-supervisé (compétition, clustering)
- Créés dynamiquement de nouvelles catégories
- Motivation biologique
- Modélisent les mémoires à court et à long termes

Principe de la résonance adaptative



Principe de la résonance adaptative




Résonance : renforcement mutuel
Adaptative : les poids sont ajustés
en cas de résonance

Le principe de résonance

- La résonance est liée au fait que les connexions se renforcent perpétuellement si une entrée est reconnue. Les patterns « bottom-up » résonnent avec les patterns « top-down »
- Quand le réseau reconnaît une entrée, aucune recherche n'est nécessaire. La résonance est immédiate
- Mais s'il ne la reconnaît pas, il doit rechercher une autre catégorie, comment faire ?
 - La couche mémoire est compétitive (à la kohonen)
 - Un seul neurone gagnant (dans les premières versions)
 - En fait cette couche est composée de « bascules » temporisées (ART toogle)

ART toogle : un dipôle




- si la bascule est active
alors elle se désactive et le
reste un certain temps même
après l'absence du signal de
mise à 0

Caractéristique des bascules sur ART

1

- Si le signal de mise à 0 est faible les entrées peuvent activer les sorties ON d'un toogle
- Si une entrée « disparaît », il se produit un rebond : la sortie ON est désactivée, la sortie OFF est activée, puis les deux sont désactivées.
- Si le signal de mise à 0 devient important les deux sorties auront tendance à devenir inactives avec une dynamique dépendant de leur état courant
- Si le signal de mise à 0 disparaît, la réactivation des sorties dépendra de leur état au moment de l'arrivée du signal
- Le mécanisme est compétitif, un seul toogle est vainqueur (voir plus loin)

ART 1 en action



ART 1 en action

- Si la couche d'entrée entre en résonance avec la mémoire alors elle propose le pattern d'entrée au « reset global ».
 - L'activation du reset (par le pattern d'entrée) est compensée par sa désactivation (par la couche d'entrée)
 - Le reset n'est pas activé
 - La résonance ne s'arrête pas

ART 1 en action

- Si il n'y a pas résonance : test d'hypothèses
 - L'activité des neurones de la couche d'entrée diminue (voir plus loin)
 - Le reset l'emporte
 - La dynamique des toggles empêche le pattern (ou les ou toggle) précédemment actifs de la couche mémoire d'être activés : la prédiction était fausse et est inhibée
 - Un autre pattern est naturellement sélectionné
 - La dynamique de l'inhibition doit être subtile pour que l'on teste tous les patterns de mémoire possibles (il faut inhiber le temps de faire tous les tests)


ART 1 en action

- A chaque nouveau test une faible modification des poids des liens entre les couches est effectuée.
- Cette modification permet d'explorer différentes hypothèses.
- Plus on met de temps à trouver un pattern correct, plus on modifie les poids.

ART 1 en action

- Vigilance :
 - Le seuil d'activation du nœud « reset » caractérise la vigilance du réseau.
 - Un seuil faible correspond à une grande vigilance (la moindre modification de l'entrée est détectée et relance une recherche)
 - Un seuil fort correspond à une vigilance faible (le réseau a une vision plus globale ou approximative des patterns).

ART 1 en action : contrôle de gain et règle des 2/3



ART 1 en action : contrôle de gain et règle des 2/3


- Le signal d'entrée arrive
 - Le contrôle de gain active la couche d'entrée
 - La couche mémoire est également activée
 - Le gain diminue
 - Les neurones de la couche d'entrée activés à la fois par les entrées et la mémoire restent actifs **si ils sont soumis à 2 activations sur 3**
 - Les autres se désactivent (moins de 2 activations sur 3)
 - Si il n'y a pas résonance, le nombre de neurones actifs va décroître, le reset intervenir.

ART 1 un algorithme

ART 1


- **Avantage**
 - Apprentissage autonome
 - pas de supervision,
 - ajout d'exemples à la volée,
 - ajout de neurones dans la mémoire à la volée
 - Permet d'ajuter le « niveau de détail que l'on cherche à apprendre
 - Mémoire associative autonome
- **Inconvénient**
 - Entrées binaires -> ART 2
 - Capacité 2^n (n neurones en couche mémoire), inconvénient ??
 - Dilemme plasticité/stabilité
- **Usage :**
 - Reconnaissance de la parole, de musiques ...
 - Reconnaissance de formes
 - Détection d'image radar
 - Classification (100 000 données à classer chez boing)

ART MAP



Apprentissage « Hebbien » (Hebb 1949)

- Plus proche des neuro-sciences



Quand un axone de la cellule A est suffisamment proche pour exciter la cellule B de façon répétitive ou persistante, il se produit un processus de croissance ou un changement métabolique tel que l'efficacité de A, en tant que cellule excitant B s'en trouve augmentée.

Des groupes de neurones qui tendent à s'exciter simultanément forment un ensemble de cellules dont l'activité peut persister à la suite du déclenchement d'un événement et peut servir à le représenter

La pensée est l'activation séquentielle de plusieurs groupes d'ensemble de cellules

Apprentissage compétitif

Ne serons pas vus

- Réseaux attracteurs statistiques
- Réseaux à avalanche
- Réseaux récurrents à backpropagation
- Réseaux de Kohonen avancés
- ...
- ...

Bibliographie

Maureen Caudill et Charles Butler : *Understanding Neural Networks, Computer explorations*, volume 1 et 2, 1992.

Claude Touzet : *Les réseaux de neurones artificiels, introduction au connexionnisme*, 1992.

Antoine Cornuéjols et Laurent Miclet : *Apprentissage artificiel, concepts et algorithmes*, eyrolles, 2002.

Réseaux de Hopfield

propagation d'entrées

- Mettre toutes les sorties à 1 (arbitraire)
- Appliquer un pattern d'entrée
 - Pour chaque neurone i
 - Activité de $i = 0$
 - Pour chaque neurone $j \neq i$
 - $\text{difference} = \text{activité de } j - \text{entrée } i$
 - $\text{resultat} = \text{difference} * w(i,j)$
 - $\text{Activité de } i = \text{activité de } i + \text{resultat}$
 - Si activité de $i > 0$ alors la sortie de i vaut +1
 - Si activité de $i = 0$ alors la sortie ne change pas
 - Sinon la sortie vaut -1

Autre illustration

- Organisation d'une carte de Kohonen
 - Beaucoup moins de neurones
 - Leurs poids servent de coordonnées pour les représenter sur une grille
 - On envoie au réseau une liste de points et il va progressivement faire en sorte de diminuer la distance entre ces points et ses neurones

Démo 2

